

UNIVERSIDADE ESTADUAL DE MATO GROSSO DO SUL - UEMS

Ciência da Computação – Unidade Universitária de Dourados

JOSÉ CARLOS DA SILVA FILHO

ALF-MoE:

Redes Especialistas com Fusão Aprendível Baseada em Atenção para Classificação e Mitigação
de Ataques Cibernéticos

Dourados

2026

José Carlos da Silva Filho

ALF-MoE:

Redes Especialistas com Fusão Aprendível Baseada em Atenção para Classificação e Mitigação
de Ataques Cibernéticos

Trabalho de Conclusão de Curso, apresentado à
Universidade Estadual de Mato Grosso do Sul
(UEMS), Ciência da Computação, Dourados,
para obtenção do título de Bacharel em Ciência
da Computação.

Orientador: Profº. Dr. Rubens Barbosa Filho

Dourados
2026

JOSÉ CARLOS DA SILVA FILHO

ALF-MOE:

Redes Especialistas com Fusão Aprendível Baseada em Atenção para Classificação e Mitigação de Ataques Cibernéticos

Trabalho de Conclusão de Curso apresentado à Universidade Estadual de Mato Grosso do Sul (UEMS), Ciência da Computação, Dourados, para obtenção do título de Bacharel *Ciência da Computação*.

Data de defesa: 12/10/2026

BANCA EXAMINADORA

Profº. Dr. Rubens Barbosa Filho

UEMS – Ciência da Computação – Unidade Universitária de Dourados

Profº. Dr. André Chastel Lima

Universidade Estadual de Mato Grosso do Sul

Profª. Dra. Glaucia Gabriel

Universidade Estadual de Mato Grosso do Sul

Profª. Dra. Raquel Marcia Müller

Universidade Estadual de Mato Grosso do Sul

À criança que sonhava ser cientista para entender o mundo e ao homem que precisou reaprender a respirar nele: obrigado por não ter deixado o nosso laboratório ficar às escuras.

AGRADECIMENTOS

Agradeço, primeiramente, a Deus, cuja providência me sustentou mesmo nos momentos em que me senti distante. Obrigado por não me conceder fardo maior do que o que eu poderia carregar e por ser a força silenciosa que me manteve de pé. À Maria, Mãe de Deus, agradeço pelo acalento materno e zeloso; por ser meu refúgio nas horas de aflição, minha proteção contra as sombras e a clareza necessária nas madrugadas de questionamento e exaustão.

À minha mãe, Rosirei, que transformou a escassez que viveu em abundância de oportunidades para o meu futuro. Obrigado por responder a cada um dos meus “porquês” e por instigar a curiosidade que hoje me torna cientista; cresci desejando ser tão inteligente quanto você. Através do seu exemplo, aprendi que o esforço é a ponte para o impossível. Guardo com carinho a memória de acordarmos antes do raiar do sol para que você trabalhasse e, à noite, ainda estudasse — você me pedia desculpas por me levar às suas aulas, sem saber que para mim era o maior dos privilégios ver de perto a sua garra. Vi seus medos e incertezas, mas jamais a vi recuar. À mulher que multiplicou o pouco para que eu tivesse tudo, e que me ensinou que o caráter e o conhecimento são as únicas riquezas inalienáveis, dedico esta vitória.

À minha noiva, Maria Eduarda, a quem devo a doçura e a estabilidade desta conquista. Você foi muito mais que uma companheira; foi o porto seguro onde ancorei nos dias de tempestade. Em meio à lógica fria dos códigos e à pressão exaustiva da academia, seu amor foi a constante que me manteve íntegro. Obrigado por ser o fôlego e a paciência nos momentos em que o *burnout* tentou silenciar meu entusiasmo, e por ter a sabedoria de me impulsionar quando minhas próprias forças falhavam. Você não apenas esteve ao meu lado; você iluminou o caminho para que eu pudesse enxergar além das minhas limitações e exaustões. Obrigado por dividir o peso da jornada e multiplicar a alegria da chegada. Este diploma é apenas o prefácio de uma vida inteira que pretendo escrever ao seu lado. Amo você.

Ao meu psicólogo, Dr. Ricardo Tiosso Panassiol, por ser o guia que me auxiliou a encontrar o caminho de volta em meio ao caos da ansiedade generalizada e do *burnout*. Obrigado por me ensinar a reconstruir minha perspectiva e por fornecer as ferramentas de resiliência necessárias para enfrentar as adversidades. Sua atuação foi fundamental para que eu não apenas concluísse este trabalho, mas recuperasse a posse de mim mesmo.

Ao meu orientador, Prof. Dr. Rubens Barbosa Filho, expresso minha mais profunda admiração. Agradeço pela orientação técnica impecável, mas, acima de tudo, pelo impacto do seu exemplo. Jamais esquecerei o dia em que lhe apresentei um problema do *Beecrowd* que me desafiava há quatro anos; vê-lo demonstrar que o embasamento teórico — através da Transformada Rápida de Fourier — resolve o que a força bruta jamais alcançaria, foi um divisor de águas em minha formação. Obrigado por me mostrar que a excelência nasce da paixão pelo conhecimento. Você é a minha maior referência de onde pretendo chegar como profissional.

Aos meus “irmãos de guerra” do “Bonde do Óclin”: Gustavo de Carvalho Brás Martins

Lopes (Gustavin), Leonardo Hirata (Hiratinha) e Luis Eduardo de Souza Vasconcelos (Louis). Nossa união transcendeu as salas de aula, tornando-se uma irmandade de apoio mútuo. Obrigado pelas horas intermináveis de algoritmos, pelos debates sobre cálculos e por tornarem o peso da graduação muito mais leve com sua lealdade e amizade.

Aos amigos Alexandre Arruda (Alê), Gabriel Fagá (Fagas) e Pedro Henrique Zaccaria (Z), agradeço pelos momentos de descontração e pelas pausas necessárias. Seja nas partidas de *Minecraft* ou nas conversas sem pressa, vocês foram o alívio essencial para que a mente pudesse descansar e o riso pudesse retornar. A jornada foi mais feliz por causa de vocês.

Aos mestres do Curso de Ciência da Computação da UEMS, cujas lições vão além dos livros. Em especial à Profa. Dra. Glaucia Gabriel, pela imensa empatia e humanidade demonstradas em meus momentos mais difíceis; ao Prof. Dr. André Chastel Lima, pela generosidade em compartilhar seu domínio sobre a Teoria dos Grafos. A dedicação de vocês é o que sustenta a qualidade desta instituição.

Por fim, agradeço à Universidade Estadual de Mato Grosso do Sul (UEMS) e ao Curso de Ciência da Computação, que me proporcionaram a base acadêmica necessária para a realização deste trabalho. Agradeço a todos os funcionários que, direta ou indiretamente, contribuíram para minha formação.

“Se você só fizer o que sabe, nunca será mais do que é agora.”
Shifu – Kung Fu Panda 3 (2016)

RESUMO

O texto deve ser composto por frases concisas em parágrafo único, utilizando o verbo na terceira pessoa. Evite símbolos e contrações que não sejam de uso corrente. Evite fórmulas, equações, diagramas etc., que não sejam absolutamente necessários; quando seu emprego for imprescindível, defini-los na primeira vez que aparecerem. Um resumo deve conter entre 150 a 500 palavras. As palavras-chave devem ficar logo abaixo do resumo, separadas entre si por ponto e vírgula e finalizadas por ponto. Além disso, devem ser grafadas com as iniciais em letra minúscula, exceto nomes próprios e nomes científicos. Para a escolha das palavras-chave consulte descritores autorizados da área, que representam o conteúdo do trabalho.

Palavras-Chave: palavra-chave; palavra-chave; palavra-chave.

ABSTRACT

The text should consist of concise sentences in a single paragraph, using the third person singular form of the verb. Avoid symbols and contractions that are not commonly used. Avoid formulas, equations, diagrams, etc., unless absolutely necessary; when their use is essential, define them the first time they appear. An abstract should contain between 150 to 500 words. Keywords should be placed right below the abstract, separated by semicolons and ending with a period. Additionally, they should be written in lowercase except for proper names and scientific names. To choose keywords, consult authorized descriptors in the field that represent the content of the work.

Keywords: keyword; keyword; keyword.

LISTA DE ILUSTRAÇÕES

Quadro 1	Síntese comparativa dos conjuntos de dados selecionados para treinamento e avaliação.	48
Quadro 2	Famílias funcionais, classes granulares e suporte amostral no CIC-BCCC-NRC-2024.	54

LISTA DE TABELAS

Tabela 1 – Síntese comparativa entre trabalhos correlatos da literatura e a proposta desta tese.	44
Tabela 2 – Distribuição de classes e suporte amostral no benchmark CSE-CIC-IDS2018.	51
Tabela 3 – Distribuição de classes e suporte amostral no benchmark CIC-UNSW-NB15.	57

LISTA DE ABREVIATURAS E SIGLAS

DDoS	Ataque Distribuído de Negação de Serviço (<i>Distributed Denial of Service</i>)
DoS	Ataque de Negação de Serviço (<i>Denial of Service</i>)
IoT	Internet das Coisas (<i>Internet of Things</i>)

LISTA DE SÍMBOLOS

α	Letra Grega Alfa
β	Letra grega Beta
γ	Letra grega Gama
e	Número de Euler
R\$	Unidade monetária Brasileira (Real)

SUMÁRIO

1	INTRODUÇÃO	16
1.1	Contextualização e Motivação	16
1.2	Definição do Problema	20
1.3	Objetivos	21
1.3.1	Objetivo Geral	21
1.3.2	Objetivos Específicos	21
1.4	Principais Contribuições	22
1.5	Organização do Trabalho	23
2	FUNDAMENTAÇÃO TEÓRICA E TRABALHOS CORRELATOS . . .	25
2.1	Ataques Cibernéticos e Sistemas de Detecção de Intrusão (NIDS)	25
2.1.1	Taxonomia de Ataques de Rede	25
2.1.2	Métodos de Identificação e Mitigação	28
2.1.2.1	Paradigmas de Detecção de Intrusão	28
2.1.2.2	Granularidade de Inspeção: DPI versus Análise Baseada em Fluxos	29
2.1.2.3	Mecanismos de Resposta e Mitigação	30
2.2	Aprendizado Profundo para Segurança de Redes	31
2.2.1	Redes Convolucionais e Recorrentes (CNN, LSTM, GRU)	31
2.2.1.1	Redes Neurais Convolucionais (CNN)	31
2.2.1.2	Redes Neurais Recorrentes e a Modelagem Temporal (LSTM e GRU)	33
2.2.1.2.1	<i>Long Short-Term Memory (LSTM):</i>	33
2.2.1.2.2	<i>Gated Recurrent Unit (GRU):</i>	34
2.2.2	Redes Densas, Autoencoders e Análise Espectral	35
2.2.2.1	Redes Neurais Totalmente Conectadas (DNN)	35
2.2.2.2	Autoencoders Convolucionais 1D (1D-CAE) e Processamento Espectral Inte- grado	35
2.2.2.2.1	<i>1. Seleção de Subdomínio e Janelamento de Hann:</i>	36
2.2.2.2.2	<i>2. Transformada Rápida de Fourier Discreta para Sinais Reais (RFFT):</i> . . .	36
2.2.2.2.3	<i>3. Codificação Convolucional 1D:</i>	36
2.2.2.2.4	<i>4. Decodificação por Convolução Transposta 1D:</i>	36
2.2.2.2.5	<i>5. Função de Perda Composta do CAE com Supervisão Profunda:</i>	37
2.2.3	Tratamento de Desbalanceamento Extremo via Focal Loss	37
2.2.4	Mixture of Experts (MoE) e Mecanismos de Fusão Atencional	38
2.2.4.1	Rede de Roteamento Dinâmico (Gating Network)	38
2.2.4.2	Mecanismo de Refinamento Atencional Aprendível (ALF)	38

2.2.4.2.1	1. Transformação Logarítmica Estabilizada:	39
2.2.4.2.2	2. Camada de Refinamento de Atenção com Pesos Afins:	39
2.2.4.2.3	3. Calibração de Confiança via Escalonamento Paramétrico (Vector Scaling):	39
2.2.4.2.4	4. Fusão por Soma Ponderada (Weighted Sum Fusion):	40
2.2.4.2.5	5. Projeção Classificatória Final Consolidada:	40
2.3	Trabalhos Correlatos	40
2.3.1	NIDS Baseados em Aprendizado Profundo	40
2.3.2	Abordagens Ensemble e Mixture of Experts em Cibersegurança	42
2.3.3	Síntese Comparativa	43
3	MATERIAIS E METODOLOGIA	47
3.1	Datasets Utilizados	47
3.1.1	CSE-CIC-IDS2018: Origem, Geração, Atributos e Distribuição Amostral	48
3.1.1.1	Topologia e Infraestrutura de Rede	49
3.1.1.2	Metodologia de Geração de Tráfego	49
3.1.1.3	Atributos Extraídos e Estrutura Tabular	50
3.1.1.4	Estatísticas e Distribuição Amostral	51
3.1.2	CIC-BCCC-NRC-2024: Origem, Geração, Atributos e Distribuição	
	Amostral	52
3.1.2.1	Infraestrutura e Topologia do Banco de Testes	52
3.1.2.2	Taxonomia dos Vetores de Ataque	52
3.1.2.3	Atributos Extraídos e Distribuição Amostral	54
3.1.3	UNSW-NB15: Origem, Geração, Atributos e Distribuição Amostral . .	54
3.1.3.1	Ambiente de Simulação e Infraestrutura de Captura	55
3.1.3.2	Taxonomia das Classes de Ataque	55
3.1.3.3	Espaço de Atributos e Alinhamento no ALF-MoE	56
3.1.3.4	Estatísticas e Distribuição Amostral	57
3.2	Pipeline de Pré-processamento e Engenharia de Features	58
3.2.1	Seleção, Normalização e Codificação	58
3.2.2	Tratamento de Desbalanceamento de Classes	58
3.3	Arquitetura Proposta: ALF-MoE	58
3.3.1	Visão Geral do Sistema e Fluxo de Dados	58
3.3.2	Modelos Especialistas (DNN, CNN, GRU, CAE, LSTM)	58
3.3.3	Gating Network	58
3.3.4	Mecanismo Attention-based Learnable Fusion (ALF)	58
3.4	Protocolo Experimental de Treinamento e Avaliação	58
3.4.1	Funções de Perda e Otimização	58
3.4.2	Métricas de Avaliação (Acurácia, Precision, Recall, F1-Score, Latência)	58
4	PIPELINE DE EXTRAÇÃO E AMBIENTE DE INFERÊNCIA	59

4.1	Captura e Processamento de Tráfego	59
4.1.1	Extração com NFStream	59
4.1.2	Mapeamento e Alinhamento de Features (NFStream → CICFlowMeter)	59
4.2	Setup de Inferência em Tempo Real	59
4.2.1	Arquitetura do Ambiente de Execução	59
4.2.2	Cenários de Teste de Estresse (Benigno, Ataques Humanos e Agentes via LLM)	59
5	RESULTADOS E DISCUSSÃO	60
5.1	Desempenho nos Datasets de Benchmark (Resultados Offline)	60
5.1.1	Análise por Classe e Desempenho Global	60
5.1.2	Estudo de Ablação (Contribuição de cada especialista e do bloco ALF) .	60
5.2	Avaliação da Extração e Inferência em Tráfego Real/PCAPs	60
5.2.1	Impacto do Mapeamento NFStream → CICFlowMeter	60
5.2.2	Throughput, Latência e Consumo Computacional	60
5.3	Avaliação sob Cenários Adversariais	60
5.3.1	Desempenho sob Tráfego Estritamente Benigno (Taxa de Falsos Positivos)	60
5.3.2	Robustez Contra Adversários Humanos	60
5.3.3	Robustez Contra Adversários Guiados por LLMs	60
6	CONCLUSÃO	61
6.1	Síntese do Trabalho	61
6.2	Limitações Identificadas	61
6.3	Trabalhos Futuros	61
	REFERÊNCIAS	62

1 INTRODUÇÃO

1.1 CONTEXTUALIZAÇÃO E MOTIVAÇÃO

A contínua expansão das infraestruturas de redes de computadores, impulsionada pela computação em nuvem, por ecossistemas corporativos distribuídos e pela proliferação ubíqua de dispositivos conectados, transformou a transmissão contínua de dados em um dos pilares estruturantes da sociedade contemporânea. Entretanto, essa interconectividade extensiva acarretou uma ampliação proporcional da superfície de ataque exposta a intervenções maliciosas, tornando os ambientes computacionais alvos recorrentes de ameaças de complexidade técnica crescente (Dreyer et al., 2018). Relatórios econômicos indicam que as perdas financeiras globais decorrentes de incidentes de segurança cibernética atingem a escala de trilhões de dólares anuais, englobando prejuízos materiais diretos, interrupções operacionais não programadas, violações de privacidade, penalidades regulatórias e o comprometimento da confiabilidade de ativos estratégicos de informação (Jada; Mayayise, 2024).

Nesse cenário de permanente vulnerabilidade, os Sistemas de Detecção de Intrusão em Redes (*Network Intrusion Detection Systems* – NIDS) consolidaram-se como elementos indispensáveis na arquitetura de defesa cibernética em profundidade (*defense-in-depth*) (Guadarrama et al., 2025; Chen et al., 2025). Historicamente, a operação dos NIDS fundamentava-se em dois paradigmas preponderantes: a detecção por assinaturas determinísticas e a inspeção profunda de pacotes (*Deep Packet Inspection* – DPI), alicerçadas na identificação de portas estáticas da camada de transporte e no exame direto do conteúdo textual ou binário da carga útil (*payload*) dos pacotes transmitidos pela rede.

Contudo, transformações substanciais nos padrões e protocolos de comunicação da Internet debilitaram a viabilidade prática dessas abordagens legadas. A adoção generalizada de mecanismos de criptografia ponta a ponta, tais como o protocolo TLS 1.3, HTTPS e DNS sobre HTTPS (*DNS over HTTPS* – DoH), combinada à utilização disseminada de Redes Privadas Virtuais (*Virtual Private Networks* – VPN) e à alocação dinâmica de portas efêmeras, tornou a carga útil dos pacotes inteiramente opaca aos dispositivos intermediários de monitoramento e filtragem (Sarhan; Layeghy; Portmann, 2022; He; Fu; Zhang, 2026). Sob tais condições operacionais, os métodos fundamentados na inspeção direta do conteúdo tornaram-se ineficazes para a identificação de ameaças encapsuladas em fluxos cifrados.

Como alternativa às limitações da análise estática de carga útil, consolidou-se na literatura o paradigma de análise comportamental de tráfego fundamentado em Aprendizado de Máquina (*Machine Learning* – ML) e Aprendizado Profundo (*Deep Learning* – DL) (Noor; Ige, 2025; Dari et al., 2024). Tais metodologias operam sobre fluxos de rede bidirecionais (*bidirectional network flows*), extraindo padrões estatísticos e temporais a partir de agregados de tráfego — tais como duração da conexão, taxas de transmissão, contagens de pacotes e bytes por sentido,

tempos entre chegadas consecutivas de pacotes (*Inter-Arrival Time* – IAT) e sinalizadores de controle das camadas de rede e transporte (TCP/IP).

Não obstante os avanços demonstrados pelos classificadores baseados em Aprendizado Profundo, parcela expressiva das soluções propostas na literatura é concebida sob uma perspectiva homogênea ou restrita de representação de atributos (*single-view representation*) (Luay et al., 2026; Luay et al., 2025). Tais modelos monolíticos empregam predominantemente uma única família arquitetural: Redes Neurais Totalmente Conectadas (*Dense Neural Networks* – DNN) para sumários estatísticos tabulares, Redes Neurais Convolucionais (*Convolutional Neural Networks* – CNN) para examinar correlações espaciais, ou Redes Neurais Recorrentes (*Recurrent Neural Networks* – RNN) para dependências sequenciais.

Essa restrição metodológica contrasta frontalmente com a natureza intrinsecamente multifacetada do tráfego malicioso contemporâneo, no qual diferentes classes de ameaças manifestam comportamentos em domínios informacionais amplamente divergentes entre si (Neto et al., 2023; Maciá-Fernández et al., 2018):

- **Ataques de Negação de Serviço (*Denial of Service* – DoS) e Negação de Serviço Distribuída (*Distributed Denial of Service* – DDoS):** caracterizam-se por perturbações estatísticas volumétricas agudas, marcadas por taxas extremas de pacotes por segundo e saturação do canal de transmissão;
- **Varreduras de portas e de rede (*Port Scans* e *IP Sweeps*):** caracterizam-se por estruturas espaciais esparsas, com distribuição sistemática de pacotes reduzidos entre múltiplos destinos em intervalos comprimidos;
- **Canais de Comando e Controle (C2), Botnets e Infiltrações:** utilizam mensagens compactas e cadências temporais programadas para mimetizar conexões legítimas, tornando os intervalos entre chegadas consecutivas (IAT) e as dinâmicas transitórias a dimensão prioritária de discriminação;
- **Fluxos de exfiltração de dados e abusos sobre aplicações web:** exibem padrões de densidade espectral, ciclicidade e periodicidade harmônica que encontram representação ótima no domínio da frequência.

Modelos monolíticos que operam sob uma única perspectiva tendem a apresentar desempenho subótimo na identificação de ataques cujas assinaturas determinantes residem em domínios ignorados pelo extrator. Embora estratégias baseadas em Aprendizado em Conjunto (*Ensemble Learning*) busquem atenuar essa deficiência combinando múltiplos classificadores (Silva, 2025; Yang et al., 2025), as abordagens convencionais comumente recorrem à fusão tardia estática (*late fusion*), agregando decisões via média aritmética simples, votação majoritária ou concatenação linear de escores (Chandroth; Stoian; Danciulescu, 2026). Esse procedimento estático desconsidera a interdependência dos domínios durante o processo de aprendizagem e falha em modular

dinamicamente a relevância de cada modelo com base no perfil particular do fluxo em análise (He; Fu; Zhang, 2026).

Com o objetivo de superar essas deficiências estruturais, Chandroth, Stoian & Danciulescu (2026) introduziram a arquitetura ALF-MoE (*Attention-Based Learnable Fusion of Specialized Expert Networks*). O ALF-MoE alicerça-se no paradigma de Mistura de Especialistas (*Mixture of Experts – MoE*) (Jacobs et al., 1991; Shazeer et al., 2017), distribuindo o aprendizado de representações entre cinco redes neurais profundas dedicadas, cada qual concebida para extrair padrões de uma modalidade informacional distinta do tráfego:

1. **Dense Neural Network (DNN):** especializada na representação de atributos estatísticos globais e tabulares agregados da conexão ($\mathbf{x}_g$), tais como duração da sessão, contagens totais de pacotes e bytes por direção e contadores de sinalizadores TCP;
2. **Convolutional Neural Network (CNN):** dedicada ao aprendizado de correlações espaciais e padrões morfológicos locais ($\mathbf{x}_s$) a partir de matrizes dimensionais derivadas dos atributos do tráfego;
3. **Gated Recurrent Unit (GRU):** orientada à captura de variações estatísticas sequenciais e dinâmicas temporais de curta cadência ($\mathbf{x}_v$), focando nos intervalos temporais entre chegadas consecutivas de pacotes (IATs);
4. **Convolutional Autoencoder (CAE):** projetado para a extração de representações comprimidas no domínio da frequência ($\mathbf{x}_f$), obtidas mediante a aplicação de uma janela periódica de Hann e o cômputo da magnitude da Transformada Rápida de Fourier Real (*Real Fast Fourier Transform – RFFT*) sobre os vetores de tráfego, associado a perdas de reconstrução;
5. **Long Short-Term Memory (LSTM):** encarregada de modelar dependências temporais de longo alcance e transições de estado ($\mathbf{x}_t$) ao longo do ciclo de vida da conexão.

Para coordenar a cooperação entre os múltiplos especialistas, a arquitetura ALF-MoE integra uma Rede de Roteamento Dinâmico (*Gating Network*) a um módulo de Fusão Aprendível Baseada em Atenção (*Attention-Based Learnable Fusion – ALF*) dotado de refinamento atencional calibrado (Chandroth; Stoian; Danciulescu, 2026). Formalmente, considere uma instância de tráfego de rede caracterizada por um vetor unificado de atributos particionado nos subespaços de entrada dos especialistas, $\mathbf{x} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_K\}$, em que cada subvetor $\mathbf{x}_k$ corresponde ao domínio processado pelo especialista $\mathcal{E}_k$, para $k \in \{1, 2, \dots, K\}$ com $K = 5$. Cada especialista produz um vetor de predição preliminar de probabilidades $\hat{\mathbf{y}}^{(k)} \in \mathbb{R}^C$, em que C denota o número de classes de tráfego:

$$\hat{\mathbf{y}}^{(k)} = \mathcal{E}_k(\mathbf{x}_k), \quad \forall k \in \{1, \dots, K\}, \quad \text{com} \quad \sum_{c=1}^C \hat{y}_c^{(k)} = 1. \quad (1)$$

Concomitantemente, a rede de roteamento $\mathcal{G}(\cdot)$ processa a instância de entrada $\mathbf{x}$, gerando um vetor de escores brutos de seleção $\mathbf{g} = [g_1, g_2, \dots, g_K]^\top \in \mathbb{R}^K$:

$$\mathbf{g} = \mathcal{G}(\mathbf{x}). \quad (2)$$

Os escores são inicialmente normalizados pela função *softmax*, produzindo uma distribuição preliminar de pesos de especialista $\boldsymbol{\alpha} = [\alpha_1, \alpha_2, \dots, \alpha_K]^\top$:

$$\alpha_k = \frac{\exp(g_k)}{\sum_{j=1}^K \exp(g_j)}, \quad \text{com} \quad \sum_{k=1}^K \alpha_k = 1. \quad (3)$$

Com o propósito de refinar a seletividade contextual e permitir que o modelo module a contribuição de cada rede com base nas correlações entre os próprios especialistas, o vetor $\boldsymbol{\alpha}$ é submetido a uma transformação logarítmica com limiar de estabilização numérica ($\epsilon > 0$) e projetado por uma transformação afim aprendível parametrizada pela matriz de pesos $\mathbf{W}_g \in \mathbb{R}^{K \times K}$ e pelo vetor de viés $\mathbf{b}_g \in \mathbb{R}^K$:

$$\mathbf{a} = \text{softmax}(\mathbf{W}_g \log(\boldsymbol{\alpha} + \epsilon) + \mathbf{b}_g), \quad (4)$$

em que $\mathbf{a} = [a_1, a_2, \dots, a_K]^\top$ representa o vetor de coeficientes de atenção, satisfazendo $\sum_{k=1}^K a_k = 1$. Para assegurar a calibração probabilística do roteamento sob distribuições complexas e assimétricas, essa formulação incorpora camadas de calibração afim baseadas em escalonamento vetorial (*Vector Scaling*) (Guo et al., 2017).

A partir dos coeficientes de atenção calibrados, as previsões individuais dos especialistas são combinadas via soma ponderada, gerando a representação intermediária fundida $\mathbf{z} \in \mathbb{R}^C$:

$$\mathbf{z} = \sum_{k=1}^K a_k \hat{\mathbf{y}}^{(k)}. \quad (5)$$

Por fim, o módulo de fusão ALF concatena o vetor intermediário $\mathbf{z}$ com as previsões de probabilidade brutas de todos os especialistas individuais, $\mathbf{e} = [\hat{\mathbf{y}}^{(1)\top}, \hat{\mathbf{y}}^{(2)\top}, \dots, \hat{\mathbf{y}}^{(K)\top}]^\top \in \mathbb{R}^{K \cdot C}$, alimentando camadas densas profundas com normalização em lote (*Batch Normalization*) e funções de ativação não lineares LeakyReLU, culminando na distribuição preditiva de probabilidades final do fluxo $\hat{\mathbf{y}}_{\text{final}} \in \mathbb{R}^C$:

$$\hat{\mathbf{y}}_{\text{final}} = \text{softmax}(\mathbf{W}_f \phi_{\text{ALF}}([\mathbf{z}^\top, \mathbf{e}^\top]^\top) + \mathbf{b}_f). \quad (6)$$

A conjugação entre especialização em domínios complementares, roteamento atencional dinâmico e fusão aprendível não linear confere à arquitetura ALF-MoE uma notável capacidade de generalização e adaptação representacional perante a diversidade do tráfego de rede contemporâneo.

1.2 DEFINIÇÃO DO PROBLEMA

A despeito dos promissores resultados obtidos no estudo original de Chandroth, Stoian & Danciulescu (2026), no qual o ALF-MoE alcançou acurácias superiores a 97% em tarefas de classificação de tráfego de aplicações e segregação de conexões VPN e não-VPN sobre bases como ISCX VPN-nonVPN, Unicauca e UNSW-IoTraffic, a transposição direta dessa arquitetura para o domínio dos Sistemas de Detecção de Intrusão em Redes (NIDS) multiclasse impõe desafios conceituais e metodológicos substanciais, os quais delimitam o problema investigado nesta tese:

Em primeiro lugar, existe uma disparidade estrutural basilar entre a classificação de aplicações e a identificação de ataques em redes operacionais. Em tarefas de classificação de aplicações, as instâncias distribuem-se de maneira comparativamente homogênea entre os rótulos de serviço, com fluxos contínuos e volumes amostrais estáveis. Em contrapartida, os conjuntos de dados de referência em segurança cibernética — a exemplo de CSE-CIC-IDS2018 (Sharafaldin; Lashkari; Ghorbani, 2018), CIC-BCCC-NRC-2024 (Sasi et al., 2025) e UNSW-NB15 (Moustafa; Slay, 2015; Sarhan; Layeghy; Portmann, 2022) — exibem um desbalanceamento de classes extremo. Nesses cenários, o tráfego estritamente benigno perfaz entre 85% e mais de 99% do total de conexões observadas, enquanto categorias críticas de invasão (tais como *Heartbleed*, *Infiltration*, *Botnets*, ataques web, *Shellcode* e *Worms*) compõem frações inferiores a 1% ou mesmo 0,1% do suporte amostral. Diante de assimetrias agudas, classificadores neurais padrão sofrem de viés sistemático em favor da classe majoritária, e as redes de roteamento correm o risco de colapso de especialistas (*expert collapse*), priorizando monotonicamente predições benignas. Determinar se a divisão em múltiplos especialistas e o roteamento atencional mantêm sua eficácia discriminatória e calibrada perante tal desbalanceamento constitui uma questão científica aberta.

Em segundo lugar, a caracterização de ameaças cibernéticas sob tráfego criptografado repousa exclusivamente sobre atributos estatísticos e comportamentais extraídos dos cabeçalhos dos fluxos. Contudo, diferentes categorias de intrusão manifestam suas assinaturas em domínios informacionais com correlações cruzadas complexas: ataques volumétricos manifestam-se no domínio estatístico global; varreduras e mapeamentos atuam com dispersão espacial; canais furtivos de persistência alteram dinâmicas sequenciais e temporais de curto prazo; e explorações com requisições repetitivas afetam densidades no domínio da frequência. A ausência de um particionamento matematicamente fundamentado dos atributos de rede para alimentar redes neurais especializadas pode comprometer a capacidade de extração de representações discriminatórias por parte de cada especialista.

Em terceiro lugar, a avaliação de modelos de aprendizado profundo na literatura de NIDS frequentemente restringe-se a ensaios sobre uma única base de dados, omitindo a capacidade de adaptação da arquitetura perante ecossistemas computacionais com características de tráfego substancialmente divergentes. A generalização de uma arquitetura baseada em MoE exige a sua validação abrangente em cenários que compreendam desde infraestruturas corporativas em

nuvem (CSE-CIC-IDS2018) até ambientes modernos de Internet das Coisas e telemetria leve (CIC-BCCC-NRC-2024) e ensaios com emulação de ataques avançados (UNSW-NB15).

Diante dessas constatações, o problema fundamental abordado neste trabalho pode ser formulado mediante a seguinte indagação científica: *Em que medida a arquitetura ALF-MoE, fundamentada no particionamento multidomínio de atributos de fluxo, em mecanismos de calibração atencional por Vector Scaling e em estratégias de otimização sob supervisão profunda, é capaz de superar modelos monolíticos e comitês convencionais de aprendizado na tarefa de detecção e classificação multiclasse de intrusões em redes de computadores sob condições de severo desbalanceamento de classes e tráfego cifrado?*

1.3 OBJETIVOS

Com o intuito de responder à questão científica delineada, estabelecem-se os objetivos geral e específicos descritos a seguir.

1.3.1 Objetivo Geral

O objetivo geral desta tese de graduação consiste em investigar, adaptar, implementar computacionalmente e avaliar empiricamente a arquitetura de aprendizado profundo baseada em Mistura de Especialistas com Fusão Aprendível por Atenção (ALF-MoE) para a tarefa de classificação multiclasse de ameaças cibernéticas em tráfego de redes de computadores, sob o regime de fluxos estatísticos bidirecionais, demonstrando sua robustez discriminatória e estabilidade perante o severo desbalanceamento amostral de classes em múltiplos conjuntos de dados de referência (CSE-CIC-IDS2018, CIC-BCCC-NRC-2024 e UNSW-NB15).

1.3.2 Objetivos Específicos

Para viabilizar o cumprimento do objetivo geral, definem-se os seguintes objetivos específicos:

1. **Estruturar o pré-processamento e o particionamento multidomínio de atributos:** Implementar um fluxo sistemático de preparação de dados sobre os conjuntos de referência em cibersegurança (CSE-CIC-IDS2018, CIC-BCCC-NRC-2024 e UNSW-NB15), contemplando rotinas de higienização de dados (eliminação de valores infinitos e ausentes), remoção de atributos colineares ou desprovidos de variância, normalização estatística e mapeamento formal das variáveis nos cinco domínios especialistas: global tabular ($\mathbf{x}_g$), espacial ($\mathbf{x}_s$), variação temporal estatística ($\mathbf{x}_v$), espectral de frequência ($\mathbf{x}_f$) e dependências temporais longas ($\mathbf{x}_t$);
2. **Construir computacionalmente a arquitetura ALF-MoE e suas camadas dedicadas:** Implementar em código funcional os cinco modelos especialistas (DNN, CNN, GRU, CAE com janelamento periódico de Hann e espectro de magnitude RFFT, e LSTM),

integrando-os à Rede de Roteamento Dinâmico (*Gating Network*) com refinamento atencional logarítmico, calibração por escalonamento vetorial (*Vector Scaling*) e ao bloco de Fusão Aprendível Baseada em Atenção (ALF);

3. **Formular a estratégia de treinamento supervisionado sob desbalanceamento severo:** Estruturar o protocolo de otimização conjunta do grafo computacional utilizando supervisão profunda (*deep supervision*) por meio de perdas auxiliares atribuídas a cada especialista e perda consolidada no módulo ALF, parametrizando a Perda Focal Multi-classe (*Focal Loss*) com fatores de ponderação α e parâmetro de foco γ para mitigar a dominância da classe benigna majoritária;
4. **Conduzir avaliação comparativa frente a classificadores monolíticos e comitês de referência:** Mensurar o desempenho preditivo da arquitetura proposta em relação a modelos profundos monolíticos isolados (DNN, CNN, GRU, CAE e LSTM isoladas) e comitês convencionais de aprendizagem (*ensembles* com votação majoritária e média simples de probabilidades), adotando métricas rigorosas de desempenho multiclasse (Acurácia Global, Precisão Ponderada e Macro, Sensibilidade/*Recall* Ponderado e Macro, e Macro F_1 -Score);
5. **Realizar estudos sistemáticos de ablação arquitetural:** Investigar o impacto individual de cada componente estrutural do modelo proposto, quantificando o ganho marginal proporcionado por cada especialista isolado, pelo módulo de fusão adaptativa ALF em comparação com métodos estáticos, pela calibração atencional via *Vector Scaling* e pelo processamento espectral Hann-RFFT no autoencoder;
6. **Avaliar a capacidade de generalização e interpretabilidade inter-dataset:** Analisar a matriz de confusão e a capacidade de identificação de classes raras de ataque nos três *benchmarks* avaliados, avaliando o comportamento e a distribuição dos pesos de atenção gerados pela *Gating Network* em resposta a diferentes famílias de intrusão cibernética.

1.4 PRINCIPAIS CONTRIBUIÇÕES

As principais contribuições teóricas, metodológicas e práticas proporcionadas por este trabalho compreendem:

1. **Adaptação e formalização da arquitetura ALF-MoE para detecção de intrusões multiclasse:** Demonstra-se a aplicabilidade e a eficácia da transposição do paradigma de Mistura de Especialistas com Fusão Aprendível por Atenção para a detecção de intrusões em redes sob tráfego criptografado, estabelecendo um esquema formal de particionamento em cinco domínios informacionais complementares (estatístico tabular, espacial, variação temporal, espectral via Hann-RFFT e dependência temporal de longo prazo);

2. **Integração de refinamento atencional calibrado e formulação para dados desbalanceados:** Implementação de um módulo de refinamento atencional dotado de projeção afim e calibração por *Vector Scaling* na *Gating Network*, associado à otimização conjunta via *Focal Loss* multiclasse e supervisão profunda (*deep supervision*), prevenindo o colapso de especialistas e assegurando elevada sensibilidade na discriminação de classes raras e furtivas de ataque;
3. **Validação empírica abrangente em múltiplos benchmarks consolidados:** Condução de avaliação experimental sistemática sobre três referências públicas contemporâneas e heterogêneas de cibersegurança (CSE-CIC-IDS2018, CIC-BCCC-NRC-2024 e UNSW-NB15), evidenciando a consistência da arquitetura frente a perfis operacionais distintos, que englobam redes corporativas em nuvem, ambientes IoT com protocolos leves (MQTT) e emulação de ataques cibernéticos complexos;
4. **Caracterização por estudos de ablação e interpretabilidade dos especialistas:** Fornecimento de uma investigação analítica detalhada que comprova a superioridade da fusão adaptativa aprendível ALF sobre abordagens monolíticas e comitês estáticos tradicionais, elucidando a correlação empírica entre os pesos dinâmicos de atenção atribuídos pela *Gating Network* e a natureza comportamental de cada classe de ameaça.

1.5 ORGANIZAÇÃO DO TRABALHO

O presente documento está estruturado em seis capítulos, ordenados conforme o encadeamento a seguir:

- **Capítulo 1 – Introdução:** Apresenta a contextualização do problema de segurança cibernética e detecção de intrusões sob tráfego cifrado, a motivação para abordagens multidomínio de aprendizado profundo, a definição formal do problema, os objetivos geral e específicos, as principais contribuições alcançadas e a organização estrutural da tese;
- **Capítulo 2 – Fundamentação Teórica e Trabalhos Correlatos:** Aborda a taxonomia das principais famílias de ataques cibernéticos em redes e os conceitos fundamentais dos Sistemas de Detecção de Intrusão. Detalha a fundamentação matemática das redes neurais profundas especializadas (DNN, CNN, GRU, CAE e LSTM), a teoria de Mistura de Especialistas (MoE), os mecanismos de atenção, a calibração de redes neurais e as funções de perda para dados desbalanceados. Conclui com uma revisão crítica da literatura recente de NIDS baseados em aprendizado profundo e fusão de modelos;
- **Capítulo 3 – Materiais e Metodologia:** Descreve os três conjuntos de dados de referência adotados como *benchmark* (CSE-CIC-IDS2018, CIC-BCCC-NRC-2024 e UNSW-NB15) e o pipeline de pré-processamento e particionamento dos atributos nos cinco domínios especialistas. Especifica a arquitetura formal do modelo ALF-MoE (redes especialistas,

Gating Network e bloco de fusão ALF), bem como o protocolo experimental de treinamento com supervisão profunda e as métricas estatísticas formais de avaliação multiclasse;

- **Capítulo 4 – Pipeline de Extração e Ambiente de Inferência:** Aborda os aspectos conceituais e estruturais relacionados à representação de fluxos de rede bidirecionais, aos modelos de temporização de tráfego e aos requisitos computacionais para a inferência analítica dos modelos neurais;
- **Capítulo 5 – Resultados e Discussão:** Expõe a análise comparativa de desempenho discriminativo da arquitetura ALF-MoE em relação aos modelos de referência nas três bases de dados consolidadas, acompanhada por estudos sistemáticos de ablação sobre os especialistas e o módulo ALF, avaliando a robustez frente a classes desbalanceadas e a interpretabilidade dos pesos atencionais;
- **Capítulo 6 – Conclusão:** Sintetiza as principais deduções e conclusões obtidas pela pesquisa, discute as limitações metodológicas do trabalho e elenca direcionamentos para a realização de pesquisas futuras.

2 FUNDAMENTAÇÃO TEÓRICA E TRABALHOS CORRELATOS

2.1 ATAQUES CIBERNÉTICOS E SISTEMAS DE DETECÇÃO DE INTRUSÃO (NIDS)

A evolução contínua das infraestruturas de telecomunicações e a crescente sofisticação dos vetores de ameaça transformaram a segurança cibernética em um dos pilares mais críticos da sociedade contemporânea. Em redes computacionais corporativas, governamentais e industriais, os dados trafegam por meio de pilhas protocolares complexas, sujeitas a vulnerabilidades de implementação, desvios operacionais e ataques intencionais orientados à degradação de serviços ou à exfiltração de informações confidenciais (Dreyer et al., 2018; Jada; Mayayise, 2024). Nesse cenário de risco permanente, a defesa em profundidade (*defense-in-depth*) consolida-se como a arquitetura padrão para resguardar ativos estratégicos, na qual os Sistemas de Detecção de Intrusão em Redes (*Network Intrusion Detection Systems* – NIDS) atuam como uma camada fundamental de vigilância contínua e telemetria analítica (Guadarrama et al., 2025; Chen et al., 2025).

Diferentemente dos dispositivos de filtragem perimetral clássicos, como os *firewalls* tradicionais fundamentados em listas estáticas de controle de acesso (*Access Control Lists* – ACL), os NIDS dedicam-se à inspeção minuciosa dos pacotes que transitam pelos enlaces físicos e lógicos, buscando identificar anomalias estatísticas, padrões de varredura ou assinaturas de exploração de vulnerabilidades (Sarhan; Layeghy; Portmann, 2022). A modelagem analítica desse tráfego requer a compreensão estrutural das categorias de ataques que desafiam os ambientes operacionais, bem como das metodologias e limitações práticas das ferramentas voltadas à sua identificação e contenção.

2.1.1 Taxonomia de Ataques de Rede

A caracterização formal do tráfego malicioso demanda sua estratificação em taxonomias consolidadas pela comunidade científica e por centros internacionais de resposta a incidentes. A literatura técnica agrupa as ameaças de rede em classes comportamentais distintas com base no objetivo da intrusão, no volume de dados injetado, no protocolo explorado e na persistência temporal da ação maliciosa (Sharafaldin; Lashkari; Ghorbani, 2018; Sarhan; Layeghy; Portmann, 2022; Neto et al., 2023). Entre as principais classes de ataques mapeadas em ambientes contemporâneos, destacam-se:

1. **Negação de Serviço e Negação de Serviço Distribuída (*Denial of Service* – DoS / *Distributed Denial of Service* – DDoS):** Os ataques de negação de serviço têm como finalidade indisponibilizar um serviço, servidor ou infraestrutura de rede, exaurindo recursos computacionais finitos (como largura de banda, memória, capacidade de processamento ou

entradas em tabelas de estado do sistema operacional) (Sharafaldin; Lashkari; Ghorbani, 2018). Manifestam-se primordialmente sob três variantes:

- *Ataques Volumétricos*: baseiam-se na inundação maciça de pacotes (*packet flooding*) para congestionar fisicamente o canal de transmissão. Empregam comumente o protocolo UDP (*UDP Flood*), mensagens ICMP (*Ping Flood*) ou técnicas de reflexão e amplificação baseadas em protocolos de camada de aplicação desprotegidos, tais como DNS, NTP e SNMP. Nestes últimos, o atacante forja o endereço IP de origem (*IP spoofing*) para o endereço da vítima e requisita respostas desproporcionalmente maiores aos servidores de reflexão abertos (Neto et al., 2023);
- *Ataques de Esgotamento de Estado TCP*: exploram os mecanismos do aperto de mão de três vias (*three-way handshake*) do protocolo TCP. O expoente clássico é o *TCP SYN Flood*, em que o adversário envia rajadas massivas de pacotes de controle com o sinalizador SYN ativo, sem completar a conexão com o pacote ACK subsequente. Em consequência, a pilha de rede da vítima mantém conexões semiabertas na fila de conexões pendentes (*backlog queue*), esgotando as estruturas de alocação de memória (*Transmission Control Blocks – TCB*) e rejeitando requisições legítimas (Sharafaldin; Lashkari; Ghorbani, 2018);
- *Ataques de Baixa Vazão em Camada de Aplicação (L7 Low-and-Slow)*: operam abaixo dos limiares de detecção volumétrica convencionais. Ferramentas como o *Slowloris* e o *R-U-Dead-Yet (RUDY)* abrem múltiplas conexões HTTP/HTTPS legítimas com o servidor web e enviam cabeçalhos ou corpos de requisição fragmentados a intervalos regulares extremamente lentos. Como o servidor reserva *threads* de processamento e conexões de soquete aguardando a finalização da mensagem HTTP, seu conjunto de conexões ativas é completamente saturado com consumo mínimo de largura de banda pelo atacante.

2. Ataques de Varredura e Reconhecimento (*Port Scanning* e *Network Probing*): Constituem a fase preliminar do ciclo de vida de uma intrusão, na qual o atacante mapeia a topologia do alvo, descobre estações ativas, identifica portas de transporte abertas e determina os sistemas operacionais e serviços em execução (*fingerprinting*) (Sarhan et al., 2021). Ferramentas automatizadas utilizam diversas técnicas de sondagem:

- *SYN Stealth Scan (TCP Half-Open)*: o scanner transmite um pacote SYN; caso o alvo responda com SYN-ACK (indicando porta aberta), o atacante envia imediatamente um pacote RST em vez de completar o aperto de mão com ACK, evitando o registro da conexão nos logs das aplicações da vítima;
- *Scans Especiais (FIN, NULL e Xmas Scans)*: exploram violações intencionais da especificação canônica da RFC 793. No *Xmas Scan*, os sinalizadores FIN, PSH e URG são ativados concomitantemente. Conforme o padrão TCP, portas fechadas

devem retornar um pacote RST, ao passo que portas abertas descartam a mensagem anômala sem resposta. Padrões desse tipo manifestam-se em atributos estatísticos de contagem de sinalizadores em fluxos agregados (Sarhan; Layeghy; Portmann, 2022).

3. **Ataques de Força Bruta (*Brute Force Attacks*):** Consistem na submissão sistemática e automatizada de extensas listas de credenciais de autenticação contra serviços administrativos e de transferência remota, tais como SSH (*Secure Shell*), FTP, RDP (*Remote Desktop Protocol*) e interfaces web de login (Sharafaldin; Lashkari; Ghorbani, 2018). No tráfego de rede, manifestam-se por sequências repetitivas de fluxos bidirecionais de curta duração, taxas de transferência moderadas e elevadíssima concentração temporal de tentativas consecutivas originadas de um único nó ou distribuídas por uma rede intermediária.
4. **Ataques a Aplicações Web e Injeção de Código:** Exploram falhas de sanitização e validação de parâmetros de entrada em servidores e aplicações web (Kaur; Kaur, 2016; Sharif, 2022). Entre as modalidades prevalentes documentadas nos conjuntos de dados de referência (como o CSE-CIC-IDS2018), incluem-se:
 - *Injeção de SQL (SQL Injection – SQLi)*: inserção de fragmentos arbitrários de instruções SQL em formulários ou parâmetros HTTP GET/POST, contornando mecanismos de controle de acesso ou expondo registros confidenciais de bancos de dados (Kaur; Kaur, 2016);
 - *Cross-Site Scripting (XSS)*: injeção de scripts maliciosos interpretados nos navegadores de usuários legítimos, possibilitando o sequestro de sessões autenticadas (*session hijacking*) e a interceptação de credenciais (Sharif, 2022);
 - *Injeção de Comandos de Sistema Operacional e Travessia de Diretórios (Directory Traversal)*: manipulação de caminhos relativos (tais como `.. / .. /`) para acessar arquivos restritos do sistema hospedeiro ou invocar binários locais.
5. **Redes Zumbis (*Botnets*) e Canais de Comando e Controle (C2):** Uma *botnet* compreende uma rede distribuída de nós comprometidos (*bots*) subordinados a uma infraestrutura centralizada ou peer-to-peer (P2P) administrada por atacantes (Sharafaldin; Lashkari; Ghorbani, 2018). O tráfego característico reside nos canais de Comando e Controle (*Command and Control – C2*). Para manter a conectividade sem suscitar alertas nos mecanismos de segurança perimetrais, os canais C2 empregam técnicas de comunicação furtiva, tais como sinalização periódica com perturbação estocástica de tempo (*beaconing* com *jitter*), Algoritmos de Geração de Domínio (*Domain Generation Algorithms – DGA*), tunelamento em consultas DNS (*DNS Tunneling*) e encapsulamento em tráfego HTTPS padrão através da porta TCP 443 com certificados digitais válidos.
6. **Ameaças Avançadas Persistentes (APTs) e Infiltrações Multi-estágio:** Campanhas APT distinguem-se pelo elevado grau de sofisticação técnica, planejamento meticuloso e

atuação prolongada voltada a alvos institucionais de alto valor (Phan; Nguyen; Bauschert, 2026). As operações ofensivas estruturam-se segundo cadeias táticas formais, a exemplo do modelo *Cyber Kill Chain* e da matriz analítica MITRE ATT&CK (Ferraz et al., 2025). O ciclo operacional multi-estágio abrange fases de reconhecimento, acesso inicial, estabelecimento de persistência, escalonamento local de privilégios, evasão de defesas, movimentação lateral na sub-rede corporativa, coleta e exfiltração de dados confidenciais (Phan; Nguyen; Bauschert, 2026; Orbinato et al., 2024). Durante a movimentação interna, os adversários empregam técnicas de *Living-off-the-Land* (LotL) e emulação adversarial avançada com módulos de anti-deteção (Orbinato et al., 2024). A identificação tempestiva dessas campanhas impõe imensa complexidade aos NIDS, uma vez que pacotes isolados exibem total conformidade sintática com os protocolos ordinários, tornando as dependências estatísticas e dinâmicas temporais de longo prazo a assinatura primordial para a detecção da anomalia (Ferraz et al., 2025).

2.1.2 Métodos de Identificação e Mitigação

A eficácia de uma postura defensiva em redes de computadores depende das estratégias de inspeção empregadas para avaliar o fluxo de informações e das ações automatizadas executadas quando uma ameaça é diagnosticada.

2.1.2.1 Paradigmas de Detecção de Intrusão

Historicamente, os sistemas de detecção de intrusão classificam-se em três paradigmas fundamentais (Guadarrama et al., 2025):

- **Detecção Baseada em Assinaturas (*Signature-Based Detection*):** Opera sob o princípio determinístico de que ameaças conhecidas manifestam padrões binários ou sintáticos invariantes no tráfego. O motor analítico compara o conteúdo dos pacotes com uma base de dados de regras padronizadas (a exemplo de Snort e Suricata), empregando casamento de padrões por sequências de bytes e expressões regulares.

A vantagem primordial reside no processamento veloz e na taxa de falsos positivos virtualmente nula para ameaças catalogadas. Em contrapartida, sua deficiência intrínseca consiste na incapacidade absoluta de identificar ataques de dia zero (*zero-day*), variações polimórficas de código malicioso ou payloads submetidos a novas técnicas de ofuscação, demandando frequentes atualizações de regras (Borgioli et al., 2024).

- **Detecção Baseada em Anomalias (*Anomaly-Based Detection*):** Assume a premissa de que o tráfego hostil diverge de maneira quantificável do comportamento ordinário da rede. O classificador constrói um perfil de referência (*baseline*) que encapsula a operação legítima observada durante períodos estáveis. Amostras posteriores que apresentem discrepâncias estatísticas relevantes em relação a esse perfil são rotuladas como suspeitas.

Sua principal virtude reside na aptidão teórica para identificar ataques inéditos e anomalias não documentadas. Todavia, sua operacionalização prática confronta o desafio da elevada taxa de falsos positivos (*False Positive Rate* – FPR), causada pela volatilidade intrínseca do tráfego computacional, em que eventos operacionais ordinários (como manutenções programadas ou picos sazonais de acesso) podem ser incorretamente categorizados como intrusões (Guadarrama et al., 2025; Silva, 2025).

- **Detecção Baseada em Especificação ou Políticas (*Specification-Based*):** Prescreve um conjunto explícito de restrições lógicas e gramaticais que delimitam o comportamento estritamente permitido aos protocolos legítimos (como transições autorizadas na máquina de estados de uma sessão de transporte ou faixas limites de parâmetros em protocolos industriais SCADA). Qualquer violação às regras canônicas é reportada como evento hostil. Embora reduza falsos positivos sem exigir grandes históricos de dados, impõe custo expressivo de modelagem manual e não identifica ataques que operem em conformidade estrita com a sintaxe do protocolo.

2.1.2.2 Granularidade de Inspeção: DPI versus Análise Baseada em Fluxos

A viabilidade técnica e a escalabilidade dos NIDS são governadas pela camada e pela granularidade com que a inspeção do tráfego é conduzida:

- **Inspeção Profunda de Pacotes (*Deep Packet Inspection* – DPI):** A metodologia DPI reconstrói integralmente as sessões de transporte e decodifica a carga útil (*payload*) dos pacotes nas camadas superiores (como HTTP, DNS e SMTP). Não obstante o nível elevado de contextualização semântica, sua aplicabilidade prática foi drasticamente comprometida pela consolidação ubíqua de protocolos com cifragem ponta a ponta obrigatória – com destaque para o TLS 1.3, HTTPS, DNS sobre HTTPS (*DNS over HTTPS* – DoH) e redes privadas virtuais (*Virtual Private Networks* – VPN) (Sarhan; Layeghy; Portmann, 2022; He; Fu; Zhang, 2026). Sob cifragem contínua, o conteúdo das mensagens torna-se opaco aos nós intermediários de rede. Ademais, o custo computacional exigido para remontar fluxos e processar expressões regulares sobre a carga útil inviabiliza sua aplicação em enlaces modernos operando em taxas de 10, 40 ou 100 Gbps (Chen et al., 2025).
- **Análise Baseada em Fluxos de Rede (*Flow-Based Analysis*):** Como resposta às limitações da análise de carga útil sob tráfego cifrado, consolidou-se o monitoramento baseado em fluxos estatísticos de tráfego (*network flows*) (Sarhan et al., 2021; Aouini; Pekar, 2022). Formalmente, um fluxo IP $\mathcal{F}$ é conceituado como uma sequência ordenada de pacotes observada em um dado intervalo temporal que compartilha uma tupla canônica de identificação, tradicionalmente expressa pela tupla de cinco campos (*5-tuple*):

$$\mathcal{F}_{id} = \langle IP_{src}, IP_{dst}, Port_{src}, Port_{dst}, Protocolo \rangle. \quad (1)$$

A partir desse agrupamento, extratores de telemetria (tais como NetFlow, IPFIX, CFlowMeter e NFStream) derivam vetores estatísticos multidimensionais que descrevem a conexão (Sarhan; Layeghy; Portmann, 2022; Aouini; Pekar, 2022): contagens totais de pacotes e bytes por sentido, tempos entre chegadas consecutivas de pacotes (*Inter-Arrival Times* – IAT), parâmetros de dispersão do comprimento dos pacotes (médias, desvios padrão, variâncias), tempos de atividade (*active*) e inatividade (*idle*), e sinalizadores TCP acumulados. Esse paradigma preserva a privacidade dos dados transmitidos, opera de maneira independente da presença de criptografia no payload e viabiliza o processamento analítico escalável tanto em redes corporativas de grande escala quanto em topologias de computação em névoa (*fog computing*) e Internet das Coisas (*Internet of Things* – IoT) (Neto et al., 2023; Čenys; Hora; Goranin, 2025; Souza, 2023).

2.1.2.3 Mecanismos de Resposta e Mitigação

O diagnóstico emitido por um sistema de monitoramento só adquire efetividade defensiva prática quando acoplado a mecanismos operacionais de contenção. A atuação divide-se em duas abordagens fundamentais:

- **Operação Passiva (NIDS):** o dispositivo é acoplado à rede de forma não disruptiva, por meio de portas espelho (*Switched Port Analyzer* – SPAN) ou acopladores físicos de sinal (*network TAP*). O sistema processa o tráfego de maneira assíncrona, despachando registros de alertas estruturados (em formatos como syslog, JSON ou CEF) para plataformas de Gerenciamento de Informações e Eventos de Segurança (*Security Information and Event Management* – SIEM) e plataformas de Orquestração, Automação e Resposta de Segurança (*Security Orchestration, Automation, and Response* – SOAR). Embora não adicione latência ao tráfego legítimo, essa abordagem não bloqueia intrusões em tempo real.
- **Operação Ativa (NIPS – *Network Intrusion Prevention System*):** o motor analítico atua diretamente na linha física ou lógica de comunicação (*inline*) ou integrado a elementos programáveis da camada de encaminhamento. Ao diagnosticar uma anomalia, o NIPS dispara medidas ativas de contenção imediata:
 - Descarte determinístico de pacotes associados ao fluxo malicioso (*packet dropping*);
 - Injeção de pacotes com o sinalizador TCP RST ativo direcionados aos extremos da conexão, provocando o término forçado e unilateral da sessão de transporte;
 - Atualização dinâmica de tabelas de filtragem no nível do kernel do sistema operacional (como `nftables` e conjuntos `ipset`), aplicando bloqueios temporais granulares sobre o endereço IP de origem;
 - Orquestração direta em planos de controle de Redes Definidas por Software (*Software-Defined Networking* – SDN) e em comutadores programáveis baseados no padrão P4,

viabilizando o redirecionamento para redes de isolamento (*honeynets*) ou aplicando políticas de descarte seletivo diretamente na taxa de transmissão da linha física (*line-rate processing*) (Chen et al., 2025).

2.2 APRENDIZADO PROFUNDO PARA SEGURANÇA DE REDES

A inadequação dos sistemas legados baseados em assinaturas perante a velocidade de mutação dos ataques contemporâneos impulsionou a adoção crescente de técnicas de Inteligência Artificial para a classificação analítica do tráfego (Noor; Ige, 2025; Dari et al., 2024). Inicialmente, as pesquisas concentraram-se em algoritmos clássicos de Aprendizado de Máquina (*Machine Learning* – ML), a exemplo de Máquinas de Vetores de Suporte (*Support Vector Machines* – SVM), Árvores de Decisão e comitês de Florestas Aleatórias (*Random Forest*) (Sainis; Srivastava; Singh, 2018). Todavia, esses modelos clássicos padecem de acentuada dependência de engenharia manual de atributos (*feature engineering*), registrando degradação de acurácia à medida que a dimensionalidade e o volume dos dados atingem a escala de enlaces industriais (Guadarrama et al., 2025).

Nesse contexto, o Aprendizado Profundo (*Deep Learning* – DL) estabeleceu-se como a abordagem metodológica central na segurança computacional moderna (Noor; Ige, 2025). Por intermédio de grafos computacionais constituídos por sucessivas transformações afins intercaladas por funções de ativação não lineares, os modelos profundos executam a extração automatizada de representações hierárquicas diretamente dos dados brutos ou de sumários de fluxo, mapeando correlações espaciais, dependências sequenciais e componentes espectrais determinantes da ação adversária (Luay et al., 2025; Luay et al., 2026).

2.2.1 Redes Convolucionais e Recorrentes (CNN, LSTM, GRU)

A modelagem estocástica do tráfego de rede abrange grandezas que variam tanto espacialmente (associações estruturais entre atributos de cabeçalho e métricas de volume) quanto sequencialmente (evolução cronológica das chegadas e tamanhos de pacotes). Famílias distintas de redes neurais foram estruturadas para atender a essas propriedades analíticas.

2.2.1.1 Redes Neurais Convolucionais (CNN)

Desenvolvidas originariamente para o processamento de arranjos bidimensionais, as Redes Neurais Convolucionais (*Convolutional Neural Networks* – CNN) baseiam-se em três princípios estruturais: campos receptivos locais (*local receptive fields*), compartilhamento de parâmetros sinápticos (*weight sharing*) e invariância a pequenas translações espaciais (Noor; Ige, 2025). Na análise de segurança de rede, essas propriedades são exploradas mediante a aplicação de operações de convolução unidimensional (1D-CNN) ou bidimensional (2D-CNN) sobre matrizes estruturadas de pacotes ou vetores tabulares de atributos de fluxo (Sarhan et al., 2021).

Formalmente, considere um vetor de entrada $\mathbf{x} \in \mathbb{R}^{L \times C_{\text{in}}}$, em que L denota o comprimento dimensional e C_{in} representa o número de canais. A operação de convolução discreta unidimensional com passo unitário, governada por um filtro de pesos $\mathbf{W}^{(l)} \in \mathbb{R}^{M \times C_{\text{in}}}$ e viés $b^{(l)} \in \mathbb{R}$, para a geração do mapa de ativação na camada l , é dada por:

$$y_i^{(l)} = \sigma \left(\sum_{c=1}^{C_{\text{in}}} \sum_{m=0}^{M-1} W_{m,c}^{(l)} x_{i+m,c} + b^{(l)} \right), \quad (2)$$

em que M denota a largura da janela do filtro convolucional (*kernel size*) e $\sigma(\cdot)$ representa a função de ativação não linear. De forma análoga, em projeções matriciais espaciais em que as características do fluxo são organizadas sob a forma de uma matriz $\mathbf{X} \in \mathbb{R}^{H \times W \times C_{\text{in}}}$, a convolução bidimensional com filtro $\mathbf{W}^{(l)} \in \mathbb{R}^{M_h \times M_w \times C_{\text{in}}}$ assume a formulação:

$$Y_{i,j}^{(l)} = \sigma \left(\sum_{c=1}^{C_{\text{in}}} \sum_{m=0}^{M_h-1} \sum_{n=0}^{M_w-1} W_{m,n,c}^{(l)} X_{i+m,j+n,c} + b^{(l)} \right). \quad (3)$$

Entre as funções de ativação comumente empregadas, destacam-se a Unidade Linear Retificada (*Rectified Linear Unit* – ReLU), expressa por $\text{ReLU}(z) = \max(0, z)$, e sua extensão com gradiente residual (*Leaky ReLU*):

$$\text{LeakyReLU}(z) = \begin{cases} z, & \text{se } z > 0, \\ \alpha_L z, & \text{se } z \leq 0, \end{cases} \quad \text{com } 0 < \alpha_L \ll 1, \quad (4)$$

a qual mitiga a inativação permanente de neurônios (*dying ReLU problem*) durante a retropropagação do gradiente.

Para acelerar a convergência e assegurar estabilidade numérica entre camadas convolucionais sucessivas, adota-se a técnica de Normalização em Lote (*Batch Normalization*) (Noor; Ige, 2025). Para um conjunto de ativações intermediárias $\mathcal{B} = \{x_1, \dots, x_B\}$, calcula-se a média amostral μ_B e a variância σ_B^2 , escalonando e transladando os dados por meio dos parâmetros aprendíveis γ e β :

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon_B}}, \quad y_i = \gamma \hat{x}_i + \beta, \quad (5)$$

sendo $\epsilon_B > 0$ uma constante de estabilização. Subsequentemente, operações de agrupamento (*Pooling*), tais como o agrupamento máximo (*Max Pooling*), extraem o valor dominante em janelas de dimensão P , comprimindo o mapa de características:

$$p_j = \max_{k \in \{0, \dots, P-1\}} (y_{j \cdot P + k}). \quad (6)$$

Em sistemas NIDS, os módulos convolucionais operam como detectores eficientes de padrões morfológicos locais, identificando dependências espaciais entre campos de cabeçalhos e métricas de transporte sem impor premissas estritas de linearidade global (Noor; Ige, 2025).

2.2.1.2 Redes Neurais Recorrentes e a Modelagem Temporal (LSTM e GRU)

Diversas manifestações de ataques – tais como canais de comando e controle com transmissão periódica, varreduras esparsas de portas e etapas graduais de infiltração – apresentam assinaturas distribuídas sequencialmente ao longo do tempo (Luay et al., 2025; Luay et al., 2026). Redes Neurais Recorrentes (*Recurrent Neural Networks* – RNN) mantêm um estado oculto recorrente $\mathbf{h}_t$, processando sequências temporais de forma cronológica recursiva.

Contudo, as variantes elementares de RNN enfrentam a limitação do desvanecimento ou explosão do gradiente (*vanishing and exploding gradients*) durante o processo de retropropagação através do tempo (*Backpropagation Through Time* – BPTT) (Noor; Ige, 2025). Quando o horizonte temporal abrange múltiplos passos T , o encadeamento sucessivo de derivadas $\prod_{k=t+1}^T \frac{\partial \mathbf{h}_k}{\partial \mathbf{h}_{k-1}}$ induz o decaimento exponencial a zero ou a divergência dos valores dos gradientes, impedindo o aprendizado de dependências remotas na sequência de pacotes.

Para contornar essa restrição, foram desenvolvidas arquiteturas fundamentadas em estruturas lógicas de controle denominadas portas (*gates*): a rede de Memória de Curto e Longo Prazo (*Long Short-Term Memory* – LSTM) e a Unidade Recorrente com Portas (*Gated Recurrent Unit* – GRU).

2.2.1.2.1 Long Short-Term Memory (LSTM):

A LSTM desacopla a preservação de contexto por intermédio de um vetor de estado celular $\mathbf{C}_t \in \mathbb{R}^d$, que viabiliza a propagação de gradientes aditivos sem degradação exponencial (Noor; Ige, 2025; Luay et al., 2025). O trânsito de informações entre passos adjacentes é modulado por três portas logísticas que operam sobre o vetor de entrada no instante atual $\mathbf{x}_t \in \mathbb{R}^m$ e o estado oculto precedente $\mathbf{h}_{t-1} \in \mathbb{R}^d$:

1. *Porta de Esquecimento* (Forget Gate): estabelece a proporção do histórico celular a ser retida ou descartada:

$$\mathbf{f}_t = \sigma(\mathbf{W}_f \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f); \quad (7)$$

2. *Porta de Entrada* (Input Gate): quantifica a magnitude com que as novas informações devem atualizar o estado celular:

$$\mathbf{i}_t = \sigma(\mathbf{W}_i \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i); \quad (8)$$

3. *Candidato ao Estado Celular* (Candidate Cell State): calcula um novo vetor candidato de contexto com ativação em tangente hiperbólica:

$$\tilde{\mathbf{C}}_t = \tanh(\mathbf{W}_c \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_c); \quad (9)$$

4. *Atualização do Estado Celular*: combina a memória pregressa com os novos candidatos calculados:

$$\mathbf{C}_t = \mathbf{f}_t \odot \mathbf{C}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{C}}_t; \quad (10)$$

5. *Porta de Saída (Output Gate) e Estado Oculto*: regula a exteriorização das ativações no estado oculto visível $\mathbf{h}_t$:

$$\mathbf{o}_t = \sigma(\mathbf{W}_o \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o), \quad (11)$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{C}_t), \quad (12)$$

em que $\sigma(z) = \frac{1}{1+e^{-z}}$ denota a função sigmoide logística, $\odot$ representa o produto de Hadamard (multiplicação elemento a elemento) e os colchetes $[\mathbf{h}_{t-1}, \mathbf{x}_t]$ denotam a concatenação vetorial. Essa modelagem permite que o classificador retenha correlações temporais em horizontes cronológicos estendidos do fluxo (Luay et al., 2025).

2.2.1.2.2 Gated Recurrent Unit (GRU):

Proposta como uma reformulação simplificada e computacionalmente mais econômica da LSTM, a rede GRU consolida o estado celular diretamente no estado oculto $\mathbf{h}_t$, eliminando a porta de saída independente (Noor; Ige, 2025; Luay et al., 2026). A arquitetura opera sobre duas portas de modulação:

1. *Porta de Atualização (Update Gate)*: pondera a proporção entre a manutenção do estado anterior e a incorporação de novos estados:

$$\mathbf{z}_t = \sigma(\mathbf{W}_z \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_z); \quad (13)$$

2. *Porta de Redefinição (Reset Gate)*: determina o grau de desconsideração da memória anterior no cômputo da ativação candidata:

$$\mathbf{r}_t = \sigma(\mathbf{W}_r \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_r); \quad (14)$$

3. *Estado Oculto Candidato*: processa a entrada atual em conjunção com a memória pregressa atenuada pela porta de redefinição:

$$\tilde{\mathbf{h}}_t = \tanh(\mathbf{W}_h \cdot [\mathbf{r}_t \odot \mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_h); \quad (15)$$

4. *Estado Oculto Definitivo*: realiza a interpolação linear entre o estado passado e o estado candidato:

$$\mathbf{h}_t = (1 - \mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t. \quad (16)$$

Por demandar menor quantidade de matrizes de parâmetros, a GRU exibe tempo de convergência reduzido e menor pegada computacional, apresentando excelente adequação à modelagem de dinâmicas transitórias e variações em intervalos entre pacotes (*Inter-Arrival Times* – IAT) (Luay et al., 2026).

2.2.2 Redes Densas, Autoencoders e Análise Espectral

A natureza heterogênea do tráfego de rede requer que atributos estáticos globais e manifestações harmônicas periódicas disponham de tratamentos algorítmicos especializados: transformações totalmente conectadas para sumários agregados e autoencoders acoplados ao processamento espectral para detecção por reconstrução de anomalias.

2.2.2.1 Redes Neurais Totalmente Conectadas (DNN)

As Redes Neurais Profundas Totalmente Conectadas (*Dense Neural Networks* – DNN ou *Multilayer Perceptrons* – MLP) fundamentam-se no encadeamento de transformações lineares seguidas por não linearidades elementares. Cada neurônio da camada l recebe todas as saídas da camada anterior $l - 1$:

$$\mathbf{h}^{(l)} = \sigma \left(\mathbf{W}^{(l)} \mathbf{h}^{(l-1)} + \mathbf{b}^{(l)} \right), \quad (17)$$

em que $\mathbf{W}^{(l)} \in \mathbb{R}^{d_l \times d_{l-1}}$ representa a matriz de pesos e $\mathbf{b}^{(l)} \in \mathbb{R}^{d_l}$ denota o vetor de viés. Em arquiteturas NIDS, as DNNs são indicadas para o processamento de variáveis tabulares globais computadas ao longo da sessão (duração, contagem acumulada de pacotes e bytes por sentido e contadores de sinalizadores TCP), nas quais a contiguidade física espacial não é necessariamente mandatória (Guadarrama et al., 2025).

2.2.2.2 Autoencoders Convolucionais 1D (1D-CAE) e Processamento Espectral Integrado

O paradigma do Autoencoder (*Autoencoder* – AE) assenta-se no aprendizado não supervisionado ou semi-supervisionado de representações latentes comprimidas (Silva, 2025). Uma rede AE típica é composta por duas estruturas acopladas: um codificador (*encoder*) $\mathcal{E}_\phi(\cdot)$, que mapeia o vetor de entrada $\mathbf{x} \in \mathbb{R}^D$ para um espaço latente de baixa dimensionalidade $\mathbf{z} \in \mathbb{R}^d$ ($d \ll D$), e um decodificador (*decoder*) $\mathcal{D}_\psi(\cdot)$, encarregado de reconstruir a entrada original gerando $\tilde{\mathbf{x}} = \mathcal{D}_\psi(\mathbf{z}) \in \mathbb{R}^D$. Em tarefas de segurança, treina-se a rede primariamente com tráfego legítimo; fluxos intrusivos com propriedades anômalas não encontram projeção adequada na variedade aprendida, provocando erros de reconstrução $\|\mathbf{x} - \tilde{\mathbf{x}}\|^2$ expressivos (Silva, 2025; Borgioli et al., 2024).

Determinadas categorias de agressão (como inundações pulsáteis periódicas, varreduras sincronizadas por temporizadores internos e canais C2 estruturados) manifestam comportamentos que se destacam como frequências harmônicas bem delineadas no domínio da frequência (Maciá-Fernández et al., 2018). Para capturar essas características, a formulação analítica do Autoencoder Convolucional 1D (1D-CAE) integra o pré-processamento espectral à arquitetura neural:

2.2.2.2.1 1. Seleção de Subdomínio e Janelamento de Hann:

A partir do vetor tabular de características $\mathbf{x} \in \mathbb{R}^F$, particiona-se um subconjunto de comprimento L_f correspondente ao domínio temporal e dinâmico $\mathbf{u} = \mathbf{x}_{1:L_f} \in \mathbb{R}^{L_f}$. Com a finalidade de atenuar o espalhamento espectral (*spectral leakage*) decorrente da truncagem finita do sinal, aplica-se uma Janela Periódica de Hann $\mathbf{w} \in \mathbb{R}^{L_f}$, formulada analiticamente por:

$$w(n) = 0,5 - 0,5 \cos\left(\frac{2\pi n}{L_f}\right), \quad \forall n \in \{0, 1, \dots, L_f - 1\}. \quad (18)$$

O sinal ponderado $\mathbf{u}_w \in \mathbb{R}^{L_f}$ resulta da multiplicação de Hadamard:

$$\mathbf{u}_w = \mathbf{u} \odot \mathbf{w}. \quad (19)$$

2.2.2.2.2 2. Transformada Rápida de Fourier Discreta para Sinais Reais (RFFT):

Sobre o sinal janelado $\mathbf{u}_w$, aplica-se a Transformada Discreta de Fourier para entradas puramente reais (*Real Fast Fourier Transform* – RFFT). Explorando a simetria hermitiana dos coeficientes de Fourier para sequências reais, obtém-se o espectro unilateral com $K_{\text{fft}} = \lfloor L_f/2 \rfloor + 1$ coeficientes discretos. A densidade de magnitude espectral $\mathbf{x}_f \in \mathbb{R}^{K_{\text{fft}}}$ é obtida pelo módulo dos números complexos:

$$x_f[k] = \left| \sum_{n=0}^{L_f-1} u_w[n] \cdot e^{-j \frac{2\pi k n}{L_f}} \right|, \quad \forall k \in \{0, 1, \dots, K_{\text{fft}} - 1\}. \quad (20)$$

2.2.2.2.3 3. Codificação Convolutiva 1D:

O vetor $\mathbf{x}_f$ é expandido para canal unitário e processado por S camadas de convolução unidimensional com filtros de dimensão K_{size} e passo s :

$$\mathbf{z}^{(s)} = \text{ReLU} \left(\mathbf{W}_e^{(s)} * \mathbf{z}^{(s-1)} + \mathbf{b}_e^{(s)} \right), \quad s \in \{1, \dots, S\}, \quad (21)$$

com $\mathbf{z}^{(0)} = \mathbf{x}_f$, resultando na representação latente compactada $\mathbf{z} = \mathbf{z}^{(S)}$.

2.2.2.2.4 4. Decodificação por Convolução Transposta 1D:

A estimativa do espectro de magnitude $\tilde{\mathbf{x}}_f \in \mathbb{R}^{K_{\text{fft}}}$ é sintetizada por camadas de Convolução Transposta 1D (*Conv1DTranspose*), invertendo o processo de redução dimensional com ajuste de comprimento espectral:

$$\tilde{\mathbf{x}}_f = \text{ReLU} \left(\mathbf{W}_d *^\top \mathbf{z} + \mathbf{b}_d \right). \quad (22)$$

2.2.2.2.5 5. Função de Perda Composta do CAE com Supervisão Profunda:

Conforme modelado no sistema ALF-MoE, o treinamento do especialista CAE é orientado por uma função de perda conjunta que sintetiza a supervisão de classificação $\mathcal{L}_{\text{cls}}$, o Erro Quadrático Médio de reconstrução espectral (*Mean Squared Error* – MSE) e a regularização L_2 sobre os pesos:

$$\mathcal{L}_{\text{CAE}} = \lambda_{\text{cls}} \mathcal{L}_{\text{cls}} + \frac{\lambda_{\text{rec}}}{N} \sum_{i=1}^N \sum_{k=0}^{K_{\text{fft}}-1} (x_{f,i}[k] - \tilde{x}_{f,i}[k])^2 + \lambda_4 \sum_{w \in \mathcal{W}_{\text{CAE}}} \|w\|_2^2, \quad (23)$$

em que N indica a quantidade de amostras do lote, λ_{rec} representa o peso da perda de reconstrução, λ_4 denota a penalização L_2 e λ_{cls} governa o gradiente supervisionado da predição auxiliar de classe. Essa formulação assegura que a representação latente $\mathbf{z}$ capture tanto propriedades discriminatórias de classes quanto a regularidade espectral do tráfego legítimo (Borgioli et al., 2024).

2.2.3 Tratamento de Desbalanceamento Extremo via Focal Loss

Conjuntos de dados de cibersegurança caracterizam-se por desbalanceamento severo de classes, em que o tráfego benigno frequentemente responde por mais de 90% das amostras, ao passo que ataques críticos (como *Infiltration*, *Web Attacks* e *Botnets*) representam frações inferiores a 1% do total coletado (Neto et al., 2023; Sarhan; Layeghy; Portmann, 2022). Nessas condições, a função convencional de Entropia Cruzada (*Categorical Cross-Entropy* – CE) tende a ser dominada pelo acúmulo de gradientes das amostras majoritárias facilmente classificáveis, negligenciando as categorias minoritárias essenciais.

Para mitigar essa assimetria, incorpora-se a função de Perda Focal (*Focal Loss* – FL), concebida por Lin et al. (2017):

$$\text{FL}(p_t) = -\alpha_t (1 - p_t)^\gamma \log(p_t), \quad (24)$$

em que $p_t \in (0, 1]$ denota a probabilidade estimada pelo classificador para a classe verdadeira do fluxo, $\gamma \geq 0$ representa o parâmetro de foco e $\alpha_t \in (0, 1]$ atua como o coeficiente ponderador de balanceamento de classe.

O fator modulador $(1 - p_t)^\gamma$ reduz a contribuição relativa de exemplos fáceis e bem calibrados ($p_t \rightarrow 1$), concentrando o esforço de otimização nos padrões raros ou fronteiros de ataque ($p_t \rightarrow 0$). Para um minilote com N observações e C categorias de tráfego, a formulação numérica com proteção contra indefinição logarítmica via limitação infinitesimal $\epsilon = 10^{-8}$ é dada por:

$$\mathcal{L}_{\text{FL}} = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \alpha_c (1 - \hat{y}_{i,c})^\gamma \log(\text{clip}(\hat{y}_{i,c}, \epsilon, 1, 0 - \epsilon)), \quad (25)$$

assegurando estabilidade numérica na convergência dos especialistas mesmo sob desproporções amostrais extremas.

2.2.4 Mixture of Experts (MoE) e Mecanismos de Fusão Atencional

O tráfego de redes contemporâneas exibe uma multiplicidade de padrões cujas manifestações diagnósticas concentram-se em subespaços analíticos distintos (Chandroth; Stoian; Danciulescu, 2026; He; Fu; Zhang, 2026). Modelos monolíticos homogêneos que forçam uma única topologia neural a contemplar correlações espaciais, dependências sequenciais e frequências harmônicas simultaneamente sofrem do fenômeno de interferência negativa de gradientes (*negative gradient interference*), culminando em compromissos de representação subótimos (Yang et al., 2025).

O paradigma de Mistura de Especialistas (*Mixture of Experts* – MoE), formulado inicialmente por Jacobs et al. (1991) e expandido para grandes arquiteturas profundas por Shazeer et al. (2017), baseia-se na divisão modular de tarefas: em vez de um único classificador geral, emprega-se um conjunto de redes especialistas especializadas $\mathcal{E}_1, \mathcal{E}_2, \dots, \mathcal{E}_K$, cuja contribuição individual para a inferência consolidada é arbitrada dinamicamente por uma Rede de Roteamento (*Gating Network*) parametrizada (Chandroth; Stoian; Danciulescu, 2026).

2.2.4.1 Rede de Roteamento Dinâmico (Gating Network)

A Gating Network atua como o módulo decisório da arquitetura MoE. Sua responsabilidade analítica consiste em examinar o contexto de cada amostra de tráfego e computar uma distribuição de probabilidade sobre os K especialistas, quantificando a pertinência diagnóstica de cada modelo para o fluxo em julgamento (He; Fu; Zhang, 2026).

Com a finalidade de dotar a rede de roteamento de capacidade discriminatória enriquecida, sua entrada recebe conjuntamente o vetor tabular bruto do fluxo $\mathbf{x} \in \mathbb{R}^F$ e a concatenação das probabilidades de classe preliminares emitidas por todos os K especialistas $\mathbf{e} = [(\hat{\mathbf{y}}^{(1)})^\top, (\hat{\mathbf{y}}^{(2)})^\top, \dots, (\hat{\mathbf{y}}^{(K)})^\top]^\top \in \mathbb{R}^{K \cdot C}$:

$$\mathbf{h}_{\text{gate}} = \text{ReLU}(\mathbf{W}_{gx}\mathbf{x} + \mathbf{b}_{gx}) + \text{ReLU}(\mathbf{W}_{ge}\mathbf{e} + \mathbf{b}_{ge}). \quad (26)$$

Após sucessivas camadas densas com regularização por Dropout, a rede infere um vetor de escores brutos de roteamento $\mathbf{g} = [g_1, g_2, \dots, g_K]^\top \in \mathbb{R}^K$, normalizado pela função softmax para assegurar que os pesos componham uma partição probabilística unitária:

$$\alpha_k = \frac{\exp(g_k)}{\sum_{j=1}^K \exp(g_j)}, \quad \forall k \in \{1, \dots, K\}, \quad \text{satisfazendo} \quad \sum_{k=1}^K \alpha_k = 1 \quad \text{e} \quad \alpha_k \geq 0. \quad (27)$$

2.2.4.2 Mecanismo de Refinamento Atencional Aprendível (ALF)

Em arranjos clássicos de MoE, a inferência final limita-se à média ponderada direta pelos pesos α_k do softmax. Todavia, sob tráfego de rede marcado por classes com padrões concorrentes

e ruídos de medição, a ativação softmax tende a exibir descalibração probabilística (*miscalibration*), atribuindo pesos desproporcionais a modelos com saídas superconfiantes (Chandroth; Stoian; Danciulescu, 2026).

Para contornar essa restrição, adota-se o mecanismo de Fusão Aprendível Baseada em Atenção (*Attention-Based Learnable Fusion* – ALF), fundamentado no refinamento atencional afim e na calibração de escores (Chandroth; Stoian; Danciulescu, 2026):

2.2.4.2.1 1. Transformação Logarítmica Estabilizada:

Os coeficientes probabilísticos $\alpha = [\alpha_1, \dots, \alpha_K]^\top$ são submetidos a uma operação de limitação inferior com valor infinitesimal $\epsilon = 10^{-7}$, seguida pelo cômputo logarítmico:

$$\log \alpha_{\text{clip}} = \log (\text{clip}(\alpha, \epsilon, 1, 0)). \quad (28)$$

A representação no domínio logarítmico converte correlações multiplicativas de certeza em grandezas aditivas, facilitando o aprendizado de sinergias através de transformações lineares.

2.2.4.2.2 2. Camada de Refinamento de Atenção com Pesos Afins:

O vetor $\log \alpha_{\text{clip}}$ é submetido a uma camada de projeção parametrizada por uma matriz de refinamento atencional $\mathbf{W}_g \in \mathbb{R}^{K \times K}$ e um vetor de viés $\mathbf{b}_g \in \mathbb{R}^K$, modulada pela tangente hiperbólica e normalizada por softmax:

$$\mathbf{a} = \text{softmax} (\tanh (\mathbf{W}_g \log \alpha_{\text{clip}} + \mathbf{b}_g)). \quad (29)$$

Essa transformação viabiliza que o modelo aprenda correlações cruzadas entre especialistas: a relevância final de um especialista $\mathcal{E}_k$ passa a depender da confiança manifestada pelo comitê como um todo.

2.2.4.2.3 3. Calibração de Confiança via Escalonamento Paramétrico (Vector Scaling):

Em conformidade com os princípios teóricos de calibração em modelos profundos estabelecidos por Guo et al. (2017), probabilidades preditas frequentemente distanciam-se das frequências observadas de acerto. Para restaurar a calibração de confiança dos escores intermediários, incorpora-se o módulo de escalonamento paramétrico (*Vector Scaling*):

$$\hat{\mathbf{s}} = \text{softmax} (\mathbf{W}_s \odot \mathbf{s} + \mathbf{b}_s), \quad (30)$$

em que $\mathbf{W}_s, \mathbf{b}_s \in \mathbb{R}^K$ são parâmetros aprendíveis inicializados respectivamente com valores unitários e nulos, modulando a entropia das decisões preliminares.

2.2.4.2.4 4. Fusão por Soma Ponderada (Weighted Sum Fusion):

Apoiando-se nos coeficientes atencionais refinados $\mathbf{a}$, as previsões individuais dos K especialistas $\hat{\mathbf{y}}^{(k)} \in \mathbb{R}^C$ são sintetizadas por soma ponderada em um vetor latente $\mathbf{Z} \in \mathbb{R}^C$:

$$\mathbf{Z} = \sum_{k=1}^K a_k \cdot \hat{\mathbf{y}}^{(k)}. \quad (31)$$

2.2.4.2.5 5. Projeção Classificatória Final Consolidada:

Com o objetivo de preservar a sensibilidade de subdomínios singulares diante de ataques altamente focados, o vetor sintetizado $\mathbf{Z}$ é concatenado com as previsões de todos os especialistas individuais:

$$\mathbf{h}_{\text{ens}} = [\mathbf{Z}^\top, (\hat{\mathbf{y}}^{(1)})^\top, (\hat{\mathbf{y}}^{(2)})^\top, \dots, (\hat{\mathbf{y}}^{(K)})^\top]^\top \in \mathbb{R}^{(K+1) \cdot C}. \quad (32)$$

O vetor concatenado $\mathbf{h}_{\text{ens}}$ é processado por camadas densas intermediárias com normalização em lote, ativações LeakyReLU e descarte aleatório (*Dropout*), sendo projetado na camada de decisão global $\hat{\mathbf{y}}_{\text{ALF}} \in \mathbb{R}^C$:

$$\hat{\mathbf{y}}_{\text{ALF}} = \text{softmax}(\mathbf{W}_{\text{out}} \mathbf{h}_{\text{ALF}} + \mathbf{b}_{\text{out}}). \quad (33)$$

Essa hierarquia analítica concede à arquitetura ALF-MoE a propriedade singular de alternar dinamicamente entre o consenso coletivo ponderado ($\mathbf{Z}$) e a especialização unívoca de um único domínio na presença de anomalias com assinaturas mono-domínio pronunciadas (Chandroth; Stoian; Danciulescu, 2026).

2.3 TRABALHOS CORRELATOS

O desenvolvimento de arquiteturas computacionais robustas para detecção de anomalias em redes constitui uma linha de investigação consolidada e fértil na Ciência da Computação. O exame crítico das abordagens existentes permite posicionar formalmente as contribuições deste trabalho, examinando a transição de classificadores profundos homogêneos para propostas estruturadas em conjuntos e misturas de especialistas.

2.3.1 NIDS Baseados em Aprendizado Profundo

A evolução dos NIDS baseados em inteligência artificial focou inicialmente na substituição de classificadores superficiais por redes neurais profundas monolíticas aplicadas de forma uniforme sobre os dados (Noor; Ige, 2025).

Sainis, Srivastava & Singh (2018) investigaram a detecção de valores atípicos (*outlier detection*) combinada a algoritmos de seleção de atributos para aprimoramento da precisão de sistemas IDS. Os autores constataram que a seleção supervisionada de variáveis reduz taxas

de falsos positivos em conjuntos de dados legados, a exemplo de KDD-Cup99 e NSL-KDD. Entretanto, a abordagem restringiu-se a classificadores rasos tradicionais (SVM, Árvores de Decisão e Random Forest) aplicados sobre a totalidade indiscriminada dos atributos, sem distinguir domínios espaciais, temporais ou espectrais específicos do tráfego.

Sarhan et al. (2021) propuseram representações universais de tráfego baseadas no protocolo NetFlow com o propósito de solucionar a fragmentação metodológica dos dados de rede. Subsequentemente, Sarhan, Layeghy & Portmann (2022) expandiram essa abordagem estabelecendo um conjunto padronizado e canônico de atributos estatísticos aplicável a múltiplos conjuntos de referência (NF-UNSW-NB15, NF-CSE-CIC-IDS2018 e NF-BoT-IoT). As análises confirmaram a viabilidade da identificação de fluxos anômalos a partir de metadados sumarizados de rede. Não obstante, os autores fundamentaram suas avaliações em classificadores convencionais estáticos, sem investigar o encadeamento dinâmico entre chegadas sucessivas de pacotes ou propriedades harmônicas de frequência.

Guadarrama et al. (2025) conduziram um estudo comparativo abrangente sobre conjuntos de dados e algoritmos de aprendizado de máquina para NIDS baseados em fluxos. O trabalho avaliou rigorosamente modelos supervisionados sob diferentes regimes de balanceamento de dados. As principais fragilidades evidenciadas pelos autores situam-se na perda severa de sensibilidade multiclasse perante categorias com baixa representatividade amostral e no custo computacional exigido pelo retreinamento de arquiteturas monolíticas quando confrontadas com volumes massivos de tráfego.

Dari et al. (2024) elaboraram uma avaliação comparativa de redes profundas para resiliência cibernética, confrontando topologias CNN, RNN e DNN na mitigação de intrusões. Os experimentos comprovaram que redes convolucionais sobressaem-se na captura de padrões morfológicos de cabeçalhos, enquanto modelos recorrentes (LSTM e GRU) destacam-se na detecção de ameaças com cadência temporal lenta. Contudo, os autores analisaram cada família de forma isolada, concluindo que nenhuma arquitetura homogênea foi capaz de manter liderança de desempenho em todas as classes de ataques simultaneamente.

Oliveira, Gonçalves & Filho (2025) conceberam o F-NIDS, um sistema de detecção de intrusão alicerçado em Aprendizado Federado (*Federated Learning*) com o objetivo de viabilizar o treinamento colaborativo entre instituições sem exposição de dados brutos. Conquanto enderece requisitos fundamentais de privacidade e descentralização em borda, o classificador local utilizado nos nós baseia-se em uma rede profunda homogênea, reproduzindo a vulnerabilidade analítica diante de ataques heterogêneos.

Abreu & Abelém (2022) apresentaram um sistema híbrido e contínuo (*on-line*) voltado à triagem e classificação de fluxos maliciosos em tempo real. A arquitetura emprega filtros estatísticos preliminares combinados a algoritmos supervisionados em linha de transmissão. Apesar dos avanços na redução da latência operacional, a solução depende de limiares determinísticos estáticos, sofrendo perda de precisão perante novas aplicações benignas que compartilham portas ordinárias de transporte.

Sasi et al. (2025) desenvolveram uma rede híbrida integrando camadas 1D-CNN e LSTM com mecanismos de autoatenção (*self-attention*) voltada a ambientes de IoT. Os resultados apontaram ganhos na detecção de ataques combinados; todavia, a complexidade quadrática do mecanismo de atenção impôs sobrecarga computacional excessiva, tornando o modelo oneroso para execução em taxas de transmissão elevadas de tráfego contínuo.

2.3.2 Abordagens Ensemble e Mixture of Experts em Cibersegurança

Buscando suplantiar os limites teóricos e operacionais das redes homogêneas, a comunidade acadêmica voltou-se para abordagens baseadas em aprendizado em conjunto (*ensemble*) e especialização de redes.

Silva (2025) propuseram o HSAE (*Hybrid Semi-Supervised Autoencoder*), uma estrutura semi-supervisionada projetada para identificação de ameaças de dia zero combinada a um comitê ensemble. O arranjo sintetiza autoencoders para a caracterização da normalidade com classificadores em comitê. Entretanto, a fusão das decisões decorre de votação majoritária ou média aritmética simples com ponderações estáticas, desconsiderando a dependência contextual das amostras sob avaliação.

Borgioli et al. (2024) estruturaram um autoencoder convolucional 1D (1D-CAE) voltado à detecção de intrusão em sistemas embarcados de tempo real com tolerância a ataques de envenenamento de dados (*data poisoning*). O método comprovou a utilidade das operações convolucionais na compressão de padrões operacionais de rede. A investigação restringiu-se, todavia, ao diagnóstico binário (tráfego anômalo versus tráfego regular), sem fornecer discriminação granular multiclasse nem integrar mecanismos dinâmicos de governança cooperativa.

Paralelamente, o emprego do paradigma de Mistura de Especialistas (MoE) começou a emergir em vertentes correlatas da segurança computacional:

Yang et al. (2025) introduziram a arquitetura MoEVD para a identificação de falhas em código-fonte de software. Sob a máxima de que nenhum modelo monolítico atende eficazmente a todas as modalidades de ameaça ("*One-for-All Does Not Work!*"), os autores demonstraram experimentalmente que classificadores generalistas colapsam perante a diversidade estrutural das vulnerabilidades. Ao segmentar o aprendizado em redes especializadas reguladas por roteamento condicional, o MoEVD superou arquiteturas de grande escala. Contudo, o processamento estático de grafos sintáticos em código impõe requisitos distintos do monitoramento em streaming de alta velocidade exigido por redes de telecomunicações.

He, Fu & Zhang (2026) apresentaram o TrafficMoE, um framework fundamentado em MoE orientado à classificação de tráfego de rede criptografado sensível à heterogeneidade dos dados (*heterogeneity-aware*). Os autores constataram que a criptografia moderna introduz distribuições disjuntas de entropia entre aplicações benignas. O sistema emprega especialistas neurais governados por roteamento adaptativo. Não obstante o mérito técnico, o trabalho ateu-se estritamente à categorização de serviços e aplicações ordinárias (como videoconferência versus

navegação convencional), sem contemplar cenários de intrusão cibernética, ataques persistentes multi-estágio ou agentes adversariais conduzidos por inteligência artificial.

Chandroth, Stoian & Danciulescu (2026) propuseram formalmente o ALF-MoE (*Attention-Based Learnable Fusion of Specialized Expert Networks*), aplicando a mistura de redes à classificação de tráfego agregado e túneis cifrados VPN. A contribuição seminal do estudo residiu na organização de cinco especialistas direcionados a quatro perspectivas distintas de atributos (estatística tabular com DNN, espacial com CNN, temporal transitória com GRU, espectral de frequência com CAE e dependência temporal de longo prazo com LSTM), coordenados por uma Gating Network dotada de refinamento de atenção aprendível (ALF) e projeção afim estabilizada. O arranjo alcançou acurácia superior a 97% em bases consolidadas como ISCX VPN-nonVPN e Unicauca.

A despeito dessa relevância metodológica, a concepção original de Chandroth, Stoian & Danciulescu (2026) circunscreveu-se a tarefas balanceadas de identificação de aplicações e operou em modo exclusivamente em lote (*batch*), sem examinar a robustez do modelo em cenários com desbalanceamento severo de ataques cibernéticos, sem validar a resiliência contra ameaças multifásicas guiadas por modelos de linguagem (LLMs) e sem contemplar a integração a motores de telemetria contínua de baixa latência em tempo real.

2.3.3 Síntese Comparativa

A análise crítica da literatura especializada permite consolidar um conjunto de lacunas estruturais que delimitam a fronteira do conhecimento na área de NIDS:

1. **Monolitismo e Ausência de Especialização Multidomínio:** a maioria expressiva das propostas recorre a modelos homogêneos (estritamente convolucionais ou estritamente recorrentes), sacrificando a acurácia em classes de ameaças cujas características diagnósticas residem em dimensões fora do escopo focalizado pela arquitetura;
2. **Fusão Estática em Comitês Convencionais:** as abordagens com múltiplos classificadores adotam majoritariamente agregações heurísticas tardias (médias aritméticas ou votação majoritária estática), desconsiderando a dependência contextual entre fluxos e a calibração de certeza mútua entre os modelos;
3. **Vulnerabilidade ao Desbalanceamento Extremo de Classes:** a literatura frequentemente avalia modelos sob métricas globais agregadas que mascaram o colapso do classificador em ataques raros ou altamente assimétricos em tráfego criptografado;
4. **Ausência de Calibração Probabilística Dinâmica:** modelos neurais modernos sofrem de superconfiança (*overconfidence*) em previsões incorretas em espaços multiclasse complexos, carecendo de mecanismos de escalonamento paramétrico integrados à tomada de decisão;

5. Limitação de Avaliação Cruzada entre Domínios: grande parte das propostas restringe-se a uma única base de dados, omitindo a validação de robustez e generalização da arquitetura perante ecossistemas heterogêneos (redes corporativas, tráfego IoT e explorações avançadas).

Para consolidar as distinções metodológicas entre os principais trabalhos da literatura e o modelo concebido nesta tese, o Quadro 1 sumariza as abordagens, modelos empregados, conjuntos de dados e fragilidades estruturais de cada iniciativa.

Tabela 1 – Síntese comparativa entre trabalhos correlatos da literatura e a proposta desta tese.

Trabalho / Referência	Metodologia / Paradigma	Modelos / Datasets	Limitações Identificadas
Sainis, Srivastava & Singh (2018)	Detecção de outliers e seleção de atributos	DT, RF, SVM (KDD-Cup99, NSL-KDD)	Modelos clássicos sem exploração multidomínio; restrito a datasets legados com tráfego sintético.
Sarhan et al. (2021); Sarhan, Layeghy & Portmann (2022)	Padronização de atributos para fluxos NetFlow	RF, NB, MLP (NF-UNSW-NB15, NF-CIC-IDS2018)	Foco exclusivo em atributos estatísticos agregados; não modela dinâmicas temporais e espectrais.
Abreu & Abelém (2022)	Sistema híbrido e em tempo real para redes	Limiar estatístico + DT/RF (Tráfego real e bases públicas)	Elevada dependência de limiares determinísticos; perda de precisão em ameaças complexas.
Guadarrama et al. (2025)	Estudo comparativo exaustivo de NIDS em fluxo	DT, RF, XGBoost, MLP (CSE-CIC-IDS2018, UNSW-NB15)	Arquiteturas homogêneas; degradação acentuada em classes com desbalanceamento extremo.
Dari et al. (2024)	Análise comparativa de redes profundas	CNN, RNN, DNN isoladas (Bases públicas de intrusão)	Ausência de fusão estruturada; nenhum modelo homogêneo dominou todas as categorias de ataque.
Oliveira, Gonçalves & Filho (2025)	Aprendizado Federado para NIDS corporativo	DNN homogênea federada (CSE-CIC-IDS2018)	Foco na descentralização; classificador local não contempla representação em múltiplos domínios.
Sasi et al. (2025)	Rede híbrida com autoatenção para IoT	1D-CNN-LSTM + Atenção (Edge-IIoTset, CICIoT2023)	Alta complexidade quadrática da autoatenção; inviável sob tráfego contínuo em alta vazão.

Continua na próxima página

Tabela 1 – Continuação da página anterior

Trabalho / Referência	Metodologia / Paradigma	Modelos / Datasets	Limitações Identificadas
Silva (2025)	Autoencoder semi-supervisionado e ensemble	HSAE + Comitê de votação (CSE-CIC-IDS2018, NSL-KDD)	Fusão tardia por votação estática; não aprende ponderações adaptativas de acordo com o contexto.
Borgioli et al. (2024)	Autoencoder Convolutacional em sistemas embarcados	1D-CAE não supervisionado (CIC-IDS2017, Modbus)	Restrito à classificação binária (anomalia vs normal); ausência de diagnóstico multiclasse.
Yang et al. (2025)	Mixture of Experts para detecção de falhas	MoE condicional com Gating (Bases de código C/C++)	Domínio de código estático; não se aplica a fluxos contínuos de pacotes em redes de dados.
He, Fu & Zhang (2026)	MoE para classificação de tráfego cifrado	MoE heterogêneo + Gating (ISCX VPN, Tráfego QUIC)	Foco na identificação de aplicações benignas cifradas; não avaliado sob ataques cibernéticos.
Chandroth, Stoian & Danciulescu (2026)	MoE com fusão atencional aprendível (ALF)	5 Especialistas (DNN, CNN, GRU, CAE, LSTM) + ALF (ISCX VPN, Unicauca)	Validado apenas em classificação de tráfego de aplicações em lote; sem validação para NIDS e streaming.
Esta Tese (ALF-MoE NIDS)	ALF-MoE Multidomínio com Mitigação Ativa	5 Especialistas + ALF + Gating calibrado + NFStream (CSE-CIC-IDS2018, CIC-BCCC-2024, UNSW-NB15)	Supera as limitações anteriores: opera em streaming de baixa latência, robusto a desbalanceamento extremo e validado contra agentes conduzidos por LLMs.

Fonte: Elaborado pelo autor (2026).

A fundamentação teórica e o mapeamento dos trabalhos correlatos expostos neste capítulo demonstram que a arquitetura ALF-MoE reúne os alicerces analíticos indispensáveis para superar os limites evidenciados na literatura. Ao segmentar a inspeção do tráfego em quatro perspectivas especializadas (tabular estática, morfológica espacial, sequencial temporal e harmônica espectral) coordenadas por uma rede de roteamento calibrada e um módulo de fusão atencional aprendível, estabelece-se a base

teórico-conceitual necessária para a formulação metodológica descrita no capítulo subsequente.

3 MATERIAIS E METODOLOGIA

3.1 DATASETS UTILIZADOS

A concepção, o treinamento e a validação empírica de Sistemas de Detecção de Intrusão em Redes (*Network Intrusion Detection Systems* – NIDS) orientados a Aprendizado de Máquina e Aprendizado Profundo são diretamente condicionados pela qualidade, diversidade e representatividade dos conjuntos de dados empregados (Sarhan; Layeghy; Portmann, 2022; Sarhan et al., 2021). Historicamente, a comunidade de segurança da informação recorreu a bases públicas pioneiras, tais como DARPA 98, KDD Cup 99 e NSL-KDD. Não obstante a sua importância histórica, tais bases tornaram-se anacrônicas face às transformações da Internet moderna: exibem tráfego artificial gerado em ambientes desprovidos de ruído operacional humano, não contemplam protocolos de transporte criptografados e contêm distribuições estatísticas de pacotes que não reproduzem a complexidade e a volumetria das ameaças contemporâneas (Sharafaldin; Lashkari; Ghorbani, 2018; Guadarrama et al., 2025).

Com o intuito de superar tais deficiências metodológicas e assegurar que os modelos avaliados operem sob condições operacionais fidedignas, este trabalho adota o paradigma de análise fundamentado em fluxos de rede bidirecionais (*bidirectional network flows*). Formalmente, um fluxo de rede $\mathcal{F}$ é definido como uma sequência temporal de pacotes de dados transmitidos entre dois pontos terminais ao longo de um canal de comunicação, unicamente indexados pela tupla quártupla de cabeçalho L3/L4 (*5-tuple*):

$$\mathcal{F} = \langle IP_{\text{orig}}, Port_{\text{orig}}, IP_{\text{dest}}, Port_{\text{dest}}, Prot \rangle, \quad (1)$$

em que IP_{orig} e IP_{dest} denotam os endereços de Protocolo de Internet (*Internet Protocol* – IP) de origem e destino, $Port_{\text{orig}}$ e $Port_{\text{dest}}$ correspondem às portas da camada de transporte (TCP ou UDP), e $Prot$ identifica o protocolo encapsulado ($Prot \in \{6 \text{ (TCP)}, 17 \text{ (UDP)}, \dots\}$).

A delimitação temporal de um fluxo é regida por duas variáveis fundamentais de controle:

1. **Tempo de Inatividade (*Idle Timeout* – τ_{idle}):** intervalo temporal máximo admissível de ausência de transmissão entre os interlocutores (comumente parametrizado em 120 s); caso superado, o fluxo é encerrado e exportado para sumarização estatística;
2. **Tempo Máximo Ativo (*Active Timeout* – τ_{active}):** limiar superior de duração total concedido a uma conexão contínua (tipicamente estabelecido em 1800 s); atingido esse limite, o fluxo é segmentado e consolidado para evitar a retenção indefinida de estados na memória volátil dos monitores de rede.

A partir do encerramento de um fluxo $\mathcal{F}$, ferramentas especializadas de extração estatística aplicam operadores de agregação sobre as distribuições de tempo, tamanho e sinalizadores, gerando um vetor de atributos numéricos $\mathbf{x} \in \mathbb{R}^D$:

$$\mathbf{x} = \phi(\mathcal{F}) = [f_1, f_2, \dots, f_D]^T, \quad (2)$$

sendo $\phi(\cdot)$ a função de mapeamento implementada pelo extrator de telemetria e D a dimensionalidade do vetor característico.

Neste trabalho, são selecionados três conjuntos de dados consolidados e complementares que cobrem diferentes espectros de tráfego, topologias e vetores de ameaça:

- **CSE-CIC-IDS2018:** referência consagrada para tráfego corporativo e ataques complexos distribuídos em infraestrutura de computação em nuvem;
- **CIC-BCCC-NRC-2024:** *benchmark* contemporâneo voltado a ambientes de Internet das Coisas (*Internet of Things* – IoT), protocolos leves de telemetria (MQTT) e variantes modernas de negação de serviço e botnets;
- **UNSW-NB15:** base de referência analítica contendo tráfego sintético e realístico de alta fidelidade gerado por hardware dedicado de emulação, com ampla diversidade de técnicas de exploração e evasão.

O Quadro 1 sintetiza as propriedades fundamentais, origens e características operacionais dos três conjuntos de dados analisados nesta pesquisa.

Quadro 1 – Síntese comparativa dos conjuntos de dados selecionados para treinamento e avaliação.

Dataset	Ano	Ambiente de Captura	Mecanismo de Geração	Atributos	Classes
CSE-CIC-IDS2018	2018	Nuvem AWS corporativa (5 departamentos e <i>server room</i>)	Agentes B-Profile (humanos) e M-Profiles (ataques)	80	15
CIC-BCCC-NRC-2024	2024	Laboratórios físicos e híbridos IoT/IoMT (IoTRL e UNB)	Dispositivos físicos/emulados, corretores MQTT e rotinas automatizadas	69	48
UNSW-NB15	2015	Cyber Range Lab (ACCS / UNSW Canberra)	Dispositivo IXIA PerfectStorm e tráfego realístico	66	10

Fonte: Elaborado pelo autor (2026).

3.1.1 CSE-CIC-IDS2018: Origem, Geração, Atributos e Distribuição Amostral

O conjunto de dados CSE-CIC-IDS2018 (*Communications Security Establishment & Canadian Institute for Cybersecurity*) foi desenvolvido mediante um projeto de cooperação técnica entre o instituto governamental canadense Communications Security Establishment e o Canadian Institute for Cybersecurity da University of New Brunswick (UNB) (Sharafaldin; Lashkari; Ghorbani, 2018). O objetivo do projeto consistiu na criação de um conjunto de dados de segurança cibernética em grande escala, hospedado publicamente na plataforma Amazon Web Services (AWS), que superasse as restrições de anonimização excessiva, volume diminuto e obsolescência de ameaças presentes em bases legadas.

3.1.1.1 Topologia e Infraestrutura de Rede

A concepção experimental do CSE-CIC-IDS2018 foi implementada integralmente em ambiente de computação em nuvem na AWS, compreendendo duas redes completamente apartadas: a Rede da Vítima (*Victim-Network*) e a Rede de Ataque (*Attack-Network*).

A *Victim-Network* replica a infraestrutura de uma organização corporativa de médio e grande porte, estruturada em cinco departamentos operacionais independentes conectados a uma sala de servidores (*Server Room*):

- **Controladora de Domínio e Infraestrutura Central:** servidor Windows Server 2016 desempenhando funções de Diretório Ativo (*Active Directory*), Servidor de Nomes de Domínio (DNS) e autenticação centralizada;
- **Servidores de Aplicação:** servidores com sistema operacional Ubuntu Linux (versões 12, 14.04 e 16.04) hospedando serviços web HTTP/HTTPS, bancos de dados relacionais e servidores FTP;
- **Estações de Trabalho Heterogêneas:** mais de 500 máquinas clientes conectadas à rede interna, englobando sistemas operacionais Windows 10, Windows 8.1, Windows 7, distribuições Linux e macOS;
- **Dispositivos de Interconexão:** firewalls corporativos (Fortinet) e switches de rede gerenciáveis configurados com espelhamento de portas (*port mirroring*) na interface do comutador principal, permitindo a gravação sem perdas de pacotes do tráfego bidirecional bruto em formato PCAP.

A *Attack-Network*, por sua vez, compreende uma sub-rede externa composta por cerca de 50 estações atacantes orquestradas externamente na AWS, operando distribuições Linux voltadas a testes de penetração (Kali Linux) e nós com Windows 8.1, provisionados com endereçamento IP público e conectividade direta com o perímetro de entrada da rede corporativa alvo.

3.1.1.2 Metodologia de Geração de Tráfego

Para mitigar a artificialidade observada em bases puramente simuladas, Sharafaldin, Lashkari & Ghorbani (2018) formalizaram uma metodologia de geração baseada em perfis comportamentais:

1. **B-Profile (*Benign Profile*):** agente de software desenvolvido em linguagem Java, encarregado de perfilar e modelar o comportamento abstrato de interações humanas de 25 perfis distintos de usuários reais. O agente B-Profile extrai propriedades estatísticas das requisições para os protocolos HTTP, HTTPS, FTP, SSH e serviços de correio eletrônico (SMTP, POP3 e IMAP), sintetizando variáveis como distribuição temporal entre requisições, tamanhos de carga útil, padrões de navegação e durações de sessão, reproduzindo um tráfego de fundo natural e não determinístico;
2. **M-Profile (*Malicious Profile*):** agentes programados dedicados à execução de rotinas estruturadas de ataque. A coleta de dados transcorreu durante dez dias úteis consecutivos em fevereiro de 2018, cobrindo sete cenários operacionais de agressão:
 - *Brute Force Attacks:* ataques automatizados de força bruta direcionados a serviços de acesso e autenticação remota (FTP e SSH);

- *Heartbleed Attack*: exploração da vulnerabilidade de leitura indevida de memória (*buffer over-read*) na extensão Heartbeat do protocolo TLS/OpenSSL;
- *Botnet Activity*: tráfego gerado por estações comprometidas pela botnet Ares, incluindo comunicação periódica de comando e controle e transferência de módulos auxiliares;
- *Denial of Service (DoS)*: saturação seletiva de recursos de servidores web mediante ataques volumétricos e de baixa cadência (*slow rate*), abrangendo DoS-Hulk, DoS-GoldenEye, DoS-SlowHTTPTest e DoS-Slowloris;
- *Distributed Denial of Service (DDoS)*: ataques distribuídos de negação de serviço orquestrados via múltiplas máquinas atacantes utilizando ferramentas como LOIC (*Low Orbit Ion Cannon*) em versões HTTP e UDP, e HOIC (*High Orbit Ion Cannon*);
- *Web Attacks*: injeção de comandos SQL (*SQL Injection*), scripts maliciosos em páginas web (*Cross-Site Scripting – XSS*) e ataques de força bruta contra formulários de autenticação web;
- *Infiltration Attack*: invasão estruturada em duas fases: na primeira etapa, uma máquina cliente interna é comprometida mediante engenharia social (download de documento PDF contendo código malicioso armazenado em pasta do serviço Dropbox) que estabelece uma porta dos fundos (*backdoor*) via Meterpreter/Metasploit; na segunda etapa, a partir da estação comprometida, os atacantes executam varreduras de mapeamento de rede (*IP sweeps*, varreduras de portas com Nmap) e enumeração de serviços (SMB, RDP, RPC) visando à movimentação lateral na rede interna.

3.1.1.3 Atributos Extraídos e Estrutura Tabular

A conversão dos arquivos PCAP brutos para o formato tabular foi executada por meio da ferramenta CICFlowMeter-V3 (Sharafaldin; Lashkari; Ghorbani, 2018), a qual inspeciona o fluxo bidirecional e calcula um total de 80 atributos estatísticos. Tais atributos compreendem:

- Estatísticas de duração da conexão e intervalos entre chegadas de pacotes (*Flow IAT*, *Fwd IAT*, *Bwd IAT*: valores mínimo, máximo, média e desvio padrão);
- Distribuições de tamanho de pacotes nas direções de avanço (*forward*) e retrocesso (*backward*);
- Métricas de taxas de transferência (*Flow Bytes/s*, *Flow Packets/s*);
- Contadores de sinalizadores do cabeçalho TCP (FIN, SYN, RST, PSH, ACK, URG, CWR, ECE);
- Comprimentos de cabeçalhos e tamanhos médios de segmentos;
- Métricas de janelas iniciais de recepção TCP (*Init Win Bytes*);
- Intervalos de atividade e inatividade estatística do canal (*Active* e *Idle*: mínimo, máximo, média e desvio padrão).

No pipeline de processamento integrado do modelo ALF-MoE, atributos constantes sem variância (como *Bwd PSH Flags* e taxas de rajada sem preenchimento) e variáveis redundantes com colinearidade

estrita foram expurgados, resultando em um vetor canônico de 62 atributos numéricos contínuos e discretos.

3.1.1.4 Estatísticas e Distribuição Amostral

O conjunto completo CSE-CIC-IDS2018 possui 16.232.943 fluxos de rede, sendo composto por 13.484.708 conexões benignas (83,07%) e 2.748.235 conexões maliciosas (16,93%) (Sarhan; Layeghy; Portmann, 2022). Na matriz experimental processada para os ensaios do modelo ALF-MoE (adotando uma partição estratificada de teste correspondente a 20% do conjunto total processado), totalizam-se 632.484 amostras de teste distribuídas em 15 classes distintas. A Tabela 2 detalha a distribuição das classes de tráfego, as categorias de ameaça e o quantitativo amostral correspondente.

Tabela 2 – Distribuição de classes e suporte amostral no benchmark CSE-CIC-IDS2018.

ID	Classe Canônica	Categoria de Ameaça	Amostras (Teste)	Proporção (%)
0	Benign	Tráfego Normal	136.285	21,55%
1	Botnet	Botnet Ares (C2)	56.873	8,99%
2	BruteForce-FTP	Força Bruta em Autenticação	38.603	6,10%
3	BruteForce-SSH	Força Bruta em Autenticação	37.790	5,97%
4	DDoS-HOIC	Negação de Serviço Distribuída	99.785	15,78%
5	DDoS-LOIC-HTTP	Negação de Serviço Distribuída	99.287	15,70%
6	DDoS-LOIC-UDP	Negação de Serviço Distribuída	345	0,05%
7	DoS-GoldenEye	Negação de Serviço (Exaustão)	8.210	1,30%
8	DoS-Hulk	Negação de Serviço (HTTP Flood)	92.260	14,59%
9	DoS-SlowHTTPTest	Negação de Serviço (Baixa Taxa)	28.048	4,43%
10	DoS-Slowloris	Negação de Serviço (Baixa Taxa)	2.238	0,35%
11	Infiltration	Movimentação Lateral e C2	32.570	5,15%
12	WebAttack-BruteForce_Web	Ataques a Aplicações Web	123	0,02%
13	WebAttack-BruteForce_XSS	Ataques a Aplicações Web	54	0,01%
14	WebAttack-SQL_Injection	Ataques a Aplicações Web	13	0,002%
Total de Instâncias Avaliadas			632.484	100,00%

Fonte: Elaborado pelo autor (2026), com base em Sharafaldin, Lashkari & Ghorbani (2018) e na documentação do projeto.

3.1.2 CIC-BCCC-NRC-2024: Origem, Geração, Atributos e Distribuição Amostral

A proliferação ubíqua de dispositivos conectados, redes de sensores sem fio e sistemas ciberfísicos ampliou substancialmente a superfície de ataque exposta a ações hostis em infraestruturas industriais e de Internet das Coisas (*Internet of Things* – IoT) (Neto et al., 2023). O tráfego gerado por ecossistemas IoT exhibe disparidades marcantes em comparação aos ambientes corporativos convencionais: caracteriza-se por mensagens assíncronas de telemetria de tamanho reduzido, protocolos de comunicação de baixa sobrecarga de cabeçalho (tais como MQTT e CoAP) e restrições energéticas e de processamento nos dispositivos de borda.

Diante dessas particularidades analíticas, o Canadian Institute for Cybersecurity (CIC), o Bell Centre for Cyber Security (BCCC) e o National Research Council Canada (NRC) desenvolveram uma iniciativa colaborativa para criar uma suíte unificada de bases de dados tabulares, designada *CIC-BCCC-NRC_TabularIoTAttack-2024* (Sasi et al., 2025).

3.1.2.1 Infraestrutura e Topologia do Banco de Testes

O ambiente físico e computacional que subsidiou a geração do CIC-BCCC-NRC-2024 integra os laboratórios *Internet of Things Research Lab* (IoTRL) do Army Cyber Institute e as bancadas de ensaio do CIC na University of New Brunswick (Sasi et al., 2025). A topologia abrange mais de 40 dispositivos terminais físicos e componentes virtuais distribuídos em múltiplos domínios funcionais:

- **Dispositivos de Automação Residencial e Comercial:** lâmpadas e tomadas inteligentes, termostatos digitais, sensores ambientais e câmeras de monitoramento IP comunicando-se via protocolos IEEE 802.11 (Wi-Fi), Zigbee, Z-Wave e Bluetooth Low Energy (BLE);
- **Concentradores e Plataformas de Orquestração:** aplicação de gerenciamento de automação centralizada (*Home Assistant*) integrada a comutadores inteligentes (Vera Plus), operando como pontes de tradução entre a rede sem fio dos sensores e a rede local cabeada;
- **Brokers e Mensageria IoT:** corretores do protocolo MQTT (*Message Queuing Telemetry Transport*) responsáveis pelo recebimento de tópicos de telemetria e sua disseminação para nós assinantes;
- **Monitoramento e Captura Transparente:** emprego de derivadores ópticos e elétricos de sinal (*network taps*) instalados entre os comutadores de borda e os gateways de saída, viabilizando a duplicação fidedigna de pacotes em tempo de execução via *dumpcap* e Wireshark sem introdução de latência ou perda na transmissão de dados.

3.1.2.2 Taxonomia dos Vetores de Ataque

O conjunto contempla uma ampla diversidade de ataques concebidos especificamente para explorar as vulnerabilidades intrínsecas aos protocolos leves e dispositivos embarcados, estruturados nas seguintes famílias operacionais (Sasi et al., 2025):

1. Ataques Específicos ao Protocolo MQTT:

- *MQTT Brute Force:* varredura exaustiva de credenciais e identificadores de cliente em serviços de mensageria;

- *MQTT DoS Connect Flood*: saturação das tabelas de conexão do corretor MQTT mediante rajadas ininterruptas de pacotes CONNECT;
- *MQTT DDoS Publish Flood*: sobrecarga nos canais de transmissão através da publicação descontrolada de tópicos volumosos em alta cadência;
- *MQTT Malformed*: injeção de pacotes com cabeçalhos corrompidos e formatos inválidos para desencadear falhas de descontinuidade no interpretador do intermediador (*broker*).

2. Inundações Volumétricas e Ataques com Fragmentação L3/L4:

- Inundações com sinalizadores TCP específicos: *ACK Flood*, *SYN Flood*, *DDoS TCP SYN Flood*, *DDoS PSHACK Flood* e *DDoS RSTFIN Flood*;
- Inundações baseadas em protocolos de transporte e controle: *DoS UDP Flood*, *DDoS UDP Flood*, *DoS ICMP Flood*, *DDoS ICMP Flood* e *DoS DNS Flood*;
- Ataques avançados de fragmentação: *DDoS ACK Fragmentation* e *DDoS ICMP Fragmentation*, os quais exploram lacunas na remontagem de datagramas pelos nós de roteamento para provocar sobrecarga de memória e esgotamento de tabelas de estado.

3. Botnets e Códigos Maliciosos IoT:

- Família Mirai: variantes ativas explorando dispositivos com credenciais padrão em portas Telnet/SSH, abrangendo *Mirai ACK Flood*, *Mirai HTTP Flood*, *Mirai Host Brute Force* e *Mirai UDP Plain*;
- *Ransomware* e *Backdoors*: códigos maliciosos direcionados ao sequestro e controle não autorizado de dispositivos embarcados.

4. Reconhecimento, Varredura e Identificação Operacional:

- Mapeamento ativo de topologia: *Recon Ping Sweep*, *Recon Host Discovery*;
- Sondagem de serviços e portas: *Port Scanning*, *Recon Port Scan*, *Scan Host Port* e *Scan UDP Attack*;
- Impressão digital de sistemas operacionais (*OS Fingerprinting*): *Recon OS Scan* e *Scan Port OS*;
- Varreduras automatizadas de vulnerabilidades: *Recon Vulnerability Scan*, *Vulnerability Scanner* e *Scan Aggressive*.

5. Ataques Man-in-the-Middle e Manipulação da Camada de Enlace:

- Envenenamento de tabelas ARP (*MITM ARP Spoofing*) e interceptação intermediária de fluxos não cifrados (*MITM*).

6. Ataques a Aplicações e Quebra de Credenciais:

- Ataques de dicionário e exaustão: *Sparta SSH Brute Force*, *Telnet Brute Force*, *Dictionary Brute Force* e *Password Attack*;
- Vulnerabilidades web e injeção: *SQL Injection*, *XSS (Cross-Site Scripting)* e *Uploading Attack*.

3.1.2.3 Atributos Extraídos e Distribuição Amostral

A conversão dos fluxos de tráfego seguiu a extração via versão estendida do CICFlowMeter otimizada para tráfego IoT, capturando dinâmicas de pacotes de tamanho reduzido e rajadas assíncronas. Após a sanitização e o descarte de identificadores diretos de rede (Flow ID, endereços IP, portas, marcas temporais e protocolos constantes), foram consolidados 69 atributos numéricos representativos.

O conjunto de dados agrega 48 classes granulares (nível de abstração 0), exibindo um volume avaliado no conjunto de teste de 588.930 amostras. O Quadro 2 agrupa as 48 classes em macro-famílias funcionais e detalha o quantitativo amostral observado no protocolo experimental da pesquisa.

Quadro 2 – Famílias funcionais, classes granulares e suporte amostral no CIC-BCCC-NRC-2024.

Macro-Família	Classes Granulares Incluídas	Amostras (Teste)	Proporção (%)
Tráfego Legítimo	Benign Traffic	47.453	8,06%
DDoS / DoS com Sinalizadores e Fragmentação	ACK Flood (38.856), DDoS PSHACK Flood (51.105), DDoS RSTFIN Flood (47.852), DDoS ACK Frag. (12.407), DDoS TCP SYN Flood (70), SYN Flood (43.651), DoS SYN Flood (14.630), DoS TCP Flood (50.711)	259.282	44,03%
DDoS / DoS Volumétrico (UDP, ICMP, DNS)	DDoS ICMP Flood (500), DDoS ICMP Frag. (1.872), DDoS UDP Flood (499), DoS UDP Flood (950), DoS ICMP Flood (682), DoS DNS Flood (334), DDoS HTTP Flood (3.005)	7.842	1,33%
Protocolos IoT (MQTT)	MQTT Brute Force (51.206), MQTT DDoS Publish Flood (21.282), MQTT DoS Connect Flood (24.921), MQTT DoS Publish Flood (190), MQTT Malformed (416)	98.015	16,64%
Botnet Mirai	Mirai ACK Flood (1.531), Mirai HTTP Flood (296), Mirai Host Brute Force (716), Mirai UDP Plain (299)	2.842	0,48%
Reconhecimento e Escaneamento	Port Scanning (26), Recon Port Scan (6.866), Recon Host Discovery (82), Recon Ping Sweep (2.830), Recon OS Scan (6.612), OS Fingerprinting (13), Scan Port OS (600), Scan Host Port (507), Scan UDP Attack (3.260), Scan Aggressive (1.411), Recon Vulnerability Scan (4.323), Vulnerability Scanner (833)	27.363	4,65%
Intercepção / MitM	MITM (2.746), MITM ARP Spoofing (3.112)	5.858	0,99%
Malware Avançado	Backdoor (5.912), Ransomware (3.203)	9.115	1,55%
Força Bruta e Autenticação	Sparta SSH Brute Force (49.269), Password Attack (26.257), Dictionary Brute Force (3.364), Telnet Brute Force (135)	79.025	13,42%
Ataques Web / Upload	SQL Injection (1.750), XSS (49.661), Uploading Attack (724)	52.135	8,85%
Total de Instâncias Avaliadas		588.930	100,00%

Fonte: Elaborado pelo autor (2026), com base em Sasi et al. (2025) e metadados de execução.

3.1.3 UNSW-NB15: Origem, Geração, Atributos e Distribuição Amostral

O conjunto de dados UNSW-NB15 foi concebido e disponibilizado em 2015 pelo *Cyber Range Lab* do *Australian Centre for Cyber Security* (ACCS), situado na Universidade de New South Wales (UNSW)

em Canberra, Austrália (Moustafa; Slay, 2015; Sarhan; Layeghy; Portmann, 2022). O propósito de sua criação consistiu na superação das deficiências técnicas das bases legadas KDD99 e NSL-KDD, provendo à comunidade acadêmica um repositório contemporâneo dotado de assinaturas de tráfego sintético combinadas a tráfego de fundo operacional realístico, acompanhado da carga útil (*payload*) completa dos pacotes.

3.1.3.1 Ambiente de Simulação e Infraestrutura de Captura

A produção do UNSW-NB15 baseou-se na plataforma de emulação de tráfego de alta densidade **IXIA PerfectStorm**, uma solução de hardware dedicada a testes de estresse e resiliência em equipamentos de rede corporativos e de missão crítica (Moustafa; Slay, 2015).

A arquitetura física do laboratório compreendeu:

- Dois servidores dedicados conectados à plataforma de emulação IXIA, responsáveis pela injeção coordenada de atividades benignas e vetores de exploração cibernética contemporâneos;
- Um terceiro servidor operando como nó roteador e receptor dos fluxos de tráfego cruzados;
- Segmentação de tráfego em canais Gigabit Ethernet através de switches gerenciáveis dotados de espelhamento transparente;
- Captura integral de pacotes via ferramenta `tcpdump`, operada em duas sessões contínuas: uma sessão de 16 horas em 22 de janeiro de 2015 e uma sessão complementar de 15 horas em 17 de fevereiro de 2015, totalizando aproximadamente 100 gigabytes de tráfego bruto compactado em formato PCAP.

3.1.3.2 Taxonomia das Classes de Ataque

O conjunto de dados abrange nove famílias consolidadas de ataques cibernéticos, além de uma classe dedicada ao tráfego legítimo (*Benign*) (Moustafa; Slay, 2015; Sarhan; Layeghy; Portmann, 2022):

1. **Fuzzers:** disparos massivos de mensagens com campos propositalmente corrompidos, comprimentos discrepantes ou dados pseudoaleatórios destinados a induzir falhas de segmentação, estouros de memória (*buffer overflow*) ou desvios inesperados na lógica de execução de programas receptores;
2. **Analysis:** procedimentos de sondagem e reconhecimento focados em serviços de aplicação e páginas web, tais como injeção de parâmetros em cabeçalhos HTTP, varreduras pontuais de diretórios e exploração de relatórios de erro para levantamento de falhas estruturais;
3. **Backdoors:** comunicações furtivas que visam estabelecer e manter portas dos fundos em sistemas previamente comprometidos, possibilitando acesso remoto privilegiado sem a necessidade de autenticação tradicional;
4. **Denial of Service (DoS):** tentativas deliberadas de esgotamento de recursos computacionais críticos (memória, núcleos de processamento ou largura de banda de rede) em servidores alvos, impedindo o atendimento de solicitações de clientes legítimos;

5. **Exploits:** execuções direcionadas de rotinas automatizadas que exploram vulnerabilidades documentadas em softwares, bibliotecas e sistemas operacionais (catalogadas sob identificadores CVE);
6. **Generic:** procedimentos de ataque genéricos que operam independentemente da implementação da aplicação alvo, tais como ataques criptográficos contra cifras de bloco e colisões induzidas em funções de dispersão (*hash*);
7. **Reconnaissance:** ações preliminares de varredura ativa (*scans*) e enumeração de topologia, destinadas a identificar portas abertas, versões de serviços e nós acessíveis na rede local;
8. **Shellcode:** injeções compactas de código de máquina binário em áreas vulneráveis de memória com o intuito de invocar uma linha de comando com privilégios de superusuário (*root shell*);
9. **Worms:** códigos maliciosos autônomos providos de mecanismos de replicação automática através da rede, os quais propagam cópias de si mesmos explorando portas de comunicação abertas em outros nós.

3.1.3.3 Espaço de Atributos e Alinhamento no ALF-MoE

Na versão original concebida por Moustafa & Slay (2015), a extração dos atributos a partir dos arquivos PCAP combinou as ferramentas de monitoramento de fluxo Argus e Bro-IDS (atualmente denominado Zeek), associadas a doze rotinas de agregação em linguagem SQL, totalizando 49 atributos divididos em cinco grupos funcionais:

- *Flow features* (4 atributos): tempos de início/fim e métricas fundamentais de identificação;
- *Basic features* (9 atributos): propriedades elementares de cabeçalho TCP/IP (protocolo, estado, contagens e tamanhos);
- *Content features* (8 atributos): características contextuais da carga útil (janelas TCP, profundidade HTTP, transferências FTP);
- *Time features* (9 atributos): intervalos IAT e taxas temporais de transferência;
- *Additional generated features* (19 atributos): variáveis de histórico relacional construídas sobre janelas deslizantes de 100 conexões e intervalos temporais de 100 segundos.

Com vistas a assegurar a consistência do modelo proposto e harmonizar o espaço de entrada entre os múltiplos especialistas da arquitetura ALF-MoE, este trabalho adota a versão do conjunto de dados alinhada ao padrão CICFlowMeter, designada *CIC-UNSW-NB15*. Por meio dessa extração, as conexões brutas dos PCAPs originais da UNSW são representadas pelas mesmas estatísticas de fluxo bidirecional empregadas nos demais benchmarks. Após a eliminação de constantes nulas e identificadores triviais, a base consolidou 66 atributos estatísticos contínuos.

3.1.3.4 Estatísticas e Distribuição Amostral

Em sua composição original integral, o UNSW-NB15 totaliza 2.540.044 fluxos de rede, sendo 2.218.761 instâncias benignas (87,35%) e 321.283 instâncias de ataque (12,65%) (Sarhan; Layeghy; Portmann, 2022). Para a realização dos ensaios de avaliação de generalização sob a versão CIC-UNSW-NB15, a partição estratificada de teste consolidou 19.858 amostras representativas abrangendo as dez classes. A Tabela 3 apresenta a distribuição detalhada de amostras, classes e proporções avaliadas.

Tabela 3 – Distribuição de classes e suporte amostral no benchmark CIC-UNSW-NB15.

ID	Classe	Descrição do Vetor de Ameaça	Amostras (Teste)	Proporção (%)
0	Analysis	Varreduras de portas e testes de injeção web	69	0,35%
1	Backdoor	Portas dos fundos e canais de acesso furtivo	87	0,44%
2	Benign	Conexões legítimas de rede corporativa	3.772	18,99%
3	DoS	Esgotamento e saturação de recursos computacionais	863	4,35%
4	Exploits	Exploração direcionada de vulnerabilidades de software	6.016	30,30%
5	Fuzzers	Pacotes malformados para indução de falhas e travamentos	5.332	26,85%
6	Generic	Colisões criptográficas e ataques genéricos de bloco	909	4,58%
7	Reconnaissance	Mapeamento de topologia e enumeração de serviços	2.364	11,90%
8	Shellcode	Payloads binários para obtenção de shell privilegiada	394	1,98%
9	Worms	Códigos maliciosos autorreplicáveis via rede	52	0,26%
Total de Instâncias Avaliadas			19.858	100,00%

Fonte: Elaborado pelo autor (2026), com base em Moustafa & Slay (2015) e relatórios do projeto.

3.2 PIPELINE DE PRÉ-PROCESSAMENTO E ENGENHARIA DE FEATURES

3.2.1 Seleção, Normalização e Codificação

3.2.2 Tratamento de Desbalanceamento de Classes

3.3 ARQUITETURA PROPOSTA: ALF-MOE

3.3.1 Visão Geral do Sistema e Fluxo de Dados

3.3.2 Modelos Especialistas (DNN, CNN, GRU, CAE, LSTM)

3.3.3 Gating Network

3.3.4 Mecanismo Attention-based Learnable Fusion (ALF)

3.4 PROTOCOLO EXPERIMENTAL DE TREINAMENTO E AVALIAÇÃO

3.4.1 Funções de Perda e Otimização

3.4.2 Métricas de Avaliação (Acurácia, Precision, Recall, F1-Score, Latência)

4 PIPELINE DE EXTRAÇÃO E AMBIENTE DE INFERÊNCIA

4.1 CAPTURA E PROCESSAMENTO DE TRÁFEGO

4.1.1 Extração com NFStream

4.1.2 Mapeamento e Alinhamento de Features (NFStream → CICFlowMeter)

4.2 SETUP DE INFERÊNCIA EM TEMPO REAL

4.2.1 Arquitetura do Ambiente de Execução

4.2.2 Cenários de Teste de Estresse (Benigno, Ataques Humanos e Agentes via LLM)

5 RESULTADOS E DISCUSSÃO

5.1 DESEMPENHO NOS DATASETS DE BENCHMARK (RESULTADOS OFFLINE)

5.1.1 Análise por Classe e Desempenho Global

5.1.2 Estudo de Ablação (Contribuição de cada especialista e do bloco ALF)

5.2 AVALIAÇÃO DA EXTRAÇÃO E INFERÊNCIA EM TRÁFEGO REAL/PCAPS

5.2.1 Impacto do Mapeamento NFStream → CICFlowMeter

5.2.2 Throughput, Latência e Consumo Computacional

5.3 AVALIAÇÃO SOB CENÁRIOS ADVERSARIAIS

5.3.1 Desempenho sob Tráfego Estritamente Benigno (Taxa de Falsos Positivos)

5.3.2 Robustez Contra Adversários Humanos

5.3.3 Robustez Contra Adversários Guiados por LLMs

6 CONCLUSÃO

6.1 SÍNTESE DO TRABALHO

6.2 LIMITAÇÕES IDENTIFICADAS

6.3 TRABALHOS FUTUROS

REFERÊNCIAS

- ABREU, D.; ABELÉM, A. Sistema híbrido e on-line de detecção e classificação de tráfego malicioso. **Anais do XL Simpósio Brasileiro de Redes de Computadores e Sistemas Distribuídos (SBRC 2022)**, Sociedade Brasileira de Computação, p. 322–335, 2022.
- AOUINI, Z.; PEKAR, A. Nfstream: A flexible network data analysis framework. **Computer Networks**, v. 204, p. 108719, 2022. ISSN 1389-1286. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1389128621005739>.
- BORGIOLO, N. et al. A convolutional autoencoder architecture for robust network intrusion detection in embedded systems. **Journal of Systems Architecture**, Elsevier BV, v. 156, p. 103283, 2024.
- CHANDROTH, J.; STOIAN, G.; DANCULESCU, D. Alf-moe: An attention-based learnable fusion of specialized expert networks for accurate traffic classification. **Mathematics**, MDPI AG, v. 14, n. 3, p. 525, 2026.
- CHEN, Y. et al. P4-nids: High-performance network monitoring and intrusion detection in p4. **Lecture Notes in Networks and Systems**, Springer Nature Switzerland, p. 355–373, 2025.
- DARI, S. S. et al. Neural networks and cyber resilience: Deep insights into ai architectures for robust security framework. **Journal of Electrical Systems**, Science Research Society, v. 19, n. 3, p. 78–95, 2024.
- DREYER, P. A. et al. **Estimating the Global Cost of Cyber Risk: Methodology and Examples**. [S.l.], 2018.
- FERRAZ, Á. L. R. et al. The procedural semantics gap in structured cti: A measurement-driven stix analysis for apt emulation. **arXiv preprint arXiv:2512.12078**, 2025.
- GUADARRAMA, J. C. M. et al. Advanced ids: a comparative study of datasets and machine learning algorithms for network flow-based intrusion detection systems. **Applied Intelligence**, 2025.
- GUO, C. et al. On calibration of modern neural networks. In: PMLR. **International Conference on Machine Learning (ICML)**. [S.l.], 2017. p. 1321–1330.
- HE, Q.; FU, X.; ZHANG, L. Trafficmoe: Heterogeneity-aware mixture of experts for encrypted traffic classification. **arXiv preprint arXiv:2603.29520**, 2026.
- JACOBS, R. A. et al. Adaptive mixtures of local experts. **Neural Computation**, MIT Press, v. 3, n. 1, p. 79–87, 1991.
- JADA, I.; MAYAYISE, T. O. The impact of artificial intelligence on organisational cyber security: An outcome of a systematic literature review. **Data and Information Management**, Elsevier BV, v. 8, n. 2, p. 100063, 2024.
- KAUR, D.; KAUR, P. Empirical analysis of web attacks. **Procedia Computer Science**, Elsevier BV, v. 78, p. 298–306, 2016.
- LIN, T.-Y. et al. Focal loss for dense object detection. In: **IEEE International Conference on Computer Vision (ICCV)**. [S.l.: s.n.], 2017. p. 2980–2988.
- LUAY, M. et al. Temporal analysis of netflow datasets for network intrusion detection systems. **arXiv preprint arXiv:2503.04404**, 2025.

- LUAY, M. et al. Time matters: Temporal netflow features for ml-based network intrusion detection. **IEEE Access**, Institute of Electrical and Electronics Engineers (IEEE), v. 14, p. 66899–66913, 2026.
- MACIÁ-FERNÁNDEZ, G. et al. Ugr‘16: A new dataset for the evaluation of cyclostationarity-based network idss. **Computers & Security**, Elsevier BV, v. 73, p. 411–424, 2018.
- MOUSTAFA, N.; SLAY, J. Unsw-nb15: a comprehensive data set for network intrusion detection systems (unsw-nb15 network data set). In: IEEE. **2015 Military Communications and Information Systems Conference (MilCIS)**. [S.l.], 2015. p. 1–6.
- NETO, E. C. P. et al. Ciciot2023: A real-time dataset and benchmark for large-scale attacks in iot environment. **Sensors**, MDPI AG, v. 23, n. 13, p. 5941, 2023.
- NOOR, M. H. M.; IGE, A. O. A survey on state-of-the-art deep learning applications and challenges. **Engineering Applications of Artificial Intelligence**, Elsevier BV, v. 159, p. 111225, 2025.
- OLIVEIRA, J. A. de; GONÇALVES, V. P.; FILHO, G. P. R. F-nids: Sistema de detecção de intrusão baseado em aprendizado federado. **Anais Estendidos do XLIII Simpósio Brasileiro de Redes de Computadores e Sistemas Distribuídos (SBRC 2025)**, Sociedade Brasileira de Computação - SBC, p. 212–221, 2025.
- ORBINATO, V. et al. Laccolith: Hypervisor-based adversary emulation with anti-detection. **IEEE Transactions on Dependable and Secure Computing**, Institute of Electrical and Electronics Engineers (IEEE), v. 21, n. 6, p. 5374–5387, 2024.
- PHAN, T. V.; NGUYEN, T. G.; BAUSCHERT, T. Deepstage: Learning autonomous defense policies against multi-stage apt campaigns. **arXiv preprint arXiv:2603.16969**, 2026.
- SAINIS, N.; SRIVASTAVA, D.; SINGH, R. Feature classification and outlier detection to increased accuracy in intrusion detection system. **International Journal of Applied Engineering Research**, v. 13, n. 10, p. 7249–7255, 2018.
- SARHAN, M. et al. Netflow datasets for machine learning-based network intrusion detection systems. **Lecture Notes of the Institute for Computer Sciences, Social Informatics and Telecommunications Engineering**, Springer International Publishing, p. 117–135, 2021.
- SARHAN, M.; LAYEGHY, S.; PORTMANN, M. Towards a standard feature set for network intrusion detection system datasets. **Mobile Networks and Applications**, Springer Science and Business Media LLC, v. 27, n. 1, p. 357–370, 2022.
- SASI, T. et al. An efficient self attention-based 1d-cnn-lstm network for iot attack detection and identification using network traffic. **Journal of Information and Intelligence**, Elsevier, v. 3, n. 4, p. 375–400, 2025.
- SHARAFALDIN, I.; LASHKARI, A. H.; GHORBANI, A. A. Toward generating a new intrusion detection dataset and intrusion traffic characterization. In: **International Conference on Information Systems Security and Privacy**. [s.n.], 2018. Disponível em: <https://api.semanticscholar.org/CorpusID:4707749>.
- SHARIF, M. H. U. Web attacks analysis and mitigation techniques. **International Journal of Engineering Research & Technology (IJERT)**, v. 11, n. 02, 2022.
- SHAZEER, N. et al. Outrageously large neural networks: The sparsely-gated mixture-of-experts layer. In: **International Conference on Learning Representations (ICLR)**. [S.l.: s.n.], 2017. p. 1–19.
- SILVA, F. C. d. **HSAE: Um Autoencoder Híbrido Não Supervisionado para Detecção de Ataques Zero-Day e sua Extensão Ensemble**. 2025. Dissertação (Dissertação de Mestrado) — Universidade Federal de Pernambuco, 2025.

SOUZA, C. A. d. **Detecção e prevenção de intrusão em computação de nevoeiro e Internet das Coisas**. 2023. Tese (Tese de Doutorado) — Universidade Federal de Santa Catarina, 2023.

YANG, X. et al. One-for-all does not work! enhancing vulnerability detection by mixture-of-experts (moe). In: **Proceedings of the ACM on Software Engineering**. [S.l.]: Association for Computing Machinery (ACM), 2025. v. 2, n. FSE, p. 446–464.

ČENYS, A.; HORA, S. K.; GORANIN, N. Emulation-based dataset emuiot-vt for nids in iot systems. **Sensors**, MDPI AG, v. 25, n. 16, p. 5077, 2025.