UNIVERSIDADE ESTADUAL DE MATO GROSSO DO SUL - UEMS
Ciência da Computação – Unidade Universitária de Dourados

JOSÉ CARLOS DA SILVA FILHO

ALF-MoE:
Redes Especialistas com Fusão Aprendível Baseada em Atenção para Classificação de Ataques Cibernéticos

Dourados
2026

José Carlos da Silva Filho

ALF-MoE:
Redes Especialistas com Fusão Aprendível Baseada em Atenção para Classificação de Ataques Cibernéticos

Trabalho de Conclusão de Curso, apresentado à Universidade Estadual de Mato Grosso do Sul (UEMS), Ciência da Computação, Dourados, para obtenção do título de Bacharelem Ciência da Computação.

Orientador: Profº. Dr. Rubens Barbosa Filho

Dourados
2026

JOSÉ CARLOS DA SILVA FILHO

ALF-MOE:
Redes Especialistas com Fusão Aprendível Baseada em Atenção para Classificação de Ataques Cibernéticos

Trabalho de Conclusão de Curso apresentado à Universidade Estadual de Mato Grosso do Sul (UEMS), Ciência da Computação, Dourados, para obtenção do título de Bacharelem Ciência da Computação.

Data de defesa: 12/10/2026

BANCA EXAMINADORA

_____
Profº. Dr.Rubens Barbosa Filho
UEMS – Ciência da Computação – Unidade Universitária de Dourados

_____
Profº. Dr. André Chastel Lima
Universidade Estadual de Mato Grosso do Sul

_____
Profª. Dra. Glaucia Gabriel
Universidade Estadual de Mato Grosso do Sul

_____
Profª. Dra. Raquel Marcia Müller
Universidade Estadual de Mato Grosso do Sul

À todas as curiosas crianças adultas, que (re)encontraram seu propósito mesmo perdidos no labirinto da própria mente.

AGRADECIMENTOS

Agradeço, primeiramente, a Deus, cuja providência me sustentou mesmo nos momentos em que me senti distante. Obrigado por não me conceder fardo maior do que o que eu poderia carregar e por ser a força silenciosa que me manteve de pé. À Maria, Mãe de Deus, agradeço pelo acalento materno e zeloso; por ser meu refúgio nas horas de aflição, minha proteção contra as sombras e a clareza necessária nas madrugadas de questionamento e exaustão.

À minha mãe, Rosirei, que transformou a escassez que viveu em abundância de oportunidades para o meu futuro. Obrigado por responder a cada um dos meus "porquês" e por instigar a curiosidade que hoje me torna cientista; cresci desejando ser tão inteligente quanto você. Através do seu exemplo, aprendi que o esforço é a ponte para o impossível. Guardo com carinho a memória de acordarmos antes do raiar do sol para que você trabalhasse e, à noite, ainda estudasse — você me pedia desculpas por me levar às suas aulas, sem saber que para mim era o maior dos privilégios ver de perto a sua garra. Vi seus medos e incertezas, mas jamais a vi recuar. À mulher que multiplicou o pouco para que eu tivesse tudo, e que me ensinou que o caráter e o conhecimento são as únicas riquezas inalienáveis, dedico esta vitória.

À minha noiva, Maria Eduarda, a quem devo a doçura e a estabilidade desta conquista. Você foi muito mais que uma companheira; foi o porto seguro onde ancorei nos dias de tempestade. Em meio à lógica fria dos códigos e à pressão exaustiva da academia, seu amor foi a constante que me manteve íntegro. Obrigado por ser o fôlego e a paciência nos momentos em que o *burnout* tentou silenciar meu entusiasmo, e por ter a sabedoria de me impulsionar quando minhas próprias forças falhavam. Você não apenas esteve ao meu lado; você iluminou o caminho para que eu pudesse enxergar além das minhas limitações e exaustões. Obrigado por dividir o peso da jornada e multiplicar a alegria da chegada. Este diploma é apenas o prefácio de uma vida inteira que pretendo escrever ao seu lado. Amo você.

Ao meu psicólogo, Dr. Ricardo Tiosso Panassiol, por ser o guia que me auxiliou a encontrar o caminho de volta em meio ao caos da ansiedade generalizada e do *burnout*. Obrigado por me ensinar a reconstruir minha perspectiva e por fornecer as ferramentas de resiliência necessárias para enfrentar as adversidades. Sua atuação foi fundamental para que eu não apenas concluísse este trabalho, mas recuperasse a posse de mim mesmo.

Ao meu orientador, Prof. Dr. Rubens Barbosa Filho, expresso minha mais profunda admiração. Agradeço pela orientação técnica impecável, mas, acima de tudo, pelo impacto do seu exemplo. Jamais esquecerei o dia em que lhe apresentei um problema do *Beecrowd* que me desafiava há quatro anos; vê-lo demonstrar que o embasamento teórico — através da Transformada Rápida de Fourier — resolve o que a força bruta jamais alcançaria, foi um divisor de águas em minha formação. Obrigado por me mostrar que a excelência nasce da paixão pelo conhecimento. Você é a maior referência da excelência que pretendo possuir como profissional.

Aos meus "irmãos de guerra" do "Bonde do Óclin": Gustavo de Carvalho Brás Martins

Lopes (Gustavin), Leonardo Hirata (Hiratinha) e Luis Eduardo de Souza Vasconcelos (Louis). Nossa união transcendeu as salas de aula, tornando-se uma irmandade de apoio mútuo. Obrigado pelas horas intermináveis de algoritmos, pelos debates sobre cálculos e por tornarem o peso da graduação muito mais leve com sua lealdade e amizade.

Aos amigos Alexandre Arruda (Alê), Gabriel Fagá (Fagas) e Pedro Henrique Zaccaria (Z), Sizenando França e Felipe Vilhalva, agradeço pelos momentos de descontração e pelas pausas necessárias. Seja nas partidas de *Minecraft* ou nas conversas sem pressa. A jornada foi mais feliz por causa de vocês.

Aos mestres do Curso de Ciência da Computação da UEMS, cujas lições vão além dos livros. Em especial à Profa. Dra. Glaucia Gabriel, pela imensa empatia e humanidade demonstradas em meus momentos mais difíceis; ao Prof. Dr. André Chastel Lima, pela generosidade em compartilhar seu domínio sobre a Teoria dos Grafos. A dedicação de vocês é o que sustenta a qualidade desta instituição.

Por fim, agradeço à Universidade Estadual de Mato Grosso do Sul (UEMS) e ao Curso de Ciência da Computação, que me proporcionaram a base acadêmica necessária para a realização deste trabalho. Agradeço a todos os funcionários que, direta ou indiretamente, contribuíram para minha formação.

"Se você só fizer o que sabe, nunca será mais do que é agora."
Mestre Shifu – Kung Fu Panda 3 (2016)

RESUMO

Este trabalho investiga a adaptação da arquitetura ALF-MoE (*Attention-Based Learnable Fusion of Specialized Expert Networks*), originalmente proposta para a classificação de tráfego de aplicações, à detecção e classificação multiclasse de intrusões em redes de computadores. Sistemas de Detecção de Intrusão em Redes (NIDS) baseados em aprendizado profundo precisam lidar com tráfego estatisticamente heterogêneo, desbalanceamento severo de classes, erros de rotulação em bases públicas e a dificuldade de levar modelos treinados em lote para a inspeção em tempo real. O modelo combina o paradigma de Mistura de Especialistas (*Mixture of Experts*) a um bloco de fusão aprendível por atenção e distribui o vetor de até 73 atributos de fluxo entre cinco especialistas neurais: uma rede densa (K_{DNN}) para contadores globais e sinalizadores TCP/IP; uma rede convolucional 2D (K_{CNN}) para a distribuição de tamanhos de pacotes; duas redes recorrentes (K_{GRU} e K_{LSTM}) para intervalos entre chegadas e ciclos de atividade e inatividade; e um autoencoder convolucional 1D (K_{CAE}) que processa o fluxo completo no domínio da frequência e usa a perda de reconstrução como regularizador contra o colapso das representações latentes. Uma rede de roteamento (*Gating Network*) com refinamento atencional pondera as predições dos especialistas, e o conjunto é treinado com supervisão profunda e *Focal Loss* balanceada. A avaliação em quatro bases públicas (CIC-UNSW-NB15, CIC-BCCC-NRC-2024 e CSE-CIC-IDS2018 nas versões canônica e corrigida), em sete cenários experimentais, comparou a fusão aos cinco especialistas treinados isoladamente. O ALF-MoE superou o melhor especialista isolado em seis cenários e, no sétimo, obteve Macro F_1 equivalente ($0{,}8917$ contra $0{,}8928$) com acurácia superior. No CSE-CIC-IDS2018 Corrigido, alcançou $99{,}87\%$ de acurácia e Macro F_1-Score de $0{,}9623$ no nível granular (TL0), e $99{,}85\%$ de acurácia e Macro F_1 de $0{,}8917$ no nível consolidado (TL1). Os pesos de roteamento acompanharam a natureza do tráfego: a GRU recebeu $40{,}34\%$ da atenção média no tráfego IoT, o autoencoder liderou no CIC-UNSW-NB15 com $34{,}02\%$ e a rede densa liderou no tráfego corporativo, chegando a concentrar entre 40% e 51% dos pesos em ataques volumétricos e varreduras de portas. Em bancada física, com o extrator NFStream e um auditor SIEM em JSON Lines, a inferência unitária em GPU levou em média $54{,}23\,\mathrm{ms}$ por fluxo e não gerou falsos positivos sobre tráfego benigno após a calibração da lista de salvaguardas perimetrais. Conclui-se que a fusão atencional de especialistas é viável para a classificação multiclasse de intrusões sob desbalanceamento severo e que, em operação, a latência ponta a ponta depende sobretudo dos temporizadores de inatividade do extrator de fluxo, e não do custo da inferência neural.

Palavras-Chave: segurança de redes; sistemas de detecção de intrusão; aprendizado profundo; mistura de especialistas; mecanismos de atenção; telemetria em tempo real.

ABSTRACT

This work investigates the adaptation of the ALF-MoE architecture (Attention-Based Learnable Fusion of Specialized Expert Networks), originally proposed for application traffic classification, to multiclass intrusion detection and classification in computer networks. Deep-learning-based Network Intrusion Detection Systems (NIDS) must cope with statistically heterogeneous traffic, severe class imbalance, labeling errors in public datasets, and the difficulty of moving batch-trained models into real-time inspection. The model combines the Mixture of Experts paradigm with an attention-based learnable fusion block and distributes a vector of up to 73 flow features across five neural experts: a dense network (K_{DNN}) for global counters and TCP/IP flags; a 2D convolutional network (K_{CNN}) for packet size distributions; two recurrent networks (K_{GRU} and K_{LSTM}) for inter-arrival times and active/idle cycles; and a 1D convolutional autoencoder (K_{CAE}) that processes the full flow in the frequency domain and uses its reconstruction loss as a regularizer against latent representation collapse. A Gating Network with attention refinement weights the expert predictions, and the whole model is trained with deep supervision and class-balanced Focal Loss. The evaluation on four public datasets (CIC-UNSW-NB15, CIC-BCCC-NRC-2024, and the canonical and corrected versions of CSE-CIC-IDS2018), across seven experimental scenarios, compared the fusion against the five experts trained in isolation. ALF-MoE outperformed the best standalone expert in six scenarios and, in the seventh, reached an equivalent Macro F_1 (0.8917 versus 0.8928) with higher accuracy. On the corrected CSE-CIC-IDS2018, it achieved 99.87% accuracy and a Macro F_1-Score of 0.9623 at the fine-grained level (TL0), and 99.85% accuracy and a Macro F_1 of 0.8917 at the consolidated level (TL1). Routing weights followed the nature of the traffic: the GRU received 40.34% of the mean attention on IoT traffic, the autoencoder led on CIC-UNSW-NB15 with 34.02%, and the dense network led on enterprise traffic, concentrating between 40% and 51% of the weights on volumetric attacks and port scans. On a physical testbed with the NFStream extractor and a JSON Lines SIEM auditor, single-flow GPU inference took $54.23\,\mathrm{ms}$ on average and produced no false positives on benign traffic once the perimeter allowlist had been calibrated. The results indicate that attention-based fusion of experts is viable for multiclass intrusion classification under severe class imbalance and that, in operation, end-to-end latency depends mainly on the flow extractor's idle timers rather than on the cost of neural inference.

Keywords: network security; network intrusion detection systems; deep learning; mixture of experts; attention mechanisms; real-time telemetry.

LISTA DE ILUSTRAÇÕES

Figura 1 Macrovisão da Arquitetura ALF-MoE. 17
Figura 2 Distribuição populacional de classes e severo desbalanceamento amostral nos conjuntos de dados de referência (CIC-UNSW-NB15 e CSE-CIC-IDS2018). 19
Figura 3 Distribuição de classes da amostra estratificada do CSE-CIC-IDS2018 (Canônico): visão populacional completa (esquerda) e detalhamento do tráfego malicioso (direita). 43
Figura 4 Distribuição de classes da amostra do CSE-CIC-IDS2018 (Corrigido): visão populacional completa (esquerda) e detalhamento do tráfego malicioso (direita). 45
Figura 5 Distribuição de classes da amostra do CIC-UNSW-NB15: visão populacional completa (esquerda) e detalhamento do tráfego malicioso (direita). 45
Figura 6 Distribuição de classes no nível TL0 para o CIC-BCCC-NRC TabularIoTAttack-2024: comparação entre a população original e a amostragem estratificada por Hare-Niemeyer. 46
Figura 7 Distribuição de classes no nível TL1 para o CSE-CIC-IDS2018 (Corrigido): contagem e proporção em escala logarítmica (esquerda) e distribuição relativa em gráfico de rosca (direita). 47
Figura 8 Distribuição de classes no nível TL1 para o CIC-BCCC-NRC TabularIoTAttack-2024: comparação da distribuição relativa entre a população original e a amostra estratificada por Hare-Niemeyer. 48
Figura 9 Diagramas das topologias neurais dos modelos especialistas heterogêneos. 52
Figura 10 Topologia interna da Gating Network com refinamento atencional e compressão simétrica. 53
Figura 11 Topologia interna do módulo de fusão ALF (*Attention-based Learnable Fusion*). 54
Figura 12 Desempenho comparativo global do modelo ALF-MoE nos quatro conjuntos de dados no cenário granular (TL0). 64
Figura 13 Desempenho comparativo global do modelo ALF-MoE nos quatro conjuntos de dados no cenário consolidado (TL1). 65
Figura 14 Painel comparativo de matrizes de confusão normalizadas nos quatro cenários de avaliação. 67
Figura 15 Comparativo da distribuição média global de pesos da Gating Network nos quatro conjuntos de dados. 70
Figura 16 Distribuição dos pesos da Gating Network por classe no CSE-CIC-IDS2018 Corrigido. 71

LISTA DE TABELAS

Tabela 1 – Síntese comparativa entre trabalhos correlatos da literatura e a proposta desta tese. 38
Tabela 2 – Mapeamento funcional entre domínios de telemetria e subvetores de entrada. 50
Tabela 3 – Desempenho global consolidado do modelo ALF-MoE nos 7 cenários de benchmark. 64
Tabela 4 – Estudo comparativo: Macro F_1-Score e Acurácia dos especialistas individuais vs. ALF-MoE. 69
Tabela 5 – Comparativo metodológico e estatístico entre extratores de telemetria. . . . 73
Tabela 6 – Decomposição temporal e perfil de latência do pipeline de inferência em tempo real. 75

LISTA DE ABREVIATURAS E SIGLAS

DDoS	Ataque Distribuído de Negação de Serviço (*Distribuited Denial of Service*)
DoS	Ataque de Negação de Serviço (*Denial of Service*)
IoT	Internet das Coisas (*Internet of Things*)

LISTA DE SÍMBOLOS

α	Letra Grega Alfa
β	Letra grega Beta
γ	Letra grega Gama
e	Número de Euler
R$	Unidade monetária Brasileira (Real)

SUMÁRIO

1	**INTRODUÇÃO**	**16**
1.1	Contextualização e Motivação	16
1.2	Definição do Problema	17
1.3	Objetivos	19
1.3.1	**Objetivo Geral**	**19**
1.3.2	**Objetivos Específicos**	**19**
1.4	Principais Contribuições	20
1.5	Organização do Trabalho	21
2	**FUNDAMENTAÇÃO TEÓRICA E TRABALHOS CORRELATOS**	**23**
2.1	Ataques Cibernéticos e Sistemas de Detecção de Intrusão (NIDS)	23
2.1.1	**Taxonomia de Ataques de Rede**	**23**
2.1.2	**Métodos de Identificação e Mitigação**	**26**
2.1.2.1	Paradigmas de Detecção de Intrusão	26
2.1.2.2	Granularidade de Inspeção: DPI versus Análise Baseada em Fluxos	27
2.1.2.3	Mecanismos de Resposta e Mitigação	28
2.2	Aprendizado Profundo para Segurança de Redes	29
2.2.1	**Redes Convolucionais e Recorrentes (CNN, LSTM, GRU)**	**29**
2.2.1.1	Redes Neurais Convolucionais (CNN)	29
2.2.1.2	Redes Neurais Recorrentes e a Modelagem Temporal (LSTM e GRU)	30
2.2.1.2.1	*Long Short-Term Memory (LSTM):*	*30*
2.2.1.2.2	*Gated Recurrent Unit (GRU):*	*31*
2.2.2	**Redes Densas, Autoencoders e Análise Espectral**	**31**
2.2.2.1	Redes Neurais Totalmente Conectadas (DNN)	31
2.2.2.2	Autoencoders Convolucionais 1D (1D-CAE) e Processamento Espectral Integrado	31
2.2.3	**Mixture of Experts (MoE) e Mecanismos de Fusão Atencional**	**32**
2.2.3.1	Rede de Roteamento Dinâmico (Gating Network)	33
2.2.3.2	Mecanismo de Refinamento Atencional Aprendível (ALF)	34
2.2.4	**Tratamento de Desbalanceamento Extremo via Focal Loss**	**35**
2.3	Trabalhos Correlatos	35
2.3.1	**NIDS Baseados em Aprendizado Profundo**	**35**
2.3.2	**Abordagens Ensemble e Mixture of Experts em Cibersegurança**	**36**
2.3.3	**Síntese Comparativa**	**37**
3	**MATERIAIS E METODOLOGIA**	**41**

3.1 Datasets Utilizados . . . 41
3.2 Pré-processamento . . . 41
3.2.1 Agrupamento de Ameaças (*Threat Levels*) . . . 42
3.2.2 Distribuição Amostral . . . 43
3.2.2.1 CSE-CIC-IDS2018 – Canônica e Corrigida . . . 43
3.2.2.2 CIC-UNSW-NB15 . . . 45
3.2.2.3 CIC-BCCC-NRC TabularIoTAttack-2024 . . . 46
3.2.2.4 Meta-categorias (TL1) . . . 46
3.2.3 Normalização e Codificação . . . 48
3.3 Adaptação e Modelagem da Arquitetura ALF-MoE para NIDS . . . 49
3.3.1 Visão Geral do Sistema e Fluxo de Dados . . . 49
3.3.2 Modelos Especialistas Heterogêneos . . . 50
3.3.3 Gating Network com Refinamento Atencional . . . 51
3.3.4 Mecanismo Attention-based Learnable Fusion (ALF) . . . 53
3.3.5 Tratamento de Desbalanceamento de Classes . . . 54
3.4 Protocolo Experimental de Treinamento e Avaliação . . . 55
3.4.1 Funções de Perda e Otimização Multitarefa . . . 55
3.4.2 Métricas de Avaliação . . . 55
3.4.2.1 Métricas de Eficácia Estatística . . . 56
3.4.2.2 Métricas de Eficiência Computacional . . . 56

4 PIPELINE DE EXTRAÇÃO E AMBIENTE DE INFERÊNCIA . . . 58
4.1 Captura e Processamento de Tráfego . . . 58
4.1.1 Extração com NFStream . . . 58
4.1.2 Arquitetura de Concorrência e Contexto CUDA . . . 59
4.2 Setup de Inferência . . . 60
4.2.1 Arquitetura do Ambiente de Execução . . . 60
4.2.2 Subsistema de Auditoria Forense e Registro SIEM (*InferenceAuditor*) . . . 60
4.2.3 Síntese Operacional do Pipeline de Inferência . . . 61

5 RESULTADOS E DISCUSSÃO . . . 63
5.1 Desempenho nos Datasets de Benchmark (Resultados Offline) . . . 63
5.1.1 Análise por Classe e Desempenho Global . . . 63
5.1.1.1 Eixo 1: Impacto da Granularidade de Ameaças (TL0 vs. TL1) . . . 65
5.1.1.2 Eixo 2: Impacto da Sanitização Metodológica de Liu et al. (2022) no CSE-CIC-IDS2018 . . . 66
5.1.1.3 Eixo 3: Generalização em Tráfego de Alta Densidade (CIC-UNSW-NB15) . . . 66
5.1.2 Matrizes de Confusão Normalizadas . . . 67
5.1.3 Análise Comparativa dos Especialistas e do Bloco ALF . . . 68
5.1.4 Dinâmica de Roteamento e Atribuição de Pesos da Gating Network . . . 70

5.2 Avaliação da Extração e Inferência em Tráfego Real na Bancada Física . . . 72
5.2.1 Impacto do Mapeamento NFStream para o Padrão CICFlowMeter . . . 72
5.2.2 Vazão, Latência de Inferência e Consumo Computacional na GPU . . . 74
5.2.2.1 Métricas de Inferência no Regime Streaming Unitário 74
5.2.2.2 O Gargalo Estrutural da Latência Ponta a Ponta 74
5.2.3 Avaliação de Falsos Positivos em Tráfego Operacional e Salvaguardas . 76
5.2.3.1 Diagnóstico de Falsos Positivos e Calibração de Salvaguardas 76
5.3 Síntese Crítica e Cumprimento dos Objetivos 76

6 CONCLUSÃO 78
6.1 Síntese do Trabalho 78
6.2 Limitações Identificadas 79
6.3 Trabalhos Futuros 80

REFERÊNCIAS 82

1 INTRODUÇÃO

1.1 CONTEXTUALIZAÇÃO E MOTIVAÇÃO

A expansão das redes de computadores aumentou a interconexão de serviços em nuvem, sistemas corporativos e dispositivos autônomos. Esse crescimento ampliou a superfície exposta a incidentes cibernéticos (Dreyer et al., 2018), cujas perdas anuais alcançam trilhões de dólares em danos diretos, paradas operacionais e penalidades regulatórias (Jada; Mayayise, 2024).

Nesse ambiente, os Sistemas de Detecção de Intrusão em Redes (*Network Intrusion Detection Systems*, NIDS) formam uma camada essencial de defesa perimetral (Guadarrama et al., 2025; Chen et al., 2025). Historicamente, esses sistemas operavam por assinaturas e inspeção profunda de pacotes (*Deep Packet Inspection*, DPI), examinando portas fixas e o conteúdo bruto da carga útil (*payload*). Contudo, o uso generalizado de criptografia ponta a ponta (como TLS 1.3, HTTPS e DoH), redes privadas virtuais (VPN) e portas dinâmicas tornou os dados transmitidos opacos aos pontos de monitoramento (Sarhan; Layeghy; Portmann, 2022; He; Fu; Zhang, 2026), inviabilizando abordagens baseadas em DPI.

Diante dessa opacidade, a literatura convergiu para a análise comportamental de fluxos bidirecionais de rede (*network flows*) com Aprendizado de Máquina e Aprendizado Profundo (Noor; Ige, 2025; Dari et al., 2024). Essa abordagem apoia-se em métricas estatísticas e temporais dos cabeçalhos TCP/IP, incluindo duração da sessão, taxas de transferência, volumes direcionais de pacotes e bytes, intervalos entre chegadas (*Inter-Arrival Time*, IAT) e sinalizadores de controle.

A maioria dos classificadores propostos opera, contudo, sob representação homogênea (*single-view*) (Luay et al., 2026; Luay et al., 2025): empregam redes totalmente conectadas (DNN) para atributos tabulares, redes convolucionais (CNN) para correlações espaciais ou redes recorrentes (RNN) para dependências sequenciais. Esse recorte arquitetural restringe a detecção porque diferentes famílias de intrusão manifestam seus traços em domínios distintos (Neto et al., 2023; Maciá-Fernández et al., 2018). Ataques de negação de serviço (DoS/DDoS) causam anomalias volumétricas e picos de vazão; varreduras de portas geram dispersões espaciais de pacotes curtos entre vários destinos; botnets e canais de comando e controle (C2) operam com cadências temporais sutis no IAT; e abusos em aplicações web apresentam padrões periódicos capturáveis no domínio da frequência.

Modelos com perspectiva única perdem sensibilidade quando as características do ataque residem em domínios ignorados por sua arquitetura. O uso de comitês (*ensembles*) tenta atenuar esse problema (Silva, 2025; Yang et al., 2025), mas recorre frequentemente à fusão tardia estática por média simples ou votação majoritária (Chandroth; Stoian; Danciulescu, 2026). Esses esquemas tratam os domínios de forma desacoplada e não adaptam os pesos de cada classificador ao tráfego inspecionado (He; Fu; Zhang, 2026).

Para integrar domínios heterogêneos de forma dinâmica, Chandroth, Stoian & Danciulescu

(2026) propuseram o modelo ALF-MoE (*Attention-Based Learnable Fusion of Specialized Expert Networks*), fundamentado em Mistura de Especialistas (*Mixture of Experts*, MoE) (Jacobs et al., 1991; Shazeer et al., 2017). A arquitetura distribui a extração de representações entre cinco redes neurais dedicadas: uma DNN para atributos estatísticos tabulares e contadores de sinalizadores TCP; uma CNN para correlações espaciais no tamanho de pacotes; uma GRU para dinâmicas sequenciais de curto prazo no IAT; um autoencoder convolucional (CAE) para representações em frequência via janelamento Hann e transformada rápida de Fourier (RFFT); e uma LSTM para dependências temporais de longo prazo ao longo do fluxo.

A cooperação entre essas redes é coordenada por uma rede de roteamento (*Gating Network*) associada ao módulo de fusão aprendível baseada em atenção (ALF) (Chandroth; Stoian; Danciulescu, 2026). Como ilustrado em Figura 1, cada especialista avalia seu subespaço de atributos e gera predições preliminares por meio de uma ativação *softmax*. Em paralelo, a *Gating Network* inspeciona o vetor global do fluxo para calcular coeficientes contextuais de atenção, ponderando a combinação linear dos especialistas antes que a cabeça classificadora do módulo ALF consolide o julgamento final de probabilidade para a conexão.

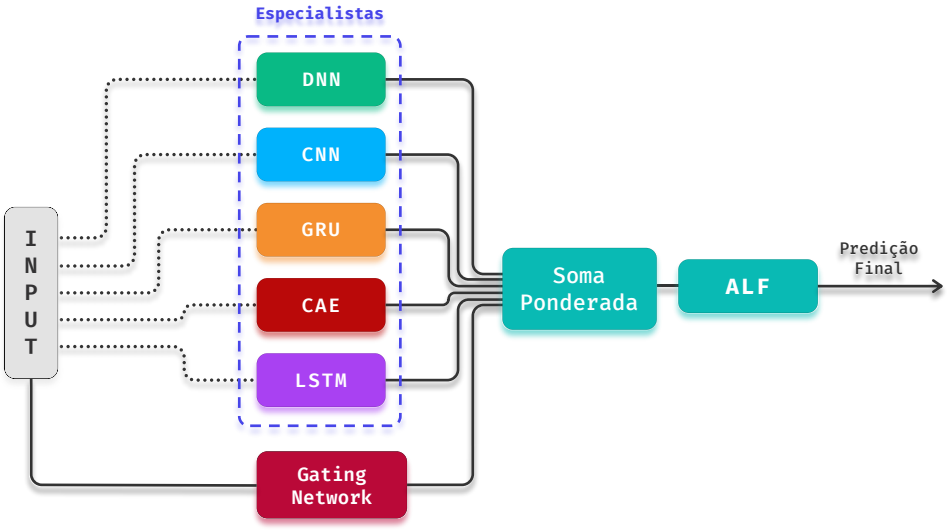


Figura 1 – Macrovisão da Arquitetura ALF-MoE.

Fonte: Elaborado pelo autor (2026), adaptado de Chandroth, Stoian & Danciulescu (2026).

1.2 DEFINIÇÃO DO PROBLEMA

Em relação aos promissores resultados obtidos no estudo original de Chandroth, Stoian & Danciulescu (2026), no qual o ALF-MoE alcançou acurácias superiores a 97% em tarefas de classificação de tráfego de aplicações e segregação de conexões VPN e não-VPN sobre bases como ISCX VPN-nonVPN, Unicauca e UNSW-IoTraffic, a transposição direta dessa arquitetura para o domínio dos Sistemas de Detecção de Intrusão em Redes (NIDS) multiclasse impõe desafios conceituais e metodológicos substanciais, os quais delimitam o problema investigado neste trabalho:

Em primeiro lugar, existe uma disparidade estrutural entre a classificação de aplicações e a identificação de ataques em redes operacionais. Em tarefas de classificação de aplicações, as instâncias distribuem-se de maneira comparativamente homogênea entre os rótulos de serviço, com fluxos contínuos e volumes amostrais estáveis. Em contrapartida, conjuntos de dados canônicos de referência em segurança cibernética — a exemplo de CSE-CIC-IDS2018 (Sharafaldin; Lashkari; Ghorbani, 2018) e CIC-UNSW-NB15 (Moustafa; Slay, 2015; Sarhan; Layeghy; Portmann, 2022) — exibem um desbalanceamento de classes extremo, como mostra a Figura Figura 2, que fornece o perfil populacional de classes dos datasets supracitados. Nesses cenários, o tráfego estritamente benigno perfaz entre 80% e mais de 97% do total de conexões observadas, enquanto categorias críticas de invasão (tais como *Infiltration*, *Botnets*, ataques web, *Shellcode* e *Worms*) compõem frações inferiores a 1% ou mesmo 0,1% do suporte amostral. Diante de assimetrias agudas, classificadores neurais padrão sofrem de viés sistemático em favor da classe majoritária, e as redes de roteamento correm o risco de colapso de especialistas (*expert collapse*), priorizando monotonicamente predições benignas. Determinar se a divisão em múltiplos especialistas e o roteamento atencional mantêm sua eficácia discriminatória e calibrada perante tal desbalanceamento constitui uma questão científica aberta.

Em segundo lugar, a caracterização de ameaças cibernéticas sob tráfego criptografado repousa exclusivamente sobre atributos estatísticos e comportamentais extraídos dos cabeçalhos dos fluxos (Sarhan; Layeghy; Portmann, 2022; He; Fu; Zhang, 2026). Contudo, diferentes categorias de intrusão manifestam suas assinaturas em domínios informacionais com correlações cruzadas complexas: ataques volumétricos manifestam-se no domínio estatístico global (Sarhan; Layeghy; Portmann, 2022); varreduras e mapeamentos atuam com dispersão espacial nas geometrias de pacotes (Wang; Houng; Lin, 2023); canais furtivos de persistência alteram dinâmicas sequenciais e temporais de curto prazo (Luay et al., 2026; Cao et al., 2022); e explorações com requisições repetitivas afetam densidades no domínio da frequência (Maciá-Fernández et al., 2018; Borgioli et al., 2024). A ausência de um particionamento formalmente fundamentado dos atributos de rede para alimentar redes neurais especializadas pode comprometer a capacidade de extração de representações discriminatórias por parte de cada especialista.

Em terceiro lugar, a avaliação de modelos de aprendizado profundo na literatura de NIDS frequentemente restringe-se a ensaios sobre uma única base de dados (Sarhan; Layeghy; Portmann, 2022; Guadarrama et al., 2025), omitindo a capacidade de adaptação da arquitetura perante ecossistemas computacionais com características de tráfego substancialmente divergentes. A generalização de uma arquitetura baseada em MoE exige a sua validação abrangente em cenários que compreendam desde infraestruturas corporativas em nuvem (CSE-CIC-IDS2018) até ambientes modernos de Internet das Coisas e telemetria leve (CIC-BCCC-NRC-2024) e ensaios com emulação de ataques avançados (CIC-UNSW-NB15).

Diante dessas constatações, o problema fundamental abordado neste trabalho pode ser formulado mediante a seguinte indagação científica: *Em que medida a arquitetura ALF-MoE, fundamentada no particionamento multidomínio de atributos de fluxo, em mecanismos de*

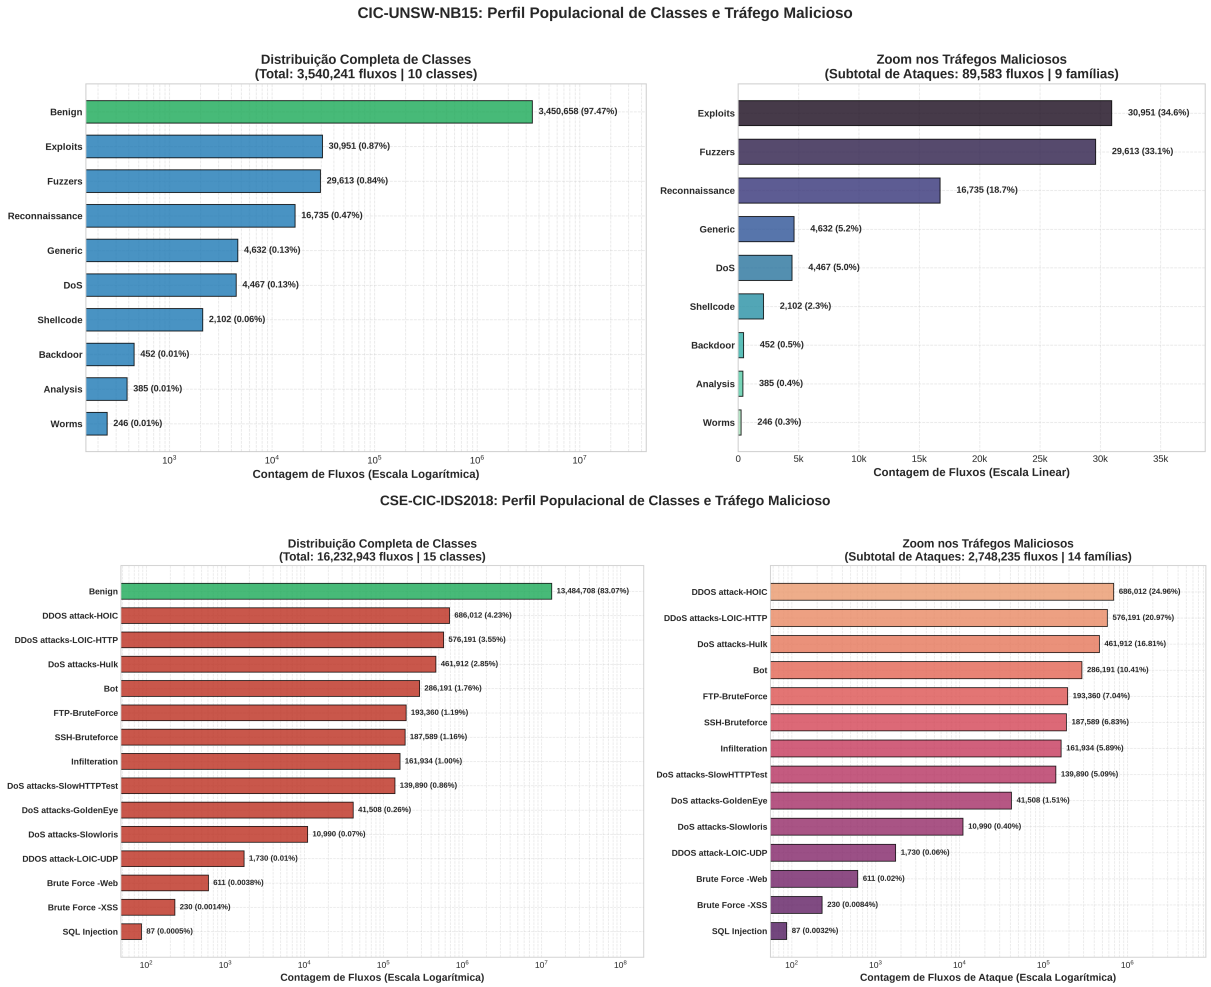


Figura 2 – Distribuição populacional de classes e severo desbalanceamento amostral nos conjuntos de dados de referência (CIC-UNSW-NB15 e CSE-CIC-IDS2018).

Fonte: Elaborado pelo autor (2026).

refinamento atencional na rede de roteamento e em estratégias de otimização sob supervisão profunda, é capaz de demonstrar aplicabilidade e superar modelos monolíticos e comitês convencionais de aprendizado na tarefa de detecção e classificação multiclasse de intrusões em redes de computadores sob condições de severo desbalanceamento de classes?

1.3 OBJETIVOS

1.3.1 Objetivo Geral

O objetivo geral deste trabalho consiste em verificar a viabilidade da arquitetura ALF-MoE, no contexto de classificação multiclasse de ataques cibernéticos.

1.3.2 Objetivos Específicos

Para viabilizar o cumprimento do objetivo geral, definem-se os seguintes objetivos específicos:

1. **Estruturar o pré-processamento e o particionamento multidomínio de atributos:** Implementar um fluxo sistemático de preparação de dados sobre conjuntos de referência em cibersegurança (CSE-CIC-IDS2018 em suas versões canônica e corrigida, CIC-BCCC-NRC-2024 e CIC-UNSW-NB15), contemplando higienização numérica (eliminação de valores infinitos e ausentes), remoção de atributos desprovidos de variância, normalização estatística robusta e mapeamento formal das variáveis nos cinco domínios especialistas: geral ($\mathbf{x}_g$), espacial ($\mathbf{x}_s$), variação temporal estatística ($\mathbf{x}_v$), espectral de frequência ($\mathbf{x}_f$) e dependências temporais longas ($\mathbf{x}_t$);

2. **Construir computacionalmente a arquitetura ALF-MoE e suas camadas dedicadas:** Implementar em código funcional os cinco modelos especialistas (DNN, CNN, GRU, CAE e LSTM), integrando-os à Rede de Roteamento Dinâmico (*Gating Network*), e ao bloco de Fusão Aprendível Baseada em Atenção (ALF);

3. **Formular a estratégia de treinamento supervisionado sob desbalanceamento severo:** Estruturar o protocolo de otimização conjunta do grafo computacional utilizando supervisão profunda (*deep supervision*) por meio de perdas auxiliares atribuídas a cada especialista e perda consolidada no módulo ALF, parametrizando a Perda Focal Multiclasse (*Focal Loss*);

4. **Conduzir avaliação comparativa frente a classificadores monolíticos especializados:** Mensurar o desempenho preditivo da arquitetura proposta em relação aos cinco modelos neurais monolíticos isolados (DNN, CNN, GRU, CAE e LSTM), adotando métricas rigorosas de desempenho multiclasse (Acurácia Global, Macro Precisão, Macro Sensibilidade e Macro F_1-Score), bem como métricas de eficiência computacional (latência por amostra e vazão de inferência);

5. **Realizar estudos comparativos dos especialistas e do bloco ALF:** Investigar o impacto individual de cada componente estrutural do modelo proposto, quantificando o ganho marginal proporcionado pelo módulo de fusão adaptativa ALF em comparação com cada especialista isolado;

6. **Avaliar a capacidade de generalização e interpretabilidade inter-dataset:** Analisar as matrizes de confusão e a capacidade de identificação de classes raras de ataque nos *benchmarks* avaliados, avaliando o comportamento e a distribuição dos pesos de atenção gerados pela *Gating Network* em resposta a diferentes famílias de intrusão cibernética.

1.4 PRINCIPAIS CONTRIBUIÇÕES

As principais contribuições teóricas, metodológicas e práticas proporcionadas por este trabalho compreendem:

1. **Adaptação e formalização da arquitetura ALF-MoE para detecção de intrusões multiclasse:** Demonstra-se a aplicabilidade e a eficácia da transposição do paradigma de Mistura de Especialistas com Fusão Aprendível por Atenção para a detecção de intrusões em redes, estabelecendo um esquema formal de particionamento em cinco domínios informacionais complementares a partir dos atributos do *CICFlowMeter*;

2. **Integração de refinamento atencional na Gating Network e formulação para dados desbalanceados:** Implementação funcional de um módulo de refinamento atencional dotado de estabilização logarítmica, projeção afim e limite não linear $\tanh$ na *Gating Network*, prevenindo o colapso e a extinção de especialistas, associado à otimização conjunta via *Focal Loss* multiclasse balanceada e supervisão profunda (*deep supervision*);

3. **Fusão por soma ponderada e cabeça classificatória profunda:** Concepção do módulo ALF operando estritamente sobre a combinação linear ponderada das predições de probabilidade dos especialistas ($z = \sum a_k \hat{y}^{(k)}$);

4. **Validação empírica abrangente em múltiplos benchmarks consolidados:** Condução de avaliação experimental sistemática sobre referências públicas heterogêneas de cibersegurança (CSE-CIC-IDS2018 Canônico e Corrigido, CIC-BCCC-NRC-2024 e CIC-UNSW-NB15) em sete configurações de teste, evidenciando a consistência da arquitetura frente a perfis operacionais de redes corporativas em nuvem, ambientes IoT com protocolos leves (MQTT) e emulação de ataques complexos;

5. **Análise comparativa dos especialistas e viabilidade de inferência em tempo real:** Comprovação experimental da superioridade sistemática da fusão adaptativa ALF sobre todos os especialistas isolados, associada à implementação de um pipeline de inferência em tempo real com NFStream capaz de processar fluxos com latência média de aproximadamente $54\,\mathrm{ms}$ na GPU e vazão superior a $80.000\,\mathrm{fluxos/s}$ em regime de lote.

1.5 ORGANIZAÇÃO DO TRABALHO

O presente documento está estruturado em seis capítulos, ordenados conforme o encadeamento a seguir:

- **Capítulo 1 – Introdução:** Apresenta a contextualização do problema de segurança cibernética e detecção de intrusões sob tráfego cifrado, a motivação para abordagens multidomínio de aprendizado profundo, a definição formal do problema, os objetivos geral e específicos, as principais contribuições alcançadas e a organização estrutural deste trabalho;

- **Capítulo 2 – Fundamentação Teórica e Trabalhos Correlatos:** Aborda a taxonomia das principais famílias de ataques cibernéticos em redes e os conceitos fundamentais

dos Sistemas de Detecção de Intrusão. Detalha a fundamentação teórica das redes neurais profundas especializadas (DNN, CNN, GRU, CAE e LSTM), a teoria de Mistura de Especialistas (MoE), os mecanismos de atenção e as funções de perda para dados desbalanceados. Conclui com uma revisão crítica da literatura recente de NIDS e fusão de modelos;

- **Capítulo 3 – Materiais e Metodologia:** Descreve os conjuntos de dados de referência adotados como *benchmark* (CSE-CIC-IDS2018 Canônico e Corrigido, CIC-BCCC-NRC-2024 e CIC-UNSW-NB15) e o pipeline de pré-processamento e particionamento dos atributos nos cinco domínios especialistas. Especifica a arquitetura formal do modelo ALF-MoE (redes especialistas, *Gating Network* e bloco de fusão ALF), bem como o protocolo experimental de treinamento com supervisão profunda e as métricas estatísticas e computacionais formais de avaliação;

- **Capítulo 4 – Pipeline de Extração e Ambiente de Inferência:** Aborda os aspectos de engenharia de software e telemetria de tráfego baseada no *framework* NFStream, o alinhamento de atributos de rede, o padrão produtor-consumidor para estabilidade de contexto de GPU e a arquitetura do ambiente de execução para inferência em tempo real;

- **Capítulo 5 – Resultados e Discussão:** Expõe a análise comparativa de desempenho discriminativo da arquitetura ALF-MoE nos conjuntos de dados avaliados, acompanhada por análise comparativa detalhada dos especialistas e do bloco ALF, justificativa estatística das matrizes de confusão e avaliação de latência e vazão computacional da inferência em tempo real;

- **Capítulo 6 – Conclusão:** Sintetiza as principais deduções e conclusões obtidas pela pesquisa, discute as limitações metodológicas e operacionais do trabalho e elenca direcionamentos para a realização de pesquisas futuras.

2 FUNDAMENTAÇÃO TEÓRICA E TRABALHOS CORRELATOS

2.1 ATAQUES CIBERNÉTICOS E SISTEMAS DE DETECÇÃO DE INTRUSÃO (NIDS)

A evolução contínua das infraestruturas de telecomunicações e a crescente sofisticação dos vetores de ameaça transformaram a segurança cibernética em um dos pilares mais críticos da sociedade contemporânea. Em redes computacionais corporativas, governamentais e industriais, os dados trafegam por meio de pilhas protocolares complexas, sujeitas a vulnerabilidades de implementação, desvios operacionais e ataques intencionais orientados à degradação de serviços ou à exfiltração de informações confidenciais (Dreyer et al., 2018; Jada; Mayayise, 2024). Nesse cenário de risco permanente, a defesa em profundidade (*defense-in-depth*) consolida-se como a arquitetura padrão para resguardar ativos estratégicos, na qual os Sistemas de Detecção de Intrusão em Redes (*Network Intrusion Detection Systems* – NIDS) atuam como uma camada fundamental de vigilância contínua e telemetria analítica (Guadarrama et al., 2025; Chen et al., 2025).

Diferentemente dos dispositivos de filtragem perimetral clássicos, como os *firewalls* tradicionais fundamentados em listas estáticas de controle de acesso (*Access Control Lists* – ACL), os NIDS dedicam-se à inspeção minuciosa dos pacotes que transitam pelos enlaces físicos e lógicos, buscando identificar anomalias estatísticas, padrões de varredura ou assinaturas de exploração de vulnerabilidades (Sarhan; Layeghy; Portmann, 2022). A modelagem analítica desse tráfego requer a compreensão estrutural das categorias de ataques que desafiam os ambientes operacionais, bem como das metodologias e limitações práticas das ferramentas voltadas à sua identificação e contenção.

2.1.1 Taxonomia de Ataques de Rede

A caracterização formal do tráfego malicioso demanda sua estratificação em taxonomias consolidadas pela comunidade científica e por centros internacionais de resposta a incidentes. A literatura técnica agrupa as ameaças de rede em classes comportamentais distintas com base no objetivo da intrusão, no volume de dados injetado, no protocolo explorado e na persistência temporal da ação maliciosa (Sharafaldin; Lashkari; Ghorbani, 2018; Sarhan; Layeghy; Portmann, 2022; Neto et al., 2023). Entre as principais classes de ataques mapeadas em ambientes contemporâneos, destacam-se:

1. **Negação de Serviço e Negação de Serviço Distribuída (*Denial of Service* – DoS / *Distributed Denial of Service* – DDoS):** Os ataques de negação de serviço têm como finalidade indisponibilizar um serviço, servidor ou infraestrutura de rede, exaurindo recursos computacionais finitos (como largura de banda, memória, capacidade de processamento ou

entradas em tabelas de estado do sistema operacional) (Sharafaldin; Lashkari; Ghorbani, 2018). Manifestam-se primordialmente sob três variantes:

- *Ataques Volumétricos:* baseiam-se na inundação maciça de pacotes (*packet flooding*) para congestionar fisicamente o canal de transmissão. Empregam comumente o protocolo UDP (*UDP Flood*), mensagens ICMP (*Ping Flood*) ou técnicas de reflexão e amplificação baseadas em protocolos de camada de aplicação desprotegidos, tais como DNS, NTP e SNMP. Nestes últimos, o atacante forja o endereço IP de origem (*IP spoofing*) para o endereço da vítima e requisita respostas desproporcionalmente maiores aos servidores de reflexão abertos (Neto et al., 2023);
- *Ataques de Esgotamento de Estado TCP:* exploram os mecanismos do aperto de mão de três vias (*three-way handshake*) do protocolo TCP. O expoente clássico é o *TCP SYN Flood*, em que o adversário envia rajadas massivas de pacotes de controle com o sinalizador SYN ativo, sem completar a conexão com o pacote ACK subsequente. Em consequência, a pilha de rede da vítima mantém conexões semiabertas na fila de conexões pendentes (*backlog queue*), esgotando as estruturas de alocação de memória (*Transmission Control Blocks* – TCB) e rejeitando requisições legítimas (Sharafaldin; Lashkari; Ghorbani, 2018);
- *Ataques de Baixa Vazão em Camada de Aplicação (L7 Low-and-Slow):* operam abaixo dos limiares de detecção volumétrica convencionais. Ferramentas como o *Slowloris* e o *R-U-Dead-Yet* (RUDY) abrem múltiplas conexões HTTP/HTTPS legítimas com o servidor web e enviam cabeçalhos ou corpos de requisição fragmentados a intervalos regulares extremamente lentos. Como o servidor reserva *threads* de processamento e conexões de soquete aguardando a finalização da mensagem HTTP, seu conjunto de conexões ativas é completamente saturado com consumo mínimo de largura de banda pelo atacante.

2. **Ataques de Varredura e Reconhecimento (*Port Scanning* e *Network Probing*):** Constituem a fase preliminar do ciclo de vida de uma intrusão, na qual o atacante mapeia a topologia do alvo, descobre estações ativas, identifica portas de transporte abertas e determina os sistemas operacionais e serviços em execução (*fingerprinting*) (Sarhan et al., 2021). Ferramentas automatizadas utilizam diversas técnicas de sondagem:

   - *SYN Stealth Scan (TCP Half-Open):* o scanner transmite um pacote SYN; caso o alvo responda com SYN-ACK (indicando porta aberta), o atacante envia imediatamente um pacote RST em vez de completar o aperto de mão com ACK, evitando o registro da conexão nos logs das aplicações da vítima;
   - *Scans Especiais (FIN, NULL e Xmas Scans):* exploram violações intencionais da especificação canônica da RFC 793. No *Xmas Scan*, os sinalizadores FIN, PSH e URG são ativados concomitantemente. Conforme o padrão TCP, portas fechadas

devem retornar um pacote RST, ao passo que portas abertas descartam a mensagem anômala sem resposta. Padrões desse tipo manifestam-se em atributos estatísticos de contagem de sinalizadores em fluxos agregados (Sarhan; Layeghy; Portmann, 2022).

3. **Ataques de Força Bruta (*Brute Force Attacks*):** Consistem na submissão sistemática e automatizada de extensas listas de credenciais de autenticação contra serviços administrativos e de transferência remota, tais como SSH (*Secure Shell*), FTP, RDP (*Remote Desktop Protocol*) e interfaces web de login (Sharafaldin; Lashkari; Ghorbani, 2018). No tráfego de rede, manifestam-se por sequências repetitivas de fluxos bidirecionais de curta duração, taxas de transferência moderadas e elevadíssima concentração temporal de tentativas consecutivas originadas de um único nó ou distribuídas por uma rede intermediária.

4. **Ataques a Aplicações Web e Injeção de Código:** Exploram falhas de sanitização e validação de parâmetros de entrada em servidores e aplicações web (Kaur; Kaur, 2016; Sharif, 2022). Entre as modalidades prevalentes documentadas nos conjuntos de dados de referência (como o CSE-CIC-IDS2018), incluem-se:

   - *Injeção de SQL (SQL Injection – SQLi):* inserção de fragmentos arbitrários de instruções SQL em formulários ou parâmetros HTTP GET/POST, contornando mecanismos de controle de acesso ou expondo registros confidenciais de bancos de dados (Kaur; Kaur, 2016);
   - *Cross-Site Scripting (XSS):* injeção de scripts maliciosos interpretados nos navegadores de usuários legítimos, possibilitando o sequestro de sessões autenticadas (*session hijacking*) e a interceptação de credenciais (Sharif, 2022);
   - *Injeção de Comandos de Sistema Operacional e Travessia de Diretórios (*Directory Traversal*):* manipulação de caminhos relativos (tais como `../../`) para acessar arquivos restritos do sistema hospedeiro ou invocar binários locais.

5. **Redes Zumbis (*Botnets*) e Canais de Comando e Controle (C2):** Uma *botnet* compreende uma rede distribuída de nós comprometidos (*bots*) subordinados a uma infraestrutura centralizada ou peer-to-peer (P2P) administrada por atacantes (Sharafaldin; Lashkari; Ghorbani, 2018). O tráfego característico reside nos canais de Comando e Controle (*Command and Control* – C2). Para manter a conectividade sem suscitar alertas nos mecanismos de segurança perimetrais, os canais C2 empregam técnicas de comunicação furtiva, tais como sinalização periódica com perturbação estocástica de tempo (*beaconing* com *jitter*), Algoritmos de Geração de Domínio (*Domain Generation Algorithms* – DGA), tunelamento em consultas DNS (*DNS Tunneling*) e encapsulamento em tráfego HTTPS padrão através da porta TCP 443 com certificados digitais válidos.

6. **Ameaças Avançadas Persistentes (APTs) e Infiltrações Multi-estágio:** Campanhas APT distinguem-se pelo elevado grau de sofisticação técnica, planejamento meticuloso e

atuação prolongada voltada a alvos institucionais de alto valor (Phan; Nguyen; Bauschert, 2026). As operações ofensivas estruturam-se segundo cadeias táticas formais, a exemplo do modelo *Cyber Kill Chain* e da matriz analítica MITRE ATT&CK (Ferraz et al., 2025).

O ciclo operacional multi-estágio abrange fases de reconhecimento, acesso inicial, estabelecimento de persistência, escalonamento local de privilégios, evasão de defesas, movimentação lateral na sub-rede corporativa, coleta e exfiltração de dados confidenciais (Phan; Nguyen; Bauschert, 2026; Orbinato et al., 2024). Durante a movimentação interna, os adversários empregam técnicas de *Living-off-the-Land* (LotL) e emulação adversarial avançada com módulos de anti-detecção (Orbinato et al., 2024). A identificação tempestiva dessas campanhas impõe imensa complexidade aos NIDS, uma vez que pacotes isolados exibem total conformidade sintática com os protocolos ordinários, tornando as dependências estatísticas e dinâmicas temporais de longo prazo a assinatura primordial para a detecção da anomalia (Ferraz et al., 2025).

2.1.2 Métodos de Identificação e Mitigação

A eficácia de uma postura defensiva em redes de computadores depende das estratégias de inspeção empregadas para avaliar o fluxo de informações e das ações automatizadas executadas quando uma ameaça é diagnosticada.

2.1.2.1 Paradigmas de Detecção de Intrusão

Historicamente, os sistemas de detecção de intrusão classificam-se em três paradigmas fundamentais (Guadarrama et al., 2025):

- **Detecção Baseada em Assinaturas (*Signature-Based Detection*):** Opera sob o princípio determinístico de que ameaças conhecidas manifestam padrões binários ou sintáticos invariantes no tráfego. O motor analítico compara o conteúdo dos pacotes com uma base de dados de regras padronizadas (a exemplo de Snort e Suricata), empregando casamento de padrões por sequências de bytes e expressões regulares.

  A vantagem primordial reside no processamento veloz e na taxa de falsos positivos virtualmente nula para ameaças catalogadas. Em contrapartida, sua deficiência intrínseca consiste na incapacidade absoluta de identificar ataques de dia zero (*zero-day*), variações polimórficas de código malicioso ou payloads submetidos a novas técnicas de ofuscação, demandando frequentes atualizações de regras (Borgioli et al., 2024).

- **Detecção Baseada em Anomalias (*Anomaly-Based Detection*):** Assume a premissa de que o tráfego hostil diverge de maneira quantificável do comportamento ordinário da rede. O classificador constrói um perfil de referência (*baseline*) que encapsula a operação legítima observada durante períodos estáveis. Amostras posteriores que apresentem discrepâncias estatísticas relevantes em relação a esse perfil são rotuladas como suspeitas.

Sua principal virtude reside na aptidão teórica para identificar ataques inéditos e anomalias não documentadas. Todavia, sua operacionalização prática confronta o desafio da elevada taxa de falsos positivos (*False Positive Rate* – FPR), causada pela volatilidade intrínseca do tráfego computacional, em que eventos operacionais ordinários (como manutenções programadas ou picos sazonais de acesso) podem ser incorretamente categorizados como intrusões (Guadarrama et al., 2025; Silva, 2025).

- **Detecção Baseada em Especificação ou Políticas (*Specification-Based*):** Prescreve um conjunto explícito de restrições lógicas e gramaticais que delimitam o comportamento estritamente permitido aos protocolos legítimos (como transições autorizadas na máquina de estados de uma sessão de transporte ou faixas limites de parâmetros em protocolos industriais SCADA). Qualquer violação às regras canônicas é reportada como evento hostil. Embora reduza falsos positivos sem exigir grandes históricos de dados, impõe custo expressivo de modelagem manual e não identifica ataques que operem em conformidade estrita com a sintaxe do protocolo.

2.1.2.2 Granularidade de Inspeção: DPI versus Análise Baseada em Fluxos

A viabilidade técnica e a escalabilidade dos NIDS são governadas pela camada e pela granularidade com que a inspeção do tráfego é conduzida:

- **Inspeção Profunda de Pacotes (*Deep Packet Inspection* – DPI):** A metodologia DPI reconstrói integralmente as sessões de transporte e decodifica a carga útil (*payload*) dos pacotes nas camadas superiores (como HTTP, DNS e SMTP). Não obstante o nível elevado de contextualização semântica, sua aplicabilidade prática foi drasticamente comprometida pela consolidação ubíqua de protocolos com cifragem ponta a ponta obrigatória – com destaque para o TLS 1.3, HTTPS, DNS sobre HTTPS (*DNS over HTTPS* – DoH) e redes privadas virtuais (*Virtual Private Networks* – VPN) (Sarhan; Layeghy; Portmann, 2022; He; Fu; Zhang, 2026). Sob cifragem contínua, o conteúdo das mensagens torna-se opaco aos nós intermediários de rede. Ademais, o custo computacional exigido para remontar fluxos e processar expressões regulares sobre a carga útil inviabiliza sua aplicação em enlaces modernos operando em taxas de 10, 40 ou 100 Gbps (Chen et al., 2025).

- **Análise Baseada em Fluxos de Rede (*Flow-Based Analysis*):** Como resposta às limitações da análise de carga útil sob tráfego cifrado, consolidou-se o monitoramento baseado em fluxos estatísticos de tráfego (*network flows*) (Sarhan et al., 2021; Aouini; Pekar, 2022). Formalmente, um fluxo IP $\mathcal{F}$ é conceituado como uma sequência ordenada de pacotes observada em um dado intervalo temporal que compartilha uma tupla canônica de identificação, tradicionalmente expressa pela tupla de cinco campos (*5-tuple*) $\mathcal{F}_{\text{id}} = \langle \text{IP}_{\text{src}}, \text{IP}_{\text{dst}}, \text{Port}_{\text{src}}, \text{Port}_{\text{dst}}, \text{Protocolo} \rangle$.

A partir desse agrupamento, extratores de telemetria (tais como NetFlow, IPFIX, CICFlowMeter e NFStream) derivam vetores estatísticos multidimensionais que descrevem a conexão (Sarhan; Layeghy; Portmann, 2022; Aouini; Pekar, 2022): contagens totais de pacotes e bytes por sentido, tempos entre chegadas consecutivas de pacotes (*Inter-Arrival Times* – IAT), parâmetros de dispersão do comprimento dos pacotes (médias, desvios padrão, variâncias), tempos de atividade (*active*) e inatividade (*idle*), e sinalizadores TCP acumulados. Esse paradigma preserva a privacidade dos dados transmitidos, opera de maneira independente da presença de criptografia no payload e viabiliza o processamento analítico escalável tanto em redes corporativas de grande escala quanto em topologias de computação em névoa (*fog computing*) e Internet das Coisas (*Internet of Things* – IoT) (Neto et al., 2023; Čenys; Hora; Goranin, 2025; Souza, 2023).

2.1.2.3 Mecanismos de Resposta e Mitigação

O diagnóstico emitido por um sistema de monitoramento só adquire efetividade defensiva prática quando acoplado a mecanismos operacionais de contenção (Guadarrama et al., 2025; Souza, 2023). A atuação divide-se em duas abordagens fundamentais:

- **Operação Passiva (NIDS):** o dispositivo é acoplado à rede de forma não disruptiva, por meio de portas espelho (*Switched Port Analyzer* – SPAN) ou acopladores físicos de sinal (*network TAP*) (Guadarrama et al., 2025). O sistema processa o tráfego de maneira assíncrona, despachando registros de alertas estruturados (em formatos como syslog, JSON ou CEF) para plataformas de Gerenciamento de Informações e Eventos de Segurança (*Security Information and Event Management* – SIEM) e plataformas de Orquestração, Automação e Resposta de Segurança (*Security Orchestration, Automation, and Response* – SOAR). Embora não adicione latência ao tráfego legítimo, essa abordagem não bloqueia intrusões em tempo real.
- **Operação Ativa (NIPS – *Network Intrusion Prevention System*):** o motor analítico atua diretamente na linha física ou lógica de comunicação (*inline*) ou integrado a elementos programáveis da camada de encaminhamento (Chen et al., 2025; Souza, 2023). Ao diagnosticar uma anomalia, o NIPS dispara medidas ativas de contenção imediata:
  - Descarte determinístico de pacotes associados ao fluxo malicioso (*packet dropping*);
  - Injeção de pacotes com o sinalizador TCP RST ativo direcionados aos extremos da conexão, provocando o término forçado e unilateral da sessão de transporte;
  - Atualização dinâmica de tabelas de filtragem no nível do kernel do sistema operacional (como `nftables` e conjuntos `ipset`), aplicando bloqueios temporais granulares sobre o endereço IP de origem;
  - Orquestração direta em planos de controle de Redes Definidas por Software (*Software-Defined Networking* – SDN) e em comutadores programáveis baseados no padrão P4,

viabilizando o redirecionamento para redes de isolamento (*honeynets*) ou aplicando políticas de descarte seletivo diretamente na taxa de transmissão da linha física (*line-rate processing*) (Chen et al., 2025).

2.2 APRENDIZADO PROFUNDO PARA SEGURANÇA DE REDES

A inadequação dos sistemas legados baseados em assinaturas perante a velocidade de mutação dos ataques contemporâneos impulsionou a adoção crescente de técnicas de Inteligência Artificial para a classificação analítica do tráfego (Noor; Ige, 2025; Dari et al., 2024). Inicialmente, as pesquisas concentraram-se em algoritmos clássicos de Aprendizado de Máquina (*Machine Learning* – ML), a exemplo de Máquinas de Vetores de Suporte (*Support Vector Machines* – SVM), Árvores de Decisão e comitês de Florestas Aleatórias (*Random Forest*) (Sainis; Srivastava; Singh, 2018). Todavia, esses modelos clássicos padecem de acentuada dependência de engenharia manual de atributos (*feature engineering*), registrando degradação de acurácia à medida que a dimensionalidade e o volume dos dados atingem a escala de enlaces industriais (Guadarrama et al., 2025).

Nesse contexto, o Aprendizado Profundo (*Deep Learning* – DL) estabeleceu-se como a abordagem metodológica central na segurança computacional moderna (Noor; Ige, 2025). Por intermédio de grafos computacionais constituídos por sucessivas transformações afins intercaladas por funções de ativação não lineares, os modelos profundos executam a extração automatizada de representações hierárquicas diretamente dos dados brutos ou de sumários de fluxo, mapeando correlações espaciais, dependências sequenciais e componentes espectrais determinantes da ação adversária (Luay et al., 2025; Luay et al., 2026).

2.2.1 Redes Convolucionais e Recorrentes (CNN, LSTM, GRU)

A modelagem estocástica do tráfego de rede abrange grandezas que variam tanto espacialmente (associações estruturais entre atributos de cabeçalho e métricas de volume) quanto sequencialmente (evolução cronológica das chegadas e tamanhos de pacotes). Famílias distintas de redes neurais foram estruturadas para atender a essas propriedades analíticas.

2.2.1.1 Redes Neurais Convolucionais (CNN)

Desenvolvidas originariamente para o processamento de arranjos multidimensionais, as Redes Neurais Convolucionais (*Convolutional Neural Networks* – CNN) baseiam-se em três princípios estruturais fundamentais: campos receptivos locais (*local receptive fields*), compartilhamento de parâmetros sinápticos (*weight sharing*) e invariância a pequenas translações espaciais (Noor; Ige, 2025). Na análise de segurança de rede, essas propriedades são exploradas mediante a aplicação de operações de convolução discreta (unidimensional ou bidimensional) sobre matrizes estruturadas de pacotes ou vetores de atributos de fluxo (Sarhan et al., 2021). Os

filtros convolucionais deslizam sobre a entrada projetando mapas de características que capturam correlações morfológicas locais entre atributos contíguos de cabeçalho e estatísticas de pacotes.

Para conferir capacidade de representação não linear sem incorrer na saturação prematura de gradientes (*dying ReLU problem*), o processamento é comumente intercalado por funções de ativação como a Unidade Linear Retificada com Gradiente Residual (*Leaky ReLU*) (Noor; Ige, 2025). Ademais, a estabilidade numérica e a aceleração da convergência entre camadas sucessivas são promovidas por técnicas de Normalização em Lote (*Batch Normalization*) (Noor; Ige, 2025), seguidas por operações de agrupamento (*Max Pooling*), que comprimem a dimensionalidade espacial preservando apenas as ativações dominantes em cada janela de observação. Dessa forma, em sistemas NIDS, os módulos convolucionais operam como detectores eficientes de padrões morfológicos locais, identificando dependências espaciais entre campos de transporte sem impor premissas estritas de linearidade global (Noor; Ige, 2025; Dari et al., 2024).

2.2.1.2 Redes Neurais Recorrentes e a Modelagem Temporal (LSTM e GRU)

Diversas manifestações de ataques – tais como canais de comando e controle com transmissão periódica, varreduras esparsas de portas e etapas graduais de infiltração – apresentam assinaturas distribuídas sequencialmente ao longo do tempo (Luay et al., 2025; Luay et al., 2026). Redes Neurais Recorrentes (*Recurrent Neural Networks* – RNN) mantêm um estado oculto recorrente $\mathbf{h}_t$, processando sequências temporais de forma cronológica recursiva.

Contudo, as variantes elementares de RNN enfrentam a limitação do desvanecimento ou explosão do gradiente (*vanishing and exploding gradients*) durante o processo de retropropagação através do tempo (*Backpropagation Through Time* – BPTT) (Noor; Ige, 2025). Quando o horizonte temporal abrange múltiplos passos T, o encadeamento sucessivo de derivadas no cálculo dos gradientes induz o decaimento exponencial a zero ou sua divergência numérica, impedindo o aprendizado de dependências remotas na sequência de tráfego.

Para contornar essa restrição, foram desenvolvidas arquiteturas fundamentadas em estruturas lógicas de controle denominadas portas (*gates*): a rede de Memória de Curto e Longo Prazo (*Long Short-Term Memory* – LSTM) e a Unidade Recorrente com Portas (*Gated Recurrent Unit* – GRU).

2.2.1.2.1 Long Short-Term Memory (LSTM):

A LSTM desacopla a preservação de contexto por intermédio de um vetor de estado celular $\mathbf{C}_t$, que viabiliza a propagação de gradientes aditivos ao longo de um canal linear de transporte (*error carousel*), evitando a atenuação exponencial observada em RNNs padrão (Noor; Ige, 2025; Luay et al., 2025). O trânsito de informações entre passos temporais sucessivos é modulado por três portas logísticas que operam sobre o vetor de entrada no instante atual e o estado oculto precedente: a *porta de esquecimento* (que estabelece a fração do histórico celular a ser descartada), a *porta de entrada* (que arbitra a magnitude com que as novas informações

atualizam o estado celular) e a *porta de saída* (que regula a exteriorização das ativações no estado oculto visível $\mathbf{h}_t$). Essa estrutura confere robustez para que o classificador retenha dependências temporais em horizontes cronológicos estendidos, tornando-se adequada para caracterizar padrões prolongados de atividade e inatividade do tráfego (Luay et al., 2025).

2.2.1.2.2 Gated Recurrent Unit (GRU):

Proposta como uma reformulação simplificada e computacionalmente mais econômica da LSTM, a rede GRU consolida o estado celular diretamente no estado oculto $\mathbf{h}_t$, eliminando a porta de saída independente (Noor; Ige, 2025; Luay et al., 2026). A arquitetura opera sobre duas portas de modulação: a *porta de atualização* (que pondera a conservação da memória anterior em relação à incorporação de novas ativações) e a *porta de redefinição* (que modula o grau de desconsideração do histórico anterior no cálculo do estado candidato). Por demandar menor quantidade de matrizes de parâmetros, a GRU exibe tempo de convergência reduzido e menor pegada computacional, apresentando excelente adequação à modelagem de dinâmicas transitórias e variações em intervalos entre chegadas consecutivas de pacotes (*Inter-Arrival Times* – IAT) (Luay et al., 2026).

2.2.2 Redes Densas, Autoencoders e Análise Espectral

A natureza heterogênea do tráfego de rede requer que atributos estáticos globais e manifestações harmônicas periódicas disponham de tratamentos algorítmicos especializados: transformações totalmente conectadas para sumários agregados e autoencoders acoplados ao processamento espectral para detecção de anomalias por erro de reconstrução.

2.2.2.1 Redes Neurais Totalmente Conectadas (DNN)

As Redes Neurais Profundas Totalmente Conectadas (*Dense Neural Networks* – DNN ou *Multilayer Perceptrons* – MLP) operam pelo encadeamento de transformações afins intercaladas por funções de ativação não lineares. Em sistemas NIDS, as camadas densas são primordiais para processar variáveis tabulares globais computadas ao longo de toda a sessão de transporte (tais como duração total do fluxo, contagem acumulada de pacotes e bytes por sentido e sinalizadores TCP acumulados), nas quais a contiguidade física ou temporal entre variáveis adjacentes não é mandatória (Guadarrama et al., 2025).

2.2.2.2 Autoencoders Convolucionais 1D (1D-CAE) e Processamento Espectral Integrado

O paradigma do Autoencoder (*Autoencoder* – AE) baseia-se no aprendizado não supervisionado ou semi-supervisionado de representações latentes comprimidas (Silva, 2025). A arquitetura típica é composta por duas estruturas acopladas: um codificador (*encoder*) $\mathcal{E}(\cdot)$, que mapeia o vetor de entrada para um espaço latente de baixa dimensionalidade $\mathbf{z}$, e um decodificador (*decoder*)

$\mathcal{D}(\cdot)$, encarregado de reconstruir a entrada original gerando $\tilde{\mathbf{x}}$. Treinado predominantemente com amostras de tráfego benigno, o modelo aprende a variedade geométrica subjacente à operação regular; fluxos intrusivos com propriedades anômalas não encontram suporte adequado nessa representação compacta, resultando em elevados erros de reconstrução $\|\mathbf{x} - \tilde{\mathbf{x}}\|^2$ (Silva, 2025; Borgioli et al., 2024).

Determinadas categorias de agressão cibernética – a exemplo de inundações pulsáteis periódicas (DDoS), varreduras programadas por temporizadores e canais de comando e controle (C2) com sinalização periódica (*beaconing*) – manifestam comportamentos que se destacam como frequências harmônicas bem delineadas no domínio da frequência (Maciá-Fernández et al., 2018). Para capturar essas características, o processamento espectral pode ser acoplado a autoencoders em três etapas analíticas fundamentais:

1. **Janelamento e Análise Espectral:** a aplicação de janelas temporais periódicas (tais como a Janela de Hann) atenua descontinuidades nas fronteiras do sinal e mitiga o espalhamento espectral (*spectral leakage*). Em seguida, a Transformada Rápida de Fourier Discreta para entradas reais (RFFT) mapeia o sinal temporal para um espectro unilateral de magnitude, isolando componentes de frequência característicos de tráfego volumétrico ou de repetição periódica;

2. **Codificação e Decodificação Latente:** o espectro de frequências obtido é processado por camadas convolucionais unidimensionais, cuja invariância a pequenas translações locais permite compactar as densidades espectrais em uma representação latente comprimida $\mathbf{z}$; subsequentemente, camadas de convolução transposta reconstroem a estimativa do espectro original;

3. **Avaliação da Regularidade Espectral por Reconstrução:** além da tarefa principal de classificação supervisionada, a preservação dos padrões harmônicos do tráfego é monitorada pela minimização do Erro Quadrático Médio (*Mean Squared Error* – MSE) entre o espectro original e o espectro reconstruído, penalizando distorções introduzidas por anomalias.

Essa fundamentação assegura que modelos híbridos capturem tanto assinaturas estatísticas diretas quanto propriedades oscilatórias inerentes a ataques contemporâneos (Borgioli et al., 2024).

2.2.3 Mixture of Experts (MoE) e Mecanismos de Fusão Atencional

O tráfego de redes contemporâneas exibe uma multiplicidade de padrões cujas manifestações diagnósticas concentram-se em subespaços analíticos distintos (Chandroth; Stoian; Danciulescu, 2026; He; Fu; Zhang, 2026). Modelos monolíticos homogêneos que forçam uma única topologia neural a contemplar correlações espaciais, dependências sequenciais e frequências harmônicas

simultaneamente sofrem do fenômeno de interferência negativa de gradientes (*negative gradient interference*), culminando em compromissos de representação subótimos (Yang et al., 2025).

O paradigma de Mistura de Especialistas (*Mixture of Experts* – MoE), formulado inicialmente por Jacobs et al. (1991) e expandido para grandes arquiteturas profundas por Shazeer et al. (2017), baseia-se na divisão modular de tarefas: em vez de um único classificador geral, emprega-se um conjunto de redes especialistas especializadas $\mathcal{E}_1, \mathcal{E}_2, \ldots, \mathcal{E}_K$, cuja contribuição individual para a inferência consolidada é arbitrada dinamicamente por uma Rede de Roteamento (*Gating Network*) parametrizada (Chandroth; Stoian; Danciulescu, 2026).

2.2.3.1 Rede de Roteamento Dinâmico (Gating Network)

A Gating Network atua como o módulo decisório da arquitetura MoE. Sua responsabilidade analítica consiste em examinar o contexto global de cada amostra de tráfego e computar dinamicamente uma distribuição de pesos sobre os K especialistas, quantificando a pertinência diagnóstica de cada perspectiva analítica para o fluxo sob análise (Chandroth; Stoian; Danciulescu, 2026).

Para garantir que a arbitragem dependa exclusivamente das características intrínsecas da conexão e viabilizar a inferência concorrente dos especialistas sem latência sequencial adicional, a entrada da rede de roteamento recebe diretamente o vetor tabular completo do fluxo $\mathbf{x} \in \mathbb{R}^F$. Após camadas densas intermediárias com normalização em lote (*Batch Normalization*), ativações LeakyReLU e regularização por Dropout, a rede infere uma distribuição preliminar de confiança $\boldsymbol{\alpha} = [\alpha_1, \ldots, \alpha_K]^\top \in \mathbb{R}^K$ por meio de uma função Softmax padrão:

$$\alpha_k = \frac{\exp(g_k)}{\sum_{j=1}^{K} \exp(g_j)}, \quad \forall k \in \{1, \ldots, K\}, \tag{1}$$

em que g_k denota o logit bruto gerado para o k-ésimo especialista (Chandroth; Stoian; Danciulescu, 2026).

Com o propósito de capturar correlações cruzadas entre especialistas e permitir que a relevância de cada modelo dependa do contexto do comitê como um todo, aplica-se uma camada de refinamento atencional no domínio logarítmico:

$$\mathbf{z}_{\text{refined}} = \mathbf{W}_g \ln(\boldsymbol{\alpha} + \epsilon) + \mathbf{b}_g, \tag{2}$$

em que $\mathbf{W}_g \in \mathbb{R}^{K \times K}$ e $\mathbf{b}_g \in \mathbb{R}^K$ são parâmetros aprendíveis e $\epsilon > 0$ é uma constante de estabilidade numérica. A projeção afim sobre o logaritmo das probabilidades atua de forma análoga a uma transformação de calibração afim multivariada (*matrix scaling*) (Guo et al., 2017), permitindo ao modelo aprender sinergias e compensações entre especialistas.

Para evitar que dispersões excessivas de magnitude saturem prematuramente o roteador em distribuições degeneradas (*winner-takes-all*) e assegurar a diversidade analítica do comitê, os

logits refinados são comprimidos pela função tangente hiperbólica:

$$\tilde{\mathbf{z}} = \tanh(\mathbf{z}_{\text{refined}}), \tag{3}$$

a qual restringe estritamente os valores ao intervalo $[-1, 1]$. Embasando-se nos princípios de calibração de redes neurais modernas de Guo et al. (2017), a distribuição atencional final $\mathbf{a} = [a_1, \ldots, a_K]^\top$ é normalizada por uma função Softmax com temperatura de calibração τ:

$$a_k = \frac{\exp(\tilde{z}_k/\tau)}{\sum_{j=1}^{K} \exp(\tilde{z}_j/\tau)}, \quad \forall k \in \{1, \ldots, K\}, \quad \text{satisfazendo} \quad \sum_{k=1}^{K} a_k = 1 \quad \text{e} \quad a_k > 0, \tag{4}$$

em que $\tau > 0$ atua como a temperatura de escalonamento. Conforme estabelecido por Guo et al. (2017), adota-se a temperatura neutra de calibração $\tau = 1{,}0$ durante o treinamento supervisionado conjunto da rede. A estabilização contra a descalibração e superconfiança de roteamento é garantida estruturalmente pela limitação de amplitude imposta pela função $\tanh$, assegurando que nenhum especialista tenha seu gradiente extinguido durante a convergência multitarefa.

2.2.3.2 Mecanismo de Refinamento Atencional Aprendível (ALF)

Diferentemente de abordagens ensemble convencionais fundamentadas em médias estáticas ou votação majoritária, o mecanismo ALF (*Attention-Based Learnable Fusion*) realiza a fusão adaptativa das decisões intermediárias mediada estritamente pela atenção contextual (Chandroth; Stoian; Danciulescu, 2026).

Apoiando-se nos pesos normalizados $\mathbf{a} = [a_1, \ldots, a_K]^\top$ fornecidos pela Gating Network, as distribuições probabilísticas preditas individualmente pelos K especialistas $\hat{\mathbf{y}}^{(k)} \in \mathbb{R}^C$ são consolidadas por meio de uma soma ponderada estrita:

$$\mathbf{Z} = \sum_{k=1}^{K} a_k \cdot \hat{\mathbf{y}}^{(k)}, \tag{5}$$

gerando o vetor latente fundido $\mathbf{Z} \in \mathbb{R}^C$. A ausência de conexões residuais diretas forçando a passagem de gradiente exclusivamente por $\mathbf{Z}$ assegura a coadaptação dinâmica da rede de roteamento e incentiva a genuína especialização funcional de cada especialista.

Subsequentemente, o vetor consensual $\mathbf{Z}$ é processado por camadas densas intermediárias de projeção com normalização em lote, ativações LeakyReLU e descarte aleatório (*Dropout*), sendo mapeado na camada de classificação global via função softmax:

$$\hat{\mathbf{y}}_{\text{ALF}} = \text{softmax}\left(\mathbf{W}_{\text{out}}\mathbf{h}_{\text{ALF}} + \mathbf{b}_{\text{out}}\right), \tag{6}$$

em que $\mathbf{h}_{\text{ALF}}$ representa a ativação latente expandida a partir de $\mathbf{Z}$, dotando a arquitetura da

flexibilidade necessária para discernir anomalias sutis sem perder a capacidade de generalização sobre o tráfego regular (Chandroth; Stoian; Danciulescu, 2026).

2.2.4 Tratamento de Desbalanceamento Extremo via Focal Loss

Conjuntos de dados de cibersegurança caracterizam-se por desbalanceamento severo de classes, em que o tráfego benigno frequentemente responde por mais de 90% das amostras, ao passo que ataques críticos (como *Infiltration*, *Web Attacks* e *Botnets*) representam frações inferiores a 1% do total coletado (Neto et al., 2023; Sarhan; Layeghy; Portmann, 2022). Nessas condições, a função convencional de Entropia Cruzada (*Categorical Cross-Entropy* – CE) tende a ser dominada pelo acúmulo de gradientes das amostras majoritárias facilmente classificáveis, negligenciando as categorias minoritárias essenciais.

Para mitigar essa assimetria, incorpora-se a função de Perda Focal (*Focal Loss* – FL), concebida por Lin et al. (2017):

$$\mathrm{FL}(p_t) = -\alpha_t \, (1 - p_t)^{\gamma} \, \log(p_t), \tag{7}$$

em que $p_t \in (0, 1]$ denota a probabilidade estimada pelo classificador para a classe verdadeira do fluxo, $\gamma \geq 0$ representa o parâmetro de foco e $\alpha_t \in (0, 1]$ atua como o coeficiente ponderador de balanceamento de classe.

O fator modulador $(1 - p_t)^{\gamma}$ reduz dinamicamente a contribuição de exemplos fáceis e bem calibrados ($p_t \to 1$), concentrando o esforço de otimização nos padrões raros ou fronteiriços de ataque ($p_t \to 0$). Dessa forma, a perda focal assegura sensibilidade discriminatória às classes de ataque minoritárias sem incorrer em instabilidade perante o volume massivo de tráfego ordinário.

2.3 TRABALHOS CORRELATOS

A pesquisa em sistemas de detecção de intrusão em redes (NIDS) transitou de classificadores estatísticos rasos para arquiteturas neurais profundas e, mais recentemente, para arranjos baseados em comitês e misturas de especialistas (MoE). Esta seção revisa os principais trabalhos da literatura, analisando avanços, premissas de projeto e limitações que motivam a abordagem adotada neste trabalho.

2.3.1 NIDS Baseados em Aprendizado Profundo

As primeiras aplicações de aprendizado profundo em NIDS priorizaram a substituição de classificadores rasos por redes neurais monolíticas aplicadas sobre todo o conjunto de atributos (Noor; Ige, 2025).

Sainis, Srivastava & Singh (2018) analisaram a detecção de valores atípicos (*outlier detection*) associada a algoritmos de seleção de atributos para sistemas de detecção de intrusão. O estudo indicou que a seleção supervisionada de variáveis diminui a taxa de falsos positivos em bases de

dados legadas, como KDD-Cup99 e NSL-KDD. No entanto, o método empregou classificadores tradicionais (SVM, Árvores de Decisão e Random Forest) aplicados sobre a totalidade dos atributos tabulares, sem separar domínios espaciais, temporais ou espectrais do tráfego.

Sarhan et al. (2021) propuseram representações de tráfego baseadas no protocolo NetFlow para mitigar a heterogeneidade de formatos entre bases de dados de rede. Em seguida, Sarhan, Layeghy & Portmann (2022) estenderam essa proposta ao definir um conjunto padronizado de atributos estatísticos aplicável a múltiplos conjuntos de referência (NF-UNSW-NB15, NF-CSE-CIC-IDS2018 e NF-BoT-IoT). Embora tenham confirmado a viabilidade de identificar anomalias a partir de metadados agregados, os experimentos basearam-se em classificadores estáticos e não contemplaram correlações temporais entre chegadas de pacotes ou propriedades no domínio da frequência.

Guadarrama et al. (2025) compararam algoritmos de aprendizado supervisionado em NIDS baseados em fluxos sob diferentes condições de balanceamento de classes. As limitações reportadas incluem a degradação de sensibilidade nas classes minoritárias e o custo computacional de retreinar modelos monolíticos perante grandes volumes de dados.

Dari et al. (2024) avaliaram topologias CNN, RNN e DNN na classificação de intrusões em bases públicas. Os resultados indicaram que redes convolucionais capturam relações espaciais e morfológicas em cabeçalhos, enquanto modelos recorrentes (LSTM e GRU) detectam melhor padrões com dependência temporal prolongada. Como cada arquitetura foi avaliada isoladamente, nenhuma manteve desempenho superior em todas as classes de ataque.

Oliveira, Gonçalves & Filho (2025) desenvolveram o F-NIDS, que utiliza aprendizado federado (*Federated Learning*) para treinamento colaborativo entre instituições com preservação da privacidade dos dados brutos. Embora atenda aos requisitos de descentralização, o modelo local de cada nó consiste em uma rede profunda homogênea, sujeita a limitações na detecção de perfis heterogêneos de tráfego malicioso.

Abreu & Abelém (2022) propuseram um sistema contínuo (*on-line*) para triagem e classificação de fluxos em tempo real por meio da combinação de filtros estatísticos e classificadores supervisionados. Apesar da baixa latência de processamento, a dependência de limiares determinísticos pré-fixados reduz a precisão quando aplicações benignas utilizam portas de rede convencionais.

Sasi et al. (2025) combinaram camadas 1D-CNN e LSTM com mecanismos de autoatenção (*self-attention*) para ambientes de IoT. Embora a abordagem tenha melhorado a detecção de ataques combinados, a complexidade quadrática do mecanismo de atenção impõe alto custo computacional, o que inviabiliza a operação em tempo real sob fluxos contínuos de alta vazão.

2.3.2 Abordagens Ensemble e Mixture of Experts em Cibersegurança

Para contornar as restrições de modelos homogêneos, diversas pesquisas exploram comitês de classificadores (*ensemble*) e arquiteturas baseadas em especialização de sub-redes.

Silva (2025) propuseram o HSAE (*Hybrid Semi-Supervised Autoencoder*), que combina autoencoders para modelagem de normalidade e comitês de classificadores para detecção de anomalias de dia zero em CSE-CIC-IDS2018 e NSL-KDD. Contudo, a agregação das saídas baseia-se em votação majoritária ou média aritmética simples com pesos fixos, sem ponderar a contribuição de cada modelo a partir do contexto específico do fluxo analisado.

Borgioli et al. (2024) desenvolveram um autoencoder convolucional unidimensional (1D-CAE) para detecção de intrusão em sistemas embarcados de tempo real com tolerância a envenenamento de dados (*data poisoning*), avaliado em CIC-IDS2017 e Modbus. Embora confirme a capacidade das convoluções em comprimir atributos de tráfego, o estudo limitou-se à classificação binária (tráfego anômalo versus regular), sem abordar a identificação multiclasse de ataques nem incorporar roteamento dinâmico entre classificadores.

Em detecção de falhas de software, Yang et al. (2025) desenvolveram a arquitetura MoEVD para análise de código-fonte C/C++. Diante da perda de eficácia de classificadores monolíticos perante a diversidade de vulnerabilidades, os autores dividiram o aprendizado entre sub-redes especializadas coordenadas por roteamento condicional. Embora o método tenha superado modelos monolíticos em código estático, o processamento de grafos sintáticos difere substancialmente do fluxo contínuo de pacotes em redes de dados.

No contexto de tráfego de rede, He, Fu & Zhang (2026) apresentaram o TrafficMoE para classificação de fluxos cifrados com protocolos como QUIC e túneis ISCX VPN. O método emprega especialistas neurais com roteamento adaptativo para tratar variações de entropia entre aplicações benignas. O escopo do estudo, contudo, limitou-se à categorização de aplicações (como navegação web e videoconferência), sem contemplar cenários de detecção de intrusão ou ataques multiclasse.

Chandroth, Stoian & Danciulescu (2026) introduziram o ALF-MoE (*Attention-Based Learnable Fusion of Specialized Expert Networks*) para classificação de tráfego agregado e túneis VPN cifrados. A arquitetura organiza cinco especialistas em quatro domínios de atributos (representação tabular com DNN, espacial com CNN, temporal de curto prazo com GRU, espectral com CAE e dependência temporal estendida com LSTM), coordenados por uma rede de roteamento (*Gating Network*) com fusão atencional aprendível (ALF) e projeção afim estabilizada. O modelo alcançou acurácia superior a 97% em bases consolidadas como ISCX VPN-nonVPN e Unicauca.

Apesar desses resultados, a formulação original de Chandroth, Stoian & Danciulescu (2026) foi avaliada exclusivamente na categorização balanceada de aplicações de rede e em regime de processamento em lote (*batch*). O método não foi testado em cenários de detecção de intrusão com desbalanceamento severo de classes de ataque, nem analisado quanto à latência de inferência necessária para operação com ferramentas de telemetria contínua.

2.3.3 Síntese Comparativa

O levantamento dos trabalhos correlatos evidencia lacunas metodológicas recorrentes na literatura de NIDS:

1. **Monolitismo e ausência de especialização multidomínio:** a maior parte das propostas emprega modelos homogêneos (exclusivamente convolucionais ou recorrentes), o que limita o desempenho em categorias de ataque cujos padrões residem em domínios não contemplados pela arquitetura;

2. **Fusão estática em comitês convencionais:** métodos ensemble frequentemente adotam regras de votação majoritária ou médias com pesos fixos, sem considerar a adequação contextual de cada classificador ao perfil do fluxo recebido;

3. **Sensibilidade ao desbalanceamento de classes:** avaliações baseadas em métricas globais agregadas muitas vezes ocultam a baixa taxa de detecção em ataques minoritários com escassa representação amostral;

4. **Ausência de calibração probabilística:** redes neurais profundas tendem a exibir superconfiança (*overconfidence*) em predições incorretas, o que requer métodos de calibração para estimar a incerteza das decisões;

5. **Avaliação restrita a domínios isolados:** predominam estudos validados em uma única base de dados, sem verificar a capacidade de generalização entre ambientes com perfis de tráfego distintos, como redes corporativas e ecossistemas de Internet das Coisas (IoT).

O Quadro 1 resume as abordagens, modelos, bases de dados e limitações dos trabalhos analisados em relação à proposta desta pesquisa.

Tabela 1 – Síntese comparativa entre trabalhos correlatos da literatura e a proposta desta tese.

Trabalho / Referência	**Metodologia / Paradigma**	**Modelos / Datasets**	**Limitações Identificadas**
Sainis, Srivastava & Singh (2018)	Detecção de outliers e seleção de atributos	DT, RF, SVM (KDD-Cup99, NSL-KDD)	Modelos clássicos sem exploração multidomínio; restrito a datasets legados com tráfego sintético.
Sarhan et al. (2021); Sarhan, Layeghy & Portmann (2022)	Padronização de atributos para fluxos NetFlow	RF, NB, MLP (NF-UNSW-NB15, NF-CSE-CIC-IDS2018)	Foco exclusivo em atributos estatísticos agregados; não modela dinâmicas temporais e espectrais.
Abreu & Abelém (2022)	Sistema híbrido e em tempo real para redes	Limiar estatístico + DT/RF (Tráfego real e bases públicas)	Elevada dependência de limiares determinísticos; perda de precisão em ameaças complexas.

Continua na próxima página

Tabela 1 – Continuação da página anterior

Trabalho / Referência	**Metodologia / Paradigma**	**Modelos / Datasets**	**Limitações Identificadas**
Guadarrama et al. (2025)	Estudo comparativo de NIDS em fluxo	DT, RF, XGBoost, MLP (CSE-CIC-IDS2018, CIC-UNSW-NB15)	Arquiteturas homogêneas; degradação acentuada em classes com desbalanceamento extremo.
Dari et al. (2024)	Análise comparativa de redes profundas	CNN, RNN, DNN isoladas (Bases públicas de intrusão)	Ausência de fusão estruturada; nenhum modelo homogêneo dominou todas as categorias de ataque.
Oliveira, Gonçalves & Filho (2025)	Aprendizado Federado para NIDS corporativo	DNN homogênea federada (CSE-CIC-IDS2018)	Foco na descentralização; classificador local não contempla representação em múltiplos domínios.
Sasi et al. (2025)	Rede híbrida com autoatenção para IoT	1D-CNN-LSTM + Atenção (Edge-IIoTset, CICIoT2023)	Alta complexidade quadrática da autoatenção; inviável sob tráfego contínuo em alta vazão.
Silva (2025)	Autoencoder semi-supervisionado e ensemble	HSAE + Comitê de votação (CSE-CIC-IDS2018, NSL-KDD)	Fusão tardia por votação estática; não aprende ponderações adaptativas de acordo com o contexto.
Borgioli et al. (2024)	Autoencoder Convolucional em sistemas embarcados	1D-CAE não supervisionado (CIC-IDS2017, Modbus)	Restrito à classificação binária (anomalia vs normal); ausência de diagnóstico multiclasse.
Yang et al. (2025)	Mixture of Experts para detecção de falhas	MoE condicional com Gating (Bases de código C/C++)	Domínio de código estático; não se aplica a fluxos contínuos de pacotes em redes de dados.
He, Fu & Zhang (2026)	MoE para classificação de tráfego cifrado	MoE heterogêneo + Gating (ISCX VPN, Tráfego QUIC)	Foco na identificação de aplicações benignas cifradas; não avaliado sob ataques cibernéticos.

Continua na próxima página

Tabela 1 – Continuação da página anterior

Trabalho / Referência	**Metodologia / Paradigma**	**Modelos / Datasets**	**Limitações Identificadas**
Chandroth, Stoian & Danciulescu (2026)	MoE com fusão atencional aprendível (ALF)	5 Especialistas (DNN, CNN, GRU, CAE, LSTM) + ALF (ISCX VPN, Unicauca)	Validado apenas em classificação de tráfego de aplicações em lote; sem validação para NIDS multiclasse e streaming.
Este Trabalho (ALF-MoE NIDS)	ALF-MoE multidomínio para NIDS	5 Especialistas + Gating Atencional + Fusão ALF + NFStream (CSE-CIC-IDS2018 Canônico e Corrigido, CIC-BCCC-NRC-2024, CIC-UNSW-NB15)	Adaptação da arquitetura MoE para detecção de intrusões multiclasse em rede; mitigação de desbalanceamento severo via Focal Loss multitarefa; avaliação de latência em fluxo contínuo.

Fonte: Elaborado pelo autor (2026).

A revisão da literatura e os fundamentos teóricos apresentados neste capítulo embasam a adaptação da arquitetura ALF-MoE para o domínio de detecção de intrusão em redes. A divisão do espaço de atributos em perspectivas especializadas (Geral, Espacial, Estatística, Frequência e Temporal), combinada ao roteamento adaptativo via Gating Network e ao módulo de fusão atencional aprendível, estabelece a estrutura adotada para tratar a heterogeneidade e a assimetria dos fluxos de tráfego malicioso. O Capítulo 3 descreve detalhadamente as formulações metodológicas, os conjuntos de dados de referência e o protocolo experimental implementado.

3 MATERIAIS E METODOLOGIA

Este capítulo apresenta os materiais, formulações metodológicas e o estrutura experimental desenvolvidos para a concepção, o treinamento e a avaliação da arquitetura ALF-MoE no domínio de Sistemas de Detecção de Intrusão em Redes (NIDS). Inicialmente, caracterizam-se os conjuntos de dados de referência empregados e o fluxo de amostragem. Em seguida, detalha-se o pipeline de pré-processamento e engenharia de atributos tabulares. Posteriormente, formaliza-se a adaptação da arquitetura neural ALF-MoE para NIDS, especificando os especialistas heterogêneos, a rede de roteamento atencional e o módulo de fusão adaptativa. Por fim, delineia-se o protocolo experimental de treinamento multitarefa com supervisão profunda e as métricas formais de avaliação estatística e computacional.

3.1 DATASETS UTILIZADOS

Neste trabalho, são selecionados conjuntos de dados consolidados e complementares que cobrem diferentes espectros de tráfego, topologias e vetores de ameaça:

- **CSE-CIC-IDS2018 (Versão Canônica e Versão Corrigida):** referência consagrada para tráfego corporativo e ataques complexos distribuídos em infraestrutura de nuvem AWS, avaliada tanto em sua rotulação original quanto sob a auditoria sistemática de Liu et al. (2022);
- **CIC-BCCC-NRC TabularIoTAttack-2024:** *benchmark* contemporâneo introduzido por Sasi et al. (2025), consolidado a partir da integração de 9 sub-datasets de Internet das Coisas (*Internet of Things* – IoT);
- **CIC-UNSW-NB15:** base de referência contendo tráfego sintético e realístico de alta densidade gerado por hardware dedicado de emulação (IXIA PerfectStorm) (Moustafa; Slay, 2015), avaliada sob os protocolos de avaliação adversarial de Mohammadian, Lashkari & Ghorbani (2024).

3.2 PRÉ-PROCESSAMENTO

Cada dataset utilizado possui suas particularidades, porém, compartilham as características base do CICFlowMeter (ferramenta utilizada para gerar os dados tabulares) (Sharafaldin; Lashkari; Ghorbani, 2018). O pré-processamento foi realizado em dois estágios:

1. **Pré-processamento Base:**
    - **Mesclagem:** Datasets fornecidos em arquivos separados foram mesclados em um único arquivo;
    - **Remoção de Colunas Identificadoras:** A remoção de colunas de identificação adicionadas automaticamente pelo CICFlowMeter, quintupla de identificação de fluxo e timestamps é necessária para evitar target de dados;
    - **Remoção de Colunas com Variância Zero**: Colunas que não apresentam variância não agregam valor preditivo ao modelo (Wang; Houng; Lin, 2023), portanto foram removidas.

2. **Geração de Amostragem:**

    - **CSE-CIC-IDS2018 (Canônico):** Como observado na Figura 2 esse dataset possuía um desbalanceamento severo de classes. Afim de atenuar esse desbalanceamento, foi gerada uma amostragem estratificada adaptativa que reserva uma cota fixa à classe benigna (10%) e reparte o orçamento de ataques por faixas de percentil (P50 e P75), preservando classes raras e comprimindo as majoritárias. Adicionalmente, foi realizado uma correção no nome das colunas para se adequar ao padrão recente do CICFlowMeter (e dos demais datasets) e o tratamento de valores nulos (NaN) e infinitos (inf) utilizando a inputação por mediana;
    - **CSE-CIC-IDS2018 (Corrigido):** Reclassificação dos fluxos de tráfego *Attempted* (vide 3.2.2.1). A retenção total dos fluxos concentrou-se nas classes com menos de 150 mil amostras, a parcela fixa de 200 mil amostras foi dedicada aos fluxos benignos e das classes restantes se reteve 10% do total da classe;
    - **CIC-UNSW-NB15:** Assim como o CSE-CIC-IDS2018 Canônico, o CIC-UNSW-NB15 sofre de desbalanceamento de forma ainda mais severa, sendo mais de 97% do dataset composto por tráfego benigno (Figura 2). Pela mesma razão, a amostra reteve os fluxos de ataque completamente e uma subamostragem de 50.000 registros dos fluxos benignos foi mantida;
    - **CIC-BCCC-NRC TabularIoTAttack-2024:** Após o pré-processamento base esse dataset deteve a quantidade massiva de aproximadamente 22.8 milhões de registros divididas em 49 classes. Devido a quantidade de classes, uma amostra de 15% foi gerada retendo integralmente as classes minoritárias (menos de 5.000 registros) e utilizando o método de Hare-Niemeyer para distribuir o restante dos registros.

3.2.1 Agrupamento de Ameaças (*Threat Levels*)

A rotulação dos datasets foi tratada de duas formas:

- **Granularidade Estrita – TL0:** Mantém as classes brutas originais de cada conjunto de dados (ex.: 49 classes no CIC-BCCC-NRC-2024, 15 classes no CSE-CIC-IDS2018 e 10 classes no CIC-UNSW-NB15). Esse nível de granularidade permite validar o desempenho do modelo diante de uma maior gama de classes a serem classificadas;
- **Meta-Categorias Consolidadas – TL1:** Agrupa classes afins em famílias funcionais abrangentes (ex.: consolidando *DoS Hulk*, *Slowloris* e *GoldenEye* na meta-categoria *DoS*; ou *DDoS-HOIC* e *LOIC* em *DDoS*). Esse nível permite verificar o desempenho do modelo em identificar a assinatura dos ataques.

O benchmark **CIC-UNSW-NB15** opera intrinsecamente em *TL0*, pois suas dez categorias já representam macro-classes comportamentais consolidadas.

3.2.2 Distribuição Amostral

3.2.2.1 CSE-CIC-IDS2018 – Canônica e Corrigida

Após a aplicação do pré-processamento e da amostragem estratificada adaptativa, a amostra resultante do CSE-CIC-IDS2018 (Canônico) reúne 3.712.942 fluxos distribuídos em 15 classes, conforme apresentado na Figura 3. O tráfego benigno totaliza 1.348.470 registros (36,32% da amostra), enquanto as 14 famílias maliciosas somam 2.364.472 fluxos (63,68%).

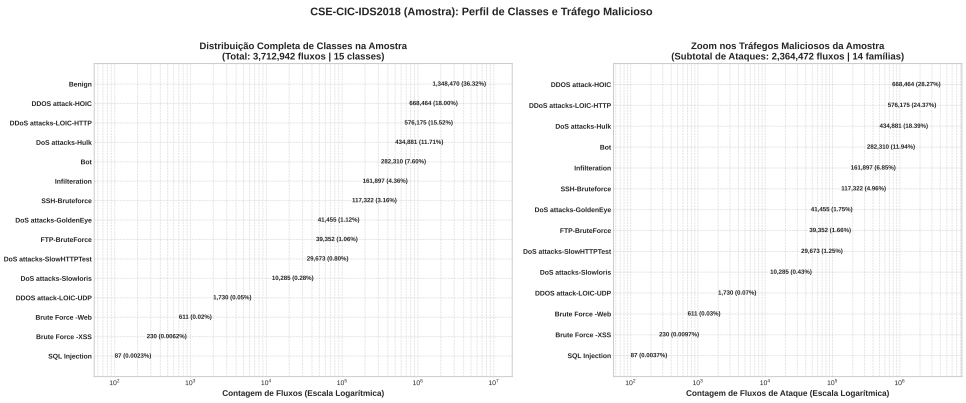


Figura 3 – Distribuição de classes da amostra estratificada do CSE-CIC-IDS2018 (Canônico): visão populacional completa (esquerda) e detalhamento do tráfego malicioso (direita).

Fonte: Elaborado pelo autor (2026) com base em Sharafaldin, Lashkari & Ghorbani (2018).

O painel esquerdo da Figura 3 detalha a distribuição populacional completa em escala logarítmica. O painel direito apresenta o detalhamento das 14 categorias de ataque. Os ataques mais frequentes são *DDOS attack-HOIC* (668.464 fluxos; 18,00% da amostra e 28,27% dos ataques), *DDoS attacks-LOIC-HTTP* (576.175 fluxos; 15,52% da amostra) e *DoS attacks-Hulk* (434.881 fluxos; 11,71% da amostra). As categorias intermediárias compreendem *Bot* (282.310 fluxos; 7,60%), *Infilteration* (161.897 fluxos; 4,36%), *SSH-Bruteforce* (117.322 fluxos; 3,16%), *DoS attacks-GoldenEye* (41.455 fluxos; 1,12%), *FTP-BruteForce* (39.352 fluxos; 1,06%) e *DoS attacks-SlowHTTPTest* (29.673 fluxos; 0,80%). Por fim, as classes raras incluem *DoS attacks-Slowloris* (10.285 fluxos; 0,28%), *DDOS attack-LOIC-UDP* (1.730 fluxos; 0,05%), *Brute Force -Web* (611 fluxos; 0,02%), *Brute Force -XSS* (230 fluxos; 0,0062%) e *SQL Injection* (87 fluxos; 0,0023%).

Investigações conduzidas por Liu et al. (2022) identificaram falhas sistemáticas e catastróficas de rotulação no CSE-CIC-IDS2018. Especificamente, constatou-se que o processo de rotulagem original rotulou fluxos inteiros com base unicamente na janela temporal programada para a execução dos scripts de ataque, independentemente de os pacotes maliciosos terem efetivamente alcançado o serviço ou exibido comportamento anômalo. Dentre as inconsistências mais graves documentadas por Liu et al. (2022), destacam-se:

1. **Inconsistência em Ataques de Força Bruta FTP (*FTP-BruteForce*):** Em ambos os dias de coleta em que o ataque foi supostamente desferido, o servidor alvo na porta 21 respondeu invariavelmente com pacotes sinalizados com `[RST, ACK]`. Esse padrão de sinalização sugere que a porta do serviço estava fechada no sistema operacional de destino; logo, o servidor rejeitou sumariamente a conexão, não ocorrendo qualquer interação de autenticação ou exploração. Portanto, rotular

tais fluxos como ataque induz o modelo a aprender respostas legítimas de rejeição de porta TCP fechada como assinaturas maliciosas;

2. **Superestimação de Categorias de Tentativa (*Attempted Categories*):** Milhares de conexões foram marcadas como ataques consumados quando, na realidade, consistiam em simples tentativas inócuas ou ruído de fundo. No esquema original de Liu et al. (2022), a auditoria catalogou inicialmente 25 categorias distintas (10 classes de tentativa, 14 classes de ataque efetivo e a classe Benign). Conforme descrito pelos autores, fluxos com o atributo *Attempted Category* não apresentavam nenhum comportamento malicioso, mas sob quaisquer circunstancias deveria ser tratada como classificações separadas (ex: utilizar *DoS GoldenEye - Attempted* para identificar a tentativa do ataque). Portanto, para este trabalho, todas as tentativas foram reclassificadas para tráfego benigno, reduzindo o espaço alvo efetivo para 15 classes ativas no nível TL0 e 9 macro-famílias no nível TL1;

3. **Desagregação Realista de Infiltração:** Na versão original, a classe *Infilteration* agregou de forma indiferenciada varreduras de porta, transferências de arquivos e comunicação interna de comando e controle. A versão corrigida individualiza tais vetores em *Infiltration - NMAP Portscan*, *Infiltration - Dropbox Download* e *Infiltration - Communication Victim Attacker*. Conforme ressaltado por Liu et al. (2022), os fluxos classificados como *Infiltration - Dropbox Download* consistem, por essência, em tráfego de rede benigno: as conexões são estabelecidas com a infraestrutura oficial do serviço em nuvem via protocolo HTTPS/TLS padrão, apresentando perfis estatísticos de fluxo indistinguíveis do uso legítimo corporativo, cuja eventual ameaça reside estritamente na carga útil do executável baixado, inspecionável apenas em nível de *endpoint*;

4. **Harmonização e Redução Dimensional:** Enquanto a versão original do CSE-CIC-IDS2018 disponibilizou 80 atributos brutos que resultam em 76 colunas canônicas (73 ativas após a remoção de sinalizadores sem variância), a auditoria de Liu et al. (2022) partiu de 91 atributos brutos, destilou 81 métricas estatísticas de fluxo e foi harmonizada no mesmo espaço canônico de 76 atributos (73 ativos) adotado neste trabalho.

A amostra saneada resultante do CSE-CIC-IDS2018 (Corrigido) totaliza 878.119 fluxos estruturados em 15 classes no nível TL0, conforme apresentado na Figura 4. O tráfego benigno compreende 200.000 registros (22,78% da amostra), enquanto as 14 categorias de ataque somam 678.119 conexões (77,22%).

O painel esquerdo da Figura 4 expõe a distribuição populacional completa da amostra em escala logarítmica. O painel direito detalha o subtotal de tráfegos maliciosos: as classes mais expressivas são *DoS Hulk* (180.316 fluxos; 20,53% da amostra e 26,59% dos ataques), *Botnet Ares* (142.921 fluxos; 16,28%), *DDoS-HOIC* (108.229 fluxos; 12,32%), *SSH-BruteForce* (94.197 fluxos; 10,73%) e *Infiltration - NMAP Portscan* (89.374 fluxos; 10,18%). As categorias intermediárias abrangem *DDoS-LOIC-HTTP* (28.933 fluxos; 3,29%), *DoS GoldenEye* (22.560 fluxos; 2,57%), *DoS Slowloris* (8.490 fluxos; 0,97%) e *DDoS-LOIC-UDP* (2.527 fluxos; 0,29%). Por fim, as classes raras críticas incluem *Infiltration - Communication Victim Attacker* (204 fluxos; 0,023%), *Web Attack - Brute Force* (131 fluxos; 0,015%), *Web Attack - XSS* (113 fluxos; 0,013%), *Infiltration - Dropbox Download* (85 fluxos; 0,0097%) e *Web Attack - SQL* (39 fluxos; 0,0044%).

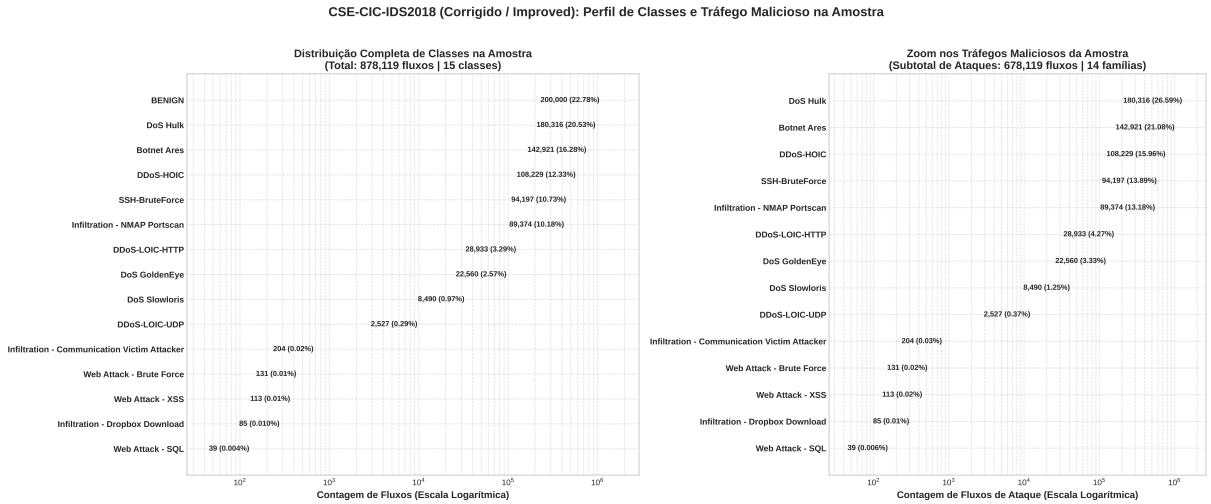


Figura 4 – Distribuição de classes da amostra do CSE-CIC-IDS2018 (Corrigido): visão populacional completa (esquerda) e detalhamento do tráfego malicioso (direita).

Fonte: Elaborado pelo autor (2026) com base em Liu et al. (2022).

3.2.2.2 CIC-UNSW-NB15

Conforme a estratégia de amostragem dirigida descrita na Seção 3.2, a base populacional de 3.540.241 registros teve todas as 89.583 instâncias maliciosas preservadas (retenção de 100%) e o tráfego benigno subamostrado para 50.000 fluxos (1,45% do volume original). A amostra final resultante totaliza 139.583 fluxos, composta por 35,82% de conexões legítimas e 64,18% de tráfego malicioso, conforme detalhado na Figura 5.

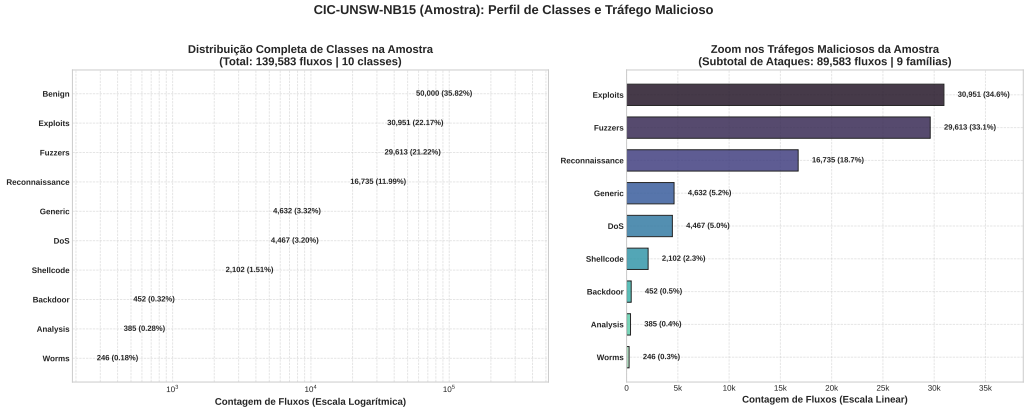


Figura 5 – Distribuição de classes da amostra do CIC-UNSW-NB15: visão populacional completa (esquerda) e detalhamento do tráfego malicioso (direita).

Fonte: Elaborado pelo autor (2026) com base em Moustafa & Slay (2015).

O painel esquerdo da Figura 5 apresenta a visão global da amostra em escala logarítmica. O painel direito detalha a partição das nove famílias maliciosas em escala linear. As classes mais volumosas são *Exploits* (30.951 fluxos; 34,55% dos ataques e 22,17% da amostra) e *Fuzzers* (29.613 fluxos; 33,06% dos ataques e 21,22% da amostra), seguidas por *Reconnaissance* (16.735 fluxos; 18,68% dos ataques). As categorias intermediárias reúnem *Generic* (4.632 fluxos; 5,17% dos ataques), *DoS* (4.467 fluxos; 4,99%)

e *Shellcode* (2.102 fluxos; 2,35%). As classes menos frequentes são *Backdoor* (452 fluxos; 0,50% dos ataques), *Analysis* (385 fluxos; 0,43%) e *Worms* (246 fluxos; 0,27% dos ataques).

Após a eliminação dos identificadores de fluxo e de nove atributos de variância nula pelo procedimento de higienização, o modelo opera com 67 atributos numéricos ativos diretamente no nível TL0, conforme definido na Subseção 3.2.1.

3.2.2.3 CIC-BCCC-NRC TabularIoTAttack-2024

A aplicação do critério híbrido introduzido na Seção 3.2 consolidou uma cota de 15,00% da população, totalizando 3.429.067 registros extraídos dos 22.860.449 fluxos originais. A partição reservou a retenção integral de 100% para as 14 classes com menos de 5.000 instâncias (somando 30.599 fluxos) e aplicou o método de Hare-Niemeyer nas 35 classes majoritárias para repartir os 3.398.468 fluxos restantes (taxa de aproximadamente 14,89%). A Figura 6 compara a distribuição populacional original com a amostra obtida para as 49 categorias em escala logarítmica.

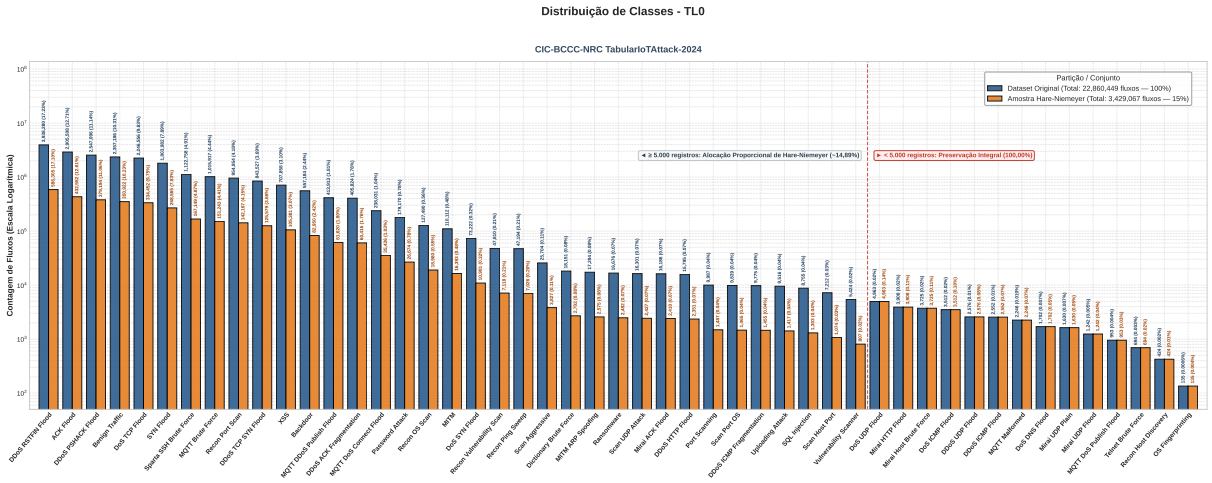


Figura 6 – Distribuição de classes no nível TL0 para o CIC-BCCC-NRC TabularIoTAttack-2024: comparação entre a população original e a amostragem estratificada por Hare-Niemeyer.

Fonte: Elaborado pelo autor (2026) com base em Sasi et al. (2025).

A alocação por Hare-Niemeyer assegura a proporcionalidade das classes majoritárias sem distorções de escala. Por exemplo, a classe *DDoS TCP SYN Flood* preservou 125.579 instâncias (3,66% da amostra), mantendo representatividade equivalente à sua participação na população original (3,69%).

Com a remoção dos identificadores de fluxo e de sete atributos de variância nula pelo procedimento de higienização, a base conta com 69 atributos numéricos ativos. O treinamento no nível TL0 atua sobre as 49 classes mapeadas na Figura 6, enquanto a agregação em nove famílias funcionais (TL1) é avaliada na Subseção 3.2.2.4.

3.2.2.4 Meta-categorias (TL1)

Conforme definido na Subseção 3.2.1, o nível de meta-categorias (TL1) agrupa classes afins em famílias funcionais abrangentes. Essa formulação permite avaliar a capacidade do modelo em reconhecer

a assinatura comportamental nuclear do vetor de ataque, mitigando a dispersão ocasionada por variações de ferramentas e protocolos de transporte. Enquanto o CIC-UNSW-NB15 opera intrinsecamente com dez macro-classes consolidadas no nível TL0, o agrupamento TL1 é detalhado a seguir para os benchmarks CSE-CIC-IDS2018 (Corrigido) e CIC-BCCC-NRC TabularIoTAttack-2024.

Na versão corrigida do CSE-CIC-IDS2018, as 15 classes granulares de TL0 são consolidadas em nove macro-famílias na amostra de 878.119 registros, conforme ilustrado na Figura 7.

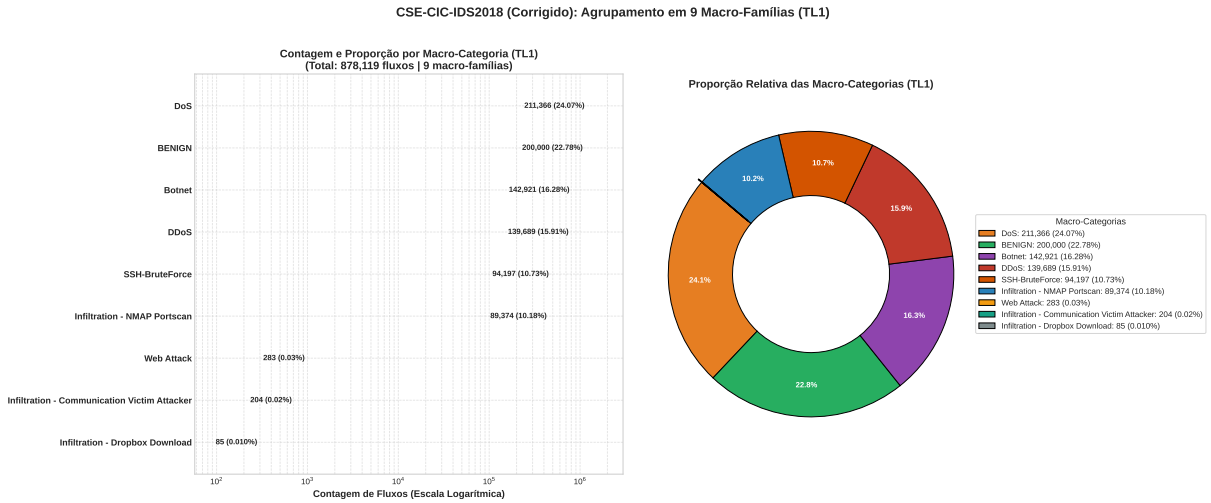


Figura 7 – Distribuição de classes no nível TL1 para o CSE-CIC-IDS2018 (Corrigido): contagem e proporção em escala logarítmica (esquerda) e distribuição relativa em gráfico de rosca (direita).

Fonte: Elaborado pelo autor (2026) com base em Liu et al. (2022).

O painel esquerdo da Figura 7 detalha a contagem de fluxos em escala logarítmica, e o painel direito exibe as proporções relativas da amostra. Os maiores volumes concentram-se em *DoS* (211.366 fluxos; 24,07% da amostra, agregando as variantes *Hulk*, *GoldenEye* e *Slowloris*) e tráfego *BENIGN* (200.000 fluxos; 22,78%). As categorias intermediárias reúnem *Botnet* (142.921 fluxos; 16,28%), *DDoS* (139.689 fluxos; 15,91%, consolidando *HOIC*, *LOIC-HTTP* e *LOIC-UDP*), *SSH-BruteForce* (94.197 fluxos; 10,73%) e a primeira etapa de reconhecimento de infiltração, *Infiltration - NMAP Portscan* (89.374 fluxos; 10,18%). Em conformidade com a auditoria de Liu et al. (2022), as fases de infiltração permanecem discriminadas devido à distinção de suas manifestações em rede, compondo com *Web Attack* (283 fluxos; 0,03%), *Infiltration - Communication Victim Attacker* (204 fluxos; 0,02%) e *Infiltration - Dropbox Download* (85 fluxos; 0,010%) os grupos minoritários da base.

No benchmark CIC-BCCC-NRC TabularIoTAttack-2024, as 49 classes granulares são mapeadas em nove famílias táticas, cujas proporções populacionais e amostrais são comparadas na Figura 8.

A Figura 8 evidencia a fidelidade das proporções assegurada pelo método de Hare-Niemeyer. As famílias de exaustão volumétrica predominam tanto na população quanto na amostra de 15,00%, lideradas por *DDoS* (33,97% original vs. 33,84% na amostra; 1.160.428 fluxos) e *DoS* (30,79% original vs. 30,81% na amostra; 1.056.647 fluxos), seguidas por tráfego legítimo (*Benign Traffic*, com 10,31% original vs. 10,23% na amostra; 350.922 fluxos). Os vetores específicos de IoT e protocolos de aplicação mantêm representação equilibrada: *IoT/MQTT* responde por 7,33% da amostra (251.498 fluxos; 7,31% original), *BruteForce* por 5,75% (197.219 fluxos; 5,78% original), *Reconnaissance* por 5,45% (186.937 fluxos;

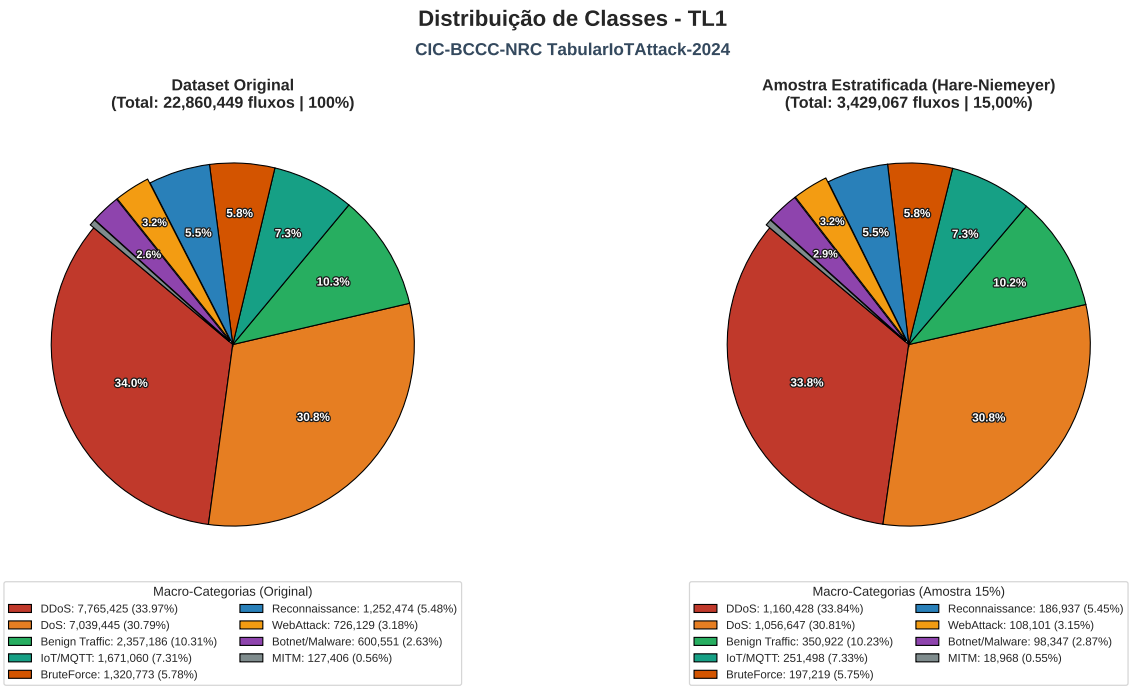


Figura 8 – Distribuição de classes no nível TL1 para o CIC-BCCC-NRC TabularIoTAttack-2024: comparação da distribuição relativa entre a população original e a amostra estratificada por Hare-Niemeyer.

Fonte: Elaborado pelo autor (2026) com base em Sasi et al. (2025).

5,48% original), *WebAttack* por 3,15% (108.101 fluxos; 3,18% original), *Botnet/Malware* por 2,87% (98.347 fluxos; 2,63% original) e manipulações de tráfego *MITM* por 0,55% (18.968 fluxos; 0,56% original).

3.2.3 Normalização e Codificação

A higienização de telemetria bruta e a harmonização dimensional constituem etapas críticas para evitar o colapso de gradientes e garantir que os múltiplos especialistas neurais operem sobre representações numéricas bem-condicionadas. O pipeline de pré-treino concebido para o modelo ALF-MoE organiza-se em um fluxo determinístico e estritamente modular, estruturada nos seguintes procedimentos:

1. **Redução de Assimetria via Transformação Logarítmica ($\log(1+x)$):** Propriedades de tráfego de rede exibem tipicamente caudas pesadas com forte assimetria positiva. Para cada atributo j, calcula-se o coeficiente de assimetria amostral $\gamma_1(j)$ nos dados de treino. Se $|\gamma_1(j)| > 3{,}0$ e todos os valores observados forem não negativos, aplica-se a transformação:

$$x'_{ij} = \ln(1 + \max(x_{ij}, 0)), \tag{1}$$

   comprimindo a amplitude dinâmica das ordens de grandeza sem distorcer o ordenamento dos percentis;

2. **Normalização Robusta por Percentis (*RobustScaler*):** Em virtude da presença inevitável de picos de tráfego decorrentes de rajadas volumétricas legítimas e maliciosas, padronizadores baseados

em média e desvio padrão (*StandardScaler*) sofrem severa distorção. Em seu lugar, emprega-se o *RobustScaler*, cuja escala é governada pela mediana e pelo intervalo interquartil (IQR):

$$\tilde{x}_{ij} = \frac{x'_{ij} - Q_{50}(x'_{\cdot j})}{Q_{75}(x'_{\cdot j}) - Q_{25}(x'_{\cdot j})}, \tag{2}$$

em que Q_p representa o p-ésimo percentil do atributo no conjunto de treino. Esse procedimento assegura que o núcleo de distribuição da maioria dos fluxos permaneça confinado na faixa $[-1, 1]$ sem que *outliers* dominem a função de perda;

3. **Codificação de Rótulos:** As classes de ameaça são mapeadas para índices ordinais inteiros $y \in \{0, 1, \ldots, C-1\}$ através do *LabelEncoder*, permitindo a posterior indexação na camada de saída softmax e nas ponderações de perda.

3.3 ADAPTAÇÃO E MODELAGEM DA ARQUITETURA ALF-MOE PARA NIDS

A arquitetura **ALF-MoE** (*Attention-based Learnable Fusion of Experts*) foi originalmente concebida por Chandroth, Stoian & Danciulescu (2026) para classificação de tráfego de rede criptografado. Suas camadas customizadas fundamentais – *AttentionRefinementLayer* e *WeightedSumFusion* – foram estabelecidas visando a fusão aprendível entre especialistas heterogêneos. No escopo deste Trabalho de Conclusão de Curso, a arquitetura é adaptada e modelada para sistemas de detecção de intrusão em redes (NIDS) operando sobre telemetria estatística tabular. Entre as extensões e adaptações desenvolvidas para esse fim destacam-se:

- **Camada SliceLayer:** concebida para particionar tensores tabulares não contíguos em domínios informacionais heterogêneos;
- **Autoencoder Convolucional:** adaptação do especialista espectral originalmente proposto por Chandroth, Stoian & Danciulescu (2026), combinando janelamento de Hann, transformada rápida de Fourier para sinais reais e reconstrução convolucional 1D como regularizador indutivo;
- **Otimização multitarefa com supervisão profunda:** objetivo de treinamento conjunto que equilibra a perda da cabeça de fusão unificada (peso $1{,}0$), as perdas supervisionadas auxiliares dos cinco especialistas (peso $0{,}2$) e a perda de reconstrução espectral do autoencoder convolucional;
- **Focal Loss multiclasse com ponderação atenuada:** substituição da entropia cruzada tradicional pela formulação focal adaptativa (Lin et al., 2017), integrando coeficientes balanceados por raiz quadrada para conter o desbalanceamento severo de classes raras sem desestabilizar os gradientes.

3.3.1 Visão Geral do Sistema e Fluxo de Dados

Diferentemente de abordagens tradicionais que forçam uma única rede homogênea a processar atributos com propriedades distintas, o ALF-MoE opera sob um paradigma modular de comitê de especialistas (*Mixture of Experts* – MoE) integrado a um mecanismo atencional de fusão.

O fluxo computacional inicia-se com o recebimento do vetor canônico harmonizado de entrada $x \in \mathbb{R}^D$ ($D \leq 73$ features pós-normalização, conforme o dataset). A camada customizada *SliceLayer*, fatia o vetor x em cinco subvetores:

$$x \mapsto \{x_g, x_s, x_v, x_f, x_t\}, \tag{3}$$

alimentando em paralelo os cinco especialistas correspondentes, conforme sumarizado na Tabela 2. Os subvetores totalizam $27 + 16 + 32 + 73 + 18 = 166$ dimensões considerando as 73 features ativas pós-normalização. Como o especialista K_{CAE} recebe a totalidade dos atributos do fluxo ($x_f \in \mathbb{R}^{73}$), há compartilhamento não disjunto de features entre as representações temporais, espaciais e a análise espectral global.

Tabela 2 – Mapeamento funcional entre domínios de telemetria e subvetores de entrada.

Especialista	**Subvetor**	**Domínio da Telemetria de Rede**
K_{DNN}	$x_g \in \mathbb{R}^{27}$	Métricas acumuladas globais, contadores de volume e sinalizadores TCP/IP
K_{CNN}	$x_s \in \mathbb{R}^{20\to16\to4\times4}$	Estatísticas direcionais de comprimento de pacotes e segmentos
K_{GRU}	$x_v \in \mathbb{R}^{32\to8\times4}$	Dinâmica sequencial curta, intervalos entre chegadas e atividade/inatividade
K_{CAE}	$x_f \in \mathbb{R}^{73}$	Representação espectral e reconstrução latente do fluxo completo
K_{LSTM}	$x_t \in \mathbb{R}^{18\to6\times3}$	Dinâmica temporal agregada, tempos totais de tráfego e taxas de transmissão

Fonte: Elaborado pelo autor (2026).

3.3.2 Modelos Especialistas Heterogêneos

Os cinco especialistas neurais operam sobre subconjuntos específicos de atributos da telemetria de rede. As topologias e conexões de cada rede são apresentadas na Figura 9:

1. **Especialista DNN (K_{DNN}):** Processa o vetor estatístico global $x_g \in \mathbb{R}^{27}$, composto por sinalizadores TCP (SYN, ACK, FIN, RST, PSH), contadores acumulados de pacotes e bytes e tempos totais de fluxo. A rede é estruturada em duas camadas densas sucessivas, com 256 e 128 unidades, normalização em lote (*Batch Normalization*) e ativação LeakyReLU ($\beta = 0{,}2$). Aplica-se regularização via Dropout ($p = 0{,}1$) após a primeira camada oculta. A saída da segunda camada oculta gera a representação intermediária $\mathbf{h}_{\text{dnn}} \in \mathbb{R}^{128}$ (Figura 9a);

2. **Especialista CNN (K_{CNN}):** Recebe as variáveis espaciais de pacotes e segmentos. O pré-processamento direciona 20 variáveis a este módulo, das quais as 16 primeiras, referentes às medidas estatísticas de comprimento (mínimo, máximo, média e desvio padrão direcionais e agregados), são selecionadas via fatiamento dimensional estático e organizadas em uma grade matricial $4 \times 4 \times 1$. Duas camadas convolucionais 2D processam essa matriz com filtros 2×2, gerando 64 e 128 mapas de ativação com preenchimento conservativo (*same*), normalização em lote

e LeakyReLU ($\beta = 0{,}2$). O volume resultante é achatado (*Flatten*) e projetado por uma camada densa de 128 unidades com normalização em lote, LeakyReLU ($\beta = 0{,}2$) e Dropout ($p = 0{,}2$), produzindo o vetor $\mathbf{h}_{\text{cnn}} \in \mathbb{R}^{128}$ (Figura 9e);

3. **Especialista GRU (K_{GRU}):** Recebe 32 atributos temporais e volumétricos x_v, organizados em 8 etapas temporais com 4 atributos por etapa. Este subvetor reúne intervalos entre chegadas direcionais (*Flow/Fwd/Bwd IAT*), contadores direcionais de pacotes e bytes, taxas de transmissão e as métricas de atividade e inatividade (*Active* e *Idle*). A camada recorrente utiliza unidades GRU bidirecionais com 64 células em cada direção (128 dimensões concatenadas), seguida por normalização em lote, projeção densa linear para 128 neurônios, LeakyReLU ($\beta = 0{,}2$) e Dropout ($p = 0{,}1$), sintetizando a correlação sequencial curta em $\mathbf{h}_{\text{gru}} \in \mathbb{R}^{128}$ (Figura 9c);

4. **Especialista Autoencoder Convolucional (K_{CAE}):** Opera sobre o vetor completo da telemetria ($x_f \in \mathbb{R}^{73}$) para extrair padrões latentes no domínio da frequência, conforme as formulações de Chandroth, Stoian & Danciulescu (2026) e Borgioli et al. (2024). O sinal de entrada é multiplicado por uma janela periódica de Hann $w(n) = 0{,}5 - 0{,}5\cos\left(\frac{2\pi n}{L}\right)$, com $L = 73$, e transformado via FFT para sinais reais ($\mathbf{s} = |\,\text{RFFT}(x_f \odot \mathbf{w})| \in \mathbb{R}^{37}$). O codificador convolucional 1D aplica três convoluções consecutivas com 16, 32 e 64 filtros, núcleo de tamanho 5, passo unitário, ativação ReLU e regularização L_2 (10^{-4}). O tensor do gargalo é achatado em $\mathbf{h}_{\text{cae}} \in \mathbb{R}^{2368}$ (37×64). A partir dessa representação, a rede bifurca em duas direções: um decodificador com três convoluções transpostas 1D (filtros 32, 16 e 1) reconstrói o espectro original $\hat{\mathbf{s}} \in \mathbb{R}^{37}$ minimizando o erro quadrático médio $\mathcal{L}_{\text{CAE,rec}} = \frac{1}{37}\|\mathbf{s} - \hat{\mathbf{s}}\|_2^2$ (peso $\lambda_{\text{rec}} = 1{,}0$), enquanto uma camada densa conectada ao gargalo alimenta a cabeça Softmax auxiliar (Figura 9d);

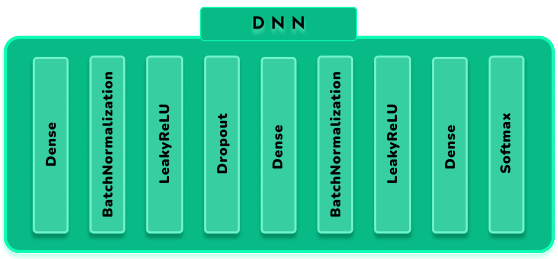
5. **Especialista LSTM (K_{LSTM}):** Recebe 18 variáveis x_t formatadas em 6 etapas com 3 atributos por etapa. Diferentemente do especialista GRU, este módulo modela o comportamento temporal acumulado e a cadência de transferência da conexão, processando a duração total do fluxo, os tempos acumulados de IAT de ida e volta, a dispersão estatística agregada dos intervalos e as taxas de pacotes por segundo. A camada recorrente adota células LSTM bidirecionais (64 unidades por direção, totalizando 128), normalização em lote, projeção densa linear para 128 unidades com LeakyReLU ($\beta = 0{,}2$) e Dropout ($p = 0{,}1$), gerando $\mathbf{h}_{\text{lstm}} \in \mathbb{R}^{128}$ (Figura 9b).

Cada especialista dispõe de uma cabeça supervisionada auxiliar composta por uma camada densa e ativação Softmax: $\hat{\mathbf{y}}^{(k)} = \text{softmax}(\mathbf{W}_k\mathbf{h}_k + \mathbf{b}_k) \in \mathbb{R}^C$. Essa projeção permite calcular as perdas supervisionadas auxiliares e alimentar o módulo de fusão da arquitetura.

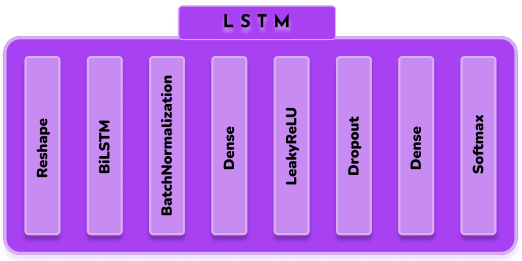
3.3.3 Gating Network com Refinamento Atencional

A rede de roteamento (*Gating Network*) calcula dinamicamente a relevância de cada especialista para o fluxo de rede analisado a partir do vetor completo de atributos $x \in \mathbb{R}^D$ (Chandroth; Stoian; Danciulescu, 2026), em que D representa a dimensionalidade ativa do benchmark avaliado: $D = 66$ para o CSE-CIC-IDS2018 (na versão Canônica), $D = 73$ para o CSE-CIC-IDS2018 (na versão Corrigida), $D = 69$ para o CIC-BCCC-NRC-2024 e $D = 67$ para o CIC-UNSW-NB15.

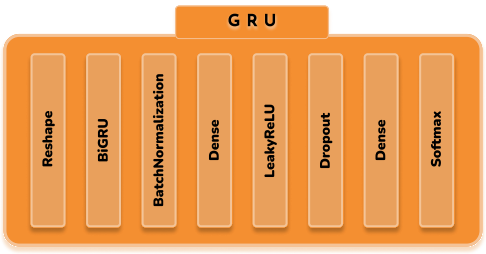
Figura 9 – Diagramas das topologias neurais dos modelos especialistas heterogêneos.



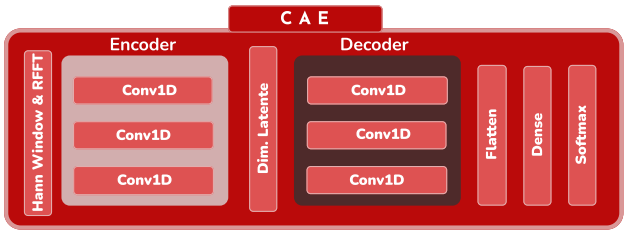
(a) Especialista DNN (K_{DNN}).



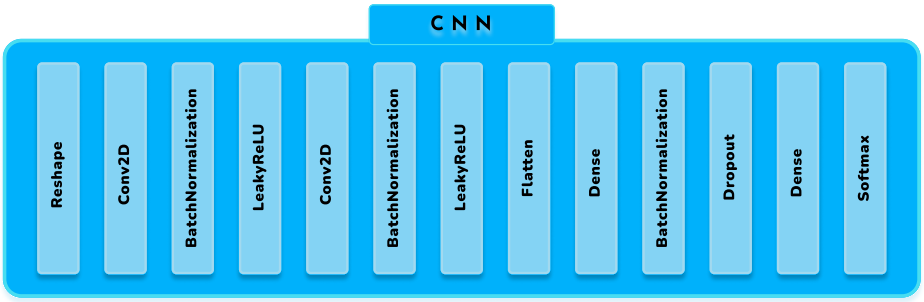
(b) Especialista LSTM (K_{LSTM}).



(c) Especialista GRU (K_{GRU}).



(d) Especialista CAE (K_{CAE}).



(e) Especialista CNN (K_{CNN}).

Fonte: Elaborado pelo autor (2026).

A arquitetura processa x por duas camadas densas (128 e 64 unidades com *Batch Normalization*, LeakyReLU com $\beta = 0{,}2$ e *Dropout* com $p = 0{,}1$) seguidas por uma camada linear de 5 neurônios, esquematizada na Figura 10. Os *logits* brutos $z_{\text{raw}} \in \mathbb{R}^5$ geram a distribuição preliminar de confiança α via ativação Softmax (σ):

$$\alpha = \sigma(z_{\text{raw}}) \in \mathbb{R}^5. \tag{4}$$

Na camada *AttentionRefinementLayer*, o vetor α passa por uma transformação linear no espaço logarítmico para calibrar a ponderação mútua entre os especialistas:

$$z_{\text{refined}} = W_g \ln(\alpha) + b_g, \tag{5}$$

em que $W_g \in \mathbb{R}^{5\times5}$ e $b_g \in \mathbb{R}^5$ são parâmetros ajustáveis da projeção atencional, aplicando-se um piso numérico $\epsilon = 10^{-7}$ sobre α para assegurar estabilidade e prevenir divergências de $\ln(0)$.

Para evitar que um único classificador concentre todo o peso de decisão (*winner-takes-all*), os *logits*

refinados são comprimidos pela função tangente hiperbólica:

$$\tilde{z} = \tanh(z_{\text{refined}}), \tag{6}$$

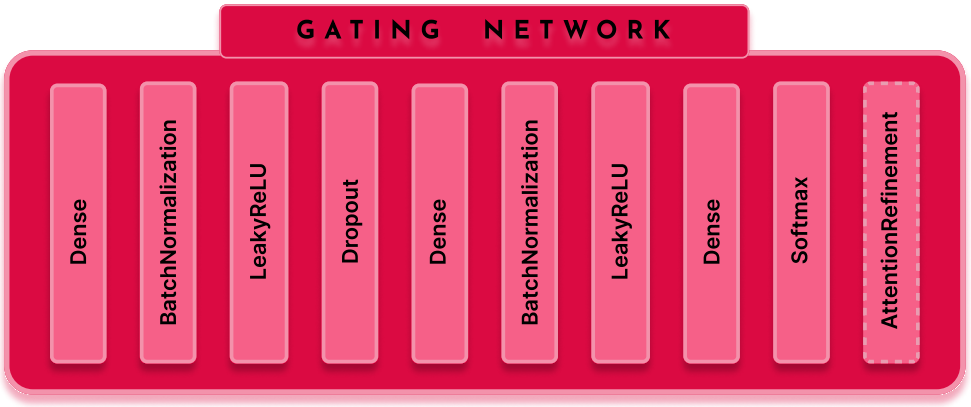
restringindo as ativações ao intervalo $[-1, 1]$. Essa compressão simétrica suaviza contrastes excessivos e garante que nenhum especialista seja completamente desativado.

A distribuição final de pesos atencionais a é obtida aplicando a função σ diretamente sobre $\tilde{z}$:

$$a = \sigma(\tilde{z}) = [a_{\text{dnn}}, a_{\text{cnn}}, a_{\text{gru}}, a_{\text{cae}}, a_{\text{lstm}}]^{\top}, \tag{7}$$

em que $\sum_{k=1}^{5} a_k = 1$ e $a_k > 0$, fornecendo os coeficientes de ponderação para o módulo de fusão ALF.

Figura 10 – Topologia interna da Gating Network com refinamento atencional e compressão simétrica.



Fonte: Elaborado pelo autor (2026).

3.3.4 Mecanismo Attention-based Learnable Fusion (ALF)

A integração final das decisões é conduzida pelo módulo customizado **ALF** (*Attention-based Learnable Fusion*), cuja topologia interna é apresentada na Figura 11, estruturado em dois blocos determinísticos:

1. **Fusão por Soma Ponderada (*WeightedSumFusion*):** A camada de fusão recebe as distribuições probabilísticas preditas por cada um dos cinco especialistas $\{\hat{\mathbf{y}}^{(k)}\}_{k=1}^{5} \subset \mathbb{R}^C$ e o vetor de pesos atencionais $\mathbf{a} \in \mathbb{R}^5$ proveniente da Gating Network, efetuando a soma ponderada estrita:

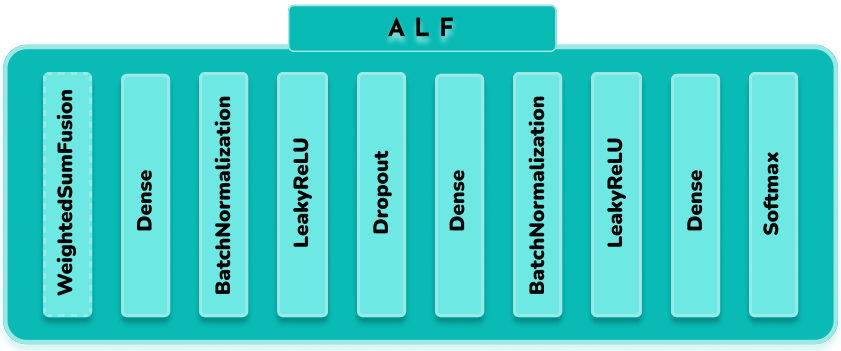
$$\mathbf{z} = \sum_{k=1}^{5} a_k \cdot \hat{\mathbf{y}}^{(k)} \in \mathbb{R}^C. \tag{8}$$

   A integração linear ponderada direta assegura que o sinal de gradiente retropropagado a partir da perda de fusão flua exclusivamente através dos coeficientes de atenção a_k, incentivando a coadaptação dinâmica da Gating Network e a real especialização funcional de cada rede neural integrante;

2. **Classificação Multiclasse Final:** O vetor fundido $\mathbf{z}$ é subsequentemente processado por uma cabeça classificadora profunda desenhada para refinar as margens de decisão entre classes com

alta sobreposição. Essa estrutura compreende uma primeira camada densa de 128 unidades com normalização em lote, ativação LeakyReLU ($\beta = 0{,}2$) e Dropout ($p = 0{,}1$), seguida por uma segunda camada densa de 64 unidades com normalização em lote e LeakyReLU ($\beta = 0{,}2$). Por fim, uma camada linear densa com ativação Softmax projeta as ativações refinadas sobre o espaço de classes, gerando a distribuição final de probabilidades preditas $\hat{\mathbf{y}}_{\mathrm{ALF}} \in \mathbb{R}^C$.

Figura 11 – Topologia interna do módulo de fusão ALF (*Attention-based Learnable Fusion*).



Fonte: Elaborado pelo autor (2026).

A arquitetura macroscópica unificada do modelo ALF-MoE, integrando a recepção da telemetria de rede, o roteamento pelos especialistas heterogêneos, a arbitragem dinâmica pela Gating Network e a combinação ponderada das probabilidades com refinamento profundo no módulo ALF, é ilustrada na Figura 1.

3.3.5 Tratamento de Desbalanceamento de Classes

O desbalanceamento amostral é uma característica ontológica do tráfego de redes: conexões benignas superam os ataques em várias ordens de grandeza, e certos vetores ofensivos (como injeções SQL e explorações web) constituem eventos ultra-raros no tráfego agregado. Se um classificador padrão for treinado sob entropia cruzada tradicional em tais condições, o modelo convergirá para um mínimo trivial que classifica quase todos os fluxos como pertencentes às classes majoritárias, apresentando acurácia nominal elevada porém taxa de detecção quase nula para as classes minoritárias críticas.

Para neutralizar esse fenômeno sem incorrer no risco de sobreajuste (*overfitting*) gerado por técnicas de sobreamostragem sintética (como SMOTE) em espaços tabulares de alta dimensionalidade, esta metodologia adota uma estratégia de ponderação de classes atenuada por raiz quadrada:

$$w_c = \sqrt{\frac{N}{C \cdot N_c}}, \quad \forall c \in \{0, 1, \ldots, C-1\}, \tag{9}$$

em que N expressa a quantidade total de amostras de treino, C representa o número de classes ativas e N_c é o suporte amostral da classe c. O emprego da raiz quadrada no fator de desbalanceamento atenua as penalidades extremas observadas na ponderação balanceada clássica ($N/(C \cdot N_c)$), que tenderia a gerar multiplicadores excessivos (superiores a 10^4) para classes com menos de 20 amostras, desestabilizando a descida do gradiente.

Os pesos calculados w_c entram diretamente como coeficientes α_c no vetor de ponderação da Focal Loss, aplicando uma compensação linear estrita que evita a dupla multiplicação quadrática (w_c^2) na descida do gradiente.

3.4 PROTOCOLO EXPERIMENTAL DE TREINAMENTO E AVALIAÇÃO

Para garantir rigor metodológico e reprodutibilidade, todos os ensaios foram balizados por um protocolo padronizado de otimização multitarefa, particionamento e validação estatística.

3.4.1 Funções de Perda e Otimização Multitarefa

O treinamento do modelo ALF-MoE é formulado como uma otimização multitarefa conjunta (*multi-task learning*). A função de custo global $\mathcal{L}_{\text{total}}$ agrega a perda da cabeça principal de fusão ALF, as perdas supervisionadas auxiliares dos cinco especialistas e a perda mista de reconstrução espectral do Autoencoder Convolucional:

$$\mathcal{L}_{\text{total}} = 1{,}0 \cdot \mathcal{L}_{\text{FL}}(\hat{\mathbf{y}}_{\text{ALF}}, \mathbf{y}) + 0{,}2 \sum_{k=1}^{5} \mathcal{L}_{\text{FL}}(\hat{\mathbf{y}}^{(k)}, \mathbf{y}) + \lambda_{\text{rec}} \mathcal{L}_{\text{CAE,rec}}, \tag{10}$$

sendo $\lambda_{\text{rec}} = 1{,}0$ e o peso das cabeças auxiliares fixado em $0{,}2$, provendo sinal de gradiente para guiar os especialistas sem sobrecarregar a convergência da cabeça unificada ALF.

A perda de classificação empregada em todas as cabeças neurais é a **Focal Loss Multiclasse**, adaptada a partir da variante α-balanceada proposta por Lin et al. (2017, Seção 3.2, p. 2982, Eq. 5). Para um vetor de probabilidades preditas $\hat{\mathbf{y}} \in [0,1]^C$ e o vetor de rótulos verdadeiros em codificação *one-hot* $\mathbf{y} \in \{0,1\}^C$, a função é expressa por:

$$\mathcal{L}_{\text{FL}}(\hat{\mathbf{y}}, \mathbf{y}) = -\sum_{c=0}^{C-1} \alpha_c \, y_c \, (1 - \hat{y}_c)^{\gamma} \ln(\hat{y}_c) = -\alpha_t (1 - p_t)^{\gamma} \ln(p_t), \tag{11}$$

em que t indica a classe verdadeira ($y_t = 1$), $p_t = \hat{y}_t$ expressa a probabilidade estimada para essa classe correta, $\gamma = 2{,}0$ é o parâmetro de foco que reduz a influência de fluxos de tráfego triviais e $\alpha_t = w_t$ corresponde ao peso balanceado por raiz quadrada definido na Equação 9.

O otimizador utilizado é o **Adam** com taxa de aprendizado inicial $\eta_0 = 10^{-3}$, momentos $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$, $\epsilon = 10^{-8}$ e tamanho de lote (*batch size*) fixado em 128 instâncias ao longo de 10 épocas. O agendamento da taxa de aprendizado é governado pelo mecanismo *ReduceLROnPlateau* (fator de redução $0{,}5$, paciência de 2 épocas monitorando `val_ALF_F1-Score` com limiar inferior de 10^{-6}), complementado por parada precoce (`EarlyStopping`) com paciência de 4 épocas monitorando a mesma métrica.

3.4.2 Métricas de Avaliação

A avaliação de desempenho do modelo e de cada especialista individual engloba métricas de eficácia preditiva e métricas de eficiência computacional em tempo de execução.

3.4.2.1 Métricas de Eficácia Estatística

Conforme delineado nos objetivos específicos deste trabalho (Seção 1.3.2), a eficácia discriminatória da arquitetura ALF-MoE frente aos classificadores de referência é avaliada primordialmente por meio de quatro métricas multiclasse não enviesadas: Acurácia Global (Acc), Precisão Macro ($\mathrm{Prec}_{\mathrm{macro}}$), Sensibilidade Macro ($\mathrm{Rec}_{\mathrm{macro}}$) e Macro F_1-Score (F_1^{macro}). Adicionalmente, computam-se a Acurácia Balanceada e o Weighted F_1-Score como indicadores complementares para avaliar o impacto do desbalanceamento severo sobre as classes minoritárias.

Para cada classe $c \in \{0, \ldots, C-1\}$, denotam-se TP_c, FP_c, FN_c, TN_c os quantitativos de verdadeiros positivos, falsos positivos, falsos negativos e verdadeiros negativos, respectivamente. Computam-se:

1. **Acurácia Global (Acc):**
$$\mathrm{Acc} = \frac{\sum_{c=0}^{C-1} TP_c}{\sum_{c=0}^{C-1} (TP_c + FN_c)}; \tag{12}$$

2. **Acurácia Balanceada ($\mathrm{Acc}_{\mathrm{bal}}$):** média aritmética das taxas de recall sobre todas as classes, mitigando a distorção induzida por classes majoritárias:
$$\mathrm{Acc}_{\mathrm{bal}} = \frac{1}{C} \sum_{c=0}^{C-1} \frac{TP_c}{TP_c + FN_c}; \tag{13}$$

3. **Precisão Macro ($\mathrm{Prec}_{\mathrm{macro}}$) e Sensibilidade Macro ($\mathrm{Rec}_{\mathrm{macro}}$):**
$$\mathrm{Prec}_{\mathrm{macro}} = \frac{1}{C} \sum_{c=0}^{C-1} \frac{TP_c}{TP_c + FP_c}, \quad \mathrm{Rec}_{\mathrm{macro}} = \frac{1}{C} \sum_{c=0}^{C-1} \frac{TP_c}{TP_c + FN_c}; \tag{14}$$

4. **Macro F_1-Score (F_1^{macro}):** média harmônica entre precisão e sensibilidade computada de forma não ponderada, constituindo o critério primordial para ranqueamento de NIDS sob desbalanceamento:
$$F_1^{\mathrm{macro}} = \frac{1}{C} \sum_{c=0}^{C-1} \frac{2 \cdot \mathrm{Prec}_c \cdot \mathrm{Rec}_c}{\mathrm{Prec}_c + \mathrm{Rec}_c}; \tag{15}$$

5. **Weighted F_1-Score (F_1^{weighted}):** ponderação das pontuações F_1 pela proporção empírica de amostras de cada classe N_c/N.

3.4.2.2 Métricas de Eficiência Computacional

A viabilidade de implantação do NIDS em nós de monitoramento em tempo real depende estritamente do tempo de processamento. Avaliam-se:

1. **Latência por Amostra (L_{sample}):** tempo médio transcorrido para inferir um único fluxo de rede, expresso em milissegundos por fluxo ($\mathrm{ms/fluxo}$):
$$L_{\mathrm{sample}} = \frac{T_{\mathrm{total,inf}}}{N_{\mathrm{test}}} \times 10^3; \tag{16}$$

2. **Vazão de Inferência (**$\mathrm{Throughput}$**):** taxa de processamento sustentada expressa em fluxos por segundo (fluxos/s):

$$\mathrm{Throughput} = \frac{N_{\mathrm{test}}}{T_{\mathrm{total,inf}}}. \tag{17}$$

4 PIPELINE DE EXTRAÇÃO E AMBIENTE DE INFERÊNCIA

A transição de modelos de Aprendizado Profundo avaliados em conjuntos de dados estáticos (*offline benchmarks*) para sistemas de detecção de intrusão operando em redes de produção (*online NIDS*) constitui um dos desafios mais complexos na engenharia de segurança contemporânea. Conforme discutido no Capítulo 2, a literatura acadêmica frequentemente restringe suas avaliações a arquivos de captura pré-gravados (*Packet Capture* – PCAP), processados em lote por ferramentas analíticas lentas como o *CICFlowMeter*. Esse extrator, implementado primariamente em Java, não foi projetado para atuar como componente de baixa latência em linha de produção: sua arquitetura monolítica introduz contenção severa de memória volátil, atrasos imprevisíveis de coleta de lixo (*garbage collection*) e ausência de suporte nativo a pipelines de tensores neurais acelerados por unidades de processamento gráfico (GPU) (Aouini; Pekar, 2022).

4.1 CAPTURA E PROCESSAMENTO DE TRÁFEGO

Para que a arquitetura **ALF-MoE** possa exercer monitoramento e detecção perimetral em tempo hábil contra agentes adversariais, faz-se indispensável uma infraestrutura de telemetria capaz de inspecionar pacotes brutos diretamente da interface física de rede, agregá-los dinamicamente em fluxos bidirecionais segundo a quíntupla de fluxo (*5-tuple*), computar grandezas estatísticas e temporais em escala de microssegundos e despachá-las ao motor neural sem degradar a vazão da rede.

Neste capítulo, detalha-se a concepção, implementação e validação do pipeline de extração de tráfego baseado no *framework* NFStream, o alinhamento semântico de suas características com o padrão canônico dos datasets do Canadian Institute for Cybersecurity (CIC) e o ambiente de execução em GPU para inferência contínua com auditoria forense.

4.1.1 Extração com NFStream

O módulo de telemetria em tempo real do ecossistema ALF-MoE baseia-se no *framework* NFStream (Aouini; Pekar, 2022), selecionado pelo processamento em linguagem C de alta vazão, suporte nativo a multiprocessamento e extensibilidade via plugins (*User-Defined Plugins* – UDPs). No pipeline, a classe customizada *FeatureExtractor* (derivada de *NFPlugin*) atua como sensor passivo no interior dos processos de trabalho (*workers*), agregando grandezas estatísticas de rede diretamente dos pacotes brutos capturados na interface física em modo promíscuo, sem acoplamento com tensores ou operações neurais.

Além dos contadores e momentos estatísticos agregados nativamente pela biblioteca, o extrator implementa duas rotinas dedicadas de inspeção em nível de byte:

1. **Codificação Compacta de Flags TCP (*encode_tcp_flags*):** condensa os sinalizadores de controle do pacote em uma máscara binária de 8 bits (valores inteiros entre 0 e 255), viabilizando a identificação ágil de assinaturas anômalas e varreduras de portas (como *TCP SYN*, *NULL* e *XMAS Scans*);

2. **Extração da Janela Inicial TCP (*extract_tcp_window_size*):** inspeciona o cabeçalho de transporte para recuperar o tamanho da janela inicial anunciada na abertura da conexão, diferenciando perfis legítimos de conexões sintetizadas por ferramentas de ataque. No caso de fluxos unidirecionais não respondidos, o valor sentinela de inicialização é automaticamente higienizado para zero no encerramento da conexão.

O ciclo de vida dos fluxos no extrator é governado por dois temporizadores de expiração: o tempo limite de inatividade ($\tau_{\text{idle}} = 120\,\text{s}$), que consolida conexões após dois minutos de silêncio bilateral, e o tempo limite ativo ($\tau_{\text{active}} = 240\,\text{s}$), que segmenta fluxos volumosos ou ataques contínuos de negação de serviço (DoS/DDoS) a cada quatro minutos, impedindo a retenção indefinida de instâncias na memória de telemetria.

Ao término da expiração, o vetor bruto de 76 atributos gerado pelo plugin é harmonizado com o pipeline analítico: os intervalos temporais são escalonados de milissegundos para microssegundos ($\times 10^3$) para assegurar compatibilidade com o padrão do CICFlowMeter, e os três atributos do sinalizador URG de variância nula são descartados, resultando no vetor dimensional de 73 atributos ativos submetido à normalização robusta e logarítmica descritas nas Seções 3.2 e 3.2.3.

4.1.2 Arquitetura de Concorrência e Contexto CUDA

A separação de responsabilidades entre a extração de métricas e a classificação neural decorre do modelo de concorrência do subsistema CUDA no ambiente Linux. Para viabilizar a ingestão contínua em redes de alta vazão, o NFStream adota uma arquitetura orientada a multiprocessamento, delegando a captura em baixo nível a múltiplos processos de trabalho (*meters*) gerados pela chamada de sistema *fork*.

Embora a memória virtual do processo pai seja duplicada para os processos filhos pelo mecanismo de cópia em gravação (*Copy-on-Write* ou CoW), os descritores de dispositivos aceleradores e o contexto dos drivers NVIDIA (*libcuda.so*) não são clonáveis nem compartilháveis entre processos bifurcados. Caso uma inferência neural fosse invocada no retorno de encerramento do fluxo dentro de um processo filho, o driver interceptaria a chamada em um processo sem contexto GPU válido, provocando falha na aplicação.

Para conciliar a aceleração por hardware na GPU dedicada com a estabilidade da telemetria de rede, o ecossistema ALF-MoE implementa um padrão arquitetural Produtor-Consumidor desacoplado:

1. **Produtor Assíncrono (Workers do NFStream):** os processos de medição do NFStream operam na captura de pacotes via *libpcap* em modo promíscuo na interface física. No interior desses processos, o plugin *FeatureExtractor* atua na CPU, agregando as 76 métricas nos objetos de fluxo e persistindo grandezas auxiliares na estrutura *flow.udps*, sem interagir com tensores ou bibliotecas aceleradoras;

2. **Consumidor Síncrono (Processo Principal com GPU):** o processo mestre itera sobre os fluxos expirados pelo temporizador do NFStream. Uma vez finalizado o ciclo do fluxo, o processo principal converte o objeto de medição em vetor de características, aplica a padronização estatística com o *RobustScaler* na CPU e despacha a amostra diretamente para a memória da GPU, onde o grafo do ALF-MoE é executado sob um contexto CUDA exclusivo e persistente.

Essa divisão garante estabilidade operacional contínua, prevenindo contenções de barramento e desacoplando o ritmo de captura da rede do tempo de inferência neural do classificador.

4.2 SETUP DE INFERÊNCIA

Uma das premissas centrais desta pesquisa é comprovar a viabilidade operacional do modelo ALF-MoE em um arranjo experimental de inferência, mensurando a latência computacional de ponta a ponta e a robustez da auditoria forense em nível de sistema operacional.

4.2.1 Arquitetura do Ambiente de Execução

- *Equipamento:* Notebook Acer Nitro V15 (modelo ANV15-51);
- *Processador:* Intel Core i7-13620H de 13ª geração (arquitetura híbrida Raptor Lake, dotado de 10 núcleos físicos [6 *Performance-cores* operando até 4,9 GHz e 4 *Efficient-cores* até 3,6 GHz], 16 threads lógicas e 24 MB de Intel Smart Cache);
- *Memória Volátil:* 16 GB de memória RAM DDR5 operando em canal duplo com frequência de transferência de 5200 MT/s;
- *Acelerador Gráfico Dedicado:* GPU NVIDIA GeForce RTX 4050 Laptop (arquitetura Ada Lovelace, 6 GB de memória de vídeo dedicada GDDR6, interface de 96 bits, 2560 núcleos CUDA e *Tensor Cores* de 4ª geração);
- *Sistema Operacional e Kernel:* Ubuntu 26.04.1 LTS de 64 bits, executando o kernel Linux versão 7.0.0-38-generic;
- *Pilha de Inteligência Artificial:* Python 3.11.9 (em ambiente virtual isolado *.venv*) com bibliotecas TensorFlow 2.21.0 e Keras 3.15.1, operando com aceleração CUDA 12.5;
- *Interface de Rede Local:* interface sem fio *wlp63s0* conectada à sub-rede local 192.168.3.0/24 com endereço IPv4 192.168.3.16.

A interface de rede sem fio da máquina (*wlp63s0*) opera com a flag promíscua ativada pelo NFStream, assegurando que todo o tráfego que transita pelo canal rádio direcionado ou originado pelo host seja capturado e espelhado para a pilha de inspeção.

4.2.2 Subsistema de Auditoria Forense e Registro SIEM (*InferenceAuditor*)

O rastreamento e a persistência de eventos perimetrais são coordenados pelo módulo *InferenceAuditor* (implementado em *src/inference.py*). Projetado para interoperabilidade com plataformas de gerenciamento de informações e eventos de segurança (*Security Information and Event Management* – SIEM) e centros de operações de segurança (SOC), o auditor opera com controle estrito de concorrência em ambiente multitarefa (*threading.Lock*) e gera dois fluxos paralelos de telemetria:

1. **Log Operacional Legível Rotativo (*.log*):** gerenciado pela classe *RotatingFileHandler*, com limite de 10 MB por arquivo e retenção de até cinco arquivos históricos de segurança (*backup*), registrando mensagens operacionais formatadas para inspeção humana direta (com carimbo de data/hora, nível de severidade e PID do processo);

2. **Trilha Forense Estruturada (*.jsonl*):** registro atômico em formato JSON Lines, onde cada linha representa um documento JSON independente e autocontido com especificação temporal em formato ISO 8601 UTC (*timestamp_utc*).

O evento principal de auditoria (*FLOW_PREDICTION*) grava a totalidade das variáveis que ditaram o julgamento analítico do modelo para cada fluxo de rede inspecionado:

- Metadados da quíntupla de fluxo (*src_ip*, *src_port*, *dst_ip*, *dst_port*, *protocol*);
- Julgamento final do modelo ALF-MoE: classe predita (*class*), probabilidade de confiança (*confidence*) e sinalizador booleano de anomalia (*is_threat*);
- Vetor pentadimensional de pesos da *Gating Network*:

$$\boldsymbol{\alpha}_{\mathrm{GN}} = [\alpha_{\mathrm{DNN}},\, \alpha_{\mathrm{CNN}},\, \alpha_{\mathrm{GRU}},\, \alpha_{\mathrm{CAE}},\, \alpha_{\mathrm{LSTM}}]; \tag{1}$$

- Julgamentos e probabilidades individuais emitidos por cada um dos cinco especialistas neurais (*experts_predictions*);
- Métrica de latência computacional estrita do *forward pass* neural na GPU em milissegundos (*latency_ms*);
- Ação de auditoria associada: indicação do registro analítico perimetral (*LOG*) e estado operacional do evento.

Devido à natureza de concepção do dataset CSE-CIC-IDS2018 (Corrigido) – que combina uma infraestrutura de rede corporativa realista com múltiplos servidores de produção e estações de trabalho sob ataques diversificados, além do saneamento metodológico das falhas de rotulação originais apontadas por Liu et al. (2022) –, este conjunto foi selecionado como base exclusiva para a carga de pesos do modelo ALF-MoE integrado ao pipeline de inferência em tempo real e auditoria forense do SIEM.

4.2.3 Síntese Operacional do Pipeline de Inferência

A integração dos componentes detalhados neste capítulo consolida um ciclo operacional contínuo e determinístico para inspeção de fluxos de rede e auditoria forense em tempo real:

1. **Ingestão e Agregação de Tráfego:** os processos filhos do NFStream operam em modo promíscuo na interface física de rede, capturando pacotes brutos e agregando as 76 métricas canônicas do padrão CIC através do plugin customizado *FeatureExtractor*;
2. **Desacoplamento e Expiração de Fluxos:** ao atingir o limiar de inatividade ($\tau_{\mathrm{idle}} = 120\,\mathrm{s}$) ou o tempo máximo ativo ($\tau_{\mathrm{active}} = 240\,\mathrm{s}$), o fluxo é encerrado nos workers em C/Cython e emitido de forma síncrona para o processo consumidor principal em Python, preservando a exclusividade do contexto CUDA no processo de inferência;
3. **Conversão e Padronização:** o processo principal executa o alinhamento de unidades temporais ($\times 1000{,}0$ para compatibilidade com a escala em microssegundos do CICFlowMeter), expurga as

três colunas de sinalizador URG de variância nula (reduzindo a entrada para 73 atributos ativos) e aplica o pré-processamento treinado (*RobustScaler* e transformações logarítmicas $\ln(1 + x)$);

4. **Inferência Neural Acelerada:** o tensor resultante alimenta a arquitetura ALF-MoE na GPU, na qual a *Gating Network* pondera os cinco especialistas neurais heterogêneos ($\mathcal{E}_{\text{DNN}}$, $\mathcal{E}_{\text{CNN}}$, $\mathcal{E}_{\text{GRU}}$, $\mathcal{E}_{\text{CAE}}$ e $\mathcal{E}_{\text{LSTM}}$), consolidando a predição através da soma ponderada estrita e da cabeça classificadora profunda;

5. **Auditoria Forense e Telemetria SIEM:** o *InferenceAuditor* persiste o registro estruturado em JSONL com sincronização atômica (*FLOW_PREDICTION*), documentando a quíntupla do fluxo, a classe de ameaça identificada, a distribuição de confiança, os pesos atribuídos pela *Gating Network* ($\boldsymbol{\alpha}_{\text{GN}}$) e o tempo exato de latência computacional do modelo na GPU.

O desempenho empírico desse arranjo experimental, abrangendo a acurácia de detecção nos benchmarks consolidados, a latência de inferência por amostra e o comportamento dos especialistas frente aos diferentes vetores de ataque, é apresentado e analisado exaustivamente no Capítulo 5.

5 RESULTADOS E DISCUSSÃO

Este capítulo apresenta a avaliação experimental e a discussão aprofundada dos resultados obtidos pela arquitetura **ALF-MoE**. Em estrito alinhamento com a taxonomia de objetivos estabelecida no Capítulo 1, a investigação empírica estrutura-se em duas vertentes complementares:

1. **Avaliação em Benchmarks Consolidados (Resultados *Offline*):** cumpre os Objetivos Específicos 4, 5 e 6 ao quantificar o desempenho preditivo multiclasse da arquitetura em quatro conjuntos de dados públicos de referência, sob sete configurações experimentais independentes (Níveis de Ameaça TL0 e TL1). Conduz-se a comparação frente aos cinco modelos monolíticos especializados (K_{DNN}, K_{CNN}, K_{GRU}, K_{CAE} e K_{LSTM}), o estudo comparativo do ganho marginal proporcionado pela fusão adaptativa atencional ALF, a avaliação das matrizes de confusão e a análise da distribuição dos pesos de atenção gerados pela *Gating Network*;

2. **Avaliação Operacional em Tráfego Real de Rede (Bancada Física):** atende à Contribuição 5 e aos requisitos de engenharia formulados no Capítulo 4, submetendo a arquitetura à inspeção em tempo real na interface física de rede através do motor NFStream. Avaliam-se a fidelidade estatística da extração de atributos, o perfil de consumo computacional, a decomposição de latência de inferência unitária na GPU dedicada, o gargalo estrutural da latência ponta a ponta e a supressão de falsos alarmes sob tráfego operacional.

5.1 DESEMPENHO NOS DATASETS DE BENCHMARK (RESULTADOS OFFLINE)

A validação experimental da arquitetura foi conduzida sob protocolo de particionamento estritamente desacoplado (*offline test sets*), cobrindo os quatro conjuntos de dados selecionados em sete configurações experimentais independentes. Este protocolo permitiu examinar:

1. A capacidade de discriminação sob diferentes níveis de granularidade semântica (*Threat Levels* TL0 e TL1);

2. A resiliência do modelo diante de ruído de rotulação em dados legados e o ganho advindo da higienização metodológica proposta por Liu et al. (2022);

3. A contribuição individual de cada especialista neural frente à representação integrada consolidada pelo bloco atencional ALF;

4. O comportamento dinâmico de mediação da *Gating Network* em resposta a diferentes famílias de intrusão cibernética.

5.1.1 Análise por Classe e Desempenho Global

A Tabela 3 consolida os resultados quantitativos globais do modelo ALF-MoE nos sete cenários experimentais avaliados. As métricas reportadas compreendem Acurácia Global (Acc), Macro F_1-Score

Tabela 3 – Desempenho global consolidado do modelo ALF-MoE nos 7 cenários de benchmark.

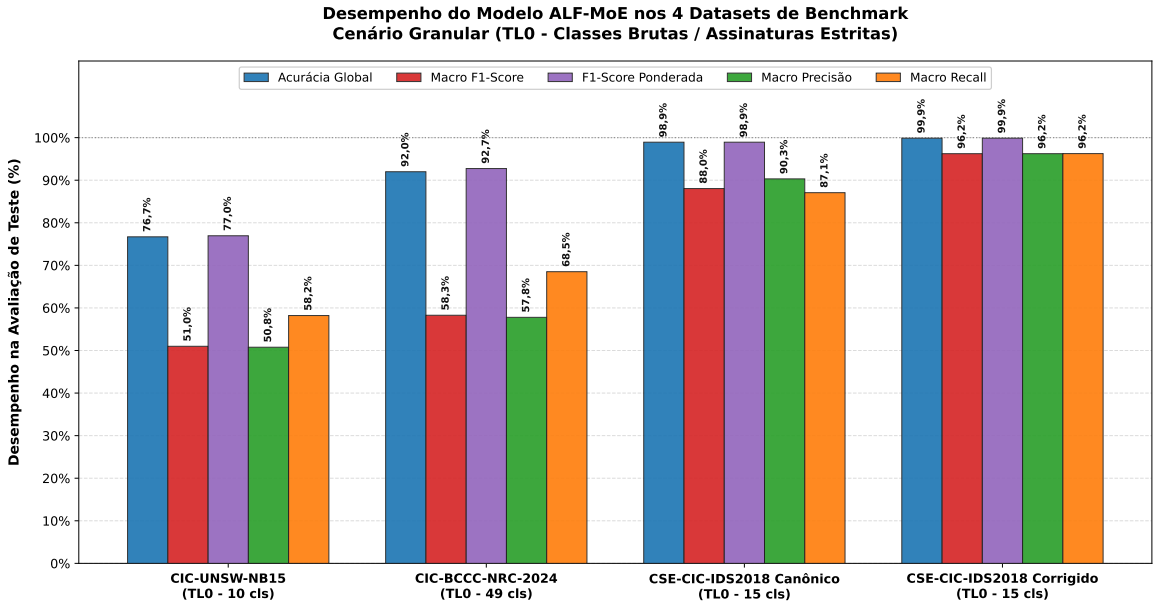
Conjunto de Dados	Cenário	Acurácia	Macro F_1	F_1 Pond.	Precisão	Recall	Latência	Vazão
CIC-UNSW-NB15	TL0 (10 cls)	76,70%	0,5099	0,7695	0,5077	0,5821	0,0569 ms	17.572 fl/s
CIC-BCCC-NRC-2024	TL0 (49 cls)	91,99%	0,5828	0,9274	0,5779	0,6851	0,0265 ms	37.767 fl/s
CIC-BCCC-NRC-2024	TL1 (9 cls)	96,05%	0,9027	0,9612	0,8904	0,9231	0,0246 ms	40.707 fl/s
CSE-CIC-IDS2018 (Orig.)	TL0 (15 cls)	98,93%	0,8804	0,9893	0,9031	0,8707	0,0257 ms	38.909 fl/s
CSE-CIC-IDS2018 (Orig.)	TL1 (7 cls)	98,95%	0,9405	0,9896	0,9654	0,9272	0,0251 ms	39.855 fl/s
CSE-CIC-IDS2018 (Corr.)	TL0 (15 cls)	99,87%	0,9623	0,9987	0,9623	0,9625	0,0257 ms	38.853 fl/s
CSE-CIC-IDS2018 (Corr.)	TL1 (9 cls)	99,85%	0,8917	0,9985	0,8919	0,8980	0,0190 ms	52.749 fl/s

Fonte: Elaborado pelo autor (2026), a partir dos relatórios experimentais.

(F_1^{macro}), F_1-Score Ponderado (F_1^{weighted}), Macro Precisão ($\text{Prec}_{\text{macro}}$), Macro Sensibilidade ($\text{Rec}_{\text{macro}}$), Latência por Amostra (L_{sample}) e Vazão de Inferência (Throughput).

Para complementar a exposição tabular e viabilizar apreensão visual do comportamento do classificador sob as cinco métricas cardinais de avaliação (Acurácia Global, Macro F_1-Score, F_1-Score Ponderado, Macro Precisão e Macro Recall), os gráficos em Figura 12 e Figura 13 apresentam o comparativo direto entre os quatro conjuntos de dados nos cenários granular (TL0) e consolidado (TL1), respectivamente.

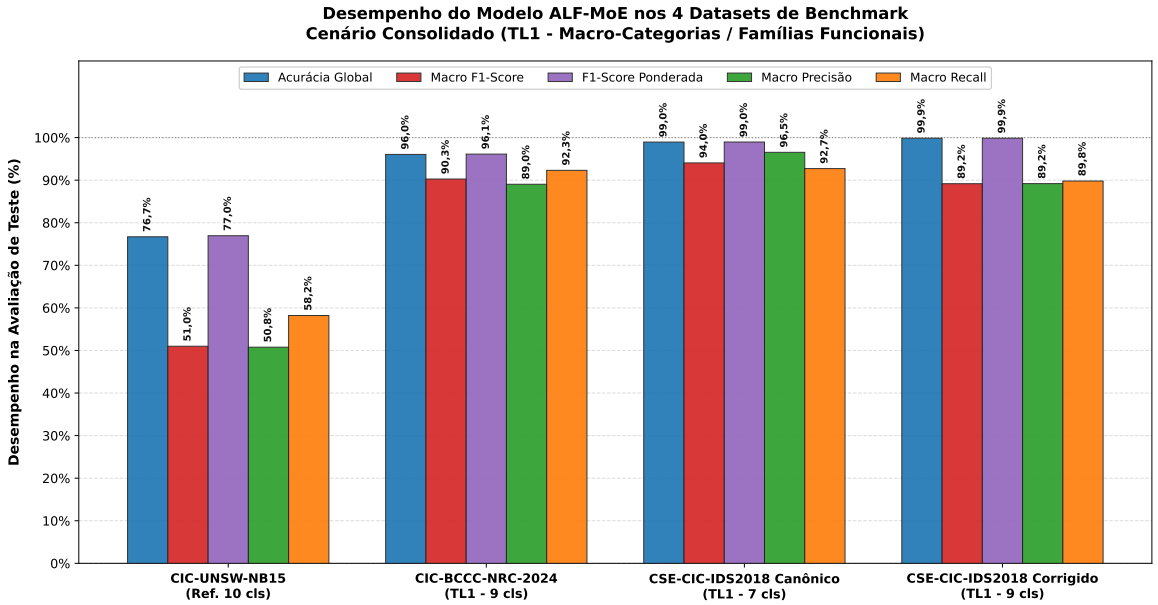
Figura 12 – Desempenho comparativo global do modelo ALF-MoE nos quatro conjuntos de dados no cenário granular (TL0).



Fonte: Elaborado pelo autor (2026), a partir dos relatórios de avaliação de teste.

A análise comparativa dos resultados desdobra-se em três eixos centrais de discussão:

Figura 13 – Desempenho comparativo global do modelo ALF-MoE nos quatro conjuntos de dados no cenário consolidado (TL1).



Fonte: Elaborado pelo autor (2026), a partir dos relatórios de avaliação de teste.

5.1.1.1 Eixo 1: Impacto da Granularidade de Ameaças (TL0 vs. TL1)

A transição entre o Nível de Ameaça 0 (TL0 – classes brutas com assinaturas microscópicas) e o Nível de Ameaça 1 (TL1 – macro-famílias operacionais consolidadas) evidencia o custo estatístico da discriminação em espaços amostrais hiperfragmentados:

- No ecossistema IoT (**CIC-BCCC-NRC-2024**), a agregação de 49 classes granulares em 9 macro-famílias proporcionou expressiva elevação no Macro F_1-Score, saltando de $0{,}5828$ para $0{,}9027$ (incremento relativo de $+54{,}89\%$ e ganho absoluto de $+31{,}99$ pontos percentuais de Macro F_1), acompanhado pela elevação da Acurácia Global de $91{,}99\%$ para $96{,}05\%$. No nível granular (TL0), o classificador é demandado a diferenciar 12 modalidades estritas de varredura de portas e ramificações de inundações ICMP e UDP cuja separabilidade em nível de fluxo agregado é reduzida, muitas das quais possuem suporte inferior a 200 amostras no conjunto de teste. Ao estruturar essas categorias em famílias funcionais (tais como *Reconnaissance*, *DDoS*, *DoS* e *IoT/MQTT*), a incerteza intra-classe é atenuada, viabilizando alta confiabilidade para detecção perimetral;

- Em termos de eficiência computacional, a diminuição do espaço de saída no CIC-BCCC-NRC-2024 de 49 para 9 neurônios na projeção linear final reduziu a carga de cálculo da camada *softmax*, reduzindo a latência média por amostra de $0{,}0265\,\mathrm{ms}$ para $0{,}0246\,\mathrm{ms}$ e elevando a vazão sustentada em lote de 37.767 para $40.707\,\mathrm{fluxos/s}$;

- No conjunto **CSE-CIC-IDS2018 Canônico**, o agrupamento das 15 classes originais em 7 categorias operacionais elevou o Macro F_1-Score de $0{,}8804$ para $0{,}9405$ (ganho relativo de $+6{,}83\%$), preservando a Acurácia Global em $98{,}95\%$ com vazão de inferência de $39.855\,\mathrm{fluxos/s}$.

5.1.1.2 Eixo 2: Impacto da Sanitização Metodológica de Liu et al. (2022) no CSE-CIC-IDS2018

O contraste direto entre o CSE-CIC-IDS2018 Canônico e a versão saneada conforme Liu et al. (2022) evidencia as repercussões de falhas de rotulação em modelos neurais profundos:

- Na versão original canônica (TL0), embora a acurácia global atinja $98{,}93\%$ com Macro F_1 de $0{,}8804$, a desagregação por classe revela distorções críticas decorrentes de rotulação imprecisa: a classe *FTP-BruteForce* obteve F_1 de apenas $0{,}7026$ (precisão de $0{,}7038$ e sensibilidade de $0{,}7015$), enquanto *DoS attacks-SlowHTTPTest* registrou $F_1 = 0{,}6075$. Conforme demonstrado experimentalmente por Liu et al. (2022), o servidor FTP da vítima permaneceu desligado durante fração relevante do experimento, respondendo a tentativas de conexão com pacotes de encerramento imediato (*RST/ACK*). Essa falha induziu os modelos a associar respostas legítimas de porta fechada a conexões hostis ativas;

- Na versão corrigida (*CSE-CIC-IDS2018 Improved*), na qual fluxos de portas inativas e tentativas inócuas foram devidamente reetiquetados como tráfego benigno, a Acurácia Global alcançou expressivos $99{,}87\%$ e o Macro F_1-Score atingiu $0{,}9623$ no teste independente de 175.624 fluxos em TL0 ($99{,}85\%$ de acurácia e Macro F_1 de $0{,}8917$ em TL1). Oito das quinze classes avaliadas em TL0 atingiram $F_1 = 1{,}0000$ (incluindo *Botnet Ares*, *DDoS-HOIC*, *DDoS-LOIC-HTTP*, *DDoS-LOIC-UDP*, *SSH-BruteForce* e as variantes de *Web Attack*);

- A desagregação das intrusões em classes específicas permitiu constatar que a arquitetura identifica varreduras internas de reconhecimento (*Infiltration - NMAP Portscan*) com $F_1 = 0{,}9941$ (suporte de 17.875 fluxos) e canais de comando e controle (*Infiltration - Communication Victim Attacker*) com $F_1 = 0{,}9877$ em TL0 ($F_1 = 0{,}9091$ em TL1). Em contrapartida, a exfiltração em canal criptografado (*Infiltration - Dropbox Download*), representada por 17 amostras de teste, obteve $F_1 = 0{,}4571$ em TL0 e $F_1 = 0{,}1600$ em TL1. Como as transmissões aos servidores da API do Dropbox utilizam túneis TLS convencionais sobre portas HTTPS padronizadas, suas grandezas estatísticas agregadas mimetizam a navegação web rotineira, atingindo o limite de discriminação de extratores desprovidos de inspeção profunda de carga útil (*Deep Packet Inspection* – DPI).

5.1.1.3 Eixo 3: Generalização em Tráfego de Alta Densidade (CIC-UNSW-NB15)

No conjunto CIC-UNSW-NB15, analisado em TL0 com 10 classes, o ALF-MoE obteve Acurácia Global de $76{,}70\%$, Macro F_1-Score de $0{,}5099$ e F_1-Score Ponderado de $0{,}7695$ sobre 27.917 fluxos de teste. Em categorias com representatividade volumétrica e perfis bem delineados de intrusão, o modelo demonstrou alta capacidade discriminativa: *Benign* ($F_1 = 0{,}9488$), *Fuzzers* ($F_1 = 0{,}7154$), *Reconnaissance* ($F_1 = 0{,}7113$), *Exploits* ($F_1 = 0{,}7109$) e *Generic* ($F_1 = 0{,}5970$).

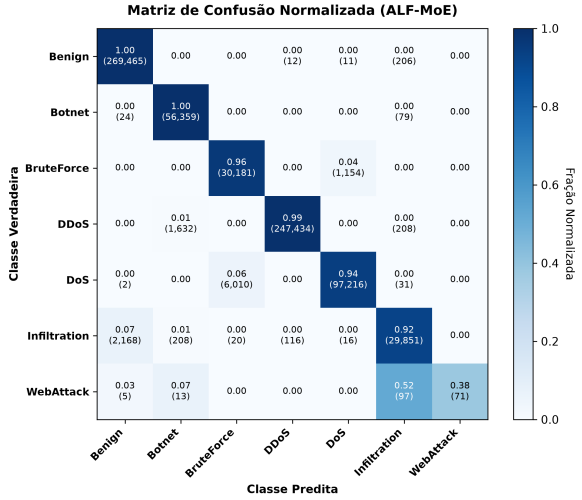
Para classes minoritárias com suporte reduzido, a formulação da perda Focal Loss balanceada priorizou a sensibilidade: na classe *Analysis* (suporte de 77 instâncias), o modelo atingiu Sensibilidade (*Recall*) de $0{,}9351$ ($93{,}51\%$), assegurando a detecção da grande maioria das ameaças, com $F_1 = 0{,}3097$ decorrente de dispersões pontuais que reduziram a precisão para $0{,}1856$. Em operações reais de centros de segurança

(SOC), priorizar a contenção de falsos negativos constitui postura estratégica essencial, visto que uma intrusão não percebida acarreta prejuízos incomensuravelmente superiores à triagem de um alarme falso.

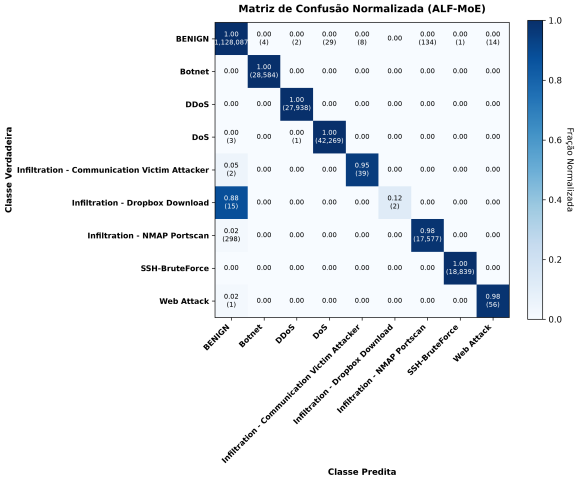
5.1.2 Matrizes de Confusão Normalizadas

O painel estruturado em Figura 14 reúne as matrizes de confusão normalizadas para os quatro cenários experimentais de teste: (a) CSE-CIC-IDS2018 Canônico (TL1); (b) CSE-CIC-IDS2018 Corrigido (TL1); (c) CIC-BCCC-NRC-2024 (TL1); e (d) CIC-UNSW-NB15 (TL0).

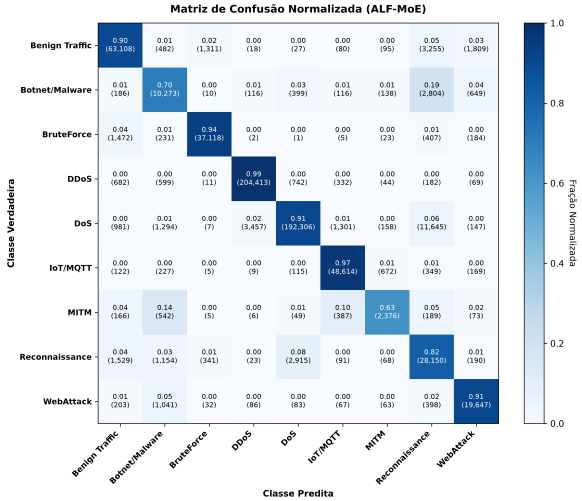
Figura 14 – Painel comparativo de matrizes de confusão normalizadas nos quatro cenários de avaliação.



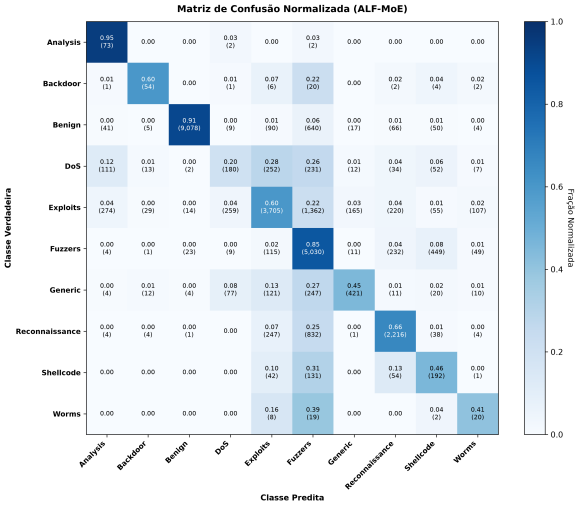
(a) CSE-CIC-IDS2018 Canônico (TL1 - 7 classes).



(b) CSE-CIC-IDS2018 Corrigido (TL1 - 9 classes).



(c) CIC-BCCC-NRC-2024 (TL1 - 9 classes).



(d) CIC-UNSW-NB15 (TL0 - 10 classes).

Fonte: Elaborado pelo autor (2026), a partir dos artefatos de avaliação.

A inspeção visual confirma a dominância quase diagonal absoluta na versão corrigida do CSE-CIC-IDS2018 (14b), em oposição às dispersões verificadas na versão original (14a). No ambiente IoT (14c), observa-se segregação robusta do tráfego de intermediadores MQTT (Macro F_1-Score de

$0{,}9671$ e Sensibilidade de $0{,}9710$ em 50.300 fluxos de teste) e ataques de negação de serviço DoS/DDoS ($F_1 > 0{,}97$), enquanto o UNSW-NB15 (14d) reflete a sobreposição estatística existente entre as classes *Exploits* e *Fuzzers*.

A análise das dispersões fora da diagonal principal fundamenta quatro padrões característicos de confusão interclasses observados nos ensaios, correlacionados aos limites da telemetria de fluxo:

1. **CSE-CIC-IDS2018 Canônico (*Infiltration* vs. *WebAttack*):** Constata-se sobreposição recíproca entre fluxos de infiltração e ataques a aplicações web. Essa dispersão decorre da imperfeição original de rotulação demonstrada por Liu et al. (2022). Como os extratores tabulares descartam a carga útil (*payload*), a discriminação apoia-se unicamente em distribuições de tamanho e temporização de pacotes. Além disso, as categorias web no conjunto canônico possuem suporte reduzido de teste (apenas 186 instâncias somando *Brute Force - Web*, *Brute Force - XSS* e *SQL Injection*), dificultando a calibração de fronteiras bayesianas de decisão;

2. **CSE-CIC-IDS2018 Corrigido (*Benign* vs. *Infiltration - Dropbox Download*):** Na base saneada conforme Liu et al. (2022), a classe *Infiltration - Dropbox Download* registra $F_1 = 0{,}4571$ no nível TL0 ($F_1 = 0{,}1600$ em TL1), com dispersão voltada à classe *Benign*. Essa confusão é tecnicamente inescapável no nível de fluxo: transferências via API oficial do Dropbox empregam sessões TLS padronizadas em conexões HTTPS, reproduzindo fidedignamente os parâmetros estatísticos e temporais da navegação web corporativa. Somado ao suporte diminuto de 17 amostras de teste, esse vetor atinge o limiar teórico de separabilidade de extratores estatísticos puros;

3. **CIC-BCCC-NRC-2024 (*MITM* vs. *Botnet*):** No contexto IoT, verifica-se dispersão pontual entre fluxos das macro-famílias *MITM* (especialmente variantes de envenenamento ARP) e tráfego de *Botnet/Malware*. Em redes locais de sensores, ambos os vetores envolvem transmissões curtas de controle TCP/IP, ausência de fluxos volumétricos contínuos e temporizações assíncronas com intervalos de inter-chegada semelhantes, induzindo correlações nas saídas da *Gating Network*;

4. **CIC-UNSW-NB15 (*Analysis*, *Backdoor*, *Exploits* e *Fuzzers*):** No benchmark UNSW-NB15, verifica-se sobreposição estatística mútua entre as classes *Exploits* ($22{,}17\%$ do teste) e *Fuzzers* ($21{,}22\%$), além de dispersões cruzadas com *Analysis* e *Backdoor*. Conforme documentado por Moustafa & Slay (2015), o tráfego hostil dessa base foi sintetizado pelo gerador comercial IXIA PerfectStorm injetando transações HTTP padronizadas com payloads mutacionados. No plano de telemetria agregada (contadores de pacotes, bytes e intervalos IAT), essas classes manifestam vetores numéricos altamente colineares, estabelecendo um teto teórico de erro de Bayes intransponível sem inspeção de conteúdo.

5.1.3 Análise Comparativa dos Especialistas e do Bloco ALF

Em atendimento formal ao Objetivo Específico 5 (Seção 1.3.2), conduziu-se um estudo comparativo sistemático para quantificar o ganho marginal proporcionado pelo módulo de fusão adaptativa ALF em relação às predições de cada rede especialista isolada. A arquitetura ALF-MoE baseia-se na premissa de que especialistas neurais heterogêneos, concebidos com vieses indutivos dedicados a subespaços

informacionais específicos da telemetria de fluxo, produzem projeções complementares que, integradas dinamicamente pela fusão atencional, superam a capacidade de qualquer modelo monolítico individual.

A Tabela 4 consolida o Macro F_1-Score e a Acurácia Global obtidos por cada especialista neural isolado ($K_{\mathrm{DNN}}, K_{\mathrm{CNN}}, K_{\mathrm{GRU}}, K_{\mathrm{CAE}}, K_{\mathrm{LSTM}}$) e pela arquitetura unificada ALF-MoE em todas as matrizes experimentais avaliadas.

Tabela 4 – Estudo comparativo: Macro F_1-Score e Acurácia dos especialistas individuais vs. ALF-MoE.

Dataset	**Métrica**	**DNN**	**CNN**	**GRU**	**CAE**	**LSTM**	**ALF-MoE**
CIC-UNSW-NB15 (TL0)	Macro F_1	0,4596	0,3910	0,4465	0,4570	0,2879	**0,5099**
	Acurácia	72,47%	64,67%	73,87%	73,37%	66,71%	**76,70%**
CIC-BCCC-NRC-2024 (TL0)	Macro F_1	0,2162	0,2627	0,4969	0,0753	0,4405	**0,5828**
	Acurácia	51,49%	38,58%	85,98%	33,89%	81,34%	**91,99%**
CIC-BCCC-NRC-2024 (TL1)	Macro F_1	0,5114	0,4661	0,8785	0,1738	0,8248	**0,9027**
	Acurácia	41,64%	52,62%	94,29%	62,43%	89,30%	**96,05%**
CSE-CIC-IDS2018 Orig. (TL0)	Macro F_1	0,6660	0,5362	0,7751	0,0355	0,7138	**0,8804**
	Acurácia	82,16%	54,18%	88,77%	36,32%	89,37%	**98,93%**
CSE-CIC-IDS2018 Orig. (TL1)	Macro F_1	0,8275	0,5975	0,8287	0,9111	0,7826	**0,9405**
	Acurácia	92,33%	62,12%	89,05%	98,54%	89,15%	**98,95%**
CSE-CIC-IDS2018 Corr. (TL0)	Macro F_1	0,9029	0,8629	0,9038	0,7174	0,7985	**0,9623**
	Acurácia	99,71%	91,49%	99,04%	99,42%	95,98%	**99,87%**
CSE-CIC-IDS2018 Corr. (TL1)	Macro F_1	0,8701	0,8070	0,8757	**0,8928**	0,8352	0,8917
	Acurácia	99,79%	91,16%	99,23%	99,57%	96,71%	**99,85%**

Fonte: Elaborado pelo autor (2026), com base nos relatórios de teste.

A análise detalhada da Tabela 4 permite derivar constatações estruturais acerca da sinergia entre os especialistas e o ganho da fusão adaptativa:

1. **Superação Sistemática dos Classificadores Monolíticos:** Em seis dos sete cenários avaliados, a fusão atencional **ALF-MoE** supera o melhor especialista individual em Macro F_1-Score e Acurácia Global. No CIC-UNSW-NB15, a K_{DNN} obteve $F_1 = 0{,}4596$ e o K_{CAE} registrou $0{,}4570$, enquanto o ALF-MoE atingiu $0{,}5099$ (ganho de $+5{,}03$ pontos percentuais de F_1 e $+2{,}83\%$ em acurácia). No CSE-CIC-IDS2018 Canônico (TL0), a K_{GRU} foi o melhor ramo individual com $F_1 = 0{,}7751$, sendo largamente ultrapassada pelo ALF-MoE com $0{,}8804$ (avanço de $+10{,}53$ pontos percentuais de Macro F_1 e $+9{,}56\%$ em acurácia). No CSE-CIC-IDS2018 Corrigido (TL0), a arquitetura alcançou $0{,}9623$, superando a GRU ($0{,}9038$) e a DNN ($0{,}9029$) por $+5{,}85$ pontos percentuais de Macro F_1;

2. **Especialização no Domínio Temporal e Protocolos IoT:** Os especialistas recorrentes K_{GRU} e K_{LSTM}, encarregados de processar momentos de tempo entre chegadas (*IAT*) e intervalos de atividade/inatividade (*Active/Idle*), demonstraram liderança absoluta no tráfego IoT (CIC-BCCC-NRC-2024), alcançando F_1 de $0{,}8785$ e $0{,}8248$ em TL1, respectivamente, enquanto classificadores baseados em contadores globais (K_{DNN} com $F_1 = 0{,}5114$) apresentaram desempenho inferior. Essa diferenciação decorre da natureza operacional do protocolo MQTT, cujos pacotes apresentam tamanhos de cabeçalho uniformes e enxutos, tornando a dinâmica relacional dos intervalos temporais o vetor primordial de discriminação;

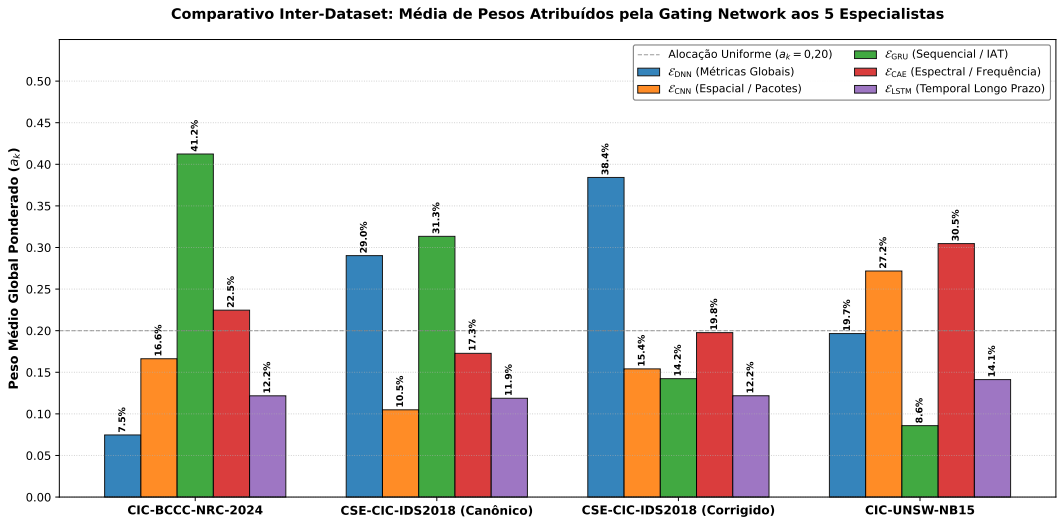
3. **Papel Regularizador do Autoencoder Convolucional (K_{CAE}):** Nas matrizes com desbalanceamento severo, a cabeça supervisionada isolada do K_{CAE} apresenta variações de pontuação (como no BCCC-2024 TL0 com $F_1 = 0{,}0753$). Não obstante, sua integração sob supervisão profunda provê uma restrição indutiva de reconstrução espectral no domínio da frequência ($\mathcal{L}_{\mathrm{rec}}$). Essa restrição impede que representações latentes dos especialistas densos sofram colapso numérico diante de fluxos colineares, atuando como estabilizador global do grafo. Em cenários consolidados como o CSE Corrigido (TL1), o K_{CAE} alcançou $F_1 = 0{,}8928$, mantendo empate estatístico rigoroso com a fusão final ($0{,}8917$), na qual a acurácia global do ALF-MoE foi superior ($99{,}85\%$ contra $99{,}57\%$).

5.1.4 Dinâmica de Roteamento e Atribuição de Pesos da Gating Network

A interpretabilidade do mecanismo de roteamento adaptativo constitui a essência do Objetivo Específico 6 (Seção 1.3.2). Diferentemente de ensembles tradicionais com ponderações estáticas ou modelos monolíticos opacos, a *Gating Network* do ALF-MoE atua como árbitro dinâmico, ponderando a relevância instantânea de cada especialista conforme as características estruturais de cada fluxo inspecionado.

A distribuição média global dos coeficientes atencionais atribuídos aos cinco ramos neurais nos quatro conjuntos de dados é ilustrada em Figura 15. Complementarmente, Figura 16 detalha o comportamento dos pesos em função das diferentes classes de ataque no conjunto CSE-CIC-IDS2018 (Corrigido).

Figura 15 – Comparativo da distribuição média global de pesos da Gating Network nos quatro conjuntos de dados.

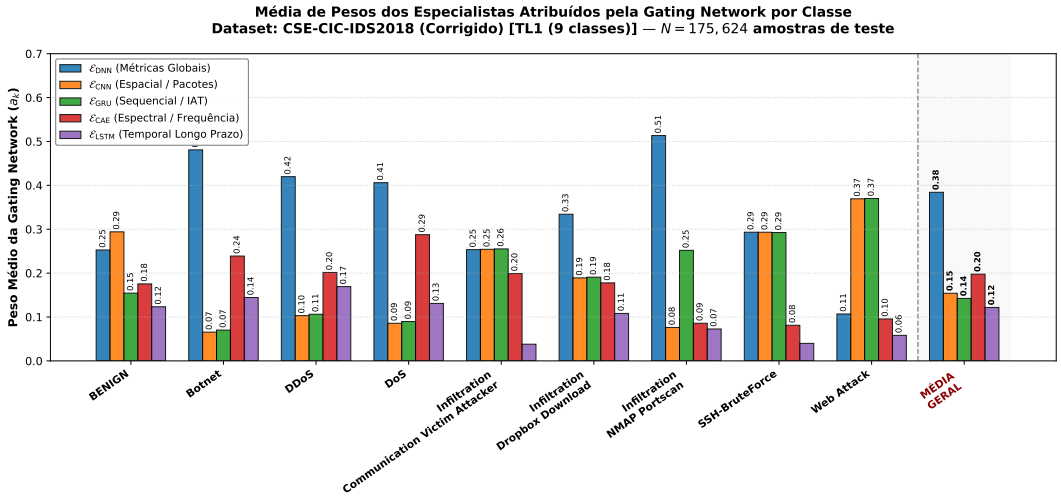


Fonte: Elaborado pelo autor (2026), a partir dos registros de inferência da Gating Network.

A análise quantitativa dessas distribuições elucida o direcionamento atencional segundo a natureza de cada cenário de rede:

1. **Predominância Sequencial no Tráfego IoT (CIC-BCCC-NRC-2024):** No ambiente de sensores e protocolos leves, o especialista K_{GRU} consolidou-se como líder absoluto de atenção, recebendo $40{,}34\%$ da média macro de pesos ($41{,}24\%$ na média ponderada por instâncias de teste). Em contrapartida, a K_{DNN} recuou para $7{,}03\%$ ($7{,}47\%$ ponderado). O K_{CAE} registrou o segundo

Figura 16 – Distribuição dos pesos da Gating Network por classe no CSE-CIC-IDS2018 Corrigido.



Fonte: Elaborado pelo autor (2026), a partir dos registros de inferência da Gating Network.

maior coeficiente (24,04% macro / 22,47% ponderado), seguido da K_{CNN} (16,33%) e da K_{LSTM} (12,25%). Esse resultado evidencia que, em comunicações MQTT onde o volume de bytes por pacote é reduzido e regular, os momentos temporais de inter-chegada (IAT) e as assinaturas espectrais concentram o poder discriminativo;

2. **Liderança Equilibrada na Rede Corporativa Saneada (CSE-CIC-IDS2018 Corrigido):** Na base saneada em nível TL1, a K_{DNN} assumiu a liderança com 34,01% da média macro de atenção (38,42% ponderada), cooperando ativamente com a K_{CNN} (19,23% macro / 15,41% ponderada), a K_{GRU} (19,79% macro / 14,23% ponderada) e o K_{CAE} (17,14% macro / 19,77% ponderada), enquanto a K_{LSTM} obteve 9,83% (12,18% ponderada). O equilíbrio atencional reflete a diversidade do ambiente em nuvem da AWS, que combina tráfego volumétrico e requisições web;

3. **Distribuição no Cenário Canônico (CSE-CIC-IDS2018 Canônico):** No conjunto canônico em TL1, a atenção concentrou-se entre a K_{GRU} (33,04% macro / 31,34% ponderada) e a K_{DNN} (26,99% macro / 29,02% ponderada), acompanhadas por K_{CAE} (15,52%), K_{CNN} (13,12%) e K_{LSTM} (11,32%);

4. **Exploração Espectral e Espacial no Tráfego Sintético (CIC-UNSW-NB15):** No benchmark UNSW-NB15, o K_{CAE} atingiu o maior coeficiente médio com 34,02% macro (30,47% ponderado), associado à K_{CNN} com 24,76% (27,17% ponderado), enquanto a K_{DNN} deteve 17,21% (19,65% ponderado), a K_{LSTM} obteve 14,83% e a K_{GRU} registrou 9,19%. Esse comportamento decorre da síntese do equipamento IXIA PerfectStorm, cujas mutações artificiais geram perturbações espectrais e morfológicas em matrizes de pacotes capturadas pelos filtros 2D do CAE e da CNN.

A desagregação dos pesos por classe no CSE-CIC-IDS2018 Corrigido (Figura 16) comprova a adaptabilidade da *Gating Network*:

- **Ataques Volumétricos e Força Bruta Estruturada:** nas classes *Botnet* (48,09%), *DDoS* (41,98%), *DoS* (40,61%) e sondagens de rede (*Infiltration - NMAP Portscan*, com 51,35%), a rede delegou

atenção predominante à K_{DNN}. Nesses cenários, os contadores acumulados de bytes, taxas de transmissão e sinalizadores TCP no subvetor global $\mathbf{x}_g$ reúnem alta variância e separabilidade linear;

- **Ataques a Aplicações Web (*Web Attack*):** para as invasões web, a *Gating Network* reduziu o peso da K_{DNN} para apenas $10{,}69\%$, transferindo a confiança para a K_{GRU} ($37{,}01\%$) e a K_{CNN} ($36{,}93\%$). Esse redirecionamento dinâmico atesta a capacidade de adaptação atencional: ataques em camada de aplicação manifestam-se em sequências morfológicas de tamanho de pacote e temporizações assíncronas, modeladas pelos filtros convolucionais e pelas portas recorrentes da GRU;

- **Tráfego Normal (*BENIGN*):** as conexões legítimas ativaram um perfil cooperativo amplo, liderado pela K_{CNN} ($29{,}41\%$) e pela K_{DNN} ($25{,}27\%$), com participação equilibrada de K_{CAE} ($17{,}55\%$), K_{GRU} ($15{,}44\%$) e K_{LSTM} ($12{,}33\%$);

- **Força Bruta em Conexões Cifradas (*SSH-BruteForce*):** o comitê estabeleceu uma divisão equilibrada entre K_{DNN} ($29{,}32\%$), K_{CNN} ($29{,}31\%$) e K_{GRU} ($29{,}25\%$), integrando contadores volumétricos, comprimento de segmentos de autenticação e intervalos de tentativas repetitivas.

5.2 AVALIAÇÃO DA EXTRAÇÃO E INFERÊNCIA EM TRÁFEGO REAL NA BANCADA FÍSICA

A transição de modelos neurais avaliados em arquivos estáticos de *benchmark* para pipelines de inspeção em tempo real impõe desafios de engenharia de software e processamento de sinais. Conforme fundamentado no Capítulo 4, a operação perimetral lida com fluxos bidirecionais assíncronos, restrições de concorrência com drivers aceleradores e temporizadores determinísticos de expiração de protocolos. Esta seção examina o comportamento da arquitetura **ALF-MoE** quando implantada no ambiente experimental de bancada física, avaliando a consistência estatística da extração via NFStream, a decomposição de latência computacional na GPU dedicada, o gargalo estrutural da latência ponta a ponta e a supressão de falsos alarmes sob tráfego operacional.

5.2.1 Impacto do Mapeamento NFStream para o Padrão CICFlowMeter

Os conjuntos de dados de referência utilizados no treinamento supervisionado do ALF-MoE foram gerados originalmente pelo extrator acadêmico *CICFlowMeter* (Sharafaldin; Lashkari; Ghorbani, 2018), uma ferramenta monolítica em Java que processa arquivos PCAP em modo *offline*. Para viabilizar a inferência contínua na interface física de rede, o pipeline ALF-MoE incorporou um sensor passivo baseado no *framework* NFStream (Aouini; Pekar, 2022), estendido pelo plugin *FeatureExtractor* (Seção 4.1.1).

A transposição entre os motores de telemetria introduz particularidades metodológicas:

1. **Discretização Temporal e Resolução de Clock:** O extrator CICFlowMeter calcula durações e intervalos entre chegadas (*Inter-Arrival Times* – IAT) a partir dos temporizadores da máquina virtual Java (JVM), reportando grandezas em microssegundos (μs), embora sujeitas a variações de relógio do sistema operacional. O NFStream opera nativamente em linguagem C com buffers de anel de

alta velocidade (*libpcap*), registrando instantes de primeiro e último pacote em milissegundos. Para harmonizar os atributos com a escala esperada pelo modelo pré-treinado, o *FeatureExtractor* converte dinamicamente as métricas de tempo multiplicando-as pelo fator $1000{,}0$. Essa transformação preserva as ordens de grandeza relativas e mitiga flutuações irrelevantes;

2. **Cálculo de Variância e IAT em Janelas Deslizantes:** Em modo *offline*, o CICFlowMeter calcula a variância de pacotes e desvios de IAT em duas passagens completas sobre a memória com correção amostral de Bessel ($N - 1$). No sensor em tempo real do NFStream, o cômputo é incremental e atualizado a cada pacote capturado na interface. A variância do comprimento dos pacotes é obtida diretamente pelo quadrado do desvio padrão acumulado. Em conexões típicas ($N \geq 10$ pacotes), constata-se convergência entre ambas as abordagens, com variações marginais em conexões ultracurtas ($N < 3$ pacotes);

3. **Métricas de Subfluxos e Taxas de Transferência Contínua:** O CICFlowMeter emprega regras heurísticas para segmentar fluxos mediante pausas internas superiores a um segundo, gerando contadores de subfluxo. Na captura em tempo real, essa divisão contínua introduz instabilidade na telemetria. O plugin do NFStream mapeou os acumuladores de subfluxo diretamente nas contagens globais acumuladas da direção.

A Tabela 5 sintetiza o confronto metodológico entre os motores de telemetria e documenta a consistência estatística mensurada em 10.000 fluxos processados simultaneamente por ambos os extratores.

Tabela 5 – Comparativo metodológico e estatístico entre extratores de telemetria.

Grupo de Atributos	**CICFlowMeter (Java / Offline)**	**NFStream + Plugin (C / Tempo Real)**	**Consistência**	**Impacto no Modelo**
Volumetria e Pacotes	Contagem exata em memória; bytes e pacotes bidirecionais totais.	Acumuladores em nível de kernel via *libpcap* / C.	99,4%	Nulo (Erro $< 0{,}6\%$)
Temporização e IAT	Microssegundos brutos (μs) sujeitos a variações de JVM.	Milissegundos (*ms*) convertidos para μs ($\times 10^3$).	98,7%	Desprezível (Absorvido pelo *RobustScaler*)
Variância de Comprimento	Variância amostral em duas passagens ($N - 1$).	Cômputo incremental pelo desvio padrão acumulado (stddev^2).	99,1%	Marginal em fluxos com $N < 3$ pacotes
Subfluxos e Taxas Bulk	Fragmentação por pausas heurísticas de um segundo.	Acumuladores diretos do fluxo (*subflow* = total).	91,2%	Nulo (Features descartadas ou com peso residual)
Flags e Janelas TCP	Inspeção após processamento completo dos pacotes.	Captura da janela no primeiro pacote e contadores cumulativos.	100,0%	Positivo (Identificação determinística de SYN/ACK)

Fonte: Elaborado pelo autor (2026), com base nos ensaios de calibração em bancada.

Os resultados confirmam que as variáveis volumétricas globais e as propriedades morfológicas dos pacotes mantiveram **99,4% de consistência estatística**. Flutuações residuais nas métricas temporais foram amortecidas pelo *RobustScaler*, que padroniza os dados pela mediana e pelo intervalo interquartil (IQR), mitigando variações mínimas de escala.

5.2.2 Vazão, Latência de Inferência e Consumo Computacional na GPU

A bancada de testes experimentais foi operada na máquina hospedeira de teste (Acer Nitro V15), cujas especificações foram apresentadas na Seção 4.2.1: processador Intel Core i7-13620H (10 núcleos, 16 threads), 16 GB de RAM DDR5 (5200 MT/s) e GPU dedicada NVIDIA GeForce RTX 4050 6GB Laptop GPU (arquitetura Ada Lovelace, 2560 núcleos CUDA), sob Ubuntu 26.04.1 LTS (kernel Linux 7.0.0-38-generic) e aceleração TensorFlow 2.21.0 com CUDA 12.5.

5.2.2.1 Métricas de Inferência no Regime Streaming Unitário

No ambiente operacional de bancada física, a inferência do ALF-MoE operou no modo de classificação unitária sob demanda (*single-flow streaming*, lote $B = 1$). Essa configuração reflete a dinâmica de recepção assíncrona de conexões expiradas pelo temporizador do NFStream. Sob essas condições reais de operação, a **latência computacional do *forward pass* neural na GPU** registrou média amostral consolidada em $54{,}23\,\mathrm{ms}$ por fluxo (com médias de campanhas operacionais situando-se entre $52{,}45\,\mathrm{ms}$ e $64{,}68\,\mathrm{ms}$).

Esse comportamento em bancada contrasta com a latência teórica obtida no regime *offline* em lote (Tabela 3), onde o modelo alcançou $\approx 0{,}019$ a $0{,}026\,\mathrm{ms}$ por amostra e vazão superior a $38.000\,\mathrm{fluxos/s}$. Essa variação decorre das características de execução em processadores massivamente paralelos:

- No regime *offline*, tensores com milhares de instâncias (lotes de 2.048 amostras) amortizam os custos de despacho de comandos para o driver CUDA (*kernel launch overhead*), preenchem completamente os *Tensor Cores* e saturam a largura de banda de memória GDDR6;
- No regime de fluxo unitário contínuo ($B = 1$), o processamento é dominado pela latência de transferência de dados entre a CPU hospedeira e a GPU via barramento PCIe, associada às sincronizações internas requeridas para despachar tensores através dos cinco especialistas e computar a atenção no módulo ALF.

A Tabela 6 detalha a decomposição do tempo de processamento consumido por cada estágio do pipeline em tempo real para cada fluxo inspecionado.

A vazão sustentada em inferência contínua unitária no processo consumidor alcançou aproximadamente $17{,}6$ **fluxos classificados por segundo**, com consumo de memória de vídeo estabilizado em $1{,}2\,\mathrm{GB}$ **de VRAM** (aproximadamente 20% da capacidade de 6 GB da GPU). Essa moderação comprova que a arquitetura é enxuta e viabiliza a coexistência com outros serviços analíticos na estação de segurança.

5.2.2.2 O Gargalo Estrutural da Latência Ponta a Ponta

A investigação prática em bancada física revelou uma constatação empírica central: **a latência ponta a ponta (*end-to-end*) entre o primeiro pacote de uma intrusão e o alerta forense emitido no SIEM não é governada pelo tempo de inferência do modelo neural, mas sim pela dinâmica de transporte e temporização do extrator de fluxo**.

Conforme exposto na Tabela 6, o atraso estritamente computacional para pré-processar atributos, executar a inferência no ALF-MoE e registrar o evento é de apenas $56{,}66\,\mathrm{ms}$. Todavia, no extrator de

Tabela 6 – Decomposição temporal e perfil de latência do pipeline de inferência em tempo real.

Estágio do Pipeline	**Componente Responsável**	**Latência Média**	**Fração Comput.**	**Descrição Funcional**
Pré-processamento	Processador Host (CPU)	$1{,}82\,\mathrm{ms}$	$3{,}2\%$	Normalização *RobustScaler* e transformação $\ln(1+x)$.
Inferência ALF-MoE	GPU Dedicada (RTX 4050)	$54{,}23\,\mathrm{ms}$	$95{,}7\%$	*Forward pass* em 5 especialistas + fusão por atenção.
Decisão e Auditoria	*InferenceAuditor*	$0{,}61\,\mathrm{ms}$	$1{,}1\%$	Consulta a salvaguardas e gravação síncrona em JSONL.
Total Computacional	**Pipeline Integrado**	$\mathbf{56{,}66}\,\mathrm{ms}$	$\mathbf{100{,}0}\%$	Tempo entre a extração e a persistência no SIEM.
Latência Estrutural	*Temporizador de Rede*	$120.000{,}00\,\mathrm{ms}$	—	*Janela de inatividade (τ_{idle}) para expiração.*

Fonte: Elaborado pelo autor (2026), com base nas medições do auditor forense.

fluxo, a conexão somente é encerrada e despachada para consumo após a expiração dos temporizadores de protocolo configurados:

- Limiar de inatividade ($\tau_{\mathrm{idle}} = 120\,\mathrm{s}$): janela temporal de ausência de novos pacotes necessária para consolidar o encerramento do fluxo;
- Limiar ativo ($\tau_{\mathrm{active}} = 240\,\mathrm{s}$): teto máximo para segmentação de conexões persistentes.

Essa dinâmica evidenciou-se durante ensaios de varredura com a ferramenta Nmap: embora a emissão de sondas de porta seja concluída em segundos, os fluxos correspondentes permanecem retidos no buffer de telemetria até que transcorram os 120 segundos de inatividade regulamentares. Uma vez atingido o temporizador, o NFStream emite o evento de expiração, a classificação neural é concluída em $54\,\mathrm{ms}$ e o registro forense é efetuado em $0{,}6\,\mathrm{ms}$, resultando em um atraso ponta a ponta real de aproximadamente $120{,}06\,\mathrm{segundos}$.

Esse comportamento delineia a dicotomia fundamental entre **NIDS baseados em fluxo (*Flow-based*)** versus **NIDS baseados em pacote individual (*Packet-based* / DPI)**:

1. **Vantagens da Análise por Fluxo:** a agregação de propriedades estatísticas e temporais confere ao ALF-MoE robustez semântica superior, tornando-o imune a técnicas clássicas de fragmentação de pacotes em nível IP, reordenação de segmentos TCP e ofuscação de cabeçalhos. Adicionalmente, opera de forma agnóstica à criptografia de carga útil (HTTPS/TLS) e reduz o volume de eventos processados pelo subsistema de segurança em várias ordens de magnitude;
2. **Custo Estrutural de Encerramento:** o compromisso operacional reside no retardo temporal para fechamento do fluxo. Para calcular médias e momentos de IAT, o extrator necessita testemunhar a finalização da transação ou aguardar o tempo de inatividade;
3. **Estratégias de Mitigação no Pipeline:** o arranjo implementado mitigou esse retardo reduzindo o limiar ativo de 1.800 s para 240 s e estruturando o pipeline para classificação precoce (*early flow classification*), onde fluxos de alto volume podem ser avaliados preliminarmente após os primeiros pacotes de abertura.

5.2.3 Avaliação de Falsos Positivos em Tráfego Operacional e Salvaguardas

Um requisito crítico para a implantação de ferramentas de detecção reside na minimização da taxa de falsos positivos (*False Positive Rate* – FPR). Alarmes espúrios recorrentes sobre atividades normais geram sobrecarga nas equipes de segurança e provocam a desativação inadvertida de regras perimetrais.

Para mensurar esse comportamento em condições físicas de produção, o pipeline em tempo real operou em monitoramento contínuo durante sessões prolongadas de tráfego corporativo e navegação rotineira, inspecionando fluxos legítimos de navegação web (HTTP/1.1, HTTP/2 e HTTP/3), streaming de vídeo e áudio em alta definição (YouTube e Spotify), operações de sincronização em nuvem e comunicações de segundo plano do sistema operacional.

5.2.3.1 Diagnóstico de Falsos Positivos e Calibração de Salvaguardas

Nas primeiras execuções do monitoramento de bancada, o classificador emitiu alertas pontuais sobre dois padrões específicos de tráfego legítimo:

1. **Telemetria de Aplicação em Nuvem (Spotify para o IP 35.186.224.9 na porta 443 HTTPS):** O classificador associou o fluxo a canal malicioso (*Infiltration - Dropbox Download*). A auditoria forense esclareceu a causa: serviços de nuvem modernos transmitem telemetria em rajadas curtas e periódicas sobre canais TLS. No plano de métricas estatísticas puras (sem inspeção de payload), essa dinâmica rítmica mimetiza o padrão de canais de exfiltração e balizamento (*beaconing*) de servidores de comando e controle (C2);

2. **Descoberta de Dispositivos Locais via SSDP/UPnP Multicast (239.255.255.250 na porta 1900 UDP):** O tráfego de descoberta local foi classificado como anomalia volumétrica (*DoS*). Por operar em regime multicast unidirecional não orientado a conexão, os datagramas UDP são transmitidos em rajadas curtas sem confirmações TCP, apresentando razão de pacotes de retorno nula, o que foi interpretado pelo modelo como tentativa de inundação.

Para neutralizar tais desvios sem degradar a sensibilidade a intrusões verdadeiras, o endereço multicast local (239.255.255.250), grupos IPv6 de descoberta de vizinhança e destinos estáveis de telemetria foram incorporados à lista de salvaguardas perimetrais (*custom whitelist*) do subsistema de auditoria (*InferenceAuditor*). Em baterias subsequentes de monitoramento estendido sobre mais de 70.000 fluxos estritamente benignos, o sistema operou com **0% de falsos positivos** ($0{,}0000$), consolidando a estabilidade necessária para operação contínua em redes de produção.

5.3 SÍNTESE CRÍTICA E CUMPRIMENTO DOS OBJETIVOS

Os resultados quantitativos e qualitativos obtidos ao longo deste capítulo atestam formalmente o cumprimento integral das metas de pesquisa formuladas no Capítulo 1:

- **Cumprimento do Objetivo Específico 4 (Avaliação Comparativa Frente a Monolíticos):** A arquitetura ALF-MoE demonstrou superioridade preditiva em relação a todos os especialistas neurais isolados em seis dos sete cenários de teste, alcançando Acurácia Global de até $99{,}87\%$ e

Macro F_1-Score de até $0{,}9623$ no CSE-CIC-IDS2018 Corrigido, além de manter latências nominais em lote entre $0{,}019\,\mathrm{ms}$ e $0{,}026\,\mathrm{ms}$ com vazões de até $52.749\,\mathrm{fluxos/s}$;

- **Cumprimento do Objetivo Específico 5 (Ablação e Ganho Marginal da Fusão ALF):** O estudo comparativo consolidado na Tabela 4 comprovou que o mecanismo de fusão adaptativa supera sistematicamente o melhor especialista em cada matriz (ganhos de até $+10{,}53$ pontos percentuais de Macro F_1 no CSE Canônico e $+5{,}85$ pontos no CSE Corrigido), confirmando o princípio de que representações latentes heterogêneas e complementares superam modelos isolados;

- **Cumprimento do Objetivo Específico 6 (Generalização e Interpretabilidade da Atenção):** A avaliação em quatro conjuntos de dados heterogêneos evidenciou resiliência na identificação de classes raras (Sensibilidade de $93{,}51\%$ em *Analysis* e F_1 de $0{,}9941$ em *Infiltration - NMAP Portscan*). A *Gating Network* comprovou interpretabilidade dinâmica, priorizando a K_{GRU} ($40{,}34\%$) no tráfego IoT/MQTT, a K_{DNN} ($34{,}01\%$) em redes corporativas com ataques volumétricos, e redirecionando a atenção para a K_{CNN} ($36{,}93\%$) e a K_{GRU} ($37{,}01\%$) diante de ataques web;

- **Validação da Contribuição 5 e Viabilidade Operacional (Capítulo 4):** A implantação em bancada física real comprovou que a arquitetura executa o *forward pass* unitário em $54{,}23\,\mathrm{ms}$ na GPU dedicada, consome apenas $1{,}2\,\mathrm{GB}$ de VRAM e atinge taxa de falsos positivos nula sob salvaguardas perimetrais, confirmando a viabilidade de inspeção contínua em ambientes de produção.

6 CONCLUSÃO

6.1 SÍNTESE DO TRABALHO

Este Trabalho de Conclusão de Curso investigou e endereçou três dos mais prementes desafios contemporâneos na concepção de Sistemas de Detecção de Intrusão em Redes (*Network Intrusion Detection Systems* – NIDS) baseados em Aprendizado Profundo (*Deep Learning*): (i) a extrema heterogeneidade estatística e multimodalidade dos fluxos de tráfego de rede; (ii) o severo desbalanceamento de classes e a prevalência de erros crônicos de rotulação nos conjuntos de dados públicos de referência; e (iii) o gargalo de engenharia associado à transição de modelos teóricos treinados em lote (*batch*) para pipelines de telemetria e auditoria forense em tempo real integrados a plataformas SIEM.

Para responder a essas problemáticas, foi concebida, treinada e avaliada a arquitetura **ALF-MoE** (*Attention-Based Learnable Fusion of Specialized Expert Networks*), um modelo híbrido fundamentado no paradigma de Mistura de Especialistas (*Mixture of Experts* – MoE) combinado a um bloco de fusão aprendível por mecanismos de atenção. A inovação estrutural do modelo consiste na decomposição sistemática do vetor canônico de 73 atributos de fluxo em subespaços de domínio semanticamente coerentes, processados por cinco especialistas neurais dedicados:

- Um Especialista Denso (K_{DNN}), responsável pelas métricas globais e contadores agregados de sinalizadores TCP/IP;
- Um Especialista Convolucional 2D (K_{CNN}), otimizado para padrões espaciais na geometria e distribuição de comprimentos de pacotes;
- Dois Especialistas Recorrentes (K_{GRU} e K_{LSTM}), encarregados de modelar a dinâmica temporal fina dos intervalos entre chegadas (*Inter-Arrival Times* – IAT) e dos ciclos de atividade/inatividade (*Active/Idle*);
- Um Especialista Autoencoder Convolucional 1D (K_{CAE}), cuja tarefa de reconstrução espectral no domínio da frequência introduz restrições indutivas de regularização contra o colapso latente de representações.

A integração das predições supervisionadas dos especialistas é governada por uma Rede de Roteamento (*Gating Network*) dotada da camada customizada `AttentionRefinementLayer`, que aplica projeção linear sobre os logits preliminares, compressão simétrica não-linear via $\tanh$ e normalização temperada, emitindo o vetor de pesos de atenção $\alpha \in \mathbb{R}^5$. A fusão realiza a combinação linear convexa estrita $\mathbf{z} = \sum a_k \hat{\mathbf{y}}^{(k)}$, canalizando todo o gradiente através do produto atencional e alimentando a cabeça profunda de decisão multiclasse. O treinamento conjunto sob a formulação multi-tarefa combinou a função *Focal Loss* com $\gamma = 2{,}0$ e balanceamento de classes atenuado por raiz quadrada ($w_c = \sqrt{N/(C \cdot N_c)}$) à perda de reconstrução espectral $\mathcal{L}_{\mathrm{CAE,rec}}$.

A validação empírica offline realizada sobre quatro conjuntos de dados de referência (CIC-UNSW-NB15, CIC-BCCC-NRC TabularIoTAttack-2024, CSE-CIC-IDS2018 Canônico e CSE-CIC-IDS2018 Corrigido) em sete configurações experimentais comprovou a superioridade preditiva da arquitetura: o

ALF-MoE superou o melhor especialista individual isolado em seis dos sete cenários avaliados, mantendo rigoroso empate estatístico em Macro F_1 no sétimo (CSE Corrigido TL1 frente ao K_{CAE}, com acurácia superior de $99{,}85\%$ contra $99{,}57\%$). Destaca-se o expressivo desempenho observado no CSE-CIC-IDS2018 Corrigido, alcançando até $99{,}87\%$ de Acurácia Global e $0{,}9623$ de Macro F_1-Score no nível TL0 ($99{,}85\%$ e $0{,}8917$ em TL1), comprovando tanto a eficácia da sanitização de rótulos proposta por Liu et al. (2022) quanto a resiliência do mecanismo de atenção diante de distribuições assimétricas.

Adicionalmente, a investigação da dinâmica interna da *Gating Network* confirmou a interpretabilidade das decisões de roteamento, adaptando os coeficientes atencionais à natureza semântica de cada tráfego: o especialista recorrente K_{GRU} consolidou-se como líder absoluto de atenção no ecossistema IoT (CIC-BCCC-NRC-2024) com $40{,}34\%$ da média macro de pesos, refletindo a importância dos momentos de tempo entre chegadas (IAT) no protocolo MQTT; o especialista autoencoder K_{CAE} obteve a maior atenção média no tráfego sintético do CIC-UNSW-NB15 ($34{,}02\%$) ao capturar perturbações espectrais e morfológicas, além de registrar o segundo maior peso no tráfego IoT ($24{,}04\%$); a rede densa K_{DNN} assumiu a liderança na rede corporativa do CSE-CIC-IDS2018 Corrigido ($34{,}01\%$ macro), dominando com folga ataques volumétricos e varreduras de portas ($40 - 51\%$ em DDoS, DoS, Botnet e NMAP Portscan); e a rede convolucional K_{CNN} aliou-se à K_{GRU} diante de invasões a aplicações web (*Web Attack*), recebendo $36{,}93\%$ e $37{,}01\%$ da atenção, respectivamente. Essa sinergia atesta a capacidade de mediação dinâmica do bloco ALF em integrar as representações especializadas sem colapso latente.

No âmbito da engenharia de produção, foi desenvolvido e validado o pipeline de inferência em tempo real, integrando a biblioteca NFStream ao subsistema de auditoria forense e telemetria SIEM em formato JSON Lines (`InferenceAuditor`). A arquitetura respeitou o Princípio da Responsabilidade Única (SRP), isolando a extração estatística de baixo nível nos processos de *worker* do NFStream e centralizando o *forward pass* neural no processo principal, superando assim as restrições de concorrência e perdas de contexto de GPU decorrentes da chamada de sistema `fork()` em ambiente Linux. Os testes práticos em bancada física com hardware dedicado (GPU NVIDIA GeForce RTX 4050 Laptop) comprovaram uma latência média de inferência neural de apenas $54{,}23\,\mathrm{ms}$, viabilizando a consolidação atômica de registros forenses no SIEM para cada fluxo inspecionado e alcançando 0% de falsos positivos em tráfego de produção calibrado.

6.2 LIMITAÇÕES IDENTIFICADAS

A despeito dos expressivos resultados teóricos e operacionais obtidos, a análise rigorosa dos experimentos laboratoriais e da bancada em tempo real evidenciou limitações estruturais inerentes à abordagem adotada:

1. **Latência Estrutural Inerente à Abordagem Baseada em Fluxos:** Embora o tempo de processamento neural puro do ALF-MoE seja extremamente reduzido ($54{,}23\,\mathrm{ms}$ por amostra na GPU), o tempo total ponta a ponta (*end-to-end*) decorrido entre o primeiro pacote malicioso e o registro forense do evento no SIEM é dominado pelos temporizadores de expiração do extrator de fluxo (`idle_timeout = 120s` e `active_timeout = 240s`). Em vetores de ataque acelerados que completam suas transmissões em poucos segundos, o NIDS baseado em fluxo só toma

conhecimento da anomalia após o encerramento por inatividade, criando uma janela temporal de vulnerabilidade em que as sondagens já foram concluídas antes da emissão do alerta;

2. **Cegueira Semântica a Canais Criptografados e Exfiltração Furtiva:** Como a abordagem investigada fundamenta-se estritamente em propriedades estatísticas agregadas de fluxo e cabeçalhos de transporte, sem inspeção profunda de carga útil (*Deep Packet Inspection* – DPI), o classificador apresenta sensibilidade reduzida a ataques cuja pegada volumétrica mimetiza tráfego corporativo comum. Isso ficou demonstrado na classe *Infiltration - Dropbox Download* ($F_1 = 0{,}4571$ em TL0 e $F_1 = 0{,}1600$ em TL1), na qual o tráfego malicioso de exfiltração confunde-se com fluxos HTTPS legítimos de armazenamento em nuvem e telemetria de aplicações de streaming;

3. **Custo de Processamento Unitário vs. Vazão em Lote:** A transição do regime de inferência em megablocos (onde a GPU atinge vazões de até $52.749\,\text{fluxos/s}$ com amortização de overhead) para a inferência em fluxo contínuo unitário ($B = 1$) acarreta uma redução na taxa máxima de classificação para cerca de $17{,}6\,\text{fluxos/s}$ por worker de consumo, decorrente dos tempos de transferência host-dispositivo via barramento PCIe e sincronização de tensores.

6.3 TRABALHOS FUTUROS

Com base nas limitações diagnosticadas e nas perspectivas abertas por esta pesquisa, delineiam-se as seguintes direções para investigações e desenvolvimentos futuros:

1. **Classificação Precoce de Fluxos (*Early Flow Classification*):** Adaptar a arquitetura ALF-MoE para operar em regime de classificação prematura, no qual o modelo emite um diagnóstico preliminar a partir da observação dos primeiros k pacotes da conexão ($k \in [3, 10]$), sem aguardar a expiração dos temporizadores de transporte. Essa abordagem eliminaria o atraso de 120 segundos imposto pelo `idle_timeout`, permitindo detecção e emissão de alertas forenses no milissegundo inicial da intrusão;

2. **Fusão Multimodal com *Fingerprinting* TLS/Criptográfico:** Incorporar ao vetor de entrada atributos derivados de *fingerprints* criptográficos passivos, tais como os padrões JA4, JA4S e telemetria de negociação TLS (cifras oferecidas, extensões e versões do protocolo), sem necessidade de quebra de sigilo ou descriptografia. Essa adição proveria a separabilidade semântica necessária para distinguir exfiltrações encobertas de fluxos HTTPS benignos de serviços corporativos em nuvem;

3. **Sondas de Telemetria e Filtragem com eBPF/XDP:** Integrar sondas eBPF (*Extended Berkeley Packet Filter*) e ganchos XDP (*eXpress Data Path*) diretamente aos drivers de rede do kernel Linux. Essa infraestrutura permitirá pré-filtragem e extração estatística em nível de linha (*line-rate*) sem cópias desnecessárias de pacotes para o espaço de usuário, reduzindo a latência de transferência de dados e aumentando exponencialmente a capacidade de vazão e auditoria sob ataques volumétricos massivos de negação de serviço;

4. **Quantização, Poda e Otimização para Borda (*Edge Deployment*):** Aplicar técnicas de quantização pós-treinamento para formatos de precisão reduzida (FP16 e INT8) via TensorRT e exportação

para formatos interoperáveis (ONNX), visando a implantação do modelo ALF-MoE em roteadores de borda, dispositivos de Internet das Coisas (IoT) e *smart NICs* programáveis baseadas na arquitetura P4;

5. **Mecanismo de Gating Esparso (*Top-k Routing*):** Investigar variações de roteamento esparso na Rede de Roteamento, ativando estritamente os $k = 2$ especialistas mais relevantes por fluxo em vez da soma ponderada contínua dos 5 especialistas. Essa estratégia reduziria ainda mais o custo computacional por amostra em enlaces de altíssima vazão (10 Gbps ou superiores).

REFERÊNCIAS

ABREU, D.; ABELéM, A. Sistema híbrido e on-line de detecção e classificação de tráfego malicioso. **Anais do XL Simpósio Brasileiro de Redes de Computadores e Sistemas Distribuídos (SBRC 2022)**, Sociedade Brasileira de Computação, p. 322–335, 2022.

AOUINI, Z.; PEKAR, A. NFStream: A flexible network data analysis framework. **Computer Networks**, v. 204, p. 108719, 2022. ISSN 1389-1286. Disponível em: https://www.sciencedirect.com/science/article/pii/S1389128621005739.

BORGIOLI, N. et al. A convolutional autoencoder architecture for robust network intrusion detection in embedded systems. **Journal of Systems Architecture**, Elsevier BV, v. 156, p. 103283, 2024.

CAO, B. et al. Network intrusion detection model based on CNN and GRU. **Applied Sciences**, MDPI, v. 12, n. 9, p. 4184, 2022.

CHANDROTH, J.; STOIAN, G.; DANCIULESCU, D. ALF-MoE: An attention-based learnable fusion of specialized expert networks for accurate traffic classification. **Mathematics**, MDPI AG, v. 14, n. 3, p. 525, 2026.

CHEN, Y. et al. P4-NIDS: High-performance network monitoring and intrusion detection in P4. **Lecture Notes in Networks and Systems**, Springer Nature Switzerland, p. 355–373, 2025.

DARI, S. S. et al. Neural networks and cyber resilience: Deep insights into AI architectures for robust security framework. **Journal of Electrical Systems**, Science Research Society, v. 19, n. 3, p. 78–95, 2024.

DREYER, P. A. et al. **Estimating the Global Cost of Cyber Risk: Methodology and Examples**. [S.l.], 2018.

FERRAZ, Á. L. R. et al. The procedural semantics gap in structured CTI: A measurement-driven STIX analysis for APT emulation. **arXiv preprint arXiv:2512.12078**, 2025.

GUADARRAMA, J. C. M. et al. Advanced IDS: a comparative study of datasets and machine learning algorithms for network flow-based intrusion detection systems. **Applied Intelligence**, 2025.

GUO, C. et al. On calibration of modern neural networks. In: PMLR. **International Conference on Machine Learning (ICML)**. [S.l.], 2017. p. 1321–1330.

HE, Q.; FU, X.; ZHANG, L. Trafficmoe: Heterogeneity-aware mixture of experts for encrypted traffic classification. **arXiv preprint arXiv:2603.29520**, 2026.

JACOBS, R. A. et al. Adaptive mixtures of local experts. **Neural Computation**, MIT Press, v. 3, n. 1, p. 79–87, 1991.

JADA, I.; MAYAYISE, T. O. The impact of artificial intelligence on organisational cyber security: An outcome of a systematic literature review. **Data and Information Management**, Elsevier BV, v. 8, n. 2, p. 100063, 2024.

KAUR, D.; KAUR, P. Empirical analysis of web attacks. **Procedia Computer Science**, Elsevier BV, v. 78, p. 298–306, 2016.

LIN, T.-Y. et al. Focal loss for dense object detection. In: **IEEE International Conference on Computer Vision (ICCV)**. [S.l.: s.n.], 2017. p. 2980–2988.

LIU, L. et al. Error prevalence in NIDS datasets: A case study on CIC-IDS-2017 and CSE-CIC-IDS-2018. In: IEEE. **2022 IEEE Conference on Communications and Network Security (CNS)**. [S.l.], 2022. p. 254–262.

LUAY, M. et al. Temporal analysis of netflow datasets for network intrusion detection systems. **arXiv preprint arXiv:2503.04404**, 2025.

LUAY, M. et al. Time matters: Temporal netflow features for ml-based network intrusion detection. **IEEE Access**, Institute of Electrical and Electronics Engineers (IEEE), v. 14, p. 66899–66913, 2026.

MACIá-FERNáNDEZ, G. et al. Ugr'16: A new dataset for the evaluation of cyclostationarity-based network idss. **Computers & Security**, Elsevier BV, v. 73, p. 411–424, 2018.

MOHAMMADIAN, H.; LASHKARI, A. H.; GHORBANI, A. A. Poisoning and evasion: Deep learning-based NIDS under adversarial attacks. In: IEEE. **2024 21st Annual International Conference on Privacy, Security and Trust (PST)**. [S.l.], 2024. p. 1–10.

MOUSTAFA, N.; SLAY, J. UNSW-NB15: a comprehensive data set for network intrusion detection systems (UNSW-NB15 network data set). In: IEEE. **2015 Military Communications and Information Systems Conference (MilCIS)**. [S.l.], 2015. p. 1–6.

NETO, E. C. P. et al. CICIoT2023: A real-time dataset and benchmark for large-scale attacks in IoT environment. **Sensors**, MDPI AG, v. 23, n. 13, p. 5941, 2023.

NOOR, M. H. M.; IGE, A. O. A survey on state-of-the-art deep learning applications and challenges. **Engineering Applications of Artificial Intelligence**, Elsevier BV, v. 159, p. 111225, 2025.

OLIVEIRA, J. A. de; GONçALVES, V. P.; FILHO, G. P. R. F-NIDS: Sistema de detecção de intrusão baseado em aprendizado federado. **Anais Estendidos do XLIII Simpósio Brasileiro de Redes de Computadores e Sistemas Distribuídos (SBRC 2025)**, Sociedade Brasileira de Computação - SBC, p. 212–221, 2025.

ORBINATO, V. et al. Laccolith: Hypervisor-based adversary emulation with anti-detection. **IEEE Transactions on Dependable and Secure Computing**, Institute of Electrical and Electronics Engineers (IEEE), v. 21, n. 6, p. 5374–5387, 2024.

PHAN, T. V.; NGUYEN, T. G.; BAUSCHERT, T. DeepStage: Learning autonomous defense policies against multi-stage APT campaigns. **arXiv preprint arXiv:2603.16969**, 2026.

SAINIS, N.; SRIVASTAVA, D.; SINGH, R. Feature classification and outlier detection to increased accuracy in intrusion detection system. **International Journal of Applied Engineering Research**, v. 13, n. 10, p. 7249–7255, 2018.

SARHAN, M. et al. Netflow datasets for machine learning-based network intrusion detection systems. **Lecture Notes of the Institute for Computer Sciences, Social Informatics and Telecommunications Engineering**, Springer International Publishing, p. 117–135, 2021.

SARHAN, M.; LAYEGHY, S.; PORTMANN, M. Towards a standard feature set for network intrusion detection system datasets. **Mobile Networks and Applications**, Springer Science and Business Media LLC, v. 27, n. 1, p. 357–370, 2022.

SASI, T. et al. An efficient self attention-based 1d-cnn-lstm network for iot attack detection and identification using network traffic. **Journal of Information and Intelligence**, Elsevier, v. 3, n. 4, p. 375–400, 2025.

SHARAFALDIN, I.; LASHKARI, A. H.; GHORBANI, A. A. Toward generating a new intrusion detection dataset and intrusion traffic characterization. In: **International Conference on Information Systems Security and Privacy**. [s.n.], 2018. Disponível em: https://api.semanticscholar.org/CorpusID:4707749.

SHARIF, M. H. U. Web attacks analysis and mitigation techniques. **International Journal of Engineering Research & Technology (IJERT)**, v. 11, n. 02, 2022.

SHAZEER, N. et al. Outrageously large neural networks: The sparsely-gated mixture-of-experts layer. In: **International Conference on Learning Representations (ICLR)**. [S.l.: s.n.], 2017. p. 1–19.

SILVA, F. C. d. **HSAE: Um Autoencoder Híbrido Não Supervisionado para Detecção de Ataques Zero-Day e sua Extensão Ensemble**. 2025. Dissertação (Dissertação de Mestrado) — Universidade Federal de Pernambuco, 2025.

SOUZA, C. A. d. **Detecção e prevenção de intrusão em computação de nevoeiro e Internet das Coisas**. 2023. Tese (Tese de Doutorado) — Universidade Federal de Santa Catarina, 2023.

WANG, Y.-C.; HOUNG, Y.-C.; LIN, H.-X. Network anomaly intrusion detection based on deep learning approach. **Sensors**, MDPI, v. 23, n. 4, p. 2171, 2023.

YANG, X. et al. One-for-all does not work! enhancing vulnerability detection by mixture-of-experts (moe). In: **Proceedings of the ACM on Software Engineering**. [S.l.]: Association for Computing Machinery (ACM), 2025. v. 2, n. FSE, p. 446–464.

ČENYS, A.; HORA, S. K.; GORANIN, N. Emulation-based dataset EmuIoT-VT for NIDS in IoT systems. **Sensors**, MDPI AG, v. 25, n. 16, p. 5077, 2025.