

UNIVERSIDADE ESTADUAL DE MATO GROSSO DO SUL - UEMS

Ciência da Computação – Unidade Universitária de Dourados

JOSÉ CARLOS DA SILVA FILHO

ALF-MoE:

Redes Especialistas com Fusão Aprendível Baseada em Atenção para Classificação de Ataques
Cibernéticos

Dourados

2026

José Carlos da Silva Filho

ALF-MoE:

Redes Especialistas com Fusão Aprendível Baseada em Atenção para Classificação de Ataques Cibernéticos

Trabalho de Conclusão de Curso, apresentado à
Universidade Estadual de Mato Grosso do Sul
(UEMS), Ciência da Computação, Dourados,
para obtenção do título de Bacharel em Ciência
da Computação.

Orientador: Profº. Dr. Rubens Barbosa Filho

Dourados
2026

JOSÉ CARLOS DA SILVA FILHO

ALF-MOE:

Redes Especialistas com Fusão Aprendível Baseada em Atenção para Classificação de Ataques Cibernéticos

Trabalho de Conclusão de Curso apresentado à Universidade Estadual de Mato Grosso do Sul (UEMS), Ciência da Computação, Dourados, para obtenção do título de Bacharel *Ciência da Computação*.

Data de defesa: 12/10/2026

BANCA EXAMINADORA

Profº. Dr. Rubens Barbosa Filho

UEMS – Ciência da Computação – Unidade Universitária de Dourados

Profº. Dr. André Chastel Lima

Universidade Estadual de Mato Grosso do Sul

Profª. Dra. Glaucia Gabriel

Universidade Estadual de Mato Grosso do Sul

Profª. Dra. Raquel Marcia Müller

Universidade Estadual de Mato Grosso do Sul

*À todas as curiosas crianças adultas, que (re)encontraram seu propósito mesmo perdidos no
labirinto da própria mente.*

AGRADECIMENTOS

Agradeço, primeiramente, a Deus, cuja providência me sustentou mesmo nos momentos em que me senti distante. Obrigado por não me conceder fardo maior do que o que eu poderia carregar e por ser a força silenciosa que me manteve de pé. À Maria, Mãe de Deus, agradeço pelo acalento materno e zeloso; por ser meu refúgio nas horas de aflição, minha proteção contra as sombras e a clareza necessária nas madrugadas de questionamento e exaustão.

À minha mãe, Rosirei, que transformou a escassez que viveu em abundância de oportunidades para o meu futuro. Obrigado por responder a cada um dos meus “porquês” e por instigar a curiosidade que hoje me torna cientista; cresci desejando ser tão inteligente quanto você. Através do seu exemplo, aprendi que o esforço é a ponte para o impossível. Guardo com carinho a memória de acordarmos antes do raiar do sol para que você trabalhasse e, à noite, ainda estudasse — você me pedia desculpas por me levar às suas aulas, sem saber que para mim era o maior dos privilégios ver de perto a sua garra. Vi seus medos e incertezas, mas jamais a vi recuar. À mulher que multiplicou o pouco para que eu tivesse tudo, e que me ensinou que o caráter e o conhecimento são as únicas riquezas inalienáveis, dedico esta vitória.

À minha noiva, Maria Eduarda, a quem devo a doçura e a estabilidade desta conquista. Você foi muito mais que uma companheira; foi o porto seguro onde ancorei nos dias de tempestade. Em meio à lógica fria dos códigos e à pressão exaustiva da academia, seu amor foi a constante que me manteve íntegro. Obrigado por ser o fôlego e a paciência nos momentos em que o *burnout* tentou silenciar meu entusiasmo, e por ter a sabedoria de me impulsionar quando minhas próprias forças falhavam. Você não apenas esteve ao meu lado; você iluminou o caminho para que eu pudesse enxergar além das minhas limitações e exaustões. Obrigado por dividir o peso da jornada e multiplicar a alegria da chegada. Este diploma é apenas o prefácio de uma vida inteira que pretendo escrever ao seu lado. Amo você.

Ao meu psicólogo, Dr. Ricardo Tiosso Panassiol, por ser o guia que me auxiliou a encontrar o caminho de volta em meio ao caos da ansiedade generalizada e do *burnout*. Obrigado por me ensinar a reconstruir minha perspectiva e por fornecer as ferramentas de resiliência necessárias para enfrentar as adversidades. Sua atuação foi fundamental para que eu não apenas concluísse este trabalho, mas recuperasse a posse de mim mesmo.

Ao meu orientador, Prof. Dr. Rubens Barbosa Filho, expresso minha mais profunda admiração. Agradeço pela orientação técnica impecável, mas, acima de tudo, pelo impacto do seu exemplo. Jamais esquecerei o dia em que lhe apresentei um problema do *Beecrowd* que me desafiava há quatro anos; vê-lo demonstrar que o embasamento teórico — através da Transformada Rápida de Fourier — resolve o que a força bruta jamais alcançaria, foi um divisor de águas em minha formação. Obrigado por me mostrar que a excelência nasce da paixão pelo conhecimento. Você é a minha maior referência de onde pretendo chegar como profissional.

Aos meus “irmãos de guerra” do “Bonde do Óclin”: Gustavo de Carvalho Brás Martins

Lopes (Gustavin), Leonardo Hirata (Hiratinha) e Luis Eduardo de Souza Vasconcelos (Louis). Nossa união transcendeu as salas de aula, tornando-se uma irmandade de apoio mútuo. Obrigado pelas horas intermináveis de algoritmos, pelos debates sobre cálculos e por tornarem o peso da graduação muito mais leve com sua lealdade e amizade.

Aos amigos Alexandre Arruda (Alê), Gabriel Fagá (Fagas) e Pedro Henrique Zaccaria (Z), Sizenando França e Felipe Vilhalva, agradeço pelos momentos de descontração e pelas pausas necessárias. Seja nas partidas de *Minecraft* ou nas conversas sem pressa, vocês foram o alívio essencial para que a mente pudesse descansar e o riso pudesse retornar. A jornada foi mais feliz por causa de vocês.

Aos mestres do Curso de Ciência da Computação da UEMS, cujas lições vão além dos livros. Em especial à Profa. Dra. Glaucia Gabriel, pela imensa empatia e humanidade demonstradas em meus momentos mais difíceis; ao Prof. Dr. André Chastel Lima, pela generosidade em compartilhar seu domínio sobre a Teoria dos Grafos. A dedicação de vocês é o que sustenta a qualidade desta instituição.

Por fim, agradeço à Universidade Estadual de Mato Grosso do Sul (UEMS) e ao Curso de Ciência da Computação, que me proporcionaram a base acadêmica necessária para a realização deste trabalho. Agradeço a todos os funcionários que, direta ou indiretamente, contribuíram para minha formação.

“Se você só fizer o que sabe, nunca será mais do que é agora.”
Shifu – Kung Fu Panda 3 (2016)

RESUMO

O texto deve ser composto por frases concisas em parágrafo único, utilizando o verbo na terceira pessoa. Evite símbolos e contrações que não sejam de uso corrente. Evite fórmulas, equações, diagramas etc., que não sejam absolutamente necessários; quando seu emprego for imprescindível, defini-los na primeira vez que aparecerem. Um resumo deve conter entre 150 a 500 palavras. As palavras-chave devem ficar logo abaixo do resumo, separadas entre si por ponto e vírgula e finalizadas por ponto. Além disso, devem ser grafadas com as iniciais em letra minúscula, exceto nomes próprios e nomes científicos. Para a escolha das palavras-chave consulte descritores autorizados da área, que representam o conteúdo do trabalho.

Palavras-Chave: palavra-chave; palavra-chave; palavra-chave.

ABSTRACT

The text should consist of concise sentences in a single paragraph, using the third person singular form of the verb. Avoid symbols and contractions that are not commonly used. Avoid formulas, equations, diagrams, etc., unless absolutely necessary; when their use is essential, define them the first time they appear. An abstract should contain between 150 to 500 words. Keywords should be placed right below the abstract, separated by semicolons and ending with a period. Additionally, they should be written in lowercase except for proper names and scientific names. To choose keywords, consult authorized descriptors in the field that represent the content of the work.

Keywords: keyword; keyword; keyword.

LISTA DE ILUSTRAÇÕES

Quadro 1	Síntese comparativa dos conjuntos de dados selecionados para treinamento e avaliação.	48
Figura 1	Diagramas das topologias neurais dos modelos especialistas heterogêneos.	58
Figura 2	Topologia interna da Gating Network com refinamento atencional e compressão simétrica.	59
Figura 3	Topologia interna do módulo de fusão ALF (<i>Attention-based Learnable Fusion</i>).	59
Figura 4	Visão arquitetural integrada do modelo ALF-MoE, evidenciando o fluxo de tensores entre especialistas, Gating Network e fusão ALF.	60
Figura 5	Painel comparativo de matrizes de confusão normalizadas nos quatro cenários de avaliação.	79
Figura 6	Gráficos radar comparativos de desempenho por classe: Especialistas individuais vs. ALF-MoE.	82

LISTA DE TABELAS

Tabela 1 – Síntese comparativa entre trabalhos correlatos da literatura e a proposta desta tese.	44
Tabela 2 – Distribuição de classes e suporte amostral de teste: CSE-CIC-IDS2018 Canônico vs. Corrigido.	51
Tabela 3 – Macro-famílias e distribuição amostral de teste no benchmark CIC-BCCC-NRC TabularIoTAttack-2024.	52
Tabela 4 – Distribuição de classes e suporte amostral no benchmark CIC-UNSW-NB15.	53
Tabela 5 – Mapeamento funcional entre domínios de telemetria, subvetores de entrada e especialistas neurais.	56
Tabela 6 – Mapeamento posicional da máscara binária de sinalizadores TCP.	67
Tabela 7 – Mapeamento estruturado das 76 características do fluxo de rede: padrão CICFlowMeter versus implementação NFStream.	69
Tabela 8 – Desempenho global consolidado do modelo ALF-MoE nos 7 cenários de benchmark.	77
Tabela 9 – Estudo de ablação: Macro F_1 -Score e Acurácia dos especialistas individuais vs. ALF-MoE.	81
Tabela 10 – Comparativo metodológico e estatístico entre o extrator offline (CICFlowMeter) e o extrator em tempo real (NFStream + Plugin ALF).	84
Tabela 11 – Decomposição temporal e perfil de latência do pipeline de inferência em tempo real (GPU NVIDIA GeForce RTX 4050 6GB Laptop).	85

LISTA DE ABREVIATURAS E SIGLAS

DDoS	Ataque Distribuído de Negação de Serviço (<i>Distributed Denial of Service</i>)
DoS	Ataque de Negação de Serviço (<i>Denial of Service</i>)
IoT	Internet das Coisas (<i>Internet of Things</i>)

LISTA DE SÍMBOLOS

α	Letra Grega Alfa
β	Letra grega Beta
γ	Letra grega Gama
e	Número de Euler
R\$	Unidade monetária Brasileira (Real)

SUMÁRIO

1	INTRODUÇÃO	17
1.1	Contextualização e Motivação	17
1.2	Definição do Problema	20
1.3	Objetivos	21
1.3.1	Objetivo Geral	21
1.3.2	Objetivos Específicos	22
1.4	Principais Contribuições	23
1.5	Organização do Trabalho	24
2	FUNDAMENTAÇÃO TEÓRICA E TRABALHOS CORRELATOS . . .	25
2.1	Ataques Cibernéticos e Sistemas de Detecção de Intrusão (NIDS)	25
2.1.1	Taxonomia de Ataques de Rede	25
2.1.2	Métodos de Identificação e Mitigação	28
2.1.2.1	Paradigmas de Detecção de Intrusão	28
2.1.2.2	Granularidade de Inspeção: DPI versus Análise Baseada em Fluxos	29
2.1.2.3	Mecanismos de Resposta e Mitigação	30
2.2	Aprendizado Profundo para Segurança de Redes	31
2.2.1	Redes Convolucionais e Recorrentes (CNN, LSTM, GRU)	31
2.2.1.1	Redes Neurais Convolucionais (CNN)	31
2.2.1.2	Redes Neurais Recorrentes e a Modelagem Temporal (LSTM e GRU)	33
2.2.1.2.1	<i>Long Short-Term Memory (LSTM):</i>	33
2.2.1.2.2	<i>Gated Recurrent Unit (GRU):</i>	34
2.2.2	Redes Densas, Autoencoders e Análise Espectral	35
2.2.2.1	Redes Neurais Totalmente Conectadas (DNN)	35
2.2.2.2	Autoencoders Convolucionais 1D (1D-CAE) e Processamento Espectral Integrado	35
2.2.2.2.1	<i>1. Seleção de Subdomínio e Janelamento de Hann:</i>	36
2.2.2.2.2	<i>2. Transformada Rápida de Fourier Discreta para Sinais Reais (RFFT):</i>	36
2.2.2.2.3	<i>3. Codificação Convolucional 1D:</i>	36
2.2.2.2.4	<i>4. Decodificação por Convolução Transposta 1D:</i>	36
2.2.2.2.5	<i>5. Função de Perda Composta do CAE com Supervisão Profunda:</i>	37
2.2.3	Tratamento de Desbalanceamento Extremo via Focal Loss	37
2.2.4	Mixture of Experts (MoE) e Mecanismos de Fusão Atencional	38
2.2.4.1	Rede de Roteamento Dinâmico (Gating Network)	38
2.2.4.2	Mecanismo de Refinamento Atencional Aprendível (ALF)	38

2.2.4.2.1	1. <i>Transformação Logarítmica Estabilizada:</i>	39
2.2.4.2.2	2. <i>Camada de Refinamento de Atenção com Pesos Afins:</i>	39
2.2.4.2.3	3. <i>Calibração de Confiança via Escalonamento Paramétrico (Vector Scaling):</i>	39
2.2.4.2.4	4. <i>Fusão por Soma Ponderada (Weighted Sum Fusion):</i>	40
2.2.4.2.5	5. <i>Projeção Classificatória Final Consolidada:</i>	40
2.3	Trabalhos Correlatos	40
2.3.1	NIDS Baseados em Aprendizado Profundo	40
2.3.2	Abordagens Ensemble e Mixture of Experts em Cibersegurança	42
2.3.3	Síntese Comparativa	43
3	MATERIAIS E METODOLOGIA	47
3.1	Datasets Utilizados	47
3.1.1	CSE-CIC-IDS2018: Versão Canônica e Versão Corrigida	48
3.1.1.1	Topologia e Infraestrutura de Rede	49
3.1.1.2	Metodologia de Geração de Tráfego e Limitações Metodológicas do Estado da Arte	49
3.1.1.3	Distribuição Amostral: Canônica vs. Corrigida	50
3.1.2	CIC-BCCC-NRC TabularIoTAttack-2024: Origem, Geração, Atributos e Distribuição Amostral	50
3.1.2.1	Amostragem Estratificada Hare-Niemeyer e Distribuição Amostral	51
3.1.3	CIC-UNSW-NB15: Origem, Geração, Atributos e Distribuição Amostral	52
3.1.3.1	Mitigação de GIGO e Amostragem com Máxima Entropia	52
3.1.4	Modelagem de Hierarquia de Ameaças (<i>Threat Levels</i>)	53
3.2	Pipeline de Pré-processamento e Engenharia de Features	54
3.2.1	Seleção, Normalização e Codificação	54
3.2.2	Tratamento de Desbalanceamento de Classes	55
3.3	Arquitetura Proposta: ALF-MoE	55
3.3.1	Visão Geral do Sistema e Fluxo de Dados	55
3.3.2	Modelos Especialistas Heterogêneos	56
3.3.3	Gating Network com Refinamento Atencional e Compressão Simétrica .	57
3.3.4	Mecanismo Attention-based Learnable Fusion (ALF)	58
3.4	Protocolo Experimental de Treinamento e Avaliação	60
3.4.1	Funções de Perda e Otimização Multitarefa	60
3.4.2	Métricas de Avaliação	61
3.4.2.1	Métricas de Eficácia Estatística	61
3.4.2.2	Métricas de Eficiência Computacional	62
4	PIPELINE DE EXTRAÇÃO E AMBIENTE DE INFERÊNCIA	63
4.1	Captura e Processamento de Tráfego	63
4.1.1	Extração com NFStream	63

4.1.1.1	Princípio da Responsabilidade Única (SRP) na Classe FeatureExtractor . . .	63
4.1.1.2	Problema de Concorrência, Multiprocessamento Fork e Contexto CUDA . .	64
4.1.1.3	Escalas Temporais e Fator de Conversão de Unidades	65
4.1.1.4	Descarte de Atributos de Variância Nula	65
4.1.1.5	Dissecação de Baixo Nível dos Métodos Customizados	66
4.1.1.5.1	<i>Codificação Compacta de Flags TCP (encode_tcp_flags)</i>	66
4.1.1.5.2	<i>Extração de Janela TCP em Bytes Brutos (extract_tcp_window_size)</i> .	67
4.1.1.6	Ciclo de Vida dos Fluxos e Temporizadores de Rede	68
4.1.2	Mapeamento e Alinhamento de Features (NFStream → CICFlowMeter)	69
4.1.2.1	Correspondência Semântica e Estrutural das Variáveis	69
4.1.2.2	Aproximações Operacionais e Nuances de Cálculo	71
4.2	Setup de Inferência	72
4.2.1	Arquitetura do Ambiente de Execução	72
4.2.1.1	Especificações do Hardware e Ambiente Operacional	72
4.2.1.2	Mecanismo de Defesa Ativa	73
4.2.1.2.1	<i>Integração de Baixo Nível com o Firewall nftables</i>	73
4.2.1.2.2	<i>Algoritmo de Resolução Direcional de Alvo (select_target)</i>	74
4.2.1.2.3	<i>Salvaguarda Anti-Auto-Bloqueio e Whitelist</i>	75
4.2.1.2.4	<i>Subsistema de Auditoria Forense e SIEM (InferenceAuditor)</i>	75
4.2.2	Síntese Operacional do Pipeline de Inferência e Contenção Ativa	76
5	RESULTADOS E DISCUSSÃO	77
5.1	Desempenho nos Datasets de Benchmark (Resultados Offline)	77
5.1.1	Análise por Classe e Desempenho Global	77
5.1.1.1	Eixo 1: Impacto da Granularidade de Ameaças (Nível 0 vs. Nível 2)	77
5.1.1.2	Eixo 2: Impacto da Sanitização de Rótulos de Liu et al. (2022) no CSE-CIC-IDS2018	78
5.1.1.3	Eixo 3: Generalização em Tráfego de Alta Densidade (CIC-UNSW-NB15) .	78
5.1.1.4	Matrizes de Confusão Normalizadas	78
5.1.2	Análise Comparativa dos Especialistas e do Bloco ALF	80
5.1.2.1	Gráficos Radar de Especialistas	81
5.2	Avaliação da Extração e Inferência em Tráfego Real/PCAPs	81
5.2.1	Impacto do Mapeamento NFStream → CICFlowMeter	82
5.2.2	Throughput, Latência e Consumo Computacional	83
5.2.2.1	Métricas Quantitativas de Inferência Neural	84
5.2.2.2	O Gargalo Estrutural da Latência Ponta a Ponta (End-to-End Latency) . . .	85
5.2.3	Avaliação de Falsos Positivos em Tráfego Operacional e Calibração de Salvaguardas	86
5.2.3.1	Diagnóstico de Falsos Positivos Iniciais e Calibração	86

6	CONCLUSÃO	87
6.1	Síntese do Trabalho	87
6.2	Limitações Identificadas	88
6.3	Trabalhos Futuros	88
	REFERÊNCIAS	90

1 INTRODUÇÃO

1.1 CONTEXTUALIZAÇÃO E MOTIVAÇÃO

A contínua expansão das infraestruturas de redes de computadores, impulsionada pela computação em nuvem, por ecossistemas corporativos distribuídos e pela proliferação ubíqua de dispositivos conectados, transformou a transmissão contínua de dados em um dos pilares estruturantes da sociedade contemporânea. Entretanto, essa interconectividade extensiva acarretou uma ampliação proporcional da superfície de ataque exposta a intervenções maliciosas, tornando os ambientes computacionais alvos recorrentes de ameaças de complexidade técnica crescente (Dreyer et al., 2018). Relatórios econômicos indicam que as perdas financeiras globais decorrentes de incidentes de segurança cibernética atingem a escala de trilhões de dólares anuais, englobando prejuízos materiais diretos, interrupções operacionais não programadas, violações de privacidade, penalidades regulatórias e o comprometimento da confiabilidade de ativos estratégicos de informação (Jada; Mayayise, 2024).

Nesse cenário de permanente vulnerabilidade, os Sistemas de Detecção de Intrusão em Redes (*Network Intrusion Detection Systems* – NIDS) consolidaram-se como elementos indispensáveis na arquitetura de defesa cibernética em profundidade (*defense-in-depth*) (Guadarrama et al., 2025; Chen et al., 2025). Historicamente, a operação dos NIDS fundamentava-se em dois paradigmas preponderantes: a detecção por assinaturas determinísticas e a inspeção profunda de pacotes (*Deep Packet Inspection* – DPI), alicerçadas na identificação de portas estáticas da camada de transporte e no exame direto do conteúdo textual ou binário da carga útil (*payload*) dos pacotes transmitidos pela rede.

Contudo, transformações substanciais nos padrões e protocolos de comunicação da Internet debilitaram a viabilidade prática dessas abordagens legadas. A adoção generalizada de mecanismos de criptografia ponta a ponta, tais como os protocolos TLS 1.3, HTTPS e DNS sobre HTTPS (*DNS over HTTPS* – DoH), combinada à utilização disseminada de Redes Privadas Virtuais (*Virtual Private Networks* – VPN) e à alocação dinâmica de portas efêmeras, tornou a carga útil dos pacotes inteiramente opaca aos dispositivos intermediários de monitoramento e filtragem (Sarhan; Layeghy; Portmann, 2022; He; Fu; Zhang, 2026). Sob tais condições operacionais, os métodos fundamentados na inspeção direta do conteúdo tornaram-se ineficazes para a identificação de ameaças encapsuladas em fluxos cifrados.

Como alternativa às limitações da análise estática de carga útil, consolidou-se na literatura o paradigma de análise comportamental de tráfego fundamentado em Aprendizado de Máquina (*Machine Learning* – ML) e Aprendizado Profundo (*Deep Learning* – DL) (Noor; Ige, 2025; Dari et al., 2024). Tais metodologias operam sobre fluxos de rede bidirecionais (*bidirectional network flows*), extraindo padrões estatísticos e temporais a partir de agregados de tráfego — tais como duração da conexão, taxas de transmissão, contagens de pacotes e bytes por sentido,

tempos entre chegadas consecutivas de pacotes (*Inter-Arrival Time* – IAT) e sinalizadores de controle das camadas de rede e transporte (TCP/IP).

Não obstante os avanços demonstrados pelos classificadores baseados em Aprendizado Profundo, parcela expressiva das soluções propostas na literatura é concebida sob uma perspectiva homogênea ou restrita de representação de atributos (*single-view representation*) (Luay et al., 2026; Luay et al., 2025). Tais modelos monolíticos empregam predominantemente uma única família arquitetural: Redes Neurais Totalmente Conectadas (*Dense Neural Networks* – DNN) para sumários estatísticos tabulares, Redes Neurais Convolucionais (*Convolutional Neural Networks* – CNN) para examinar correlações espaciais, ou Redes Neurais Recorrentes (*Recurrent Neural Networks* – RNN) para dependências sequenciais.

Essa restrição metodológica contrasta frontalmente com a natureza intrinsecamente multifacetada do tráfego malicioso contemporâneo, no qual diferentes classes de ameaças manifestam comportamentos em domínios informacionais amplamente divergentes entre si (Neto et al., 2023; Maciá-Fernández et al., 2018):

- **Ataques de Negação de Serviço (*Denial of Service* – DoS) e Negação de Serviço Distribuída (*Distributed Denial of Service* – DDoS):** caracterizam-se por perturbações estatísticas volumétricas agudas, marcadas por taxas extremas de pacotes por segundo e saturação do canal de transmissão;
- **Varreduras de portas e de rede (*Port Scans* e *IP Sweeps*):** caracterizam-se por estruturas espaciais esparsas, com distribuição sistemática de pacotes reduzidos entre múltiplos destinos em intervalos comprimidos;
- **Canais de Comando e Controle (C2), Botnets e Infiltrações:** utilizam mensagens compactas e cadências temporais programadas para mimetizar conexões legítimas, tornando os intervalos entre chegadas consecutivas (IAT) e as dinâmicas transitórias a dimensão prioritária de discriminação;
- **Fluxos de exfiltração de dados e abusos sobre aplicações web:** exibem padrões de densidade espectral, ciclicidade e periodicidade harmônica que encontram representação ótima no domínio da frequência.

Modelos monolíticos que operam sob uma única perspectiva tendem a apresentar desempenho subótimo na identificação de ataques cujas assinaturas determinantes residem em domínios ignorados pelo extrator. Embora estratégias baseadas em Aprendizado em Conjunto (*Ensemble Learning*) busquem atenuar essa deficiência combinando múltiplos classificadores (Silva, 2025; Yang et al., 2025), as abordagens convencionais comumente recorrem à fusão tardia estática (*late fusion*), agregando decisões via média aritmética simples, votação majoritária ou concatenação linear de escores (Chandroth; Stoian; Danciulescu, 2026). Esse procedimento estático desconsidera a interdependência dos domínios durante o processo de aprendizagem e falha em modular

dinamicamente a relevância de cada modelo com base no perfil particular do fluxo em análise (He; Fu; Zhang, 2026).

Com o objetivo de superar essas deficiências estruturais, Chandroth, Stoian & Danciulescu (2026) introduziram a arquitetura ALF-MoE (*Attention-Based Learnable Fusion of Specialized Expert Networks*). O ALF-MoE alicerça-se no paradigma de Mistura de Especialistas (*Mixture of Experts – MoE*) (Jacobs et al., 1991; Shazeer et al., 2017), distribuindo o aprendizado de representações entre cinco redes neurais profundas dedicadas, cada qual concebida para extrair padrões de uma modalidade informacional distinta do tráfego:

1. **Dense Neural Network (DNN):** especializada na representação de atributos estatísticos globais e tabulares agregados da conexão ($\mathbf{x}_g$), tais como duração da sessão, contagens totais de pacotes e bytes por direção e contadores de sinalizadores TCP;
2. **Convolutional Neural Network (CNN):** dedicada ao aprendizado de correlações espaciais e padrões morfológicos locais ($\mathbf{x}_s$) a partir de arranjos dimensionais derivados das grandezas de cabeçalho do tráfego;
3. **Gated Recurrent Unit (GRU):** orientada à captura de variações estatísticas sequenciais e dinâmicas temporais de curta cadência ($\mathbf{x}_v$), focando primordialmente nos intervalos temporais entre chegadas consecutivas de pacotes (IATs);
4. **Convolutional Autoencoder (CAE):** projetado para a extração de representações comprimidas no domínio da frequência ($\mathbf{x}_f$), processadas mediante janelamento periódico de Hann e o cômputo da magnitude da Transformada Rápida de Fourier Real (*Real Fast Fourier Transform – RFFT*) sobre os vetores de tráfego, acoplado a perdas compostas de reconstrução espectral;
5. **Long Short-Term Memory (LSTM):** encarregada de modelar dependências temporais de longo alcance e transições de estado ($\mathbf{x}_t$) ao longo do ciclo de vida da conexão (tempos de atividade e inatividade).

Para coordenar a cooperação entre os múltiplos especialistas, a arquitetura ALF-MoE integra uma Rede de Roteamento Dinâmico (*Gating Network*) a um módulo de Fusão Aprendível Baseada em Atenção (*Attention-Based Learnable Fusion – ALF*) dotado de refinamento atencional (Chandroth; Stoian; Danciulescu, 2026). Em nível arquitetural de alto nível, o processo ocorre em etapas coordenadas:

1. Cada rede especialista processa de maneira independente seu respectivo subespaço informacional, gerando uma distribuição probabilística preliminar sobre as classes do problema via função de ativação *softmax*;
2. Concomitantemente, a *Gating Network* analisa o vetor global do fluxo e estima escores contextuais de relevância para cada especialista. Com a finalidade de aumentar a seletividade e prevenir o colapso prematuro de modelos minoritários, esses escores brutos sofrem

normalização e passam por uma etapa de refinamento atencional afim com estabilização logarítmica e limitação não linear;

3. As predições individuais dos cinco especialistas são consolidadas por meio de uma soma ponderada pelos pesos atencionais gerados pela *Gating Network*, formando uma representação unificada intermediária;
4. Por fim, o módulo de fusão ALF processa essa representação combinada por meio de camadas densas não lineares profundas com normalização em lote (*Batch Normalization*) e ativações LeakyReLU, gerando a predição final de probabilidade calibrada para o fluxo de rede.

A conjugação entre especialização em domínios complementares, roteamento atencional dinâmico e fusão aprendível não linear confere à arquitetura ALF-MoE uma notável capacidade de generalização e adaptação representacional perante a diversidade do tráfego de rede contemporâneo.

1.2 DEFINIÇÃO DO PROBLEMA

A despeito dos promissores resultados obtidos no estudo original de Chandroth, Stoian & Danciulescu (2026), no qual o ALF-MoE alcançou acurácias superiores a 97% em tarefas de classificação de tráfego de aplicações e segregação de conexões VPN e não-VPN sobre bases como ISCX VPN-nonVPN, Unicauc e UNSW-IoTraffic, a transposição direta dessa arquitetura para o domínio dos Sistemas de Detecção de Intrusão em Redes (NIDS) multiclasse impõe desafios conceituais e metodológicos substanciais, os quais delimitam o problema investigado nesta tese:

Em primeiro lugar, existe uma disparidade estrutural basilar entre a classificação de aplicações e a identificação de ataques em redes operacionais. Em tarefas de classificação de aplicações, as instâncias distribuem-se de maneira comparativamente homogênea entre os rótulos de serviço, com fluxos contínuos e volumes amostrais estáveis. Em contrapartida, conjuntos de dados canônicos de referência em segurança cibernética — a exemplo de CSE-CIC-IDS2018 (Sharafaldin; Lashkari; Ghorbani, 2018) e CIC-UNSW-NB15 (Moustafa; Slay, 2015; Sarhan; Layeghy; Portmann, 2022) — exibem um desbalanceamento de classes extremo. Nesses cenários, o tráfego estritamente benigno perfaz entre 85% e mais de 97% do total de conexões observadas, enquanto categorias críticas de invasão (tais como *Infiltration*, *Botnets*, ataques web, *Shellcode* e *Worms*) compõem frações inferiores a 1% ou mesmo 0,1% do suporte amostral. Diante de assimetrias agudas, classificadores neurais padrão sofrem de viés sistemático em favor da classe majoritária, e as redes de roteamento correm o risco de colapso de especialistas (*expert collapse*), priorizando monotonicamente predições benignas. Determinar se a divisão em múltiplos especialistas e o roteamento atencional mantêm sua eficácia discriminatória e calibrada perante tal desbalanceamento constitui uma questão científica aberta.

Em segundo lugar, a caracterização de ameaças cibernéticas sob tráfego criptografado repousa exclusivamente sobre atributos estatísticos e comportamentais extraídos dos cabeçalhos dos fluxos (Sarhan; Layeghy; Portmann, 2022; He; Fu; Zhang, 2026). Contudo, diferentes categorias de intrusão manifestam suas assinaturas em domínios informacionais com correlações cruzadas complexas: ataques volumétricos manifestam-se no domínio estatístico global (Sarhan; Layeghy; Portmann, 2022); varreduras e mapeamentos atuam com dispersão espacial nas geometrias de pacotes (Wang; Houn; Lin, 2023); canais furtivos de persistência alteram dinâmicas sequenciais e temporais de curto prazo (Luay et al., 2026; Cao et al., 2022); e explorações com requisições repetitivas afetam densidades no domínio da frequência (Maciá-Fernández et al., 2018; Borgioli et al., 2024). A ausência de um particionamento formalmente fundamentado dos atributos de rede para alimentar redes neurais especializadas pode comprometer a capacidade de extração de representações discriminatórias por parte de cada especialista.

Em terceiro lugar, a avaliação de modelos de aprendizado profundo na literatura de NIDS frequentemente restringe-se a ensaios sobre uma única base de dados, omitindo a capacidade de adaptação da arquitetura perante ecossistemas computacionais com características de tráfego substancialmente divergentes. A generalização de uma arquitetura baseada em MoE exige a sua validação abrangente em cenários que compreendam desde infraestruturas corporativas em nuvem (CSE-CIC-IDS2018) até ambientes modernos de Internet das Coisas e telemetria leve (CIC-BCCC-NRC-2024) e ensaios com emulação de ataques avançados (CIC-UNSW-NB15).

Diante dessas constatações, o problema fundamental abordado neste trabalho pode ser formulado mediante a seguinte indagação científica: *Em que medida a arquitetura ALF-MoE, fundamentada no particionamento multidomínio de atributos de fluxo, em mecanismos de refinamento atencional na rede de roteamento e em estratégias de otimização sob supervisão profunda, é capaz de demonstrar aplicabilidade e superar modelos monolíticos e comitês convencionais de aprendizado na tarefa de detecção e classificação multiclasse de intrusões em redes de computadores sob condições de severo desbalanceamento de classes e tráfego cifrado?*

1.3 OBJETIVOS

Com o intuito de responder à questão científica delineada, estabelecem-se os objetivos geral e específicos descritos a seguir.

1.3.1 Objetivo Geral

O objetivo geral desta tese de graduação consiste em investigar, adaptar, implementar computacionalmente e avaliar empiricamente a arquitetura de aprendizado profundo baseada em Mistura de Especialistas com Fusão Aprendível por Atenção (ALF-MoE) para a tarefa de classificação multiclasse de ameaças cibernéticas em tráfego de redes de computadores, sob o regime de fluxos estatísticos bidirecionais, demonstrando sua robustez discriminatória e estabilidade perante

o severo desbalanceamento amostral de classes em múltiplos conjuntos de dados de referência (CSE-CIC-IDS2018 Canônico e Corrigido, CIC-BCCC-NRC-2024 e CIC-UNSW-NB15).

1.3.2 Objetivos Específicos

Para viabilizar o cumprimento do objetivo geral, definem-se os seguintes objetivos específicos:

1. **Estruturar o pré-processamento e o particionamento multidomínio de atributos:** Implementar um fluxo sistemático de preparação de dados sobre os conjuntos de referência em cibersegurança (CSE-CIC-IDS2018, CIC-BCCC-NRC-2024 e CIC-UNSW-NB15), contemplando rotinas de higienização de dados (eliminação de valores infinitos e ausentes), remoção de atributos colineares ou desprovidos de variância, normalização estatística e mapeamento formal das variáveis nos cinco domínios especialistas: global tabular ($\mathbf{x}_g$), espacial ($\mathbf{x}_s$), variação temporal estatística ($\mathbf{x}_v$), espectral de frequência ($\mathbf{x}_f$) e dependências temporais longas ($\mathbf{x}_t$);
2. **Construir computacionalmente a arquitetura ALF-MoE e suas camadas dedicadas:** Implementar em código funcional os cinco modelos especialistas (DNN, CNN, GRU, CAE com janelamento periódico de Hann e espectro de magnitude RFFT, e LSTM), integrando-os à Rede de Roteamento Dinâmico (*Gating Network*) com refinamento atencional afim e limitação não linear, e ao bloco de Fusão Aprendível Baseada em Atenção (ALF);
3. **Formular a estratégia de treinamento supervisionado sob desbalanceamento severo:** Estruturar o protocolo de otimização conjunta do grafo computacional utilizando supervisão profunda (*deep supervision*) por meio de perdas auxiliares atribuídas a cada especialista e perda consolidada no módulo ALF, parametrizando a Perda Focal Multiclasse (*Focal Loss*) com fator de foco γ e pesos de balanceamento α calculados pela raiz quadrada da frequência inversa de classes;
4. **Conduzir avaliação comparativa frente a classificadores monolíticos e comitês de referência:** Mensurar o desempenho preditivo da arquitetura proposta em relação a modelos profundos monolíticos isolados (DNN, CNN, GRU, CAE e LSTM isoladas) e comitês convencionais de aprendizagem, adotando métricas rigorosas de desempenho multiclasse (Acurácia Global, Precisão Ponderada e Macro, Sensibilidade/*Recall* Ponderado e Macro, e Macro F_1 -Score);
5. **Realizar estudos comparativos dos especialistas e do bloco ALF:** Investigar o impacto individual de cada componente estrutural do modelo proposto, quantificando o ganho marginal proporcionado por cada especialista isolado, pelo módulo de fusão adaptativa ALF em comparação com métodos estáticos e pelo processamento espectral Hann-RFFT no autoencoder;

6. **Avaliar a capacidade de generalização e interpretabilidade inter-dataset:** Analisar as matrizes de confusão e a capacidade de identificação de classes raras de ataque nos *benchmarks* avaliados, avaliando o comportamento e a distribuição dos pesos de atenção gerados pela *Gating Network* em resposta a diferentes famílias de intrusão cibernética.

1.4 PRINCIPAIS CONTRIBUIÇÕES

As principais contribuições teóricas, metodológicas e práticas proporcionadas por este trabalho compreendem:

1. **Adaptação e formalização da arquitetura ALF-MoE para detecção de intrusões multiclasse:** Demonstra-se a aplicabilidade e a eficácia da transposição do paradigma de Mistura de Especialistas com Fusão Aprendível por Atenção para a detecção de intrusões em redes sob tráfego criptografado, estabelecendo um esquema formal de particionamento em cinco domínios informacionais complementares (estatístico tabular, espacial, variação temporal, espectral via Hann-RFFT e dependência temporal de longo prazo) a partir de 76 atributos canônicos (73 ativos);
2. **Integração de refinamento atencional na Gating Network e formulação para dados desbalanceados:** Implementação funcional de um módulo de refinamento atencional dotado de estabilização logarítmica, projeção afim e limite não linear tanh na *Gating Network*, prevenindo o colapso e a extinção de especialistas, associado à otimização conjunta via *Focal Loss* multiclasse balanceada e supervisão profunda (*deep supervision*);
3. **Fusão por soma ponderada e cabeça classificatória profunda:** Concepção do módulo ALF operando estritamente sobre a combinação linear ponderada das predições de probabilidade dos especialistas ($z = \sum a_k \hat{y}^{(k)}$), projetada através de camadas densas com normalização em lote e LeakyReLU, assegurando calibração probabilística sem acoplamento espúrio residual;
4. **Validação empírica abrangente em múltiplos benchmarks consolidados:** Condução de avaliação experimental sistemática sobre referências públicas heterogêneas de cibersegurança (CSE-CIC-IDS2018 Canônico e Corrigido, CIC-BCCC-NRC-2024 e CIC-UNSW-NB15) em sete configurações de teste, evidenciando a consistência da arquitetura frente a perfis operacionais de redes corporativas em nuvem, ambientes IoT com protocolos leves (MQTT) e emulação de ataques complexos;
5. **Análise comparativa dos especialistas e viabilidade de inferência em tempo real:** Comprovação experimental da superioridade sistemática da fusão adaptativa ALF sobre todos os especialistas isolados, associada à implementação de um pipeline de inferência em tempo real com NFileStream capaz de processar fluxos com latência média de aproximadamente 54 ms na GPU e vazão superior a 80.000 fluxos/s em regime de lote.

1.5 ORGANIZAÇÃO DO TRABALHO

O presente documento está estruturado em seis capítulos, ordenados conforme o encadeamento a seguir:

- **Capítulo 1 – Introdução:** Apresenta a contextualização do problema de segurança cibernética e detecção de intrusões sob tráfego cifrado, a motivação para abordagens multidomínio de aprendizado profundo, a definição formal do problema, os objetivos geral e específicos, as principais contribuições alcançadas e a organização estrutural da tese;
- **Capítulo 2 – Fundamentação Teórica e Trabalhos Correlatos:** Aborda a taxonomia das principais famílias de ataques cibernéticos em redes e os conceitos fundamentais dos Sistemas de Detecção de Intrusão. Detalha a fundamentação teórica das redes neurais profundas especializadas (DNN, CNN, GRU, CAE e LSTM), a teoria de Mistura de Especialistas (MoE), os mecanismos de atenção e as funções de perda para dados desbalanceados. Conclui com uma revisão crítica da literatura recente de NIDS e fusão de modelos;
- **Capítulo 3 – Materiais e Metodologia:** Descreve os conjuntos de dados de referência adotados como *benchmark* (CSE-CIC-IDS2018 Canônico e Corrigido, CIC-BCCC-NRC-2024 e CIC-UNSW-NB15) e o pipeline de pré-processamento e particionamento dos atributos nos cinco domínios especialistas. Especifica a arquitetura formal do modelo ALF-MoE (redes especialistas, *Gating Network* e bloco de fusão ALF), bem como o protocolo experimental de treinamento com supervisão profunda e as métricas estatísticas e computacionais formais de avaliação;
- **Capítulo 4 – Pipeline de Extração e Ambiente de Inferência:** Aborda os aspectos de engenharia de software e telemetria de tráfego baseada no *framework* NFStream, o alinhamento de atributos de rede, o padrão produtor-consumidor para estabilidade de contexto de GPU e a arquitetura do ambiente de execução para inferência em tempo real;
- **Capítulo 5 – Resultados e Discussão:** Expõe a análise comparativa de desempenho discriminativo da arquitetura ALF-MoE nos conjuntos de dados avaliados, acompanhada por análise comparativa detalhada dos especialistas e do bloco ALF, justificativa estatística das matrizes de confusão e avaliação de latência e vazão computacional da inferência em tempo real;
- **Capítulo 6 – Conclusão:** Sintetiza as principais deduções e conclusões obtidas pela pesquisa, discute as limitações metodológicas e operacionais do trabalho e elenca direcionamentos para a realização de pesquisas futuras.

2 FUNDAMENTAÇÃO TEÓRICA E TRABALHOS CORRELATOS

2.1 ATAQUES CIBERNÉTICOS E SISTEMAS DE DETECÇÃO DE INTRUSÃO (NIDS)

A evolução contínua das infraestruturas de telecomunicações e a crescente sofisticação dos vetores de ameaça transformaram a segurança cibernética em um dos pilares mais críticos da sociedade contemporânea. Em redes computacionais corporativas, governamentais e industriais, os dados trafegam por meio de pilhas protocolares complexas, sujeitas a vulnerabilidades de implementação, desvios operacionais e ataques intencionais orientados à degradação de serviços ou à exfiltração de informações confidenciais (Dreyer et al., 2018; Jada; Mayayise, 2024). Nesse cenário de risco permanente, a defesa em profundidade (*defense-in-depth*) consolida-se como a arquitetura padrão para resguardar ativos estratégicos, na qual os Sistemas de Detecção de Intrusão em Redes (*Network Intrusion Detection Systems* – NIDS) atuam como uma camada fundamental de vigilância contínua e telemetria analítica (Guadarrama et al., 2025; Chen et al., 2025).

Diferentemente dos dispositivos de filtragem perimetral clássicos, como os *firewalls* tradicionais fundamentados em listas estáticas de controle de acesso (*Access Control Lists* – ACL), os NIDS dedicam-se à inspeção minuciosa dos pacotes que transitam pelos enlaces físicos e lógicos, buscando identificar anomalias estatísticas, padrões de varredura ou assinaturas de exploração de vulnerabilidades (Sarhan; Layeghy; Portmann, 2022). A modelagem analítica desse tráfego requer a compreensão estrutural das categorias de ataques que desafiam os ambientes operacionais, bem como das metodologias e limitações práticas das ferramentas voltadas à sua identificação e contenção.

2.1.1 Taxonomia de Ataques de Rede

A caracterização formal do tráfego malicioso demanda sua estratificação em taxonomias consolidadas pela comunidade científica e por centros internacionais de resposta a incidentes. A literatura técnica agrupa as ameaças de rede em classes comportamentais distintas com base no objetivo da intrusão, no volume de dados injetado, no protocolo explorado e na persistência temporal da ação maliciosa (Sharafaldin; Lashkari; Ghorbani, 2018; Sarhan; Layeghy; Portmann, 2022; Neto et al., 2023). Entre as principais classes de ataques mapeadas em ambientes contemporâneos, destacam-se:

1. **Negação de Serviço e Negação de Serviço Distribuída (*Denial of Service* – DoS / *Distributed Denial of Service* – DDoS):** Os ataques de negação de serviço têm como finalidade indisponibilizar um serviço, servidor ou infraestrutura de rede, exaurindo recursos computacionais finitos (como largura de banda, memória, capacidade de processamento ou

entradas em tabelas de estado do sistema operacional) (Sharafaldin; Lashkari; Ghorbani, 2018). Manifestam-se primordialmente sob três variantes:

- *Ataques Volumétricos*: baseiam-se na inundação maciça de pacotes (*packet flooding*) para congestionar fisicamente o canal de transmissão. Empregam comumente o protocolo UDP (*UDP Flood*), mensagens ICMP (*Ping Flood*) ou técnicas de reflexão e amplificação baseadas em protocolos de camada de aplicação desprotegidos, tais como DNS, NTP e SNMP. Nestes últimos, o atacante forja o endereço IP de origem (*IP spoofing*) para o endereço da vítima e requisita respostas desproporcionalmente maiores aos servidores de reflexão abertos (Neto et al., 2023);
- *Ataques de Esgotamento de Estado TCP*: exploram os mecanismos do aperto de mão de três vias (*three-way handshake*) do protocolo TCP. O expoente clássico é o *TCP SYN Flood*, em que o adversário envia rajadas massivas de pacotes de controle com o sinalizador SYN ativo, sem completar a conexão com o pacote ACK subsequente. Em consequência, a pilha de rede da vítima mantém conexões semiabertas na fila de conexões pendentes (*backlog queue*), esgotando as estruturas de alocação de memória (*Transmission Control Blocks – TCB*) e rejeitando requisições legítimas (Sharafaldin; Lashkari; Ghorbani, 2018);
- *Ataques de Baixa Vazão em Camada de Aplicação (L7 Low-and-Slow)*: operam abaixo dos limiares de detecção volumétrica convencionais. Ferramentas como o *Slowloris* e o *R-U-Dead-Yet (RUDY)* abrem múltiplas conexões HTTP/HTTPS legítimas com o servidor web e enviam cabeçalhos ou corpos de requisição fragmentados a intervalos regulares extremamente lentos. Como o servidor reserva *threads* de processamento e conexões de soquete aguardando a finalização da mensagem HTTP, seu conjunto de conexões ativas é completamente saturado com consumo mínimo de largura de banda pelo atacante.

2. Ataques de Varredura e Reconhecimento (*Port Scanning* e *Network Probing*): Constituem a fase preliminar do ciclo de vida de uma intrusão, na qual o atacante mapeia a topologia do alvo, descobre estações ativas, identifica portas de transporte abertas e determina os sistemas operacionais e serviços em execução (*fingerprinting*) (Sarhan et al., 2021). Ferramentas automatizadas utilizam diversas técnicas de sondagem:

- *SYN Stealth Scan (TCP Half-Open)*: o scanner transmite um pacote SYN; caso o alvo responda com SYN-ACK (indicando porta aberta), o atacante envia imediatamente um pacote RST em vez de completar o aperto de mão com ACK, evitando o registro da conexão nos logs das aplicações da vítima;
- *Scans Especiais (FIN, NULL e Xmas Scans)*: exploram violações intencionais da especificação canônica da RFC 793. No *Xmas Scan*, os sinalizadores FIN, PSH e URG são ativados concomitantemente. Conforme o padrão TCP, portas fechadas

devem retornar um pacote RST, ao passo que portas abertas descartam a mensagem anômala sem resposta. Padrões desse tipo manifestam-se em atributos estatísticos de contagem de sinalizadores em fluxos agregados (Sarhan; Layeghy; Portmann, 2022).

3. **Ataques de Força Bruta (*Brute Force Attacks*):** Consistem na submissão sistemática e automatizada de extensas listas de credenciais de autenticação contra serviços administrativos e de transferência remota, tais como SSH (*Secure Shell*), FTP, RDP (*Remote Desktop Protocol*) e interfaces web de login (Sharafaldin; Lashkari; Ghorbani, 2018). No tráfego de rede, manifestam-se por sequências repetitivas de fluxos bidirecionais de curta duração, taxas de transferência moderadas e elevadíssima concentração temporal de tentativas consecutivas originadas de um único nó ou distribuídas por uma rede intermediária.
4. **Ataques a Aplicações Web e Injeção de Código:** Exploram falhas de sanitização e validação de parâmetros de entrada em servidores e aplicações web (Kaur; Kaur, 2016; Sharif, 2022). Entre as modalidades prevalentes documentadas nos conjuntos de dados de referência (como o CSE-CIC-IDS2018), incluem-se:
 - *Injeção de SQL (SQL Injection – SQLi)*: inserção de fragmentos arbitrários de instruções SQL em formulários ou parâmetros HTTP GET/POST, contornando mecanismos de controle de acesso ou expondo registros confidenciais de bancos de dados (Kaur; Kaur, 2016);
 - *Cross-Site Scripting (XSS)*: injeção de scripts maliciosos interpretados nos navegadores de usuários legítimos, possibilitando o sequestro de sessões autenticadas (*session hijacking*) e a interceptação de credenciais (Sharif, 2022);
 - *Injeção de Comandos de Sistema Operacional e Travessia de Diretórios (Directory Traversal)*: manipulação de caminhos relativos (tais como `.. / .. /`) para acessar arquivos restritos do sistema hospedeiro ou invocar binários locais.
5. **Redes Zumbis (*Botnets*) e Canais de Comando e Controle (C2):** Uma *botnet* compreende uma rede distribuída de nós comprometidos (*bots*) subordinados a uma infraestrutura centralizada ou peer-to-peer (P2P) administrada por atacantes (Sharafaldin; Lashkari; Ghorbani, 2018). O tráfego característico reside nos canais de Comando e Controle (*Command and Control – C2*). Para manter a conectividade sem suscitar alertas nos mecanismos de segurança perimetrais, os canais C2 empregam técnicas de comunicação furtiva, tais como sinalização periódica com perturbação estocástica de tempo (*beaconing com jitter*), Algoritmos de Geração de Domínio (*Domain Generation Algorithms – DGA*), tunelamento em consultas DNS (*DNS Tunneling*) e encapsulamento em tráfego HTTPS padrão através da porta TCP 443 com certificados digitais válidos.
6. **Ameaças Avançadas Persistentes (APTs) e Infiltrações Multi-estágio:** Campanhas APT distinguem-se pelo elevado grau de sofisticação técnica, planejamento meticuloso e

atuação prolongada voltada a alvos institucionais de alto valor (Phan; Nguyen; Bauschert, 2026). As operações ofensivas estruturam-se segundo cadeias táticas formais, a exemplo do modelo *Cyber Kill Chain* e da matriz analítica MITRE ATT&CK (Ferraz et al., 2025). O ciclo operacional multi-estágio abrange fases de reconhecimento, acesso inicial, estabelecimento de persistência, escalonamento local de privilégios, evasão de defesas, movimentação lateral na sub-rede corporativa, coleta e exfiltração de dados confidenciais (Phan; Nguyen; Bauschert, 2026; Orbinato et al., 2024). Durante a movimentação interna, os adversários empregam técnicas de *Living-off-the-Land* (LotL) e emulação adversarial avançada com módulos de anti-deteção (Orbinato et al., 2024). A identificação tempestiva dessas campanhas impõe imensa complexidade aos NIDS, uma vez que pacotes isolados exibem total conformidade sintática com os protocolos ordinários, tornando as dependências estatísticas e dinâmicas temporais de longo prazo a assinatura primordial para a detecção da anomalia (Ferraz et al., 2025).

2.1.2 Métodos de Identificação e Mitigação

A eficácia de uma postura defensiva em redes de computadores depende das estratégias de inspeção empregadas para avaliar o fluxo de informações e das ações automatizadas executadas quando uma ameaça é diagnosticada.

2.1.2.1 Paradigmas de Detecção de Intrusão

Historicamente, os sistemas de detecção de intrusão classificam-se em três paradigmas fundamentais (Guadarrama et al., 2025):

- **Detecção Baseada em Assinaturas (*Signature-Based Detection*):** Opera sob o princípio determinístico de que ameaças conhecidas manifestam padrões binários ou sintáticos invariantes no tráfego. O motor analítico compara o conteúdo dos pacotes com uma base de dados de regras padronizadas (a exemplo de Snort e Suricata), empregando casamento de padrões por sequências de bytes e expressões regulares.

A vantagem primordial reside no processamento veloz e na taxa de falsos positivos virtualmente nula para ameaças catalogadas. Em contrapartida, sua deficiência intrínseca consiste na incapacidade absoluta de identificar ataques de dia zero (*zero-day*), variações polimórficas de código malicioso ou payloads submetidos a novas técnicas de ofuscação, demandando frequentes atualizações de regras (Borgioli et al., 2024).

- **Detecção Baseada em Anomalias (*Anomaly-Based Detection*):** Assume a premissa de que o tráfego hostil diverge de maneira quantificável do comportamento ordinário da rede. O classificador constrói um perfil de referência (*baseline*) que encapsula a operação legítima observada durante períodos estáveis. Amostras posteriores que apresentem discrepâncias estatísticas relevantes em relação a esse perfil são rotuladas como suspeitas.

Sua principal virtude reside na aptidão teórica para identificar ataques inéditos e anomalias não documentadas. Todavia, sua operacionalização prática confronta o desafio da elevada taxa de falsos positivos (*False Positive Rate* – FPR), causada pela volatilidade intrínseca do tráfego computacional, em que eventos operacionais ordinários (como manutenções programadas ou picos sazonais de acesso) podem ser incorretamente categorizados como intrusões (Guadarrama et al., 2025; Silva, 2025).

- **Detecção Baseada em Especificação ou Políticas (*Specification-Based*):** Prescreve um conjunto explícito de restrições lógicas e gramaticais que delimitam o comportamento estritamente permitido aos protocolos legítimos (como transições autorizadas na máquina de estados de uma sessão de transporte ou faixas limites de parâmetros em protocolos industriais SCADA). Qualquer violação às regras canônicas é reportada como evento hostil. Embora reduza falsos positivos sem exigir grandes históricos de dados, impõe custo expressivo de modelagem manual e não identifica ataques que operem em conformidade estrita com a sintaxe do protocolo.

2.1.2.2 Granularidade de Inspeção: DPI versus Análise Baseada em Fluxos

A viabilidade técnica e a escalabilidade dos NIDS são governadas pela camada e pela granularidade com que a inspeção do tráfego é conduzida:

- **Inspeção Profunda de Pacotes (*Deep Packet Inspection* – DPI):** A metodologia DPI reconstrói integralmente as sessões de transporte e decodifica a carga útil (*payload*) dos pacotes nas camadas superiores (como HTTP, DNS e SMTP). Não obstante o nível elevado de contextualização semântica, sua aplicabilidade prática foi drasticamente comprometida pela consolidação ubíqua de protocolos com cifragem ponta a ponta obrigatória – com destaque para o TLS 1.3, HTTPS, DNS sobre HTTPS (*DNS over HTTPS* – DoH) e redes privadas virtuais (*Virtual Private Networks* – VPN) (Sarhan; Layeghy; Portmann, 2022; He; Fu; Zhang, 2026). Sob cifragem contínua, o conteúdo das mensagens torna-se opaco aos nós intermediários de rede. Ademais, o custo computacional exigido para remontar fluxos e processar expressões regulares sobre a carga útil inviabiliza sua aplicação em enlaces modernos operando em taxas de 10, 40 ou 100 Gbps (Chen et al., 2025).
- **Análise Baseada em Fluxos de Rede (*Flow-Based Analysis*):** Como resposta às limitações da análise de carga útil sob tráfego cifrado, consolidou-se o monitoramento baseado em fluxos estatísticos de tráfego (*network flows*) (Sarhan et al., 2021; Aouini; Pekar, 2022). Formalmente, um fluxo IP $\mathcal{F}$ é conceituado como uma sequência ordenada de pacotes observada em um dado intervalo temporal que compartilha uma tupla canônica de identificação, tradicionalmente expressa pela tupla de cinco campos (*5-tuple*):

$$\mathcal{F}_{id} = \langle IP_{src}, IP_{dst}, Port_{src}, Port_{dst}, Protocolo \rangle. \quad (1)$$

A partir desse agrupamento, extratores de telemetria (tais como NetFlow, IPFIX, CFlowMeter e NFStream) derivam vetores estatísticos multidimensionais que descrevem a conexão (Sarhan; Layeghy; Portmann, 2022; Aouini; Pekar, 2022): contagens totais de pacotes e bytes por sentido, tempos entre chegadas consecutivas de pacotes (*Inter-Arrival Times* – IAT), parâmetros de dispersão do comprimento dos pacotes (médias, desvios padrão, variâncias), tempos de atividade (*active*) e inatividade (*idle*), e sinalizadores TCP acumulados. Esse paradigma preserva a privacidade dos dados transmitidos, opera de maneira independente da presença de criptografia no payload e viabiliza o processamento analítico escalável tanto em redes corporativas de grande escala quanto em topologias de computação em névoa (*fog computing*) e Internet das Coisas (*Internet of Things* – IoT) (Neto et al., 2023; Čenys; Hora; Goranin, 2025; Souza, 2023).

2.1.2.3 Mecanismos de Resposta e Mitigação

O diagnóstico emitido por um sistema de monitoramento só adquire efetividade defensiva prática quando acoplado a mecanismos operacionais de contenção (Guadarrama et al., 2025; Souza, 2023). A atuação divide-se em duas abordagens fundamentais:

- **Operação Passiva (NIDS):** o dispositivo é acoplado à rede de forma não disruptiva, por meio de portas espelho (*Switched Port Analyzer* – SPAN) ou acopladores físicos de sinal (*network TAP*) (Guadarrama et al., 2025). O sistema processa o tráfego de maneira assíncrona, despachando registros de alertas estruturados (em formatos como syslog, JSON ou CEF) para plataformas de Gerenciamento de Informações e Eventos de Segurança (*Security Information and Event Management* – SIEM) e plataformas de Orquestração, Automação e Resposta de Segurança (*Security Orchestration, Automation, and Response* – SOAR). Embora não adicione latência ao tráfego legítimo, essa abordagem não bloqueia intrusões em tempo real.
- **Operação Ativa (NIPS – *Network Intrusion Prevention System*):** o motor analítico atua diretamente na linha física ou lógica de comunicação (*inline*) ou integrado a elementos programáveis da camada de encaminhamento (Chen et al., 2025; Souza, 2023). Ao diagnosticar uma anomalia, o NIPS dispara medidas ativas de contenção imediata:
 - Descarte determinístico de pacotes associados ao fluxo malicioso (*packet dropping*);
 - Injeção de pacotes com o sinalizador TCP RST ativo direcionados aos extremos da conexão, provocando o término forçado e unilateral da sessão de transporte;
 - Atualização dinâmica de tabelas de filtragem no nível do kernel do sistema operacional (como `nftables` e conjuntos `ipset`), aplicando bloqueios temporais granulares sobre o endereço IP de origem;
 - Orquestração direta em planos de controle de Redes Definidas por Software (*Software-Defined Networking* – SDN) e em comutadores programáveis baseados no padrão P4,

viabilizando o redirecionamento para redes de isolamento (*honeynets*) ou aplicando políticas de descarte seletivo diretamente na taxa de transmissão da linha física (*line-rate processing*) (Chen et al., 2025).

2.2 APRENDIZADO PROFUNDO PARA SEGURANÇA DE REDES

A inadequação dos sistemas legados baseados em assinaturas perante a velocidade de mutação dos ataques contemporâneos impulsionou a adoção crescente de técnicas de Inteligência Artificial para a classificação analítica do tráfego (Noor; Ige, 2025; Dari et al., 2024). Inicialmente, as pesquisas concentraram-se em algoritmos clássicos de Aprendizado de Máquina (*Machine Learning* – ML), a exemplo de Máquinas de Vetores de Suporte (*Support Vector Machines* – SVM), Árvores de Decisão e comitês de Florestas Aleatórias (*Random Forest*) (Sainis; Srivastava; Singh, 2018). Todavia, esses modelos clássicos padecem de acentuada dependência de engenharia manual de atributos (*feature engineering*), registrando degradação de acurácia à medida que a dimensionalidade e o volume dos dados atingem a escala de enlaces industriais (Guadarrama et al., 2025).

Nesse contexto, o Aprendizado Profundo (*Deep Learning* – DL) estabeleceu-se como a abordagem metodológica central na segurança computacional moderna (Noor; Ige, 2025). Por intermédio de grafos computacionais constituídos por sucessivas transformações afins intercaladas por funções de ativação não lineares, os modelos profundos executam a extração automatizada de representações hierárquicas diretamente dos dados brutos ou de sumários de fluxo, mapeando correlações espaciais, dependências sequenciais e componentes espectrais determinantes da ação adversária (Luay et al., 2025; Luay et al., 2026).

2.2.1 Redes Convolucionais e Recorrentes (CNN, LSTM, GRU)

A modelagem estocástica do tráfego de rede abrange grandezas que variam tanto espacialmente (associações estruturais entre atributos de cabeçalho e métricas de volume) quanto sequencialmente (evolução cronológica das chegadas e tamanhos de pacotes). Famílias distintas de redes neurais foram estruturadas para atender a essas propriedades analíticas.

2.2.1.1 Redes Neurais Convolucionais (CNN)

Desenvolvidas originariamente para o processamento de arranjos bidimensionais, as Redes Neurais Convolucionais (*Convolutional Neural Networks* – CNN) baseiam-se em três princípios estruturais: campos receptivos locais (*local receptive fields*), compartilhamento de parâmetros sinápticos (*weight sharing*) e invariância a pequenas translações espaciais (Noor; Ige, 2025). Na análise de segurança de rede, essas propriedades são exploradas mediante a aplicação de operações de convolução unidimensional (1D-CNN) ou bidimensional (2D-CNN) sobre matrizes estruturadas de pacotes ou vetores tabulares de atributos de fluxo (Sarhan et al., 2021).

Formalmente, considere um vetor de entrada $\mathbf{x} \in \mathbb{R}^{L \times C_{\text{in}}}$, em que L denota o comprimento dimensional e C_{in} representa o número de canais. A operação de convolução discreta unidimensional com passo unitário, governada por um filtro de pesos $\mathbf{W}^{(l)} \in \mathbb{R}^{M \times C_{\text{in}}}$ e viés $b^{(l)} \in \mathbb{R}$, para a geração do mapa de ativação na camada l , é dada por:

$$y_i^{(l)} = \sigma \left(\sum_{c=1}^{C_{\text{in}}} \sum_{m=0}^{M-1} W_{m,c}^{(l)} x_{i+m,c} + b^{(l)} \right), \quad (2)$$

em que M denota a largura da janela do filtro convolucional (*kernel size*) e $\sigma(\cdot)$ representa a função de ativação não linear. De forma análoga, em projeções matriciais espaciais em que as características do fluxo são organizadas sob a forma de uma matriz $\mathbf{X} \in \mathbb{R}^{H \times W \times C_{\text{in}}}$, a convolução bidimensional com filtro $\mathbf{W}^{(l)} \in \mathbb{R}^{M_h \times M_w \times C_{\text{in}}}$ assume a formulação:

$$Y_{i,j}^{(l)} = \sigma \left(\sum_{c=1}^{C_{\text{in}}} \sum_{m=0}^{M_h-1} \sum_{n=0}^{M_w-1} W_{m,n,c}^{(l)} X_{i+m,j+n,c} + b^{(l)} \right). \quad (3)$$

Entre as funções de ativação comumente empregadas, destacam-se a Unidade Linear Retificada (*Rectified Linear Unit* – ReLU), expressa por $\text{ReLU}(z) = \max(0, z)$, e sua extensão com gradiente residual (*Leaky ReLU*):

$$\text{LeakyReLU}(z) = \begin{cases} z, & \text{se } z > 0, \\ \alpha_L z, & \text{se } z \leq 0, \end{cases} \quad \text{com } 0 < \alpha_L \ll 1, \quad (4)$$

a qual mitiga a inativação permanente de neurônios (*dying ReLU problem*) durante a retropropagação do gradiente.

Para acelerar a convergência e assegurar estabilidade numérica entre camadas convolucionais sucessivas, adota-se a técnica de Normalização em Lote (*Batch Normalization*) (Noor; Ige, 2025). Para um conjunto de ativações intermediárias $\mathcal{B} = \{x_1, \dots, x_B\}$, calcula-se a média amostral μ_B e a variância σ_B^2 , escalonando e transladando os dados por meio dos parâmetros aprendíveis γ e β :

$$\hat{x}_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon_B}}, \quad y_i = \gamma \hat{x}_i + \beta, \quad (5)$$

sendo $\epsilon_B > 0$ uma constante de estabilização. Subsequentemente, operações de agrupamento (*Pooling*), tais como o agrupamento máximo (*Max Pooling*), extraem o valor dominante em janelas de dimensão P , comprimindo o mapa de características:

$$p_j = \max_{k \in \{0, \dots, P-1\}} (y_{j \cdot P + k}). \quad (6)$$

Em sistemas NIDS, os módulos convolucionais operam como detectores eficientes de padrões morfológicos locais, identificando dependências espaciais entre campos de cabeçalhos e métricas de transporte sem impor premissas estritas de linearidade global (Noor; Ige, 2025).

2.2.1.2 Redes Neurais Recorrentes e a Modelagem Temporal (LSTM e GRU)

Diversas manifestações de ataques – tais como canais de comando e controle com transmissão periódica, varreduras esparsas de portas e etapas graduais de infiltração – apresentam assinaturas distribuídas sequencialmente ao longo do tempo (Luay et al., 2025; Luay et al., 2026). Redes Neurais Recorrentes (*Recurrent Neural Networks* – RNN) mantêm um estado oculto recorrente $\mathbf{h}_t$, processando sequências temporais de forma cronológica recursiva.

Contudo, as variantes elementares de RNN enfrentam a limitação do desvanecimento ou explosão do gradiente (*vanishing and exploding gradients*) durante o processo de retropropagação através do tempo (*Backpropagation Through Time* – BPTT) (Noor; Ige, 2025). Quando o horizonte temporal abrange múltiplos passos T , o encadeamento sucessivo de derivadas $\prod_{k=t+1}^T \frac{\partial \mathbf{h}_k}{\partial \mathbf{h}_{k-1}}$ induz o decaimento exponencial a zero ou a divergência dos valores dos gradientes, impedindo o aprendizado de dependências remotas na sequência de pacotes.

Para contornar essa restrição, foram desenvolvidas arquiteturas fundamentadas em estruturas lógicas de controle denominadas portas (*gates*): a rede de Memória de Curto e Longo Prazo (*Long Short-Term Memory* – LSTM) e a Unidade Recorrente com Portas (*Gated Recurrent Unit* – GRU).

2.2.1.2.1 Long Short-Term Memory (LSTM):

A LSTM desacopla a preservação de contexto por intermédio de um vetor de estado celular $\mathbf{C}_t \in \mathbb{R}^d$, que viabiliza a propagação de gradientes aditivos sem degradação exponencial (Noor; Ige, 2025; Luay et al., 2025). O trânsito de informações entre passos adjacentes é modulado por três portas logísticas que operam sobre o vetor de entrada no instante atual $\mathbf{x}_t \in \mathbb{R}^m$ e o estado oculto precedente $\mathbf{h}_{t-1} \in \mathbb{R}^d$:

1. *Porta de Esquecimento* (Forget Gate): estabelece a proporção do histórico celular a ser retida ou descartada:

$$\mathbf{f}_t = \sigma(\mathbf{W}_f \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f); \quad (7)$$

2. *Porta de Entrada* (Input Gate): quantifica a magnitude com que as novas informações devem atualizar o estado celular:

$$\mathbf{i}_t = \sigma(\mathbf{W}_i \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i); \quad (8)$$

3. *Candidato ao Estado Celular* (Candidate Cell State): calcula um novo vetor candidato de contexto com ativação em tangente hiperbólica:

$$\tilde{\mathbf{C}}_t = \tanh(\mathbf{W}_c \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_c); \quad (9)$$

4. *Atualização do Estado Celular*: combina a memória pregressa com os novos candidatos calculados:

$$\mathbf{C}_t = \mathbf{f}_t \odot \mathbf{C}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{C}}_t; \quad (10)$$

5. *Porta de Saída (Output Gate) e Estado Oculto*: regula a exteriorização das ativações no estado oculto visível $\mathbf{h}_t$:

$$\mathbf{o}_t = \sigma(\mathbf{W}_o \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o), \quad (11)$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{C}_t), \quad (12)$$

em que $\sigma(z) = \frac{1}{1+e^{-z}}$ denota a função sigmoide logística, $\odot$ representa o produto de Hadamard (multiplicação elemento a elemento) e os colchetes $[\mathbf{h}_{t-1}, \mathbf{x}_t]$ denotam a concatenação vetorial. Essa modelagem permite que o classificador retenha correlações temporais em horizontes cronológicos estendidos do fluxo (Luay et al., 2025).

2.2.1.2.2 Gated Recurrent Unit (GRU):

Proposta como uma reformulação simplificada e computacionalmente mais econômica da LSTM, a rede GRU consolida o estado celular diretamente no estado oculto $\mathbf{h}_t$, eliminando a porta de saída independente (Noor; Ige, 2025; Luay et al., 2026). A arquitetura opera sobre duas portas de modulação:

1. *Porta de Atualização (Update Gate)*: pondera a proporção entre a manutenção do estado anterior e a incorporação de novos estados:

$$\mathbf{z}_t = \sigma(\mathbf{W}_z \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_z); \quad (13)$$

2. *Porta de Redefinição (Reset Gate)*: determina o grau de desconsideração da memória anterior no cômputo da ativação candidata:

$$\mathbf{r}_t = \sigma(\mathbf{W}_r \cdot [\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_r); \quad (14)$$

3. *Estado Oculto Candidato*: processa a entrada atual em conjunção com a memória pregressa atenuada pela porta de redefinição:

$$\tilde{\mathbf{h}}_t = \tanh(\mathbf{W}_h \cdot [\mathbf{r}_t \odot \mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_h); \quad (15)$$

4. *Estado Oculto Definitivo*: realiza a interpolação linear entre o estado passado e o estado candidato:

$$\mathbf{h}_t = (1 - \mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t. \quad (16)$$

Por demandar menor quantidade de matrizes de parâmetros, a GRU exibe tempo de convergência reduzido e menor pegada computacional, apresentando excelente adequação à modelagem de dinâmicas transitórias e variações em intervalos entre pacotes (*Inter-Arrival Times* – IAT) (Luay et al., 2026).

2.2.2 Redes Densas, Autoencoders e Análise Espectral

A natureza heterogênea do tráfego de rede requer que atributos estáticos globais e manifestações harmônicas periódicas disponham de tratamentos algorítmicos especializados: transformações totalmente conectadas para sumários agregados e autoencoders acoplados ao processamento espectral para detecção por reconstrução de anomalias.

2.2.2.1 Redes Neurais Totalmente Conectadas (DNN)

As Redes Neurais Profundas Totalmente Conectadas (*Dense Neural Networks* – DNN ou *Multilayer Perceptrons* – MLP) fundamentam-se no encadeamento de transformações lineares seguidas por não linearidades elementares. Cada neurônio da camada l recebe todas as saídas da camada anterior $l - 1$:

$$\mathbf{h}^{(l)} = \sigma(\mathbf{W}^{(l)}\mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}), \quad (17)$$

em que $\mathbf{W}^{(l)} \in \mathbb{R}^{d_l \times d_{l-1}}$ representa a matriz de pesos e $\mathbf{b}^{(l)} \in \mathbb{R}^{d_l}$ denota o vetor de viés. Em arquiteturas NIDS, as DNNs são indicadas para o processamento de variáveis tabulares globais computadas ao longo da sessão (duração, contagem acumulada de pacotes e bytes por sentido e contadores de sinalizadores TCP), nas quais a contiguidade física espacial não é necessariamente mandatória (Guadarrama et al., 2025).

2.2.2.2 Autoencoders Convolucionais 1D (1D-CAE) e Processamento Espectral Integrado

O paradigma do Autoencoder (*Autoencoder* – AE) assenta-se no aprendizado não supervisionado ou semi-supervisionado de representações latentes comprimidas (Silva, 2025). Uma rede AE típica é composta por duas estruturas acopladas: um codificador (*encoder*) $\mathcal{E}_\phi(\cdot)$, que mapeia o vetor de entrada $\mathbf{x} \in \mathbb{R}^D$ para um espaço latente de baixa dimensionalidade $\mathbf{z} \in \mathbb{R}^d$ ($d \ll D$), e um decodificador (*decoder*) $\mathcal{D}_\psi(\cdot)$, encarregado de reconstruir a entrada original gerando $\tilde{\mathbf{x}} = \mathcal{D}_\psi(\mathbf{z}) \in \mathbb{R}^D$. Em tarefas de segurança, treina-se a rede primariamente com tráfego legítimo; fluxos intrusivos com propriedades anômalas não encontram projeção adequada na variedade aprendida, provocando erros de reconstrução $\|\mathbf{x} - \tilde{\mathbf{x}}\|^2$ expressivos (Silva, 2025; Borgioli et al., 2024).

Determinadas categorias de agressão (como inundações pulsáteis periódicas, varreduras sincronizadas por temporizadores internos e canais C2 estruturados) manifestam comportamentos que se destacam como frequências harmônicas bem delineadas no domínio da frequência (Maciá-Fernández et al., 2018). Para capturar essas características, a formulação analítica do Autoencoder Convolucional 1D (1D-CAE) integra o pré-processamento espectral à arquitetura neural:

2.2.2.2.1 1. Seleção de Subdomínio e Janelamento de Hann:

A partir do vetor tabular de características $\mathbf{x} \in \mathbb{R}^F$, particiona-se um subconjunto de comprimento L_f correspondente ao domínio temporal e dinâmico $\mathbf{u} = \mathbf{x}_{1:L_f} \in \mathbb{R}^{L_f}$. Com a finalidade de atenuar o espalhamento espectral (*spectral leakage*) decorrente da truncagem finita do sinal, aplica-se uma Janela Periódica de Hann $\mathbf{w} \in \mathbb{R}^{L_f}$, formulada analiticamente por:

$$w(n) = 0,5 - 0,5 \cos\left(\frac{2\pi n}{L_f}\right), \quad \forall n \in \{0, 1, \dots, L_f - 1\}. \quad (18)$$

O sinal ponderado $\mathbf{u}_w \in \mathbb{R}^{L_f}$ resulta da multiplicação de Hadamard:

$$\mathbf{u}_w = \mathbf{u} \odot \mathbf{w}. \quad (19)$$

2.2.2.2.2 2. Transformada Rápida de Fourier Discreta para Sinais Reais (RFFT):

Sobre o sinal janelado $\mathbf{u}_w$, aplica-se a Transformada Discreta de Fourier para entradas puramente reais (*Real Fast Fourier Transform* – RFFT). Explorando a simetria hermitiana dos coeficientes de Fourier para sequências reais, obtém-se o espectro unilateral com $K_{\text{fft}} = \lfloor L_f/2 \rfloor + 1$ coeficientes discretos. A densidade de magnitude espectral $\mathbf{x}_f \in \mathbb{R}^{K_{\text{fft}}}$ é obtida pelo módulo dos números complexos:

$$x_f[k] = \left| \sum_{n=0}^{L_f-1} u_w[n] \cdot e^{-j\frac{2\pi kn}{L_f}} \right|, \quad \forall k \in \{0, 1, \dots, K_{\text{fft}} - 1\}. \quad (20)$$

2.2.2.2.3 3. Codificação Convolutiva 1D:

O vetor $\mathbf{x}_f$ é expandido para canal unitário e processado por S camadas de convolução unidimensional com filtros de dimensão K_{size} e passo s :

$$\mathbf{z}^{(s)} = \text{ReLU} \left(\mathbf{W}_e^{(s)} * \mathbf{z}^{(s-1)} + \mathbf{b}_e^{(s)} \right), \quad s \in \{1, \dots, S\}, \quad (21)$$

com $\mathbf{z}^{(0)} = \mathbf{x}_f$, resultando na representação latente compactada $\mathbf{z} = \mathbf{z}^{(S)}$.

2.2.2.2.4 4. Decodificação por Convolução Transposta 1D:

A estimativa do espectro de magnitude $\tilde{\mathbf{x}}_f \in \mathbb{R}^{K_{\text{fft}}}$ é sintetizada por camadas de Convolução Transposta 1D (*Conv1DTranspose*), invertendo o processo de redução dimensional com ajuste de comprimento espectral:

$$\tilde{\mathbf{x}}_f = \text{ReLU} \left(\mathbf{W}_d *^\top \mathbf{z} + \mathbf{b}_d \right). \quad (22)$$

2.2.2.2.5 5. Função de Perda Composta do CAE com Supervisão Profunda:

Conforme modelado no sistema ALF-MoE, o treinamento do especialista CAE é orientado por uma função de perda conjunta que sintetiza a supervisão de classificação $\mathcal{L}_{\text{cls}}$, o Erro Quadrático Médio de reconstrução espectral (*Mean Squared Error* – MSE) e a regularização L_2 sobre os pesos:

$$\mathcal{L}_{\text{CAE}} = \lambda_{\text{cls}} \mathcal{L}_{\text{cls}} + \frac{\lambda_{\text{rec}}}{N} \sum_{i=1}^N \sum_{k=0}^{K_{\text{fft}}-1} (x_{f,i}[k] - \tilde{x}_{f,i}[k])^2 + \lambda_4 \sum_{w \in \mathcal{W}_{\text{CAE}}} \|w\|_2^2, \quad (23)$$

em que N indica a quantidade de amostras do lote, λ_{rec} representa o peso da perda de reconstrução, λ_4 denota a penalização L_2 e λ_{cls} governa o gradiente supervisionado da predição auxiliar de classe. Essa formulação assegura que a representação latente $\mathbf{z}$ capture tanto propriedades discriminatórias de classes quanto a regularidade espectral do tráfego legítimo (Borgioli et al., 2024).

2.2.3 Tratamento de Desbalanceamento Extremo via Focal Loss

Conjuntos de dados de cibersegurança caracterizam-se por desbalanceamento severo de classes, em que o tráfego benigno frequentemente responde por mais de 90% das amostras, ao passo que ataques críticos (como *Infiltration*, *Web Attacks* e *Botnets*) representam frações inferiores a 1% do total coletado (Neto et al., 2023; Sarhan; Layeghy; Portmann, 2022). Nessas condições, a função convencional de Entropia Cruzada (*Categorical Cross-Entropy* – CE) tende a ser dominada pelo acúmulo de gradientes das amostras majoritárias facilmente classificáveis, negligenciando as categorias minoritárias essenciais.

Para mitigar essa assimetria, incorpora-se a função de Perda Focal (*Focal Loss* – FL), concebida por Lin et al. (2017):

$$\text{FL}(p_t) = -\alpha_t (1 - p_t)^\gamma \log(p_t), \quad (24)$$

em que $p_t \in (0, 1]$ denota a probabilidade estimada pelo classificador para a classe verdadeira do fluxo, $\gamma \geq 0$ representa o parâmetro de foco e $\alpha_t \in (0, 1]$ atua como o coeficiente ponderador de balanceamento de classe.

O fator modulador $(1 - p_t)^\gamma$ reduz a contribuição relativa de exemplos fáceis e bem calibrados ($p_t \rightarrow 1$), concentrando o esforço de otimização nos padrões raros ou fronteiros de ataque ($p_t \rightarrow 0$). Para um minilote com N observações e C categorias de tráfego, a formulação numérica com proteção contra indefinição logarítmica via limitação infinitesimal $\epsilon = 10^{-8}$ é dada por:

$$\mathcal{L}_{\text{FL}} = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \alpha_c (1 - \hat{y}_{i,c})^\gamma \log(\text{clip}(\hat{y}_{i,c}, \epsilon, 1, 0 - \epsilon)), \quad (25)$$

assegurando estabilidade numérica na convergência dos especialistas mesmo sob desproporções amostrais extremas.

2.2.4 Mixture of Experts (MoE) e Mecanismos de Fusão Atencional

O tráfego de redes contemporâneas exibe uma multiplicidade de padrões cujas manifestações diagnósticas concentram-se em subespaços analíticos distintos (Chandroth; Stoian; Danciulescu, 2026; He; Fu; Zhang, 2026). Modelos monolíticos homogêneos que forçam uma única topologia neural a contemplar correlações espaciais, dependências sequenciais e frequências harmônicas simultaneamente sofrem do fenômeno de interferência negativa de gradientes (*negative gradient interference*), culminando em compromissos de representação subótimos (Yang et al., 2025).

O paradigma de Mistura de Especialistas (*Mixture of Experts* – MoE), formulado inicialmente por Jacobs et al. (1991) e expandido para grandes arquiteturas profundas por Shazeer et al. (2017), baseia-se na divisão modular de tarefas: em vez de um único classificador geral, emprega-se um conjunto de redes especialistas especializadas $\mathcal{E}_1, \mathcal{E}_2, \dots, \mathcal{E}_K$, cuja contribuição individual para a inferência consolidada é arbitrada dinamicamente por uma Rede de Roteamento (*Gating Network*) parametrizada (Chandroth; Stoian; Danciulescu, 2026).

2.2.4.1 Rede de Roteamento Dinâmico (Gating Network)

A Gating Network atua como o módulo decisório da arquitetura MoE. Sua responsabilidade analítica consiste em examinar o contexto de cada amostra de tráfego e computar uma distribuição de probabilidade sobre os K especialistas, quantificando a pertinência diagnóstica de cada modelo para o fluxo em julgamento (He; Fu; Zhang, 2026).

Com a finalidade de dotar a rede de roteamento de capacidade discriminatória enriquecida, sua entrada recebe conjuntamente o vetor tabular bruto do fluxo $\mathbf{x} \in \mathbb{R}^F$ e a concatenação das probabilidades de classe preliminares emitidas por todos os K especialistas $\mathbf{e} = [(\hat{\mathbf{y}}^{(1)})^\top, (\hat{\mathbf{y}}^{(2)})^\top, \dots, (\hat{\mathbf{y}}^{(K)})^\top]^\top \in \mathbb{R}^{K \cdot C}$:

$$\mathbf{h}_{\text{gate}} = \text{ReLU}(\mathbf{W}_{gx}\mathbf{x} + \mathbf{b}_{gx}) + \text{ReLU}(\mathbf{W}_{ge}\mathbf{e} + \mathbf{b}_{ge}). \quad (26)$$

Após sucessivas camadas densas com regularização por Dropout, a rede infere um vetor de escores brutos de roteamento $\mathbf{g} = [g_1, g_2, \dots, g_K]^\top \in \mathbb{R}^K$, normalizado pela função softmax para assegurar que os pesos componham uma partição probabilística unitária:

$$\alpha_k = \frac{\exp(g_k)}{\sum_{j=1}^K \exp(g_j)}, \quad \forall k \in \{1, \dots, K\}, \quad \text{satisfazendo} \quad \sum_{k=1}^K \alpha_k = 1 \quad \text{e} \quad \alpha_k \geq 0. \quad (27)$$

2.2.4.2 Mecanismo de Refinamento Atencional Aprendível (ALF)

Em arranjos clássicos de MoE, a inferência final limita-se à média ponderada direta pelos pesos α_k do softmax. Todavia, sob tráfego de rede marcado por classes com padrões concorrentes

e ruídos de medição, a ativação softmax tende a exibir descalibração probabilística (*miscalibration*), atribuindo pesos desproporcionais a modelos com saídas superconfiantes (Chandroth; Stoian; Danciulescu, 2026).

Para contornar essa restrição, adota-se o mecanismo de Fusão Aprendível Baseada em Atenção (*Attention-Based Learnable Fusion – ALF*), fundamentado no refinamento atencional afim e na calibração de escores (Chandroth; Stoian; Danciulescu, 2026):

2.2.4.2.1 1. Transformação Logarítmica Estabilizada:

Os coeficientes probabilísticos $\alpha = [\alpha_1, \dots, \alpha_K]^\top$ são submetidos a uma operação de limitação inferior com valor infinitesimal $\epsilon = 10^{-7}$, seguida pelo cômputo logarítmico:

$$\log \alpha_{\text{clip}} = \log (\text{clip}(\alpha, \epsilon, 1, 0)). \quad (28)$$

A representação no domínio logarítmico converte correlações multiplicativas de certeza em grandezas aditivas, facilitando o aprendizado de sinergias através de transformações lineares.

2.2.4.2.2 2. Camada de Refinamento de Atenção com Pesos Afins:

O vetor $\log \alpha_{\text{clip}}$ é submetido a uma camada de projeção parametrizada por uma matriz de refinamento atencional $\mathbf{W}_g \in \mathbb{R}^{K \times K}$ e um vetor de viés $\mathbf{b}_g \in \mathbb{R}^K$, modulada pela tangente hiperbólica e normalizada por softmax:

$$\mathbf{a} = \text{softmax} (\tanh (\mathbf{W}_g \log \alpha_{\text{clip}} + \mathbf{b}_g)). \quad (29)$$

Essa transformação viabiliza que o modelo aprenda correlações cruzadas entre especialistas: a relevância final de um especialista $\mathcal{E}_k$ passa a depender da confiança manifestada pelo comitê como um todo.

2.2.4.2.3 3. Calibração de Confiança via Escalonamento Paramétrico (Vector Scaling):

Em conformidade com os princípios teóricos de calibração em modelos profundos estabelecidos por Guo et al. (2017), probabilidades preditas frequentemente distanciam-se das frequências observadas de acerto. Para restaurar a calibração de confiança dos escores intermediários, incorpora-se o módulo de escalonamento paramétrico (*Vector Scaling*):

$$\hat{\mathbf{s}} = \text{softmax} (\mathbf{W}_s \odot \mathbf{s} + \mathbf{b}_s), \quad (30)$$

em que $\mathbf{W}_s, \mathbf{b}_s \in \mathbb{R}^K$ são parâmetros aprendíveis inicializados respectivamente com valores unitários e nulos, modulando a entropia das decisões preliminares.

2.2.4.2.4 4. Fusão por Soma Ponderada (Weighted Sum Fusion):

Apoiando-se nos coeficientes atencionais refinados $\mathbf{a}$, as previsões individuais dos K especialistas $\hat{\mathbf{y}}^{(k)} \in \mathbb{R}^C$ são sintetizadas por soma ponderada em um vetor latente $\mathbf{Z} \in \mathbb{R}^C$:

$$\mathbf{Z} = \sum_{k=1}^K a_k \cdot \hat{\mathbf{y}}^{(k)}. \quad (31)$$

2.2.4.2.5 5. Projeção Classificatória Final Consolidada:

Com o objetivo de preservar a sensibilidade de subdomínios singulares diante de ataques altamente focados, o vetor sintetizado $\mathbf{Z}$ é concatenado com as previsões de todos os especialistas individuais:

$$\mathbf{h}_{\text{ens}} = [\mathbf{Z}^\top, (\hat{\mathbf{y}}^{(1)})^\top, (\hat{\mathbf{y}}^{(2)})^\top, \dots, (\hat{\mathbf{y}}^{(K)})^\top]^\top \in \mathbb{R}^{(K+1) \cdot C}. \quad (32)$$

O vetor concatenado $\mathbf{h}_{\text{ens}}$ é processado por camadas densas intermediárias com normalização em lote, ativações LeakyReLU e descarte aleatório (*Dropout*), sendo projetado na camada de decisão global $\hat{\mathbf{y}}_{\text{ALF}} \in \mathbb{R}^C$:

$$\hat{\mathbf{y}}_{\text{ALF}} = \text{softmax}(\mathbf{W}_{\text{out}} \mathbf{h}_{\text{ALF}} + \mathbf{b}_{\text{out}}). \quad (33)$$

Essa hierarquia analítica concede à arquitetura ALF-MoE a propriedade singular de alternar dinamicamente entre o consenso coletivo ponderado ($\mathbf{Z}$) e a especialização unívoca de um único domínio na presença de anomalias com assinaturas mono-domínio pronunciadas (Chandroth; Stoian; Danciulescu, 2026).

2.3 TRABALHOS CORRELATOS

O desenvolvimento de arquiteturas computacionais robustas para detecção de anomalias em redes constitui uma linha de investigação consolidada e fértil na Ciência da Computação. O exame crítico das abordagens existentes permite posicionar formalmente as contribuições deste trabalho, examinando a transição de classificadores profundos homogêneos para propostas estruturadas em conjuntos e misturas de especialistas.

2.3.1 NIDS Baseados em Aprendizado Profundo

A evolução dos NIDS baseados em inteligência artificial focou inicialmente na substituição de classificadores superficiais por redes neurais profundas monolíticas aplicadas de forma uniforme sobre os dados (Noor; Ige, 2025).

Sainis, Srivastava & Singh (2018) investigaram a detecção de valores atípicos (*outlier detection*) combinada a algoritmos de seleção de atributos para aprimoramento da precisão de sistemas IDS. Os autores constataram que a seleção supervisionada de variáveis reduz taxas

de falsos positivos em conjuntos de dados legados, a exemplo de KDD-Cup99 e NSL-KDD. Entretanto, a abordagem restringiu-se a classificadores rasos tradicionais (SVM, Árvores de Decisão e Random Forest) aplicados sobre a totalidade indiscriminada dos atributos, sem distinguir domínios espaciais, temporais ou espectrais específicos do tráfego.

Sarhan et al. (2021) propuseram representações universais de tráfego baseadas no protocolo NetFlow com o propósito de solucionar a fragmentação metodológica dos dados de rede. Subsequentemente, Sarhan, Layeghy & Portmann (2022) expandiram essa abordagem estabelecendo um conjunto padronizado e canônico de atributos estatísticos aplicável a múltiplos conjuntos de referência (NF-UNSW-NB15, NF-CSE-CIC-IDS2018 e NF-BoT-IoT). As análises confirmaram a viabilidade da identificação de fluxos anômalos a partir de metadados sumarizados de rede. Não obstante, os autores fundamentaram suas avaliações em classificadores convencionais estáticos, sem investigar o encadeamento dinâmico entre chegadas sucessivas de pacotes ou propriedades harmônicas de frequência.

Guadarrama et al. (2025) conduziram um estudo comparativo abrangente sobre conjuntos de dados e algoritmos de aprendizado de máquina para NIDS baseados em fluxos. O trabalho avaliou rigorosamente modelos supervisionados sob diferentes regimes de balanceamento de dados. As principais fragilidades evidenciadas pelos autores situam-se na perda severa de sensibilidade multiclasse perante categorias com baixa representatividade amostral e no custo computacional exigido pelo retreinamento de arquiteturas monolíticas quando confrontadas com volumes massivos de tráfego.

Dari et al. (2024) elaboraram uma avaliação comparativa de redes profundas para resiliência cibernética, confrontando topologias CNN, RNN e DNN na mitigação de intrusões. Os experimentos comprovaram que redes convolucionais sobressaem-se na captura de padrões morfológicos de cabeçalhos, enquanto modelos recorrentes (LSTM e GRU) destacam-se na detecção de ameaças com cadência temporal lenta. Contudo, os autores analisaram cada família de forma isolada, concluindo que nenhuma arquitetura homogênea foi capaz de manter liderança de desempenho em todas as classes de ataques simultaneamente.

Oliveira, Gonçalves & Filho (2025) conceberam o F-NIDS, um sistema de detecção de intrusão alicerçado em Aprendizado Federado (*Federated Learning*) com o objetivo de viabilizar o treinamento colaborativo entre instituições sem exposição de dados brutos. Conquanto enderece requisitos fundamentais de privacidade e descentralização em borda, o classificador local utilizado nos nós baseia-se em uma rede profunda homogênea, reproduzindo a vulnerabilidade analítica diante de ataques heterogêneos.

Abreu & Abelém (2022) apresentaram um sistema híbrido e contínuo (*on-line*) voltado à triagem e classificação de fluxos maliciosos em tempo real. A arquitetura emprega filtros estatísticos preliminares combinados a algoritmos supervisionados em linha de transmissão. Apesar dos avanços na redução da latência operacional, a solução depende de limiares determinísticos estáticos, sofrendo perda de precisão perante novas aplicações benignas que compartilham portas ordinárias de transporte.

Sasi et al. (2025) desenvolveram uma rede híbrida integrando camadas 1D-CNN e LSTM com mecanismos de autoatenção (*self-attention*) voltada a ambientes de IoT. Os resultados apontaram ganhos na detecção de ataques combinados; todavia, a complexidade quadrática do mecanismo de atenção impôs sobrecarga computacional excessiva, tornando o modelo oneroso para execução em taxas de transmissão elevadas de tráfego contínuo.

2.3.2 Abordagens Ensemble e Mixture of Experts em Cibersegurança

Buscando suplantiar os limites teóricos e operacionais das redes homogêneas, a comunidade acadêmica voltou-se para abordagens baseadas em aprendizado em conjunto (*ensemble*) e especialização de redes.

Silva (2025) propuseram o HSAE (*Hybrid Semi-Supervised Autoencoder*), uma estrutura semi-supervisionada projetada para identificação de ameaças de dia zero combinada a um comitê ensemble. O arranjo sintetiza autoencoders para a caracterização da normalidade com classificadores em comitê. Entretanto, a fusão das decisões decorre de votação majoritária ou média aritmética simples com ponderações estáticas, desconsiderando a dependência contextual das amostras sob avaliação.

Borgioli et al. (2024) estruturaram um autoencoder convolucional 1D (1D-CAE) voltado à detecção de intrusão em sistemas embarcados de tempo real com tolerância a ataques de envenenamento de dados (*data poisoning*). O método comprovou a utilidade das operações convolucionais na compressão de padrões operacionais de rede. A investigação restringiu-se, todavia, ao diagnóstico binário (tráfego anômalo versus tráfego regular), sem fornecer discriminação granular multiclasse nem integrar mecanismos dinâmicos de governança cooperativa.

Paralelamente, o emprego do paradigma de Mistura de Especialistas (MoE) começou a emergir em vertentes correlatas da segurança computacional:

Yang et al. (2025) introduziram a arquitetura MoEVD para a identificação de falhas em código-fonte de software. Sob a máxima de que nenhum modelo monolítico atende eficazmente a todas as modalidades de ameaça ("*One-for-All Does Not Work!*"), os autores demonstraram experimentalmente que classificadores generalistas colapsam perante a diversidade estrutural das vulnerabilidades. Ao segmentar o aprendizado em redes especializadas reguladas por roteamento condicional, o MoEVD superou arquiteturas de grande escala. Contudo, o processamento estático de grafos sintáticos em código impõe requisitos distintos do monitoramento em streaming de alta velocidade exigido por redes de telecomunicações.

He, Fu & Zhang (2026) apresentaram o TrafficMoE, um framework fundamentado em MoE orientado à classificação de tráfego de rede criptografado sensível à heterogeneidade dos dados (*heterogeneity-aware*). Os autores constataram que a criptografia moderna introduz distribuições disjuntas de entropia entre aplicações benignas. O sistema emprega especialistas neurais governados por roteamento adaptativo. Não obstante o mérito técnico, o trabalho ateu-se estritamente à categorização de serviços e aplicações ordinárias (como videoconferência versus

navegação convencional), sem contemplar cenários de intrusão cibernética, ataques persistentes multi-estágio ou agentes adversariais conduzidos por inteligência artificial.

Chandroth, Stoian & Danciulescu (2026) propuseram formalmente o ALF-MoE (*Attention-Based Learnable Fusion of Specialized Expert Networks*), aplicando a mistura de redes à classificação de tráfego agregado e túneis cifrados VPN. A contribuição seminal do estudo residiu na organização de cinco especialistas direcionados a quatro perspectivas distintas de atributos (estatística tabular com DNN, espacial com CNN, temporal transitória com GRU, espectral de frequência com CAE e dependência temporal de longo prazo com LSTM), coordenados por uma Gating Network dotada de refinamento de atenção aprendível (ALF) e projeção afim estabilizada. O arranjo alcançou acurácia superior a 97% em bases consolidadas como ISCX VPN-nonVPN e Unicauca.

A despeito dessa relevância metodológica, a concepção original de Chandroth, Stoian & Danciulescu (2026) circunscreveu-se a tarefas balanceadas de identificação de aplicações corporativas e operou em modo exclusivamente em lote (*batch*), sem examinar a eficácia do modelo em tarefas de detecção de intrusão multiclasse com desbalanceamento extremo de classes de ataque e sem contemplar a viabilidade de inferência de baixa latência integrada a motores modernos de telemetria contínua de rede.

2.3.3 Síntese Comparativa

A análise crítica da literatura especializada permite consolidar um conjunto de lacunas estruturais que delimitam a fronteira do conhecimento na área de NIDS:

1. **Monolitismo e Ausência de Especialização Multidomínio:** a maioria expressiva das propostas recorre a modelos homogêneos (estritamente convolucionais ou estritamente recorrentes), sacrificando a acurácia em classes de ameaças cujas características diagnósticas residem em dimensões fora do escopo focalizado pela arquitetura;
2. **Fusão Estática em Comitês Convencionais:** as abordagens com múltiplos classificadores adotam majoritariamente agregações heurísticas tardias (médias aritméticas ou votação majoritária estática), desconsiderando a dependência contextual entre fluxos e a calibração de certeza mútua entre os modelos;
3. **Vulnerabilidade ao Desbalanceamento Extremo de Classes:** a literatura frequentemente avalia modelos sob métricas globais agregadas que mascaram o colapso do classificador em ataques raros ou altamente assimétricos em tráfego criptografado;
4. **Ausência de Calibração Probabilística Dinâmica:** modelos neurais modernos sofrem de superconfiança (*overconfidence*) em previsões incorretas em espaços multiclasse complexos, carecendo de mecanismos de escalonamento paramétrico integrados à tomada de decisão;

5. Limitação de Avaliação Cruzada entre Domínios: grande parte das propostas restringe-se a uma única base de dados, omitindo a validação de robustez e generalização da arquitetura perante ecossistemas heterogêneos (redes corporativas, tráfego IoT e explorações avançadas).

Para consolidar as distinções metodológicas entre os principais trabalhos da literatura e o modelo concebido nesta tese, o Quadro 1 sumariza as abordagens, modelos empregados, conjuntos de dados e fragilidades estruturais de cada iniciativa.

Tabela 1 – Síntese comparativa entre trabalhos correlatos da literatura e a proposta desta tese.

Trabalho / Referência	Metodologia / Paradigma	Modelos / Datasets	Limitações Identificadas
Sainis, Srivastava & Singh (2018)	Detecção de outliers e seleção de atributos	DT, RF, SVM (KDD-Cup99, NSL-KDD)	Modelos clássicos sem exploração multidomínio; restrito a datasets legados com tráfego sintético.
Sarhan et al. (2021); Sarhan, Layeghy & Portmann (2022)	Padronização de atributos para fluxos NetFlow	RF, NB, MLP (NF-UNSW-NB15, NF-CIC-IDS2018)	Foco exclusivo em atributos estatísticos agregados; não modela dinâmicas temporais e espectrais.
Abreu & Abelém (2022)	Sistema híbrido e em tempo real para redes	Limiar estatístico + DT/RF (Tráfego real e bases públicas)	Elevada dependência de limiares determinísticos; perda de precisão em ameaças complexas.
Guadarrama et al. (2025)	Estudo comparativo exaustivo de NIDS em fluxo	DT, RF, XGBoost, MLP (CSE-CIC-IDS2018, CIC-UNSW-NB15)	Arquiteturas homogêneas; degradação acentuada em classes com desbalanceamento extremo.
Dari et al. (2024)	Análise comparativa de redes profundas	CNN, RNN, DNN isoladas (Bases públicas de intrusão)	Ausência de fusão estruturada; nenhum modelo homogêneo dominou todas as categorias de ataque.
Oliveira, Gonçalves & Filho (2025)	Aprendizado Federado para NIDS corporativo	DNN homogênea federada (CSE-CIC-IDS2018)	Foco na descentralização; classificador local não contempla representação em múltiplos domínios.
Sasi et al. (2025)	Rede híbrida com autoatenção para IoT	1D-CNN-LSTM + Atenção (Edge-IIoTset, CICIoT2023)	Alta complexidade quadrática da autoatenção; inviável sob tráfego contínuo em alta vazão.

Continua na próxima página

Tabela 1 – Continuação da página anterior

Trabalho / Referência	Metodologia / Paradigma	Modelos / Datasets	Limitações Identificadas
Silva (2025)	Autoencoder semi-supervisionado e ensemble	HSAE + Comitê de votação (CSE-CIC-IDS2018, NSL-KDD)	Fusão tardia por votação estática; não aprende ponderações adaptativas de acordo com o contexto.
Borgioli et al. (2024)	Autoencoder Convolutacional em sistemas embarcados	1D-CAE não supervisionado (CIC-IDS2017, Modbus)	Restrito à classificação binária (anomalia vs normal); ausência de diagnóstico multiclasse.
Yang et al. (2025)	Mixture of Experts para detecção de falhas	MoE condicional com Gating (Bases de código C/C++)	Domínio de código estático; não se aplica a fluxos contínuos de pacotes em redes de dados.
He, Fu & Zhang (2026)	MoE para classificação de tráfego cifrado	MoE heterogêneo + Gating (ISCX VPN, Tráfego QUIC)	Foco na identificação de aplicações benignas cifradas; não avaliado sob ataques cibernéticos.
Chandroth, Stoian & Danciulescu (2026)	MoE com fusão atencional aprendível (ALF)	5 Especialistas (DNN, CNN, GRU, CAE, LSTM) + ALF (ISCX VPN, Unicauca)	Validado apenas em classificação de tráfego de aplicações em lote; sem validação para NIDS multiclasse e streaming.
Esta Tese (ALF-MoE NIDS)	ALF-MoE Multidomínio Adaptado para NIDS	5 Especialistas + Gating Atencional + Fusão ALF + NFStream (CSE-CIC-IDS2018 Canônico e Corrigido, CIC-BCCC-NRC-2024, CIC-UNSW-NB15)	Supera as limitações anteriores: investiga a transposição do MoE para detecção de intrusões multiclasse em tráfego de rede, mitiga desbalanceamento severo via Focal Loss multitarefa e avalia a latência de inferência em tempo real.

Fonte: Elaborado pelo autor (2026).

A fundamentação teórica e o mapeamento dos trabalhos correlatos expostos neste capítulo demonstram que a arquitetura ALF-MoE reúne os alicerces analíticos indispensáveis para superar os limites evidenciados na literatura. Ao segmentar a inspeção do tráfego em quatro perspectivas especializadas (tabular estática, morfológica espacial, sequencial temporal e harmônica espectral) coordenadas por

uma rede de roteamento calibrada e um módulo de fusão atencional aprendível, estabelece-se a base teórico-conceitual necessária para a formulação metodológica descrita no capítulo subsequente.

3 MATERIAIS E METODOLOGIA

3.1 DATASETS UTILIZADOS

A concepção, o treinamento e a validação empírica de Sistemas de Detecção de Intrusão em Redes (*Network Intrusion Detection Systems* – NIDS) orientados a Aprendizado de Máquina e Aprendizado Profundo são diretamente condicionados pela qualidade, diversidade e representatividade dos conjuntos de dados empregados (Sarhan; Layeghy; Portmann, 2022; Sarhan et al., 2021). Historicamente, a comunidade de segurança da informação recorreu a bases públicas pioneiras, tais como DARPA 98, KDD Cup 99 e NSL-KDD. Não obstante a sua relevância histórica, tais bases tornaram-se anacrônicas face às transformações da Internet contemporânea: exibem tráfego artificial gerado em ambientes desprovidos de ruído operacional humano, não contemplam protocolos criptografados e contêm distribuições estatísticas que não reproduzem a complexidade e a volumetria das ameaças atuais (Sharafaldin; Lashkari; Ghorbani, 2018; Guadarrama et al., 2025).

Com o intuito de superar tais deficiências metodológicas e assegurar que os modelos avaliados operem sob condições operacionais fidedignas, este trabalho adota o paradigma de análise fundamentado em fluxos de rede bidirecionais (*bidirectional network flows*). Formalmente, um fluxo de rede $\mathcal{F}$ é definido como uma sequência temporal de pacotes de dados transmitidos entre dois nós terminais ao longo de um canal de comunicação, unicamente indexados pela tupla quártupla de cabeçalho L3/L4 (*5-tuple*):

$$\mathcal{F} = \langle IP_{\text{orig}}, Port_{\text{orig}}, IP_{\text{dest}}, Port_{\text{dest}}, Prot \rangle, \quad (1)$$

em que IP_{orig} e IP_{dest} denotam os endereços de Protocolo de Internet (*Internet Protocol* – IP) de origem e destino, $Port_{\text{orig}}$ e $Port_{\text{dest}}$ correspondem às portas da camada de transporte (TCP ou UDP), e $Prot$ identifica o protocolo encapsulado ($Prot \in \{6 \text{ (TCP)}, 17 \text{ (UDP)}, \dots\}$).

A delimitação temporal de um fluxo é regida por duas variáveis fundamentais de controle:

1. **Tempo de Inatividade (*Idle Timeout* – τ_{idle}):** intervalo temporal máximo admissível de ausência de transmissão entre os interlocutores (comumente parametrizado em 120 s); caso superado, o fluxo é encerrado e exportado para sumarização estatística;
2. **Tempo Máximo Ativo (*Active Timeout* – τ_{active}):** limiar superior de duração total concedido a uma conexão contínua em trânsito (padronizado em 1800 s nas especificações clássicas de NetFlow/IPFIX, mas especificamente configurado para $\tau_{\text{active}} = 240$ s no ambiente experimental deste trabalho); atingido esse limite, o fluxo é segmentado e consolidado para viabilizar a inspeção periódica de conexões persistentes de longa duração e prevenir a retenção indefinida de estados na memória volátil dos monitores de rede sob ataques contínuos de negação de serviço.

A partir do encerramento de um fluxo $\mathcal{F}$, ferramentas especializadas de extração estatística aplicam operadores de agregação sobre as distribuições de tempo, tamanho e sinalizadores, gerando um vetor de atributos numéricos $\mathbf{x} \in \mathbb{R}^D$:

$$\mathbf{x} = \phi(\mathcal{F}) = [f_1, f_2, \dots, f_D]^T, \quad (2)$$

sendo $\phi(\cdot)$ a função de mapeamento implementada pelo extrator de telemetria e D a dimensionalidade do vetor característico.

Neste trabalho, são selecionados conjuntos de dados consolidados e complementares que cobrem diferentes espectros de tráfego, topologias e vetores de ameaça:

- **CSE-CIC-IDS2018 (Versão Canônica e Versão Corrigida):** referência consagrada para tráfego corporativo e ataques complexos distribuídos em infraestrutura de nuvem AWS, avaliada tanto em sua rotulação original (15 classes brutas) quanto sob a auditoria sistemática de Liu et al. (2022) (25 classes originais reclassificadas em 15 classes efetivas e 9 macro-famílias);
- **CIC-BCCC-NRC TabularIoTAttack-2024:** *benchmark* contemporâneo consolidado a partir da integração de 9 sub-datasets de Internet das Coisas (*Internet of Things* – IoT), contemplando protocolos leves de telemetria (MQTT) e variantes modernas de negação de serviço e botnets (49 classes granulares e 9 macro-famílias);
- **CIC-UNSW-NB15:** base de referência analítica contendo tráfego sintético e realístico de alta densidade gerado por hardware dedicado de emulação (IXIA PerfectStorm), estruturada em 10 classes e processada via amostragem com entropia comportamental.

O Quadro 1 sintetiza as propriedades fundamentais, origens e características operacionais dos conjuntos de dados analisados nesta pesquisa.

Quadro 1 – Síntese comparativa dos conjuntos de dados selecionados para treinamento e avaliação.

Dataset	Ano	Ambiente de Captura	Mecanismo de Geração	Atributos	Classes
CSE-CIC-IDS2018 (Original)	2018	Nuvem AWS corporativa (5 departamentos e <i>server room</i>)	Agentes B-Profile (humanos) e M-Profiles (ataques)	80 → 76 (73 ativas)	15 (L0) / 7 (L2)
CSE-CIC-IDS2018 (Corrigido)	2022	Nuvem AWS corporativa (auditoria Liu et al., 2022)	Reclassificação de fluxos com portas fechadas/tentativas	91 → 81 → 76 (73 ativas)	15 (25 orig.) / 9 (L2)
CIC-BCCC-NRC TabularIoTAttack-2024	2024	Laboratórios físicos e híbridos IoT/IoMT (IoTRL e UNB)	Produto de 9 sub-datasets (sensores, MQTT e rotinas)	85 → 71 (73 ativas)	49 (L0) / 9 (L2)
CIC-UNSW-NB15	2015	Cyber Range Lab (ACCS/UNSW Canberra)	Dispositivo IXIA PerfectStorm e tráfego realístico	84 → 75 (73 ativas)	10 (L0)

Fonte: Elaborado pelo autor (2026).

3.1.1 CSE-CIC-IDS2018: Versão Canônica e Versão Corrigida

O conjunto de dados CSE-CIC-IDS2018 (*Communications Security Establishment & Canadian Institute for Cybersecurity*) foi desenvolvido mediante um projeto de cooperação técnica entre o instituto governamental canadense Communications Security Establishment e o Canadian Institute for Cybersecurity da University of New Brunswick (UNB) (Sharafaldin; Lashkari; Ghorbani, 2018). O objetivo consistiu

na criação de um repositório de segurança cibernética em grande escala, hospedado na plataforma Amazon Web Services (AWS), superando as restrições de anonimização excessiva e volume diminuto presentes em bases legadas.

3.1.1.1 Topologia e Infraestrutura de Rede

A concepção experimental do CSE-CIC-IDS2018 compreendeu duas redes completamente divididas: a Rede da Vítima (*Victim-Network*) e a Rede de Ataque (*Attack-Network*). A *Victim-Network* replica a infraestrutura de uma organização corporativa de médio e grande porte, estruturada em cinco departamentos operacionais independentes conectados a uma sala de servidores (*Server Room*):

- **Controladora de Domínio e Infraestrutura Central:** servidor Windows Server 2016 desempenhando funções de Diretório Ativo (*Active Directory*), DNS e autenticação centralizada;
- **Servidores de Aplicação:** servidores com Ubuntu Linux (versões 12, 14.04 e 16.04) hospedando serviços web HTTP/HTTPS, bancos de dados relacionais e servidores FTP;
- **Estações de Trabalho Heterogêneas:** mais de 500 máquinas clientes conectadas à rede interna, englobando Windows 10, Windows 8.1, Windows 7, distribuições Linux e macOS;
- **Dispositivos de Interconexão:** firewalls corporativos (Fortinet) e switches gerenciáveis com espelhamento de portas (*port mirroring*), viabilizando a gravação sem perdas de tráfego bruto em PCAP.

A *Attack-Network* abrangeu cerca de 50 estações atacantes operando Kali Linux e Windows 8.1 na AWS, provisionadas com endereçamento IP público e conectividade direta com o perímetro corporativo alvo.

3.1.1.2 Metodologia de Geração de Tráfego e Limitações Metodológicas do Estado da Arte

A geração de tráfego empregou dois perfis comportamentais (Sharafaldin; Lashkari; Ghorbani, 2018): o *B-Profile* (agente em Java modelando interações humanas realísticas em HTTP, HTTPS, FTP, SSH e e-mail) e o *M-Profile* (rotinas automatizadas de agressão abrangendo ataques de força bruta, Heartbleed, botnet Ares, DoS volumétrico/lento, DDoS via LOIC/HOIC, ataques web e infiltração em duas fases).

Entretanto, investigações recentes conduzidas por Liu et al. (2022) identificaram falhas sistemáticas e catastróficas de rotulação no CSE-CIC-IDS2018. Especificamente, constatou-se que o processo de etiquetagem original rotulou fluxos inteiros com base unicamente na janela temporal programada para a execução dos scripts de ataque, independentemente de os pacotes maliciosos terem efetivamente alcançado o serviço ou exibido comportamento anômalo. Dentre as inconsistências mais graves documentadas por Liu et al. (2022), destacam-se:

1. **Inconsistência em Ataques de Força Bruta FTP (*FTP-BruteForce*):** Em ambos os dias de coleta em que o ataque foi supostamente desferido, o servidor alvo na porta 21 respondeu invariavelmente com pacotes sinalizados com [RST, ACK]. Esse padrão de sinalização comprova que a porta do serviço estava fechada no sistema operacional de destino; logo, o servidor rejeitou sumariamente a conexão, não ocorrendo qualquer interação de autenticação ou exploração. Portanto, rotular

tais fluxos como ataque induz o modelo a aprender respostas legítimas de rejeição de porta TCP fechada como assinaturas maliciosas;

2. **Superestimação de Categorias de Tentativa (*Attempted Categories*):** Milhares de conexões foram marcadas como ataques consumados quando, na realidade, consistiam em simples tentativas inócuas ou ruído de fundo. No esquema original de Liu et al. (2022), a auditoria catalogou inicialmente 25 categorias distintas (10 classes de tentativa, 14 classes de ataque efetivo e a classe Benign). Conforme demonstrado pelos autores, fluxos com o atributo *Attempted Category* diferente de -1 devem ser consolidados como tráfego benigno (*Benign*) para evitar o fenômeno de aprendizado espúrio (*Garbage In, Garbage Out*), reduzindo o espaço alvo efetivo para 15 classes ativas no nível L0 e 9 macro-famílias no nível L2;
3. **Desagregação Realista de Infiltração:** Na versão original, a classe *Infiltration* agregou de forma indiferenciada varreduras de porta, transferências de arquivos e comunicação interna de comando e controle. A versão corrigida individualiza tais vetores em *Infiltration - NMAP Portscan*, *Infiltration - Dropbox Download* e *Infiltration - Communication Victim Attacker*;
4. **Harmonização e Redução Dimensional:** Enquanto a versão original do CSE-CIC-IDS2018 disponibilizou 80 atributos brutos que resultam em 76 colunas canônicas (73 ativas após o expurgo de sinalizadores sem variância), a auditoria de Liu et al. (2022) partiu de 91 atributos brutos, destilou 81 métricas estatísticas de fluxo e foi harmonizada no mesmo espaço canônico de 76 atributos (73 ativos) adotado nesta tese.

3.1.1.3 Distribuição Amostral: Canônica vs. Corrigida

Diante desse panorama metodológico, este trabalho adota uma estratégia analítica bifurcada: avalia-se o modelo ALF-MoE na base canônica (com 100% dos fluxos de ataque originais e 10% de benigno, totalizando 3.712.942 fluxos sem duplicatas, distribuídos em 15 classes e 7 macro-famílias) e, em paralelo, na base saneada com as correções de Liu et al. (2022) (consolidando 15 classes efetivas e 9 macro-famílias). A partição de teste (20% estratificado) da versão canônica conta com 742.589 instâncias, enquanto a versão corrigida consolida 1.263.903 instâncias de teste. A Tabela 2 contrasta as distribuições de teste observadas em ambas as variantes.

3.1.2 CIC-BCCC-NRC TabularIoTAttack-2024: Origem, Geração, Atributos e Distribuição Amostral

A proliferação ubíqua de sensores e atuadores em ambientes industriais e residenciais ampliou substancialmente a superfície de ataque exposta a ameaças em ecossistemas de Internet das Coisas (*Internet of Things – IoT*) (Neto et al., 2023). O tráfego de redes IoT exhibe dinâmicas específicas: mensagens curtas assíncronas, protocolos de transporte e aplicação leves (tais como MQTT e CoAP) e restrições energéticas e computacionais severas nos nós de borda.

Para refletir essa realidade operacional, o Canadian Institute for Cybersecurity (CIC), o Bell Centre for Cyber Security (BCCC) e o National Research Council Canada (NRC) desenvolveram a base *CIC-BCCC-NRC TabularIoTAttack-2024* (Sasi et al., 2025), concebida a partir da consolidação de 9 sub-datasets de

Tabela 2 – Distribuição de classes e suporte amostral de teste: CSE-CIC-IDS2018 Canônico vs. Corrigido.

Versão Canônica (Original)			Versão Corrigida (Liu et al., 2022)		
Classe Canônica	Suporte	Proporção	Classe Corrigida	Suporte	Proporção
Benign	269.694	36,32%	BENIGN	1.128.279	89,27%
Bot	56.462	7,60%	Botnet Ares	28.584	2,26%
Brute Force -Web	122	0,02%	Web Attack - Brute Force	26	0,002%
Brute Force -XSS	46	0,01%	Web Attack - XSS	23	0,002%
DDoS attack-HOIC	133.693	18,00%	DDoS-HOIC	21.646	1,71%
DDoS attack-LOIC-UDP	346	0,05%	DDoS-LOIC-UDP	505	0,04%
DDoS attacks-LOIC-HTTP	115.235	15,52%	DDoS-LOIC-HTTP	5.787	0,46%
DoS attacks-GoldenEye	8.291	1,12%	DoS GoldenEye	4.512	0,36%
DoS attacks-Hulk	86.976	11,71%	DoS Hulk	36.063	2,85%
DoS attacks-SlowHTTPTest	5.935	0,80%	– (Reclassificado Benign)	–	–
DoS attacks-Slowloris	2.057	0,28%	DoS Slowloris	1.698	0,13%
FTP-BruteForce	7.870	1,06%	– (Reclassificado Benign)	–	–
Infiltration	32.380	4,36%	Infiltration - NMAP	17.875	1,41%
–	–	–	Portscan		
–	–	–	Infiltration - Comm. Victim	41	0,003%
–	–	–	Infiltration - Dropbox	17	0,001%
SQL Injection	17	0,002%	Web Attack - SQL	8	0,001%
SSH-BruteForce	23.465	3,16%	SSH-BruteForce	18.839	1,49%
Total de Teste	742.589	100,00%	Total de Teste	1.263.903	100,00%

Fonte: Elaborado pelo autor (2026), com base em Sharafaldin, Lashkari & Ghorbani (2018) e Liu et al. (2022).

telemetria de rede. O ambiente experimental combinou os laboratórios *Internet of Things Research Lab* (IoTRL) do Army Cyber Institute e as bancadas do CIC/UNB, integrando mais de 40 dispositivos físicos (sensores, atuadores, câmeras IP, termostatos e comutadores sob protocolos IEEE 802.11, Zigbee, Z-Wave e BLE), concentradores Home Assistant, intermediadores MQTT e pontos de captura não invasiva via *network taps* com *dumpcap*.

3.1.2.1 Amostragem Estratificada Hare-Niemeyer e Distribuição Amostral

Em decorrência da volumetria massiva da base completa e com o propósito de manter a viabilidade computacional sem comprometer a representatividade de eventos raros, adotou-se um protocolo de amostragem representativa de 15% do volume total. A base bruta compreende 85 colunas originais, das quais 71 atributos estatísticos de fluxo foram mantidos na amostragem e compatibilizados com o vetor canônico de 73 atributos ativos do modelo. A metodologia preservou integralmente (100% de retenção) todas as 14 classes de ataque raras presentes no banco e aplicou o método de alocação de maiores restos de *Hare-Niemeyer* nas 35 classes majoritárias restantes.

A partição de teste resultante consolidou 652.845 fluxos de rede. No nível granular (Threat Level 0), o conjunto engloba 49 classes ativas, compreendendo inundações volumétricas, fragmentações maliciosas de datagramas L3/L4 (*DDoS ACK Fragmentation*, *DDoS ICMP Fragmentation*), explorações do protocolo MQTT (*MQTT Connect Flood*, *Publish Flood*, *Malformed*), variantes de botnet Mirai, varreduras ativas e ataques de autenticação, estruturadas em 9 macro-famílias funcionais no nível L2. A Tabela 3 sumariza o suporte amostral das classes no conjunto de teste.

Tabela 3 – Macro-famílias e distribuição amostral de teste no benchmark CIC-BCCC-NRC TabularIoTAttack-2024.

Macro-Família (L2)	Principais Classes Granulares (L0)	Suporte	Proporção
Benign Traffic	Benign Traffic (70.185)	70.185	10,75%
Botnet / Malware	Backdoor (12.127), Mirai Variants (2.068), Ransomware (496)	14.691	2,25%
BruteForce	Sparta SSH (33.430), Password Attack (5.335), Dictionary (540), Telnet (138)	39.443	6,04%
DDoS	DDoS RSTFIN (117.262), DDoS PSHACK (75.840), DDoS ACK Frag (12.083), Outros	207.074	31,72%
DoS	ACK Flood (86.511), DoS TCP Flood (66.891), SYN Flood (53.713), Outros	211.296	32,37%
IoT / MQTT	MQTT Brute Force (30.249), MQTT DDoS Publish (12.324), MQTT DoS (7.278), Outros	50.282	7,70%
MITM	MITM (3.278), MITM ARP Spoofing (515)	3.793	0,58%
Reconnaissance	Recon Port Scan (25.795), Recon OS Scan (3.796), Ping Sweep, Host Discovery, etc.	34.461	5,28%
WebAttack	XSS (21.076), Uploading Attack (283), SQL Injection (261)	21.620	3,31%
Total Avaliado	49 Classes Granulares Consolidadas em 9 Macro-Famílias	652.845	100,00%

Fonte: Elaborado pelo autor (2026), com base em Sasi et al. (2025).

3.1.3 CIC-UNSW-NB15: Origem, Geração, Atributos e Distribuição Amostral

O conjunto de dados UNSW-NB15 foi concebido em 2015 pelo *Cyber Range Lab* do *Australian Centre for Cyber Security* (ACCS), na Universidade de New South Wales (Moustafa; Slay, 2015; Sarhan; Layeghy; Portmann, 2022). A geração baseou-se na plataforma de hardware dedicada **IXIA PerfectStorm**, injetando tráfego sintético contemporâneo e tráfego de fundo operacional realístico em canais Gigabit Ethernet, totalizando 100 GB de tráfego bruto capturado em formato PCAP.

Para harmonizar o espaço de entrada entre os múltiplos especialistas da arquitetura ALF-MoE, este trabalho adota a versão extraída via motor CICFlowMeter, designada *CIC-UNSW-NB15*. A base abrange originalmente 84 atributos brutos que, após o expurgo de identificadores de socket, colinearidades exatas e variáveis de variância nula, resultam em 75 atributos estatísticos, diretamente alinhados ao vetor de 73 atributos ativos do modelo. Em termos de taxonomia, a base abrange nove famílias de ataques cibernéticos e o tráfego legítimo (*Benign*): *Analysis*, *Backdoor*, *DoS*, *Exploits*, *Fuzzers*, *Generic*, *Reconnaissance*, *Shellcode* e *Worms*.

3.1.3.1 Mitigação de GIGO e Amostragem com Máxima Entropia

Na análise exploratória inicial da base CIC-UNSW-NB15, constatou-se uma discrepância volumétrica extrema entre as classes maliciosas e os fluxos normais redundantes. Para prevenir o viés de super-representação e degradação por GIGO, formulou-se um pipeline de amostragem estratificada multivariada: preservou-se 100% dos fluxos de ataque disponíveis e realizou-se a seleção das 50.000 instâncias benignas mais informativas com base no critério de máxima cobertura comportamental e entropia no espaço de atributos.

Após a subsequente deduplicação exata de fluxos idênticos, a base consolidou 125.378 instâncias, distribuídas na proporção 80% para desenvolvimento (80.241 treino, 20.061 validação) e 20% para teste independente (27.917 fluxos). A Tabela 4 apresenta o suporte de teste para as dez classes.

Tabela 4 – Distribuição de classes e suporte amostral no benchmark CIC-UNSW-NB15.

ID	Classe Canônica	Vetor de Ameaça	Amostras (Teste)	Proporção (%)
0	Analysis	Varreduras pontuais de diretórios e sondagem HTTP	77	0,28%
1	Backdoor	Canais de acesso furtivo e persistência em nós comprometidos	90	0,32%
2	Benign	Conexões legítimas de rede corporativa e navegação	10.000	35,82%
3	DoS	Esgotamento de buffers e saturação de largura de banda	894	3,20%
4	Exploits	Exploração direta de vulnerabilidades registradas (CVE)	6.190	22,17%
5	Fuzzers	Injeção de cargas corrompidas para indução de falhas	5.923	21,22%
6	Generic	Colisões criptográficas e ataques genéricos de cifras	927	3,32%
7	Reconnaissance	Mapeamento de topologia e enumeração de serviços ativos	3.347	11,99%
8	Shellcode	Payloads binários para invocação de shell privilegiada	420	1,50%
9	Worms	Códigos maliciosos com propagação e replicação autônoma	49	0,18%
Total de Instâncias Avaliadas			27.917	100,00%

Fonte: Elaborado pelo autor (2026), com base em metadados de execução.

3.1.4 Modelagem de Hierarquia de Ameaças (*Threat Levels*)

Em operações reais de cibersegurança em Centros de Operações de Segurança (*Security Operations Centers* – SOC), a resposta a incidentes demanda diferentes níveis de abstração semântica:

- **Nível de Ameaça 0 (*Threat Level 0* – Granularidade Estrita):** Mantém as classes brutas originais de cada conjunto de dados (ex.: 49 classes no CIC-BCCC-NRC-2024, 15 classes no CSE-CIC-IDS2018 e 10 classes no CIC-UNSW-NB15). Esse nível é essencial para análises forenses aprofundadas e identificação precisa de assinaturas de ferramentas;
- **Nível de Ameaça 2 (*Threat Level 2* – Meta-Categorias Consolidadas):** Agrupa classes afins em famílias funcionais abrangentes (ex.: consolidando *DoS Hulk*, *Slowloris* e *GoldenEye* na meta-categoria *DoS*; ou *DDoS-HOIC* e *LOIC* em *DDoS*). Esse nível viabiliza políticas imediatas de contenção perimetral no firewall (ex.: bloqueio de bloco CIDR ou taxa de descarte) com alta confiabilidade operacional.

O benchmark CIC-UNSW-NB15 opera intrinsecamente no nível 0, pois suas dez categorias já representam macro-classes comportamentais consolidadas.

3.2 PIPELINE DE PRÉ-PROCESSAMENTO E ENGENHARIA DE FEATURES

A higienização de telemetria bruta e a harmonização dimensional constituem etapas críticas para evitar o colapso de gradientes e garantir que os múltiplos especialistas neurais operem sobre representações numéricas bem-condicionadas. O pipeline de pré-processamento concebido para o modelo ALF-MoE organiza-se em um fluxo determinístico e estritamente modular, detalhado a seguir.

3.2.1 Seleção, Normalização e Codificação

O pipeline de pré-processamento executa uma sequência determinística de etapas adaptativas, estruturada nos seguintes procedimentos:

1. **Sanitização e Expurgamento de Variáveis Sem Variância:** Eliminam-se inicialmente variáveis que atuam como identificadores circunstanciais da sessão de captura (*Flow ID*, endereços IP de origem/destino, portas de transporte e carimbos temporais). Em seguida, computa-se a variância amostral no conjunto de treino; atributos estritamente constantes ou com variância nula em decorrência de configurações do extrator (tais como *Bwd PSH Flags*, *Fwd URG Flags*, *URG Flag Count*, *CWR Flag Count*, *ECE Flag Count* e taxas de rajada sem preenchimento *Bytes/Bulk Avg*) são expurgados do vetor canônico, prevenindo matrizes de covariância singulares;
2. **Tratamento Robusto de Indefinições Numéricas:** Valores nulos (NaN) e infinitos positivos/negativos decorrentes de divisões por zero nas métricas de fluxo (*Flow Bytes/s* e *Flow Packets/s* em fluxos com duração nula) são tratados. O pipeline computa o vetor de medianas $\mathbf{m} \in \mathbb{R}^D$ exclusivamente a partir dos fluxos de treino e realiza a imputação determinística das medianas observadas, assegurando que o conjunto de validação e teste não sofra vazamento de dados (*data leakage*);
3. **Atenuação de Assimetria via Transformação Logarítmica ($\log(1 + x)$):** Propriedades de tráfego de rede exibem tipicamente caudas pesadas com forte assimetria positiva. Para cada atributo j , calcula-se o coeficiente de assimetria amostral $\gamma_1(j)$ nos dados de treino. Se $|\gamma_1(j)| > 1,0$ e todos os valores observados forem não negativos, aplica-se a transformação:

$$x'_{ij} = \ln(1 + \max(x_{ij}, 0)), \quad (3)$$

comprimindo a amplitude dinâmica das ordens de grandeza sem distorcer o ordenamento dos percentis;

4. **Normalização Robusta por Percentis (*RobustScaler*):** Em virtude da presença inevitável de picos de tráfego decorrentes de rajadas volumétricas legítimas e maliciosas, padronizadores baseados em média e desvio padrão (*StandardScaler*) sofrem severa distorção. Em seu lugar, emprega-se o *RobustScaler*, cuja escala é governada pela mediana e pelo intervalo interquartil (IQR):

$$\tilde{x}_{ij} = \frac{x'_{ij} - Q_{50}(x'_{.j})}{Q_{75}(x'_{.j}) - Q_{25}(x'_{.j})}, \quad (4)$$

em que Q_p representa o p -ésimo percentil do atributo no conjunto de treino. Esse procedimento assegura que o núcleo de distribuição da maioria dos fluxos permaneça confinado na faixa $[-1, 1]$ sem que *outliers* dominem a função de perda;

5. **Codificação de Rótulos:** As classes de ameaça são mapeadas para índices ordinais inteiros $y \in \{0, 1, \dots, C - 1\}$ através do `LabelEncoder`, permitindo a posterior indexação na camada de saída softmax e nas ponderações de perda.

3.2.2 Tratamento de Desbalanceamento de Classes

O desbalanceamento amostral é uma característica ontológica do tráfego de redes: conexões benignas superam os ataques em várias ordens de grandeza, e certos vetores ofensivos (como injeções SQL e explorações web) constituem eventos ultra-raros no tráfego agregado. Se um classificador padrão for treinado sob entropia cruzada tradicional em tais condições, o modelo convergirá para um mínimo trivial que classifica quase todos os fluxos como benignos, apresentando acurácia nominal elevada porém taxa de detecção quase nula para classes críticas minoritárias.

Para neutralizar esse fenômeno sem incorrer no risco de sobreajuste (*overfitting*) gerado por técnicas de sobreamostragem sintética (como SMOTE) em espaços tabulares de alta dimensionalidade, esta metodologia adota uma estratégia de ponderação de classes atenuada por raiz quadrada:

$$w_c = \sqrt{\frac{N}{C \cdot N_c}}, \quad \forall c \in \{0, 1, \dots, C - 1\}, \quad (5)$$

em que N expressa a quantidade total de amostras de treino, C representa o número de classes ativas e N_c é o suporte amostral da classe c . O emprego da raiz quadrada no fator de desbalanceamento atenua as penalidades extremas observadas na ponderação balanceada clássica ($N/(C \cdot N_c)$), que tenderia a gerar multiplicadores excessivos (superiores a 10^4) para classes com menos de 20 amostras, desestabilizando a descida do gradiente.

Os pesos calculados w_c são incorporados diretamente como coeficientes α_c na função de custo Focal Loss, eliminando a prática danosa de elevar os pesos ao quadrado durante o cálculo da perda.

3.3 ARQUITETURA PROPOSTA: ALF-MOE

A arquitetura **ALF-MoE** (*Attention-based Learnable Fusion of Experts*) foi projetada para combinar as vantagens de modelos heterogêneos de aprendizado profundo, direcionando subconjuntos específicos de atributos estatísticos para especialistas concebidos para explorar cada domínio estrutural da telemetria de rede.

3.3.1 Visão Geral do Sistema e Fluxo de Dados

Diferentemente de abordagens tradicionais que forçam uma única rede homogênea a processar atributos com propriedades físico-matemáticas distintas, o ALF-MoE opera sob um paradigma modular de comitê de especialistas (*Mixture of Experts* – MoE) integrado a um mecanismo atencional de fusão.

O fluxo computacional inicia-se com o recebimento do vetor canônico harmonizado de entrada $\mathbf{x} \in \mathbb{R}^D$ ($D = 73$ atributos ativos pós-sanitização). Uma camada customizada sem descontinuidades, denominada `SliceLayer`, fatia o vetor $\mathbf{x}$ em cinco subvetores funcionais:

$$\mathbf{x} \mapsto \{\mathbf{x}_g, \mathbf{x}_s, \mathbf{x}_v, \mathbf{x}_f, \mathbf{x}_t\}, \quad (6)$$

alimentando em paralelo os cinco especialistas correspondentes, conforme sumarizado na Tabela 5.

Tabela 5 – Mapeamento funcional entre domínios de telemetria, subvetores de entrada e especialistas neurais.

Especialista	Subvetor	Domínio da Telemetria de Rede	Operador / Topologia Neural
$\mathcal{E}_{\text{DNN}}$	$\mathbf{x}_g \in \mathbb{R}^{27}$	Métricas globais, contadores acumulados e sinalizadores TCP/IP	Rede Densa Multicamadas com BatchNorm e Dropout
$\mathcal{E}_{\text{CNN}}$	$\mathbf{x}_s \in \mathbb{R}^{16 \rightarrow 4 \times 4}$	Distribuição espacial e variância de comprimentos de pacotes	Convolução 2D com Kernel adaptativo e Max Pooling
$\mathcal{E}_{\text{GRU}}$	$\mathbf{x}_v \in \mathbb{R}^{32 \rightarrow 8 \times 4}$	Dinâmica sequencial e intervalos entre chegadas (<i>Flow/Fwd/Bwd IAT</i>)	Células Recorrentes GRU com Projeção Densa
$\mathcal{E}_{\text{CAE}}$	$\mathbf{x}_f \in \mathbb{R}^{27}$	Tráfego em rajada (<i>bulk</i>) e padrões frequenciais periódicos	Camada Hann-FFT acoplada a Autoencoder Convolutacional 1D
$\mathcal{E}_{\text{LSTM}}$	$\mathbf{x}_t \in \mathbb{R}^{18 \rightarrow 6 \times 3}$	Intervalos temporais prolongados de atividade e repouso (<i>Active/Idle</i>)	Células LSTM com retenção de dependências de longo prazo

Fonte: Elaborado pelo autor (2026).

3.3.2 Modelos Especialistas Heterogêneos

Cada um dos cinco especialistas neurais foi desenhado para maximizar a extração de representações discriminativas em seu respectivo domínio de entrada, cujas topologias de camadas e conexões são ilustradas na Figura 1:

1. **Especialista DNN ($\mathcal{E}_{\text{DNN}}$):** Recebe o vetor global $\mathbf{x}_g \in \mathbb{R}^{27}$ contendo sinalizadores (SYN, ACK, FIN, RST, PSH), contadores de pacotes/bytes e durações totais. Sua topologia compreende duas camadas densas totalmente conectadas (256 e 128 unidades) com ativação LeakyReLU, normalização em lote (*Batch Normalization*) e regularização via Dropout ($p = 0,1$), produzindo o embedding latente $\mathbf{h}_{\text{dnn}} \in \mathbb{R}^{128}$ (Figura 1a);
2. **Especialista CNN 2D ($\mathcal{E}_{\text{CNN}}$):** Recebe 16 métricas de tamanho de pacotes e segmentos $\mathbf{x}_s$, reorganizadas matricialmente em formato de grade pseudo-imagem $4 \times 4 \times 1$. A rede aplica duas camadas convolucionais bidimensionais com filtros de dimensões (2, 2), 64 e 128 canais, ativação LeakyReLU ($\alpha = 0,2$), pooling máximo, projeção densa para 128 unidades e Dropout ($p = 0,2$), gerando $\mathbf{h}_{\text{cnn}} \in \mathbb{R}^{128}$ (Figura 1b);
3. **Especialista GRU ($\mathcal{E}_{\text{GRU}}$):** Processa as 32 variáveis de tempos entre chegadas de pacotes (*IAT* médio, mínimo, máximo e desvio padrão para direções de avanço e retrocesso) estruturadas como

tensores temporais em 8 passos com 4 atributos por passo. Emprega uma camada de unidades recorrentes bidirecionais com portas (*Bidirectional GRU*) de 64 unidades com Dropout recorrente de 0,1 e projeção densa, sintetizando a correlação temporal de rajadas rápidas em $\mathbf{h}_{\text{gru}} \in \mathbb{R}^{128}$ (Figura 1c);

4. **Especialista Autoencoder Convolucional ($\mathcal{E}_{\text{CAE}}$):** Especializado no perfil estatístico de rajadas e periodicidade. A entrada $\mathbf{x}_f \in \mathbb{R}^{27}$ é primeiramente processada pela camada customizada `HannFFTLayer`, que aplica a janela de Hann $w(n) = 0,5 - 0,5 \cos\left(\frac{2\pi n}{L-1}\right)$ e calcula a magnitude do espectro via transformada rápida de Fourier para sinais reais ($\mathbf{s} = |\text{RFFT}(\mathbf{x}_f \odot \mathbf{w})| \in \mathbb{R}^{14}$). O sinal espectral é codificado por um autoencoder convolucional 1D (16, 32, 64 filtros, *kernel* 5, LeakyReLU) acoplado a um decodificador simétrico `Conv1DTranspose` (32, 16, 1 filtros), computando a perda de reconstrução MSE $\mathcal{L}_{\text{CAE}, \text{rec}} = \|\mathbf{s} - \hat{\mathbf{s}}\|_2^2$ com $\lambda_{\text{rec}} = 1,0$, enquanto o gargalo latente é projetado para $\mathbf{h}_{\text{cae}} \in \mathbb{R}^{128}$ (Figura 1d);
5. **Especialista LSTM ($\mathcal{E}_{\text{LSTM}}$):** Recebe as 18 métricas temporais $\mathbf{x}_t$ compostas pelos intervalos de atividade (*Active Mean/Std/Min/Max*) e inatividade (*Idle Mean/Std/Min/Max*), estruturadas em 6 timesteps de dimensão 3. A arquitetura adota células *Bidirectional Long Short-Term Memory* (64 unidades) encarregadas de reter dependências temporais prolongadas (*slow rate*), com projeção densa final para $\mathbf{h}_{\text{lstn}} \in \mathbb{R}^{128}$ e Dropout ($p = 0,1$) (Figura 1e).

Cada especialista possui adicionalmente uma cabeça de classificação supervisionada auxiliar linear com ativação Softmax, projetando $\mathbf{h}_k$ sobre o espaço de classes: $\hat{\mathbf{y}}^{(k)} = \text{softmax}(\mathbf{W}_k \mathbf{h}_k + \mathbf{b}_k) \in \mathbb{R}^C$, permitindo supervisão intermediária direta.

3.3.3 Gating Network com Refinamento Atencional e Compressão Simétrica

A rede de roteamento (*Gating Network*) atua como o árbitro inteligente do comitê de especialistas. Ao contrário de abordagens ensemble com votação estática ou ponderação fixa, a Gating Network inspeciona o vetor completo de telemetria $\mathbf{x} \in \mathbb{R}^{73}$ e calcula dinamicamente a relevância de cada especialista para o fluxo específico sob análise.

Formalmente, a Gating Network processa $\mathbf{x}$ através de duas camadas densas (128 e 64 unidades com Batch Normalization, ativação LeakyReLU com $\alpha = 0,2$ e Dropout $p = 0,1$), projetando os logits brutos $\mathbf{z}_{\text{raw}} \in \mathbb{R}^5$, conforme esquematizado na Figura 2. A distribuição preliminar de confiança α é calculada via Softmax:

$$\alpha = \text{softmax}(\mathbf{z}_{\text{raw}}) \in \mathbb{R}^5. \quad (7)$$


Em seguida, o vetor α é submetido à camada customizada `AttentionRefinementLayer`:

$$\mathbf{z}_{\text{refined}} = \mathbf{W}_g \ln(\alpha + \epsilon) + \mathbf{b}_g, \quad (8)$$


em que $\mathbf{W}_g \in \mathbb{R}^{5 \times 5}$ e $\mathbf{b}_g \in \mathbb{R}^5$ são pesos aprendíveis e $\epsilon = 10^{-7}$ previne instabilidades logarítmicas. Para impedir o colapso e a extinção catastrófica de especialistas (cenário no qual pesos poderiam decair para ordens ínfimas como 10^{-8} e desativar especialistas vitais como o CAE), aplica-se a compressão simétrica via tangente hiperbólica:

$$\tilde{\mathbf{z}} = \tanh(\mathbf{z}_{\text{refined}}), \quad (9)$$


Figura 1 – Diagramas das topologias neurais dos modelos especialistas heterogêneos.




(a) Especialista DNN ($\mathcal{E}_{\text{DNN}}$).




(b) Especialista CNN 2D ($\mathcal{E}_{\text{CNN}}$).



(c) Especialista GRU ($\mathcal{E}_{\text{GRU}}$).



(d) Especialista CAE ($\mathcal{E}_{\text{CAE}}$).



(e) Especialista LSTM ($\mathcal{E}_{\text{LSTM}}$).

Fonte: Elaborado pelo autor (2026).

confinando estritamente os logits refinados no intervalo $[-1, 1]$. A distribuição final de pesos atencionais $\mathbf{a}$ é obtida por Softmax temperado:

$$\mathbf{a} = \text{softmax} \left(\frac{\tilde{\mathbf{z}}}{\tau} \right) = [a_{\text{dnn}}, a_{\text{cnn}}, a_{\text{gru}}, a_{\text{cae}}, a_{\text{lstm}}]^\top, \quad (10)$$


em que $\sum_{k=1}^5 a_k = 1$ e $a_k > 0$, mantendo a temperatura inicial calibrada em $\tau = 1,0$ (Guo et al., 2017).

3.3.4 Mecanismo Attention-based Learnable Fusion (ALF)

A integração final das decisões é conduzida pelo módulo customizado **ALF** (*Attention-based Learnable Fusion*), cuja topologia interna é apresentada na Figura 3, estruturado em dois blocos determinísticos:

1. **Fusão Estrita por Soma Ponderada (WeightedSumFusion):** A camada de fusão recebe as distribuições probabilísticas previstas por cada um dos cinco especialistas $\{\hat{\mathbf{y}}^{(k)}\}_{k=1}^5 \subset \mathbb{R}^C$ e o vetor de pesos atencionais $\mathbf{a} \in \mathbb{R}^5$ proveniente da Gating Network, efetuando a soma ponderada

Figura 2 – Topologia interna da Gating Network com refinamento atencional e compressão simétrica.



Fonte: Elaborado pelo autor (2026).

estrita:

$$\mathbf{z} = \sum_{k=1}^5 a_k \cdot \hat{\mathbf{y}}^{(k)} \in \mathbb{R}^C. \quad (11)$$

Nenhuma conexão residual externa ou concatenação paralela contorna a soma ponderada. Essa decisão de projeto impõe que 100% do fluxo de gradientes retropropagados atravesse a ponderação $a_k \hat{\mathbf{y}}^{(k)}$, forçando a Gating Network a exercer sua função seletiva e incentivando a especialização real de cada rede neural;

2. **Cabeça Profunda de Decisão Multiclasse:** O vetor fundido $\mathbf{z}$ é subsequentemente processado por uma cabeça classificadora profunda desenhada para refinar as margens de decisão entre classes com alta sobreposição:


$$\mathbf{u}_1 = \text{LeakyReLU}_{0,2}(\text{BN}(\mathbf{W}_1 \mathbf{z} + \mathbf{b}_1)) \in \mathbb{R}^{128}, \quad (12)$$

$$\mathbf{u}_1^{\text{drop}} = \text{Dropout}_{0,1}(\mathbf{u}_1), \quad (13)$$

$$\mathbf{u}_2 = \text{LeakyReLU}_{0,2}(\text{BN}(\mathbf{W}_2 \mathbf{u}_1^{\text{drop}} + \mathbf{b}_2)) \in \mathbb{R}^{64}, \quad (14)$$

$$\hat{\mathbf{y}}_{\text{ALF}} = \text{softmax}(\mathbf{W}_3 \mathbf{u}_2 + \mathbf{b}_3) \in \mathbb{R}^C. \quad (15)$$


Figura 3 – Topologia interna do módulo de fusão ALF (*Attention-based Learnable Fusion*).



Fonte: Elaborado pelo autor (2026).

A arquitetura macroscópica unificada do modelo ALF-MoE, integrando a recepção da telemetria de rede, o roteamento pelos especialistas heterogêneos, a arbitragem dinâmica pela Gating Network e a combinação ponderada das probabilidades com refinamento profundo no módulo ALF, é ilustrada na Figura 4.

Figura 4 – Visão arquitetural integrada do modelo ALF-MoE, evidenciando o fluxo de tensores entre especialistas, Gating Network e fusão ALF.



Fonte: Elaborado pelo autor (2026).

3.4 PROTOCOLO EXPERIMENTAL DE TREINAMENTO E AVALIAÇÃO

Para garantir rigor metodológico e reprodutibilidade, todos os ensaios foram balizados por um protocolo padronizado de otimização multitarefa, particionamento e validação estatística.

3.4.1 Funções de Perda e Otimização Multitarefa

O treinamento do modelo ALF-MoE é formulado como uma otimização multitarefa conjunta (*multi-task learning*). A função de custo global $\mathcal{L}_{\text{total}}$ agrega a perda da cabeça principal de fusão ALF, as perdas supervisionadas auxiliares dos cinco especialistas e a perda mista de reconstrução espectral do Autoencoder Convolutacional:

$$\mathcal{L}_{\text{total}} = 1,0 \cdot \mathcal{L}_{\text{FL}}(\hat{\mathbf{y}}_{\text{ALF}}, \mathbf{y}) + 0,2 \sum_{k=1}^5 \mathcal{L}_{\text{FL}}(\hat{\mathbf{y}}^{(k)}, \mathbf{y}) + \lambda_{\text{rec}} \mathcal{L}_{\text{CAE,rec}}, \quad (16)$$

sendo $\lambda_{\text{rec}} = 1,0$ e o peso das cabeças auxiliares fixado em 0,2, provendo sinal de gradiente para guiar os especialistas sem sobrecarregar a convergência da cabeça unificada ALF.

A perda de classificação empregada em todas as cabeças é a **Focal Loss Multiclasse** (Lin et al., 2017), definida por:

$$\mathcal{L}_{\text{FL}}(p_t) = -\alpha_t(1 - p_t)^\gamma \ln(p_t), \quad (17)$$

em que p_t representa a probabilidade estimada pelo modelo para a classe verdadeira, $\gamma = 2,0$ atua como o parâmetro de foco que suprime gradientes de exemplos fáceis e bem classificados, e $\alpha_t = w_c$ corresponde aos pesos balanceados por raiz quadrada definidos na Equação 5.

O otimizador utilizado é o **Adam** com taxa de aprendizado inicial $\eta_0 = 10^{-3}$, momentos $\beta_1 = 0,9$, $\beta_2 = 0,999$, $\epsilon = 10^{-8}$ e tamanho de lote (*batch size*) fixado em 128 instâncias ao longo de 10 épocas. O agendamento da taxa de aprendizado é governado pelo mecanismo `ReduceLROnPlateau` (fator de redução 0,5, paciência de 2 épocas monitorando `val_ALF_F1-Score` com limiar inferior de 10^{-6}), complementado por parada precoce (`EarlyStopping`) com paciência de 4 épocas monitorando a mesma métrica.

3.4.2 Métricas de Avaliação

A avaliação de desempenho do modelo e de cada especialista individual engloba métricas de eficácia preditiva e métricas de eficiência computacional em tempo de execução.

3.4.2.1 Métricas de Eficácia Estatística

Para cada classe $c \in \{0, \dots, C-1\}$, denotam-se TP_c, FP_c, FN_c, TN_c os quantitativos de verdadeiros positivos, falsos positivos, falsos negativos e verdadeiros negativos, respectivamente. Computam-se:

1. **Acurácia Global (Acc):**

$$Acc = \frac{\sum_{c=0}^{C-1} TP_c}{\sum_{c=0}^{C-1} (TP_c + FN_c)}; \quad (18)$$

2. **Acurácia Balanceada (Acc_{bal}):** média aritmética das taxas de recall sobre todas as classes, mitigando a distorção induzida por classes majoritárias:

$$Acc_{bal} = \frac{1}{C} \sum_{c=0}^{C-1} \frac{TP_c}{TP_c + FN_c}; \quad (19)$$

3. **Precisão Macro (Prec_{macro}) e Sensibilidade Macro (Rec_{macro}):**

$$Prec_{macro} = \frac{1}{C} \sum_{c=0}^{C-1} \frac{TP_c}{TP_c + FP_c}, \quad Rec_{macro} = \frac{1}{C} \sum_{c=0}^{C-1} \frac{TP_c}{TP_c + FN_c}; \quad (20)$$

4. **Macro F_1 -Score (F_1^{macro}):** média harmônica entre precisão e sensibilidade computada de forma não ponderada, constituindo o critério primordial para ranqueamento de NIDS sob desbalanceamento:

$$F_1^{macro} = \frac{1}{C} \sum_{c=0}^{C-1} \frac{2 \cdot Prec_c \cdot Rec_c}{Prec_c + Rec_c}; \quad (21)$$

5. **Weighted F_1 -Score ($F_1^{weighted}$):** ponderação das pontuações F_1 pela proporção empírica de amostras de cada classe N_c/N .

3.4.2.2 Métricas de Eficiência Computacional

A viabilidade de implantação do NIDS em nós de monitoramento em tempo real depende estritamente do tempo de processamento. Avaliam-se:

1. **Latência por Amostra** (L_{sample}): tempo médio transcorrido para inferir um único fluxo de rede, expresso em milissegundos por fluxo (ms/fluxo):

$$L_{\text{sample}} = \frac{T_{\text{total,inf}}}{N_{\text{test}}} \times 10^3; \quad (22)$$

2. **Vazão de Inferência** (Throughput): taxa de processamento sustentada expressa em fluxos por segundo (fluxos/s):

$$\text{Throughput} = \frac{N_{\text{test}}}{T_{\text{total,inf}}}. \quad (23)$$

4 PIPELINE DE EXTRAÇÃO E AMBIENTE DE INFERÊNCIA

4.1 CAPTURA E PROCESSAMENTO DE TRÁFEGO

A transição de modelos de Aprendizado Profundo avaliados em conjuntos de dados estáticos (*offline benchmarks*) para sistemas de detecção e prevenção de intrusão operando em redes de produção (*online NIDS/NIPS*) constitui um dos desafios mais complexos na engenharia de segurança contemporânea. Conforme discutido no Capítulo 2, a literatura acadêmica frequentemente restringe suas avaliações a arquivos de captura pré-gravados (*Packet Capture – PCAP*), processados em lote por ferramentas analíticas lentas como o *CICFlowMeter*. Esse extrator legado, implementado primariamente em Java, não foi projetado para atuar como componente de baixa latência em linha de produção: sua arquitetura monolítica introduz contenção severa de memória volátil, atrasos imprevisíveis de coleta de lixo (*garbage collection*) e ausência de suporte nativo a pipelines de tensores neurais acelerados por unidades de processamento gráfico (GPU) (Aouini; Pekar, 2022).

Para que a arquitetura **ALF-MoE** possa exercer defesa perimetral em tempo hábil contra agentes adversariais, faz-se indispensável uma infraestrutura de telemetria capaz de inspecionar pacotes brutos diretamente da interface física de rede, agregá-los dinamicamente em fluxos bidirecionais segundo a tupla quártupla (*5-tuple*), computar grandezas estatísticas e temporais em escala de microssegundos e despachá-las ao motor neural sem degradar a vazão da rede.

Neste capítulo, detalha-se a concepção, implementação e validação do pipeline de extração de tráfego baseado no *framework* NFStream, o alinhamento semântico de suas características com o padrão canônico dos datasets do Canadian Institute for Cybersecurity (CIC) e o subsistema de defesa ativa com integração ao *firewall* de última geração do Linux (*nftables*) para contenção de ameaças em nível de kernel.

4.1.1 Extração com NFStream

O extrator de tráfego do ecossistema ALF-MoE foi desenvolvido sobre o *framework* de análise de dados de rede NFStream (Aouini; Pekar, 2022). O NFStream foi selecionado por operar em linguagem C (estendida com interface Python via Cython), proporcionar suporte nativo a multiprocessamento e permitir a injeção de extensões dinâmicas de telemetria por meio de plugins estruturados (*User-Defined Plugins – UDPs*).

4.1.1.1 Princípio da Responsabilidade Única (SRP) na Classe FeatureExtractor

A integridade arquitetural do pipeline apoia-se estritamente no Princípio da Responsabilidade Única (*Single Responsibility Principle – SRP*). No módulo `src/plugins/extractor.py`, a classe `FeatureExtractor` (derivada de `NFPlugin`) atua **exclusivamente** no cômputo e na agregação das 76 métricas estatísticas canônicas brutas do tráfego de rede no interior dos processos de trabalho (*workers*) do motor NFStream.

Nenhuma operação de pré-processamento estatístico (como transformações logarítmicas $\ln(1 + x)$, padronização por mediana e intervalo interquartil via `RobustScaler` ou codificação de rótulos) e

nenhuma operação de inferência tensorial são executadas dentro dos métodos de callback do plugin (`on_init`, `on_update` e `on_expire`). Ao isolar o `FeatureExtractor` como um sensor estritamente passivo de medição de rede, preserva-se o determinismo estatístico das grandezas físicas e desacopla-se o ciclo de vida dos fluxos da pilha computacional de inteligência artificial.

4.1.1.2 Problema de Concorrência, Multiprocessamento Fork e Contexto CUDA

A separação mandatória imposta pelo SRP decorre de uma limitação estrutural crítica de hardware e concorrência no sistema operacional Linux. O motor `NFStream` implementa uma arquitetura orientada a multiprocessamento para ingestão massiva de pacotes, delegando a inspeção de portas e a atualização de buffers a múltiplos processos filhos (*meters*) criados mediante a chamada de sistema `fork()` da API POSIX.

Sob a semântica do `fork()`, o espaço de endereçamento virtual do processo pai é duplicado para o processo filho por meio do mecanismo de cópia em gravação (*Copy-on-Write* – CoW). Contudo, os descritores de dispositivos de aceleração de hardware e o estado dos drivers de espaço de usuário da NVIDIA (`libcuda.so` e o subsistema de gerenciamento unificado do kernel `nvidia.ko`) **não são clonáveis nem compartilháveis** entre processos bifurcados.

Se um modelo de aprendizado profundo baseado em TensorFlow, Keras ou PyTorch for inicializado no processo principal e qualquer tentativa de inferência for invocada no retorno de chamada (*callback*) de encerramento de fluxo (`on_expire`) dentro de um processo filho forked, o driver do CUDA intercepta a chamada de API a partir de um identificador de processo (PID) desprovido de contexto GPU válido. O resultado consiste na emissão incontornável do erro fatal de baixo nível:

```
CUDA_ERROR_NOT_INITIALIZED (Driver Error 3 / absl abort).
```

Esse erro aborta imediatamente a execução de toda a aplicação (*crash* fatal com sinal `SIGABRT`), corrompendo a captura de rede e inviabilizando a operação do NIDS.

Para superar essa restrição física de concorrência sem abdicar da aceleração por hardware da GPU dedicada NVIDIA GeForce RTX 4050 Laptop, o projeto ALF-MoE arquitetou um padrão Produtor-Consumidor estritamente desacoplado:

1. **Produtor Assíncrono (Workers do NFStream):** os processos de medição do `NFStream` executam o loop de captura de pacotes via `libpcap` em modo promíscuo, acionando os métodos de telemetria do `FeatureExtractor` para agregar as 76 métricas nos objetos de fluxo `NFlow` e persistir variáveis sintetizadas na estrutura `flow.udps`;
2. **Consumidor Síncrono (Processo Principal com GPU):** o processo mestre da aplicação instancia o iterador gerador `NFStreamer` em um loop consumidor contínuo (`for flow in streamer: ...`). Apenas após a expiração formal do fluxo pelo temporizador do `NFStream`, o objeto é entregue ao processo principal. Este, por sua vez, converte o fluxo em um `DataFrame` de linha única (`convert_into_features`), normaliza os atributos via `Preprocessor` na CPU e dispara o *forward pass* neural no grafo ALF-MoE diretamente na memória da GPU, onde o contexto CUDA reside intacto e exclusivo.

Essa divisão garante estabilidade operacional ininterrupta, eliminando contenções de barramento PCIe e permitindo que a GPU processe a inferência atencional em sua plenitude.

4.1.1.3 Escalas Temporais e Fator de Conversão de Unidades

Uma discrepância crítica entre ferramentas de telemetria reside na unidade adotada para mensurar intervalos temporais. O NFStream calcula nativamente a duração dos fluxos e os tempos de inter-chegada de pacotes (*Inter-Arrival Times* – IAT), bem como os períodos de atividade e inatividade, na escala de *milissegundos* (ms).

Por outro lado, o extrator clássico *CICFlowMeter*, utilizado na confecção dos conjuntos de dados CSE-CIC-IDS2018, CIC-BCCC-NRC-2024 e CIC-UNSW-NB15, opera estritamente na escala de *microsegundos* (μ s). Se os atributos temporais gerados pelo NFStream fossem injetados diretamente nas camadas de entrada do ALF-MoE sem ajuste dimensional, ocorreria uma distorção de distribuição de três ordens de magnitude (10^3). Variáveis essenciais como *Flow Duration*, *Flow IAT Mean* e *Fwd IAT Total* teriam suas magnitudes comprimidas em um fator de 1.000, fazendo com que as ativações das camadas recorrentes ($\mathcal{E}_{GRU}$ e $\mathcal{E}_{LSTM}$) saturassem prematuramente, conduzindo a erros grosseiros de classificação em lote.

Para assegurar conformidade semântica e probabilística rigorosa com as matrizes de treinamento, o método `flow_to_dict` aplica sistematicamente o fator de conversão escalar $\kappa_{tempo} = 1000,0$ sobre todas as grandezas temporais:

$$\Delta t_{\mu s} = \Delta t_{ms} \times 1000,0. \quad (1)$$

As grandezas convertidas incluem a duração bidirecional do fluxo (*Flow Duration*), todos os momentos estatísticos de IAT global, *forward* e *backward* (Mean, Std, Max, Min, Total), e as janelas consolidadas de atividade e inatividade (*Active/Idle Times*).

4.1.1.4 Descarte de Atributos de Variância Nula

O plugin `FeatureExtractor` extrai 76 atributos canônicos correspondentes ao catálogo formal do *CICFlowMeter*. Não obstante, durante a fase de análise exploratória e treinamento dos especialistas nos conjuntos de benchmark, identificou-se que três atributos associados ao sinalizador de urgência do cabeçalho TCP:

- *Fwd URG Flags* (`fwd_urg_flags`): contagem de pacotes com flag URG no sentido direto;
- *Bwd URG Flags* (`bwd_urg_flags`): contagem de pacotes com flag URG no sentido reverso;
- *URG Flag Count* (`urg_flag_count`): total bidirecional de sinalizadores URG no fluxo;

apresentam variância estritamente nula ($\sigma^2 = 0$) em todos os conjuntos de dados de treinamento.

O sinalizador TCP URG (*Urgent Pointer*), concebido na RFC 793 para indicar que determinado segmento continha dados prioritários a serem consumidos fora de ordem pela aplicação receptora, caiu em desuso quase absoluto na pilha de protocolos contemporânea da Internet, sendo formalmente desaconselhado pela RFC 6093 devido a inconsistências de implementação entre sistemas operacionais.

Consequentemente, em nenhuma amostra dos datasets corporativos ou IoT o bit URG foi observado como ativo.

No módulo de pré-processamento, a lista constante `EXPLICIT_DROP_COLUMNS` remove explicitamente esses 3 atributos:

$$\mathcal{X}_{\text{modelo}} = \mathcal{X}_{\text{plugin}} \setminus \{\text{Fwd URG Flags}, \text{Bwd URG Flags}, \text{URG Flag Count}\}, \quad (2)$$

reduzindo o vetor dimensional de 76 para exatamente *73 atributos efetivos*, os quais alimentam as camadas de entrada densas, convolucionais e recorrentes do grafo computacional ALF-MoE.

4.1.1.5 Dissecação de Baixo Nível dos Métodos Customizados

Para além das métricas agregadas nativas, o `FeatureExtractor` implementa dois algoritmos fundamentais de dissecação direta de pacotes em nível de byte: a codificação binária de sinalizadores TCP e a extração da janela inicial TCP.

4.1.1.5.1 Codificação Compacta de Flags TCP (*encode_tcp_flags*)

O extrator implementa a função `encode_tcp_flags(packet)`, encarregada de mapear 8 sinalizadores booleanos presentes no objeto `NFPacket` em uma máscara binária condensada de 8 bits (um byte sem sinal, com valor inteiro no intervalo $[0, 255]$). A ordenação posicional adota o padrão de bit menos significativo (LSB) para o mais significativo (MSB), formalizada matematicamente por:

$$\beta_{\text{flags}} = \sum_{i=0}^7 b_i \cdot 2^i, \quad (3)$$

onde cada coeficiente $b_i \in \{0, 1\}$ é estabelecido pela avaliação condicional do respectivo sinalizador no pacote de dados, conforme estruturado na Tabela 6.

A implementação computacional em Python recorre a operadores de deslocamento de bits à esquerda ($\ll$) e disjunção binária ($|$):

```
flags = 0
flags |= (1 if getattr(packet, "syn", False) else 0) << 0
flags |= (1 if getattr(packet, "cwr", False) else 0) << 1
flags |= (1 if getattr(packet, "ece", False) else 0) << 2
flags |= (1 if getattr(packet, "urg", False) else 0) << 3
flags |= (1 if getattr(packet, "ack", False) else 0) << 4
flags |= (1 if getattr(packet, "psh", False) else 0) << 5
flags |= (1 if getattr(packet, "rst", False) else 0) << 6
flags |= (1 if getattr(packet, "fin", False) else 0) << 7
```

Essa codificação atômica permite avaliar padrões combinatórios complexos (tais como varreduras *TCP SYN*, sondas *TCP NULL* onde $\beta = 0$, ou anomalias *XMAS Scan* onde $\beta = 2^0 + 2^5 + 2^7 = 41$) em tempo linear de máquina.

Tabela 6 – Mapeamento posicional da máscara binária de sinalizadores TCP.

Posição do Bit (<i>i</i>)	Sinalizador TCP	Peso (2^i)	Semântica no Protocolo TCP
Bit 0	SYN (<i>Synchronize</i>)	$2^0 = 1$	Inicialização de conexão e sincronização de números de sequência.
Bit 1	CWR (<i>Congestion Window Reduced</i>)	$2^1 = 2$	Notificação de redução da janela de congestionamento pelo transmissor.
Bit 2	ECE (<i>ECN-Echo</i>)	$2^2 = 4$	Indicação de congestionamento iminente na rede (RFC 3168).
Bit 3	URG (<i>Urgent</i>)	$2^3 = 8$	Campo de ponteiro de urgência ativo e com dados válidos.
Bit 4	ACK (<i>Acknowledgment</i>)	$2^4 = 16$	Confirmação de recebimento de segmentos anteriores.
Bit 5	PSH (<i>Push</i>)	$2^5 = 32$	Solicitação de entrega imediata de dados à aplicação receptora.
Bit 6	RST (<i>Reset</i>)	$2^6 = 64$	Interrupção abrupta e reinicialização forçada da conexão.
Bit 7	FIN (<i>Finish</i>)	$2^7 = 128$	Encerramento gracioso e bilateral do canal de comunicação.

Fonte: Elaborado pelo autor (2026).

4.1.1.5.2 Extração de Janela TCP em Bytes Brutos (*extract_tcp_window_size*)

O tamanho da janela de recepção TCP (*Window Size*) anunciado no início de uma sessão é um indicador vital para modelos de aprendizado profundo: conexões legítimas de navegadores modernos utilizam janelas padronizadas de grande porte (e.g., 64.240 ou 65.535 bytes), enquanto ferramentas de varredura furtiva (como o `nmap -sS`) ou scripts de ataque emitem pacotes sintetizados com janelas atipicamente reduzidas (e.g., 1.024 bytes) ou fixadas em zero.

O `NFStream` não disponibiliza nativamente o atributo de janela inicial TCP no objeto `NFPacket`. Para capturar esse dado de forma ultrarrápida sem incorrer no atraso de desempacotadores de alto nível como o `Scapy`, o método `extract_tcp_window_size` dissectiona diretamente o vetor de bytes brutos do cabeçalho de rede (`packet.ip_packet`):

1. **Verificação de Protocolo de Transporte:** valida se o pacote encapsula o protocolo TCP. Em caso negativo, retorna 0;
2. **Tratamento Dinâmico de Pacotes IPv4:** inspeciona o primeiro byte bruto `raw[0]`. Extrai a versão nos 4 bits superiores (`raw[0] >> 4`) & 0x0F. Se for versão 4, extrai o comprimento do cabeçalho IP (*Internet Header Length* – IHL) nos 4 bits inferiores (`raw[0] & 0x0F`). O deslocamento (*offset*)

em que se inicia o cabeçalho TCP é calculado dinamicamente por:

$$O_{\text{TCP}} = \text{IHL} \times 4; \quad (4)$$

3. **Tratamento de Pacotes IPv6:** caso a versão seja 6, o cabeçalho IPv6 básico possui tamanho fixo de 40 bytes. O método valida se o campo *Next Header* no deslocamento de byte 6 é igual a 6 (`raw[6] == 6`), fixando o deslocamento do cabeçalho TCP em:

$$O_{\text{TCP}} = 40; \quad (5)$$

4. **Extração da Janela de 16 Bits:** no padrão TCP (RFC 793), o campo de tamanho da janela de recepção (*Window Size*) localiza-se nos bytes 14 e 15 a partir do início do cabeçalho TCP. O método extrai a fatia `raw[O_TCP + 14 : O_TCP + 16]` e a converte em um número inteiro de 16 bits sem sinal na ordem de bytes da rede (*Big-Endian*):

$$\mathcal{W}_{\text{TCP}} = (\text{raw}[O_{\text{TCP}} + 14] \ll 8) \mid \text{raw}[O_{\text{TCP}} + 15]. \quad (6)$$

No callback `on_update`, as variáveis `fwd_init_win_bytes` e `bwd_init_win_bytes` são inicializadas com valor sentinela `-1` e registradas estritamente no primeiro pacote observado de cada sentido do fluxo (`packet.direction == 0` para o sentido de ida e `packet.direction == 1` para o sentido de volta), congelando o anúncio inicial de buffer da conexão.

4.1.1.6 Ciclo de Vida dos Fluxos e Temporizadores de Rede

O ciclo de vida de monitoramento do NFStream é governado por três eventos estocásticos de rede gerenciados no plugin:

- `on_init(packet, flow)`: disparado na chegada do primeiro pacote que define a tupla quártupla. Inicializa todos os acumuladores estatísticos em `flow.udps`, estabelece os ponteiros de tempo inicial e invoca `on_update`;
- `on_update(packet, flow)`: invocado a cada novo pacote subsequente pertencente ao fluxo. Incrementa comprimentos de cabeçalho, atualiza o menor segmento observado, acumula pacotes com dados úteis e gerencia os intervalos entre rajadas de transmissão;
- `on_expire(flow)`: invocado no encerramento formal do fluxo. Consolida taxas de transferência em bytes e pacotes por segundo, calcula médias de tamanho de segmento, extrai a variância do comprimento dos pacotes e estrutura as estatísticas completas de tempo ativo (*Active*) e ocioso (*Idle*).

O streamer de produção é configurado em modo promíscuo com análise estatística nativa ativada, operando sob dois temporizadores fundamentais de rede:

1. **Tempo Limite de Inatividade (`idle_timeout = 120s`):** define que, se uma conexão permanecer 120 segundos sem que nenhum pacote transite em ambos os sentidos, o fluxo é considerado encerrado e emitido para classificação;

2. **Tempo Limite Ativo (`active_timeout = 240s`):** estabelece que fluxos contínuos e volumosos (tais como transferências massivas de arquivos ou inundações prolongadas de DoS/DDoS) não fiquem retidos indefinidamente na memória do monitor. Ao completar 240 segundos de existência ativa, o fluxo é segmentado, expirado e imediatamente enviado ao pipeline neural, garantindo que ataques volumétricos persistentes sejam detectados e mitigados em no máximo 4 minutos.

4.1.2 Mapeamento e Alinhamento de Features (NFStream → CICFlowMeter)

Para viabilizar a inferência com modelos treinados em conjuntos como CSE-CIC-IDS2018, CIC-BCCC-NRC-2024 e CIC-UNSW-NB15, estabeleceu-se um mapeamento semântico e estatístico completo entre as propriedades nativas do objeto `NFlow` do NFStream e as colunas canônicas geradas pelo software *CICFlowMeter*.

4.1.2.1 Correspondência Semântica e Estrutural das Variáveis

As características que compõem o vetor de fluxo dividem-se em duas categorias de origem:

1. **Variáveis Nativas do NFStream:** extraídas diretamente pelo núcleo em C da biblioteca. Compreendem contadores agregados de pacotes, contadores de bytes brutos, valores extremos e momentos de primeira ordem de comprimentos de pacotes, estatísticas de intervalos entre chegadas em milissegundos e contagens direcionadas de flags TCP;
2. **Variáveis Sintetizadas via Plugin (`flow.udps`):** métricas que não existem na implementação base do NFStream e que foram sintetizadas no `FeatureExtractor` para fechar a paridade exata com o padrão CIC. Abrangem as janelas iniciais de recepção TCP, a variância do comprimento dos pacotes calculada a partir do quadrado do desvio padrão amostral, o comprimento agregado de cabeçalhos de camada 3 e 4, a razão de tráfego reverso sobre direto, a contagem de pacotes portadores de carga útil e os momentos de tempo ativo e inativo.

A Tabela 7 apresenta o catálogo estruturado agrupando os 76 atributos em 7 categorias funcionais, discriminando a correspondência exata entre a nomenclatura *CICFlowMeter*, o atributo correspondente no NFStream/Plugin, a unidade de mensuração padronizada e a forma de obtenção.

Tabela 7 – Mapeamento estruturado das 76 características do fluxo de rede: padrão *CICFlowMeter* versus implementação NFStream.

Atributo <i>CICFlowMeter</i>	Atributo NFStream / Plugin UDPS	Unidade	Origem
1. Identificação e Duração			
Flow ID	<code>id</code>	—	Nativo
Src IP	<code>src_ip</code>	IPv4/v6	Nativo
Src Port	<code>src_port</code>	Porta L4	Nativo
Dst IP	<code>dst_ip</code>	IPv4/v6	Nativo
Dst Port	<code>dst_port</code>	Porta L4	Nativo
Protocol	<code>protocol</code>	IANA	Nativo
Timestamp	<code>bidirectional_first_seen_ms</code>	Epoch ms	Nativo
Flow Duration	<code>bidirectional_duration_ms × 10³</code>	μ s	Nativo ($\times 10^3$)

Continua na próxima página

Tabela 7 – Continuação da página anterior

Atributo CICFlowMeter	Atributo NFStream / Plugin UDPS	Unidade	Origem
2. Estatísticas de Tamanho de Pacote			
Total Fwd Packet	src2dst_packets	Contagem	Nativo
Total Bwd packets	dst2src_packets	Contagem	Nativo
Total Length of Fwd Packet	src2dst_bytes	Bytes	Nativo
Total Length of Bwd Packet	dst2src_bytes	Bytes	Nativo
Fwd Packet Length Min / Max	src2dst_min_ps / max_ps	Bytes	Nativo
Fwd Packet Length Mean / Std	src2dst_mean_ps / stddev_ps	Bytes	Nativo
Bwd Packet Length Min / Max	dst2src_min_ps / max_ps	Bytes	Nativo
Bwd Packet Length Mean / Std	dst2src_mean_ps / stddev_ps	Bytes	Nativo
Packet Length Min / Max	bidirectional_min_ps / max_ps	Bytes	Nativo
Packet Length Mean / Std	bidirectional_mean_ps / stddev_ps	Bytes	Nativo
Packet Length Variance	packet_length_variance	Bytes ²	Plugin UDPS
3. Intervalos entre Chegadas (Inter-Arrival Times – IAT)			
Flow IAT Mean / Std	bidirectional_mean/stddev_piat_ms × 10 ³	μs	Nativo (× 10 ³)
Flow IAT Max / Min	bidirectional_max/min_piat_ms × 10 ³	μs	Nativo (× 10 ³)
Fwd IAT Total	src2dst_duration_ms × 10 ³	μs	Nativo (× 10 ³)
Fwd IAT Mean / Std	src2dst_mean/stddev_piat_ms × 10 ³	μs	Nativo (× 10 ³)
Fwd IAT Max / Min	src2dst_max/min_piat_ms × 10 ³	μs	Nativo (× 10 ³)
Bwd IAT Total	dst2src_duration_ms × 10 ³	μs	Nativo (× 10 ³)
Bwd IAT Mean / Std	dst2src_mean/stddev_piat_ms × 10 ³	μs	Nativo (× 10 ³)
Bwd IAT Max / Min	dst2src_max/min_piat_ms × 10 ³	μs	Nativo (× 10 ³)
4. Sinalizadores (Flags) TCP			
Fwd PSH Flags / Bwd PSH Flags	src2dst/dst2src_psh_packets	Contagem	Nativo
Fwd URG Flags / Bwd URG Flags [†]	src2dst/dst2src_urg_packets	Contagem	Nativo
FIN / SYN / RST Flag Count	bidirectional_fin/syn/rst_packets	Contagem	Nativo
PSH / ACK / URG [†] Flag Count	bidirectional_psh/ack/urg_packets	Contagem	Nativo
CWR / ECE Flag Count	bidirectional_cwr/ece_packets	Contagem	Nativo

Continua na próxima página

Tabela 7 – Continuação da página anterior

Atributo CICFlowMeter	Atributo NFStream / Plugin UDPS	Unidade	Origem
5. Cabeçalhos e Taxas de Transferência			
Fwd / Bwd Header Length	fwd/bwd_header_length	Bytes	Plugin UDPS
Flow Bytes/s	bytes_per_second	Bytes/s	Plugin UDPS
Flow Packets/s	packets_per_second	Pkts/s	Plugin UDPS
FWD Packets/s / Bwd Packets/s	fwd/bwd_packets_per_second	Pkts/s	Plugin UDPS
Down/Up Ratio	down_up_ratio	Proporção	Plugin UDPS
Average Packet Size	avg_bytes_per_packet	Bytes	Plugin UDPS
Fwd / Bwd Segment Size Avg	fwd/bwd_segment_size_avg	Bytes	Plugin UDPS
6. Subfluxos e Transmissão em Lote (Bulk)			
Subflow Fwd / Bwd Packets	subflow_fwd/bwd_packets	Contagem	Plugin UDPS
Subflow Fwd / Bwd Bytes	subflow_fwd/bwd_bytes	Bytes	Plugin UDPS
Fwd / Bwd Bytes/Bulk Avg	fwd/bwd_bytes_bulk_avg	Bytes	Plugin UDPS
Fwd / Bwd Packet/Bulk Avg	fwd/bwd_packet_bulk_avg	Pkts	Plugin UDPS
Fwd / Bwd Bulk Rate Avg	fwd/bwd_bulk_rate_avg	Taxa	Plugin UDPS
7. Janelas TCP e Métricas de Atividade / Inatividade (Active/Idle)			
Fwd / Bwd Init Win Bytes	fwd/bwd_init_win_bytes	Bytes (16b)	Plugin UDPS
Fwd Act Data Pkts	fwd_act_data_pkts	Contagem	Plugin UDPS
Fwd Seg Size Min	fwd_seg_size_min	Bytes	Plugin UDPS
Active Mean / Std / Max / Min	active_mean, std, max, min	μs	Plugin UDPS
Idle Mean / Std / Max / Min	idle_mean, std, max, min	μs	Plugin UDPS

Fonte: Elaborado pelo autor (2026). [†] Atributos de variância nula descartados na camada pré-processadora.

4.1.2.2 Aproximações Operacionais e Nuances de Cálculo

A replicação exata do comportamento do CICFlowMeter em um ambiente de streaming de alto desempenho exige esclarecer três aproximações e nuances metodológicas:

1. **Cálculo de Subfluxos (*Subflow Features*):** no CICFlowMeter original, os subfluxos são definidos como rajadas contíguas de pacotes separadas por períodos ociosos superiores a um limiar fixo. Em fluxos contínuos de curta e média duração observados em tráfego interativo ou ataques rápidos, o subfluxo coincide integralmente com a totalidade do fluxo principal. Assim, no término do fluxo, o plugin atribui:

$$\text{subflow_fwd_packets} = \text{flow.src2dst_packets}, \quad (7)$$

$$\text{subflow_fwd_bytes} = \text{flow.src2dst_bytes}, \quad (8)$$

$$\text{subflow_bwd_packets} = \text{flow.dst2src_packets}, \quad (9)$$

$$\text{subflow_bwd_bytes} = \text{flow.dst2src_bytes}. \quad (10)$$

Essa aproximação preserva a consistência estatística, uma vez que a grande maioria das instâncias nos datasets CSE-CIC-IDS2018 e CIC-UNSW-NB15 é composta por conexões com apenas 1 subfluxo representativo;

2. **Métricas de Transmissão em Lote (*Bulk Rates*):** o `CICFlowMeter` contém uma máquina de estados heurística para quantificar transferências volumétricas contínuas (*bulk*), exigindo um mínimo de 3 pacotes consecutivos com carga útil transmitidos com espaçamento inferior a 1 segundo. Na prática empírica da literatura de NIDS, tais atributos apresentam valor 0,0 em mais de 99,8% das amostras dos datasets públicos, não agregando separabilidade analítica aos classificadores. No `FeatureExtractor`, as 6 métricas de bulk são inicializadas e mantidas em 0,0, eliminando sobrecarga computacional de rastreamento de estados sem perda de acurácia;
3. **Janelas de Atividade e Inatividade (*Active/Idle Dynamics*):** para a caracterização temporal fina exigida pelos especialistas recorrentes ($\mathcal{E}_{GRU}$ e $\mathcal{E}_{LSTM}$), o plugin rastreia a evolução dos pacotes utilizando o limiar clássico de ociosidade de 5 segundos ($5.000\text{ ms} = 5.000.000\text{ }\mu\text{s}$). Durante o método `on_update`, se o intervalo entre chegadas do pacote atual exceder o limiar (`packet.delta_time > 5000`), o período ativo acumulado até o instante anterior é consolidado e registrado na lista `active_times`, enquanto o tempo de espera decorrido é adicionado à lista `idle_times`. Ao término do fluxo (`on_expire`), calculam-se a média aritmética, o valor mínimo, o valor máximo e o desvio padrão amostral dessas séries em microssegundos. Caso o fluxo termine sem jamais ter atingido o limiar de 5 segundos de silêncio, o período ativo é consolidado como a própria duração integral do fluxo e os atributos ociosos mantêm-se em zero.

4.2 SETUP DE INFERÊNCIA

Uma das premissas centrais desta pesquisa é transcender a avaliação puramente teórica em arquivos CSV desacoplados e comprovar a aplicabilidade do modelo ALF-MoE em um arranjo experimental de inferência (*testbed*), mensurando a latência computacional de ponta a ponta e a eficácia das rotinas de mitigação ativa em nível de sistema operacional.

4.2.1 Arquitetura do Ambiente de Execução

O arranjo experimental de bancada foi projetado para simular a topologia típica de uma estação de trabalho corporativa ou servidor perimetral protegido por um NIDS/NIPS inteligente, sob ataque a partir de uma máquina adversária na mesma infraestrutura de rede local.

4.2.1.1 Especificações do Hardware e Ambiente Operacional

O ambiente físico compõe-se de dois nós computacionais heterogêneos conectados por meio de uma rede local sem fio (WLAN):

- *Equipamento:* Notebook Acer Nitro V15 (modelo ANV15-51);
- *Processador:* Intel Core i7-13620H de 13ª geração (arquitetura híbrida Raptor Lake, dotado de 10 núcleos físicos [6 *Performance-cores* operando até 4,9 GHz e 4 *Efficient-cores* até 3,6 GHz], 16 threads lógicas e 24 MB de Intel Smart Cache);
- *Memória Volátil:* 16 GB de memória RAM DDR5 operando em canal duplo com frequência de transferência de 5200 MT/s;
- *Acelerador Gráfico Dedicado:* GPU NVIDIA GeForce RTX 4050 Laptop (arquitetura Ada Lovelace, 6 GB de memória de vídeo dedicada GDDR6, interface de 96 bits, 2560 núcleos CUDA e *Tensor Cores* de 4ª geração);
- *Sistema Operacional e Kernel:* Ubuntu 26.04.1 LTS de 64 bits, executando o kernel Linux versão 7.0.0-31-generic;

- *Pilha de Inteligência Artificial*: Python 3.11/3.14 com bibliotecas TensorFlow 2.18 e Keras 3, compiladas com aceleração CUDA 12.4 e cuDNN 9.1;
- *Endereço IP na Rede Local*: configurado estaticamente em 192.168.3.16/24.

A interface de rede sem fio da máquina (wlp63s0) opera com a flag promíscua ativada pelo NFStream, assegurando que todo o tráfego que transita pelo canal rádio direcionado ou originado pelo host seja capturado e espelhado para a pilha de inspeção.

4.2.1.2 Mecanismo de Defesa Ativa

A grande maioria dos sistemas NIDS acadêmicos atua meramente como classificadores passivos em pós-processamento, gerando relatórios de alerta após a conclusão e o eventual sucesso de uma intrusão. O ecossistema ALF-MoE supera essa passividade ao integrar o agente de mitigação ativa `ActiveDefenseAgent` (implementado em `src/inference.py`).

4.2.1.2.1 Integração de Baixo Nível com o Firewall `nftables`

O subsistema de contenção utiliza a infraestrutura moderna do projeto Netfilter no kernel Linux: o *firewall* de última geração `nftables` (Netfilter Project, 2024), sucessor arquitetural do legado `iptables`. O `nftables` oferece execução atômica baseada em bytecode em uma máquina virtual no espaço de kernel (`nft_expr`), permitindo que conjuntos de endereços IP (*sets*) sejam consultados em complexidade temporal de busca constante $\mathcal{O}(1)$ via árvores balanceadas ou tabelas hash, sem a degradação de desempenho linear $\mathcal{O}(N)$ típica das longas cadeias encadeadas de regras do `iptables`.

Ao ser inicializado com privilégios de superusuário (*root*), o `ActiveDefenseAgent` instancia programaticamente as seguintes estruturas no kernel via utilitário `nft`:

1. **Tabela Dedicada:** cria a tabela de filtragem `inet alf_defense`:

```
nft add table inet alf_defense
```

2. **Conjunto Dinâmico com Expiração Nativa:** cria o conjunto de endereços IP `blocked_ips` com a flag de temporizador ativada (`flags timeout`) e tempo de retenção de 300 segundos (5 minutos):

```
nft add set inet alf_defense blocked_ips {
    type ipv4_addr; flags timeout; timeout 300s;
}
```

A ativação nativa de `timeout` no kernel constitui um avanço crítico de engenharia: elimina a necessidade de processos de segundo plano (*daemons*) em Python realizando varreduras periódicas em espaço de usuário para desbloquear endereços após 5 minutos. O próprio escalonador de temporizadores do kernel Linux expira e expurga os endereços IP da tabela hash no instante exato em que os 300 segundos se esgotam;

3. **Cadeia de Entrada com Prioridade de Intercepção:** cria a cadeia `input` associada ao gancho `hook input` com prioridade estrita `-10`:

```
nft add chain inet alf_defense input {
    type filter hook input priority -10; policy accept;
}
```

A prioridade -10 posiciona o filtro de mitigação antes de qualquer cadeia padrão de filtragem (que normalmente operam com prioridade 0), assegurando que pacotes hostis sejam interceptados e descartados logo após a etapa de desfragmentação e pré-roteamento IP do kernel, antes que possam consumir recursos do soquete TCP, alocar memória no subsistema de rede ou alcançar servidores de aplicação como o Apache ou o SSH;

4. **Regra de Descarte Sumário:** injeta a regra de bloqueio com comentário forense:

```
nft add rule inet alf_defense input \
    ip saddr @blocked_ips drop comment "I SEE YOU!"
```

Ao receber qualquer pacote com endereço de origem (`ip saddr`) pertencente ao conjunto `blocked_ips`, o kernel executa a ação de descarte silencioso (`drop`), sem emitir pacotes de encerramento TCP RST ou mensagens ICMP de porta inacessível (*port unreachable*), impedindo que o atacante meça o estado interno das portas da vítima.

4.2.1.2.2 Algoritmo de Resolução Direcional de Alvo (*select_target*)

Como os fluxos de rede capturados pelo NFStream são agregados de forma estritamente bidirecional, um fluxo contém sempre dois interlocutores: `src_ip` e `dst_ip`. Caso uma ameaça seja classificada pelo ALF-MoE (por exemplo, uma conexão de canal reverso originada a partir da própria vítima em direção à porta do atacante, ou respostas de varreduras), o IP do atacante pode ocupar a posição de origem ou de destino.

Se o agente bloqueasse ingenuamente o campo `src_ip`, a própria máquina vítima seria inserida no conjunto `blocked_ips` durante a detecção de um shell reverso ou de conexões iniciadas localmente, resultando na perda catastrófica de conectividade do próprio sistema de defesa.

Para eliminar esse risco, o método `select_target(src_ip, dst_ip)` avalia as pontas da conexão perante as salvaguardas de proteção (`is_protected`):

```
def select_target(self, src_ip: Optional[str],
                  dst_ip: Optional[str]) -> Optional[str]:
    clean_src = str(src_ip).strip() if src_ip else ""
    clean_dst = str(dst_ip).strip() if dst_ip else ""

    src_prot = self.is_protected(clean_src)
    dst_prot = self.is_protected(clean_dst)

    if src_prot and not dst_prot:
        return clean_dst
    if dst_prot and not src_prot:
        return clean_src
    if not src_prot and clean_src:
        return clean_src
    if not dst_prot and clean_dst:
        return clean_dst
    return None
```

O algoritmo isola univocamente a contraparte remota maliciosa para bloqueio, garantindo que o host local protegido permaneça imune à ação de descarte.

4.2.1.2.3 Salvaguarda Anti-Auto-Bloqueio e Whitelist

A blindagem do host vítima apoia-se em um mecanismo dinâmico de whitelist (*whitelist*). Durante a inicialização do agente, a função `get_host_local_ips()` executa o comando de sistema `ip -j addr`, inspeciona os objetos JSON retornados pelo subsistema de rede do Linux e descobre dinamicamente todos os endereços IPv4 e IPv6 atribuídos a todas as interfaces físicas e virtuais do host (incluindo adaptadores Wi-Fi, Ethernet e pontes do Docker como `docker0`).

Adicionalmente, a whitelist estática `BASE_WHITELIST` incorpora:

- Endereços de loopback: `127.0.0.1` e `::1`;
- Endereços nulos e coringas: `0.0.0.0` e `:::`;
- Endereços de difusão (*broadcast*): `255.255.255.255`;
- Tráfego de descoberta local SSDP e UPnP: `239.255.255.250`;
- Endereços de multicast IPv6: `ff02::c` e `ff02::fb`;
- O endereço do gateway padrão da rede local: `192.168.3.1`.

A inclusão explícita do gateway padrão decorre de uma lição empírica essencial colhida durante as rodadas de calibração preliminares: quando o atacante executa inundações volumétricas ou varreduras que atingem serviços de roteamento, o fluxo capturado pode referenciar temporariamente a porta do roteador. Caso o IP do gateway fosse bloqueado, o hospedeiro vítima perderia instantaneamente todo o acesso à rede local e à Internet. As salvaguardas implementadas eliminam essa vulnerabilidade estrutural.

4.2.1.2.4 Subsistema de Auditoria Forense e SIEM (*InferenceAuditor*)

O rastreamento de eventos é coordenado pelo módulo `InferenceAuditor`. Desenvolvido para conformidade com plataformas de gerenciamento de eventos de segurança (*Security Information and Event Management* – SIEM) e centros de operações de segurança (SOC), o auditor opera com sincronização de threads (`threading.Lock`) e gera dois fluxos paralelos de dados:

1. **Log Operacional Legível Rotativo (.log):** gerenciado pela classe `RotatingFileHandler`, com limite de 10 MB por arquivo e retenção de até 5 arquivos históricos de *backup*, registrando mensagens formatadas legíveis por humanos com carimbo de data/hora, nível de severidade e PID;
2. **Trilha Forense Estruturada (.jsonl):** registro atômico em formato JSON Lines, onde cada linha representa um documento JSON independente e autocontido com especificação temporal em formato ISO 8601 UTC (`timestamp_utc`).

O evento principal (`FLOW_PREDICTION`) grava a totalidade das variáveis que ditaram o julgamento analítico do modelo para cada fluxo inspecionado:

- Metadados da 5-tuple (`src_ip, src_port, dst_ip, dst_port, protocol`);
- Julgamento final do ALF-MoE: classe predita (`class`), probabilidade de confiança (`confidence`) e flag booleana de ameaça (`is_threat`);
- Vetor pentadimensional de pesos da *Gating Network*:

$$\alpha_{GN} = [\alpha_{DNN}, \alpha_{CNN}, \alpha_{GRU}, \alpha_{CAE}, \alpha_{LSTM}]; \quad (11)$$

- Julgamentos individuais de cada um dos cinco especialistas neurais (`experts_predictions`);

- Métrica de latência computacional estrita do *forward pass* neural em milissegundos (`latency_ms`);
- Ação de contenção executada pelo agente: LOG (tráfego permitido), BLOCKED: <IP> (bloqueio ativado no `nftables`), ALREADY_BLOCKED (IP já retido no conjunto) ou HOST_PROTECTED (alvo na whitelist).

4.2.2 Síntese Operacional do Pipeline de Inferência e Contenção Ativa

A integração dos componentes detalhados neste capítulo consolida um ciclo operacional contínuo e determinístico para inspeção de fluxos de rede e defesa ativa em tempo real:

1. **Ingestão e Agregação de Tráfego:** os processos filhos do NFStream operam em modo promíscuo na interface física de rede, capturando pacotes brutos e agregando as 76 métricas canônicas do padrão CIC através do plugin customizado `FeatureExtractor`;
2. **Desacoplamento e Expiração de Fluxos:** ao atingir o limiar de inatividade ($\tau_{\text{idle}} = 120\text{ s}$) ou o tempo máximo ativo ($\tau_{\text{active}} = 240\text{ s}$), o fluxo é encerrado nos workers em C/Cython e emitido de forma síncrona para o processo consumidor principal em Python, contornando a restrição de bifurcação de contexto CUDA (`CUDA_ERROR_NOT_INITIALIZED`);
3. **Conversão e Padronização:** o processo principal executa o alinhamento de unidades temporais ($\times 1000,0$ para compatibilidade com a escala em microssegundos do `CICFlowMeter`), expurga as 3 colunas de sinalizador URG de variância nula (reduzindo a entrada para 73 atributos ativos) e aplica o pré-processamento treinado (`RobustScaler` e transformações logarítmicas $\ln(1 + x)$);
4. **Inferência Neural Acelerada:** o tensor resultante alimenta a arquitetura ALF-MoE na GPU, na qual a *Gating Network* pondera os cinco especialistas neurais heterogêneos ($\mathcal{E}_{\text{DNN}}$, $\mathcal{E}_{\text{CNN}}$, $\mathcal{E}_{\text{GRU}}$, $\mathcal{E}_{\text{CAE}}$ e $\mathcal{E}_{\text{LSTM}}$), consolidando a predição através da soma ponderada estrita e da cabeça classificadora profunda;
5. **Mitigação Ativa e Auditoria Forense:** caso a classe predita indique uma ameaça com probabilidade superior ao limiar configurado ($\tau_{\text{threshold}} = 0,70$) e o endereço não conste nas listas brancas de salvaguarda, o `ActiveDefenseAgent` adiciona o IP ofensor diretamente ao conjunto dinâmico `blocked_ips` da tabela `nftables` do kernel Linux (com expiração automática de 300 s), enquanto o `InferenceAuditor` persiste o registro estruturado em JSONL com sincronização atômica.

O desempenho empírico desse arranjo experimental, abrangendo a acurácia de detecção nos benchmarks consolidados, a latência de inferência por amostra e o comportamento dos especialistas frente aos diferentes vetores de ataque, é apresentado e analisado exaustivamente no Capítulo 5.

5 RESULTADOS E DISCUSSÃO

5.1 DESEMPENHO NOS DATASETS DE BENCHMARK (RESULTADOS OFFLINE)

A validação empírica da arquitetura ****ALF-MoE**** foi conduzida sob um protocolo rigoroso de teste em partições estritamente desacopladas (*offline test sets*), cobrindo os quatro conjuntos de dados analisados em sete configurações experimentais independentes. Este protocolo permitiu avaliar: (i) a capacidade de discriminação sob diferentes níveis de abstração semântica (*Threat Levels* 0 e 2); (ii) a resiliência do modelo diante de falhas de rotulação em dados legados e o ganho obtido após a sanitização SOTA de Liu et al. (2022); e (iii) a contribuição individual de cada especialista neural versus a representação integrada alcançada pelo bloco atencional ALF.

5.1.1 Análise por Classe e Desempenho Global

A Tabela 8 consolida os resultados quantitativos globais do modelo ALF-MoE em todas as matrizes experimentais avaliadas. As métricas reportadas englobam Acurácia Global (Acc), Macro F_1 -Score (F_1^{macro}), Macro Precisão ($\text{Prec}_{\text{macro}}$), Macro Sensibilidade ($\text{Rec}_{\text{macro}}$), Latência por Amostra (L_{sample}) e Vazão de Inferência (Throughput).

Tabela 8 – Desempenho global consolidado do modelo ALF-MoE nos 7 cenários de benchmark.

Conjunto de Dados	Cenário	Acurácia	Macro F_1	Precisão	Recall	Latência	Vazão
CIC-UNSW-NB15	L0 (10 cls)	75,11%	0,5069	0,5103	0,6087	0,0479 ms	20.896 fl/s
CIC-BCCC-NRC-2024	L0 (49 cls)	82,29%	0,4501	0,4505	0,5095	0,0184 ms	54.258 fl/s
CIC-BCCC-NRC-2024	L2 (9 cls)	92,83%	0,8476	0,8382	0,8617	0,0122 ms	82.129 fl/s
CSE-CIC-IDS2018 (Orig.)	L0 (15 cls)	98,96%	0,8773	0,9045	0,8669	0,0119 ms	84.135 fl/s
CSE-CIC-IDS2018 (Orig.)	L2 (7 cls)	98,38%	0,9050	0,9658	0,8855	0,0111 ms	90.017 fl/s
CSE-CIC-IDS2018 (Corr.)	L0 (15 cls)	99,97%	0,8918	0,8814	0,9144	0,0162 ms	61.765 fl/s
CSE-CIC-IDS2018 (Corr.)	L2 (9 cls)	99,96%	0,8851	0,9579	0,8927	0,0118 ms	84.858 fl/s

Fonte: Elaborado pelo autor (2026), a partir dos relatórios experimentais.

A análise comparativa dos resultados experimentais desdobra-se em três eixos centrais de discussão:

5.1.1.1 Eixo 1: Impacto da Granularidade de Ameaças (Nível 0 vs. Nível 2)

A transição entre o Nível de Ameaça 0 (classes brutas com assinaturas estritas) e o Nível de Ameaça 2 (meta-categorias operacionais consolidadas) evidencia o custo estatístico da discriminação em espaços de classes hiper-fragmentados:

- No ambiente IoT (**CIC-BCCC-NRC-2024**), a consolidação de 49 classes granulares em 9 macro-famílias proporcionou uma elevação substantiva no Macro F_1 -Score, saltando de 0,4501 para 0,8476 (um incremento relativo de +88,3%), acompanhado pelo aumento da Acurácia Global de 82,29% para 92,83%. No nível granular (L0), o modelo é compelido a distinguir entre 12 variantes microscópicas de varredura e múltiplas ramificações de inundações ICMP/UDP cuja separabilidade estatística no nível de fluxo agregado é tênue, muitas com suporte inferior a 200 instâncias de teste. Ao agregar essas variantes em famílias funcionais (como *Reconnaissance*, *DDoS* e *IoT/MQTT*), a incerteza intra-classe é eliminada, gerando um modelo de altíssima confiabilidade operacional para acionamento perimetral;

- Em termos de eficiência computacional, a redução do espaço de saída no CIC-BCCC-NRC-2024 aliviou a carga de computação da projeção linear final, reduzindo a latência de 0,0184 ms para 0,0122 ms por fluxo e elevando a vazão sustentada de 54.258 para 82.129 fluxos/s.

5.1.1.2 Eixo 2: Impacto da Sanitização de Rótulos de Liu et al. (2022) no CSE-CIC-IDS2018

O contraste direto entre o CSE-CIC-IDS2018 Canônico e a versão corrigida segundo Liu et al. (2022) elucida de forma categórica as consequências do ruído de rotulação em modelos de aprendizado profundo:

- Na versão original canônica (L0), o modelo atinge 98,96% de acurácia global com Macro F_1 de 0,8773. Contudo, a inspeção detalhada por classe revela anomalias críticas: a classe *FTP-BruteForce* obteve F_1 de 0,7344 e precisão de apenas 0,6843. Essa degradação decorre diretamente da falha de etiquetagem comprovada por Liu et al. (2022), na qual o servidor na porta 21 estava inativo e respondia com pacotes de encerramento [RST, ACK]. O classificador era forçado a aprender que respostas legítimas de porta fechada equivaliam a força bruta ativa, gerando confusão sistemática com o tráfego normal;
- Na versão corrigida (*CSE-CIC-IDS2018 Improved*), na qual fluxos com portas fechadas e tentativas inócuas foram reclassificados como benignos, a Acurácia Global alcançou expressivos 99,97% e o Weighted F_1 -Score atingiu 0,9997 no teste independente de 1.263.903 fluxos;
- Além disso, a desagregação da infiltração em classes específicas permitiu constatar que o modelo detecta varreduras internas (*Infiltration - NMAP Portscan*) com $F_1 = 0,9912$ e canais de comando vítima-atacante com $F_1 = 0,8636$. Em contrapartida, a exfiltração pontual em tráfego criptografado (*Infiltration - Dropbox Download*), representada por meras 17 amostras de teste, obteve $F_1 = 0,1818$, demonstrando que conexões legítimas a serviços de nuvem HTTPS constituem o vetor de maior furtividade para extratores baseados puramente em estatísticas de fluxo sem inspeção de carga útil.

5.1.1.3 Eixo 3: Generalização em Tráfego de Alta Densidade (CIC-UNSW-NB15)

No conjunto CIC-UNSW-NB15, que não sofreu agregação em níveis superiores (operando estritamente em L0 com 10 classes), o ALF-MoE alcançou Acurácia Global de 75,11% e Macro F_1 -Score de 0,5069. Em classes de tráfego volumétrico e ataques de penetração complexos, o modelo exibiu excelente discriminação: *Benign* ($F_1 = 0,9495$), *Fuzzers* ($F_1 = 0,6968$), *Exploits* ($F_1 = 0,6876$) e *Reconnaissance* ($F_1 = 0,7169$).


Para categorias com suporte diminuto, a função de perda Focal Loss balanceada priorizou a sensibilidade em detrimento da precisão: na classe *Analysis* (suporte 77), o modelo obteve Sensibilidade (*Recall*) de 0,9481 (Acurácia Balanceada de 0,9661), prevenindo a omissão do ataque embora gerando falsos positivos que reduziram o F_1 para 0,2479. Esse comportamento reflete a postura conservadora deliberadamente imposta pelo fator de foco da Focal Loss, indispensável para ambientes corporativos em que o custo de um falso negativo (uma invasão ignorada) é infinitamente superior ao de uma inspeção secundária de falso positivo.

5.1.1.4 Matrizes de Confusão Normalizadas

A Figura 5 reúne as matrizes de confusão normalizadas para os quatro conjuntos de dados representativos: (a) CSE-CIC-IDS2018 Canônico (L2); (b) CSE-CIC-IDS2018 Corrigido (L2); (c) CIC-BCCC-NRC-2024 (L2); e (d) CIC-UNSW-NB15 (L0).


A inspeção visual confirma a dominância quase diagonal absoluta na versão corrigida do CSE-CIC-IDS2018 (Figura 5b), em contraste com a dispersão de erros verificada na versão original (Figura 5a). No ambiente IoT (Figura 5c), observa-se perfeita segregação de tráfego de intermediadores MQTT (96,0% de acerto) e inundações DoS/DDoS (> 94%), enquanto o UNSW-NB15 (Figura 5d) ilustra a sobreposição natural existente entre as classes *Exploits* e *Fuzzers*.

Figura 5 – Paineis comparativos de matrizes de confusão normalizadas nos quatro cenários de avaliação.



(a) CSE-CIC-IDS2018 Canônico (L2 - 7 classes).

(b) CSE-CIC-IDS2018 Corrigido (L2 - 9 classes).



(c) CIC-BCCC-NRC-2024 (L2 - 9 classes).

(d) CIC-UNSW-NB15 (L0 - 10 classes).

Fonte: Elaborado pelo autor (2026), a partir dos artefatos de avaliação.

A análise pormenorizada das dispersões fora da diagonal principal permite fundamentar quatro padrões específicos de confusão interclasses observados nos experimentos, balizados pelas restrições físico-matemáticas da telemetria de fluxo:

1. **CSE-CIC-IDS2018 Canônico (*Infiltration* vs. *WebAttack*):** Verifica-se sobreposição estatística mútua entre fluxos de infiltração e ataques a aplicações web. Essa confusão decorre do fato de ambos os vetores operarem predominantemente sobre os protocolos de transporte das portas 80 (HTTP) e 443 (HTTPS), compartilhando assinaturas idênticas de cabeçalho TCP e cadência de requisições. Como os extratores NetFlow/CICFlowMeter descartam o conteúdo da carga útil (*payload*), a diferenciação apoia-se unicamente em distribuições de tamanho e temporização de pacotes. Além disso, a classe *WebAttack* no conjunto canônico conta com suporte diminuto de teste (apenas 186 instâncias somando *Brute Force - Web*, *Brute Force - XSS* e *SQL Injection*), limitando a estimativa das fronteiras bayesianas de decisão;

2. **CSE-CIC-IDS2018 Corrigido (*Benign vs. Infiltration - Dropbox Download*):** Na base saneada conforme Liu et al. (2022), a classe *Infiltration - Dropbox Download* alcança $F_1 = 0,1818$ com dispersão preponderante em direção à classe *Benign*. Essa confusão é tecnicamente inevitável no nível de fluxo: a exfiltração de dados e download de artefatos maliciosos via API oficial do Dropbox utiliza canais TLS legítimos em conexões HTTPS padronizadas, reproduzindo rigorosamente as grandezas estatísticas e temporais da navegação web corporativa. Aliado ao suporte ultra-reduzido de apenas 17 amostras de teste, esse vetor atinge o limite intrínseco de separabilidade de extratores estritamente baseados em fluxo de rede;
3. **CIC-BCCC-NRC TabularIoTAttack-2024 (*MITM vs. Botnet*):** No ecossistema IoT, constata-se confusão pontual entre fluxos das macro-famílias *MITM* (especialmente variantes de *ARP Spoofing*) e tráfego de *Botnet*. Em redes locais de sensores e atuadores, ambos os vetores caracterizam-se por mensagens curtas de controle TCP/IP, ausência de fluxos volumétricos em rajada (*bulk*) e temporizações assíncronas com intervalos de inter-chegada assemelhados, induzindo dispersão correlacionada nos logits da Gating Network;
4. **CIC-UNSW-NB15 (*Analysis, Backdoor, Exploits e Fuzzers*):** No benchmark UNSW-NB15, verifica-se sobreposição estatística mútua entre as classes *Exploits* (22,17% do teste) e *Fuzzers* (21,22%), além de falsos positivos cruzados com *Analysis* e *Backdoor*. Conforme documentado por Moustafa & Slay (2015), o tráfego sintético dessa base foi sintetizado pelo gerador de hardware comercial IXIA PerfectStorm injetando transações HTTP padronizadas com payloads mutacionados. No plano da telemetria de fluxo (contadores agregados de pacotes, bytes e intervalos IAT), essas classes produzem vetores numéricos virtualmente idênticos, delimitando um teto teórico de erro de Bayes intransponível sem inspeção profunda de pacotes (DPI).

5.1.2 Análise Comparativa dos Especialistas e do Bloco ALF

A arquitetura ALF-MoE apoia-se no princípio de que especialistas neurais heterogêneos, concebidos para extrair representações de domínios específicos da telemetria de rede, oferecem projeções complementares que, ao serem integradas pela fusão por atenção adaptativa, superam a capacidade preditiva de qualquer modelo monolítico individual. Para quantificar essa premissa de projeto e mensurar o ganho advindo do bloco atencional ALF sobre os ramos isolados, realizou-se uma análise comparativa sistemática entre as predições supervisionadas das cinco cabeças especializadas ($\mathcal{E}_{DNN}$, $\mathcal{E}_{CNN}$, $\mathcal{E}_{GRU}$, $\mathcal{E}_{CAE}$, $\mathcal{E}_{LSTM}$) e a predição da cabeça integrada ALF-MoE.

A Tabela 9 sumariza o Macro F_1 -Score e a Acurácia Global obtidos por cada especialista e pela cabeça unificada ALF nos sete cenários de teste.

A análise minuciosa da Tabela 9 permite derivar conclusões estruturais acerca do comportamento dos especialistas e do ganho proporcionado pela fusão ALF:

1. **Superação Sistemática do Melhor Especialista Individual:** Em todos os cenários sem exceção, a fusão atencional **ALF-MoE** alcança o melhor Macro F_1 -Score global. No CIC-UNSW-NB15, o melhor especialista isolado foi a $\mathcal{E}_{DNN}$ ($F_1 = 0,4611$), enquanto o ALF-MoE atingiu 0,5069 (ganho de +4,58 pontos percentuais de F_1 e +3,34% em acurácia). No CSE-CIC-IDS2018 Canônico (L0), o ganho é ainda mais acentuado: o melhor especialista individual foi a $\mathcal{E}_{GRU}$ com $F_1 = 0,7681$, superada largamente pelo ALF-MoE com 0,8773 (um salto de +10,92 pontos de F_1 e +5,91% de acurácia sobre a DNN);
2. **Especialização Funcional por Domínio:** Os especialistas $\mathcal{E}_{GRU}$ e $\mathcal{E}_{LSTM}$, encarregados da telemetria de intervalos temporais (*IAT* e *Active/Idle*), demonstraram liderança folgada no tráfego IoT (CIC-BCCC-NRC-2024), alcançando F_1 de 0,8451 e 0,8163, respectivamente, enquanto os modelos alimentados unicamente por propriedades de pacotes ou globais sofreram degradação. Isso decorre da natureza do protocolo MQTT, cujos pacotes apresentam tamanho uniforme de cabeçalho, tornando os padrões de tempo entre chegadas o elemento primordial de discriminação;

Tabela 9 – Estudo de ablação: Macro F_1 -Score e Acurácia dos especialistas individuais vs. ALF-MoE.

Dataset	Métrica	DNN	CNN	GRU	CAE	LSTM	ALF-MoE
CIC-UNSW-NB15 (L0)	Macro F_1	0,4611	0,4053	0,4367	0,2525	0,2779	0,5069
	Acurácia	71,77%	58,56%	71,42%	62,28%	64,12%	75,11%
CIC-BCCC-NRC-2024 (L0)	Macro F_1	0,0057	0,2496	0,4448	0,1246	0,3676	0,4501
	Acurácia	10,88%	41,31%	82,33%	60,73%	80,06%	82,29%
CIC-BCCC-NRC-2024 (L2)	Macro F_1	0,1284	0,5551	0,8451	0,2557	0,8163	0,8476
	Acurácia	12,41%	57,04%	92,26%	60,55%	90,88%	92,83%
CSE-CIC-IDS2018 Orig. (L0)	Macro F_1	0,7588	0,5485	0,7681	0,4750	0,6891	0,8773
	Acurácia	93,05%	51,73%	88,62%	69,61%	89,09%	98,96%
CSE-CIC-IDS2018 Orig. (L2)	Macro F_1	0,8442	0,5925	0,8181	0,3029	0,7880	0,9050
	Acurácia	94,30%	61,53%	88,62%	44,05%	88,13%	98,38%
CSE-CIC-IDS2018 Corr. (L0)	Macro F_1	0,7862	0,7156	0,8390	0,4405	0,7598	0,8918
	Acurácia	99,85%	92,87%	99,40%	78,51%	98,37%	99,97%
CSE-CIC-IDS2018 Corr. (L2)	Macro F_1	0,8134	0,6953	0,8464	0,5115	0,7344	0,8851
	Acurácia	99,85%	92,84%	99,34%	77,40%	97,77%	99,96%

Fonte: Elaborado pelo autor (2026), com base nos relatórios de teste.

3. **Papel Regularizador do Autoencoder Convolutacional ($\mathcal{E}_{CAE}$):** Embora o $\mathcal{E}_{CAE}$ isole pontuações mais modestas como classificador autônomo (variando entre $F_1 = 0,1246$ e $0,5115$), sua inclusão no grafo computacional provê uma restrição de reconstrução espectral no domínio da frequência ($\mathcal{L}_{CAE_rec}$) que atua como regularizador indutivo, impedindo que os especialistas densos entrem em colapso latente diante de fluxos volumétricos colineares.

5.1.2.1 Gráficos Radar de Especialistas


A complementaridade multidomínio dos modelos é visualizada na Figura 6, que reúne os gráficos radar de comparação entre cada especialista e a arquitetura ALF-MoE nos quatro conjuntos de teste.

Em todas as representações radiais da Figura 6, o polígono correspondente ao ****ALF-MoE**** (em linha de destaque) delimita a envoltória superior em virtualmente todas as direções de ataque. Mesmo quando um especialista específico exhibe deficiência em um determinado vetor (por exemplo, a queda acentuada da DNN em classes IoT ou da CNN em ataques de força bruta), o mecanismo de fusão atencional redistribui dinamicamente os pesos para os especialistas mais bem capacitados, demonstrando a robustez teórica e prática do projeto ALF-MoE.


5.2 AVALIAÇÃO DA EXTRAÇÃO E INFERÊNCIA EM TRÁFEGO REAL/PCAPS

A transição de modelos de Aprendizado Profundo avaliados em partições estáticas de *benchmark* para pipelines operacionais de inspeção de rede em tempo real impõe severos desafios de engenharia de software e processamento de sinais. Enquanto a avaliação *offline* assume dados pré-segmentados, normalizados e perfeitamente indexados, o ambiente de produção lida com fluxos bidirecionais concorrentes, assincronia de eventos, variações de temporização de *hardware* e restrições de latência determinística. Esta seção examina o comportamento do arcabouço ****ALF-MoE**** quando implantado em bancada física real, analisando a fidelidade da extração de características em tempo real via NFStream, o perfil de consumo de recursos computacionais e os gargalos estruturais de latência ponta a ponta.


Figura 6 – Gráficos radar comparativos de desempenho por classe: Especialistas individuais vs. ALF-MoE.




(a) CSE-CIC-IDS2018 Canônico (L2).



(b) CSE-CIC-IDS2018 Corrigido (L2).



(c) CIC-BCCC-NRC-2024 (L2).



(d) CIC-UNSW-NB15 (L0).

Fonte: Elaborado pelo autor (2026), a partir dos artefatos de avaliação.

5.2.1 Impacto do Mapeamento NFStream → CICFlowMeter

Os conjuntos de dados de referência utilizados no treinamento supervisionado do ALF-MoE (notadamente CSE-CIC-IDS2018, CIC-UNSW-NB15 e CIC-BCCC-NRC-2024) foram originalmente gerados por meio do extrator proprietário *CICFlowMeter* (Sharafaldin; Lashkari; Ghorbani, 2018), uma aplicação monolítica escrita em Java que processa arquivos de captura (.pcap) de forma puramente *offline*. Para viabilizar a inferência em tempo de execução na interface de rede da máquina vítima, concebeu-se um pipeline de produção fundamentado no *framework* NFStream (Aouini; Pekar, 2022), estendido por um *plugin* customizado em C/Python (*FeatureExtractor*).

A migração entre esses dois motores de telemetria introduz discrepâncias estatísticas inerentes à natureza de suas arquiteturas:

1. **Discretização Temporal e Resolução de Clock:** O *CICFlowMeter* original depende dos temporizadores da máquina virtual Java (JVM) e das ligações da biblioteca *jNetPcap*, expressando durações e intervalos

entre chegadas (*Inter-Arrival Times* – IAT) em microssegundos (μs), embora frequentemente truncados ou arredondados pela granulação de milissegundos do relógio subjacente do sistema operacional. Em contrapartida, o motor do NFStream opera nativamente em linguagem C com suporte a *buffers* de anel de alta velocidade no espaço de usuário (`libpcap / AF_PACKET`), capturando os instantes de primeiro e último pacote em milissegundos de precisão (`bidirectional_first_seen_ms`). Para compatibilizar o vetor de entrada com a distribuição esperada pelo modelo neural, o `FeatureExtractor` converte dinamicamente as grandezas temporais multiplicando-as pelo fator de escala 1000,0. Embora essa transformação preserve a magnitude relativa dos intervalos, ela remove variações microscópicas de submilissegundos que constavam nos dados de treino;

2. **Cálculo de Variância e IAT em Janelas Deslizantes:** Em ambiente *offline*, o `CICFlowMeter` calcula a variância do comprimento dos pacotes e os desvios padrão de IAT em duas passagens completas sobre o vetor de pacotes em memória, utilizando a fórmula da variância amostral clássica com correção de Bessel ($N - 1$). No extrator em tempo real do NFStream, o cômputo é realizado incrementalmente em janelas deslizantes sem que o extrator conheça previamente o tamanho total ou a duração final da conexão. A variância do comprimento dos pacotes é aproximada pelo quadrado do desvio padrão nativo acumulado (`bidirectional_stddev_ps2`). Em conexões de longa duração ($N \geq 10$ pacotes), a lei dos grandes números garante convergência quase perfeita entre ambas as formulações. Todavia, em conexões ultracurtas ($N < 3$ pacotes) — típicas de sondagens TCP SYN avulsas —, o cálculo incremental sofre de degenerescência numérica marginal nos graus de liberdade amostrais;
3. **Métricas de Subfluxos e Taxas de Bulk:** O `CICFlowMeter` adota regras heurísticas complexas para fragmentar um fluxo contínuo em “subfluxos” (*subflows*) caso ocorram períodos de inatividade interna superiores a 1 segundo, gerando atributos como `Subflow_Fwd_Packets` e `Subflow_Fwd_Bytes`. De forma similar, suas taxas de transferência contínua (*Bulk Rates*) exigem a observação de blocos ininterruptos de dados. Na implementação em tempo real, tais agregações tornam-se voláteis e computacionalmente onerosas. O `FeatureExtractor` optou por mapear os acumuladores de subfluxo diretamente para as contagens globais da direção (`src2dst_packets` e `src2dst_bytes`).

A Tabela 10 sintetiza a comparação metodológica entre os extratores e reporta o índice de consistência estatística mensurado em 10.000 fluxos de validação cruzada entre capturas processadas concomitantemente por ambas as ferramentas.

Os resultados empíricos confirmam que os atributos volumétricos globais e as propriedades morfológicas dos pacotes (médias, mínimos e máximos) mantiveram **99,4% de consistência estatística**. As pequenas flutuações registradas nas métricas temporais de IAT foram integralmente absorvidas pela etapa de normalização robusta (`RobustScaler`), que dimensiona os dados segundo a mediana e o intervalo interquartil (IQR), mitigando a sensibilidade a desvios mínimos de escala. Por sua vez, a simplificação nas métricas de subfluxo e *bulk* não comprometeu a acurácia global do ALF-MoE, uma vez que a etapa de seleção de atributos e o mecanismo de fusão atencional já atribuíam pesos residuais a essas grandezas em favor da telemetria temporal fina modelada pelos especialistas recorrentes ($\mathcal{E}_{GRU}$ e $\mathcal{E}_{LSTM}$).

5.2.2 Throughput, Latência e Consumo Computacional

A viabilidade de um sistema de detecção e resposta perimetral em tempo real depende estritamente do atendimento a requisitos estritos de temporização e moderação no consumo de recursos de *hardware*. A bancada de testes experimentais foi montada sobre a máquina hospedeira da vítima (Acer Nitro V15), equipada com uma unidade de processamento gráfico dedicada **NVIDIA GeForce RTX 4050 6GB Laptop GPU** (arquitetura Ada Lovelace, 2.560 núcleos CUDA, barramento de 96 bits), operando sobre o sistema operacional Ubuntu Linux (kernel 7.0.0-31-generic).

Tabela 10 – Comparativo metodológico e estatístico entre o extrator offline (CICFlowMeter) e o extrator em tempo real (NFStream + Plugin ALF).

Grupo de Atributos	CICFlowMeter (Java / Offline)	NFStream + Plugin (C / Tempo Real)	Consistência	Impacto no Modelo
Volumetria Global e Pacotes	Contagem exata em memória; bytes e pacotes bidirecionais totais.	Acumuladores em nível de kernel via <code>libpcap</code> / C.	99,4%	Nulo (Erro < 0,6%)
Temporização e IAT	Microsegundos brutos (μs) sujeitos a jitter de JVM.	Milissegundos (ms) convertidos para μs ($\times 1000$).	98,7%	Desprezível (Absorvido pelo <code>RobustScaler</code>)
Variância de Comprimento	Variância amostral em duas passagens ($N - 1$).	Cômputo incremental pelo desvio padrão acumulado ($stddev^2$).	99,1%	Marginal em fluxos com $N < 3$ pacotes
Subfluxos e Taxas Bulk	Fragmentação por pausas heurísticas de 1 segundo.	Acumuladores diretos do fluxo (<code>subflow = total</code>).	91,2%	Nulo (Features descartadas ou com peso residual)
Flags e Janelas TCP	Inspeção pós-fato sobre pacotes armazenados.	Captura síncrona no primeiro pacote de cada direção.	100,0%	Positivo (Identificação determinística de SYN/ACK)

Fonte: Elaborado pelo autor (2026), com base nos ensaios de calibração em bancada.

5.2.2.1 Métricas Quantitativas de Inferência Neural

No ambiente operacional de bancada, a inferência do ALF-MoE foi executada no modo de classificação unitária sob demanda (*single-flow streaming*, lote $B = 1$), refletindo a chegada progressiva e assíncrona de fluxos encerrados pela camada de captura. Sob essa condição de produção, a **latência pura de *forward pass* neural** variou na faixa de 52,45 ms a 64,68 ms **por fluxo**, com média amostral consolidada em 54,23 ms.

Esse comportamento contrasta expressivamente com os resultados do *benchmark offline* reportados na Seção 5.1, onde o modelo alcançou latências nominais de $\approx 0,012$ ms por fluxo e vazão teórica superior a 84.000 fluxos/s. Essa discrepância decorre diretamente da física de execução em processadores massivamente paralelos:

- No regime *offline*, o processamento ocorre em megablocos parametrizados (e.g. lotes de 2.048 amostras), amortizando os custos fixos de sobrecarga de invocação do kernel CUDA (*kernel launch overhead*), saturando completamente os *Tensor Cores* e maximizando a largura de banda de memória GDDR6;
- No regime de fluxo contínuo unitário ($B = 1$), o gargalo é dominado pela latência de transferência de dados hospedeiro-dispositivo (*host-to-device* via barramento PCIe) e pelas barreiras de sincronização interna exigidas pela passagem simultânea de tensores pelas cinco redes especialistas e pelo cômputo sequencial da matriz de atenção do bloco ALF.

A Tabela 11 apresenta a decomposição minuciosa do tempo de processamento consumido por cada estágio do pipeline em tempo real para cada fluxo recebido.

A vazão sustentada em regime contínuo de inferência alcançou aproximadamente 17,6 **fluxos classificados por segundo** no processo principal. O consumo de memória de vídeo da GPU estabilizou-se em 1,2 GB de **VRAM** (cerca de 20% da capacidade nominal de 6 GB), evidenciando que a arquitetura ALF-MoE é computacionalmente enxuta e viabiliza a coexistência harmônica do motor de segurança com outras cargas analíticas, serviços locais ou interfaces gráficas na máquina protegida.

Tabela 11 – Decomposição temporal e perfil de latência do pipeline de inferência em tempo real (GPU NVIDIA GeForce RTX 4050 6GB Laptop).

Estágio do Pipeline	Componente Responsável	Latência Média	Fração Comput.	Descrição Funcional
Pré-processamento	Processador Host (CPU)	1,82 ms	3,2%	Normalização RobustScaler e transformação loglp.
Inferência ALF-MoE	GPU Dedicada (RTX 4050)	54,23 ms	95,7%	<i>Forward pass</i> em 5 especialistas + fusão por atenção.
Decisão e Defesa Ativa	Subsistema NIPS (Kernel)	0,61 ms	1,1%	Consulta de <i>whitelist</i> e injeção de regra no <i>nftables</i> .
Total Computacional	Pipeline Integrado	56,66 ms	100,0%	Tempo entre a extração e a mitigação no firewall.
<i>Latência Estrutural</i>	<i>Temporizador de Rede</i>	120.000,00 ms	—	<i>Janela de inatividade (idle_timeout) para expiração.</i>

Fonte: Elaborado pelo autor (2026), com base nas medições do auditor forense (InferenceAuditor).

5.2.2.2 O Gargalo Estrutural da Latência Ponta a Ponta (End-to-End Latency)

A investigação em bancada revelou uma constatação empírica fundamental para a ciência da computação e segurança de redes: **a latência ponta a ponta (*end-to-end*) entre o disparo do primeiro pacote malicioso e o bloqueio efetivo da conexão no *firewall* não é governada pelo modelo de aprendizado de máquina, mas sim pela dinâmica de transporte do extrator de fluxo.**

Conforme exposto na Tabela 11, o tempo estritamente computacional gasto para normalizar os atributos, executar a inferência atencional multi-expert e registrar a regra no *nftables* é de apenas 56,66 ms. Todavia, na captura em tempo real, o objeto de fluxo só é finalizado e disponibilizado para consumo após a expiração dos temporizadores de protocolo configurados no motor de telemetria:

- `idle_timeout = 120s`: intervalo de silêncio exigido entre dois pacotes consecutivos de uma mesma tupla para que a conexão seja dada como inativa e encerrada;
- `active_timeout = 240s`: duração máxima contínua permitida para conexões persistentes antes de sua segmentação forçada (reduzida de 1.800 s para 240 s durante os ensaios de calibração).

Essa dependência manifestou-se claramente nos ensaios práticos com a ferramenta Nmap: uma varredura de portas em modo básico completa o envio de suas sondas em menos de 30 segundos. No entanto, os fluxos correspondentes permanecem retidos no extrator, aguardando que transcorram os 120 segundos de inatividade após o último pacote transmitido. Apenas quando o cronômetro atinge 120 s o NFStream dispara o evento `on_expire`, liberando o fluxo para a inferência neural (54 ms) e culminando no descarte pelo *nftables* (0,6 ms). O atraso ponta a ponta real atinge, portanto, cerca de 120,06 segundos.

Esse fenômeno suscita uma reflexão técnica profunda sobre a **dicotomia entre NIDS baseados em fluxo (*Flow-based*) versus NIDS baseados em pacote individual (*Packet-based* / DPI)**:

1. **Vantagens Inerentes da Abordagem por Fluxo:** A computação de métricas estatísticas agregadas (médias de tamanho, variâncias e desvios de IAT) confere ao ALF-MoE robustez semântica superior. O modelo analisa a dinâmica relacional da conversa, tornando-se imune a técnicas evasivas clássicas de fragmentação de pacotes em nível IP, desordenação proposital de segmentos TCP ou ofuscação de cabeçalhos. Além disso, a abordagem é totalmente agnóstica à criptografia de carga útil (TLS/HTTPS) e reduz em ordens de magnitude o volume de dados a ser inspecionado pelo subsistema de segurança;

2. **Custo Estrutural de Encerramento:** O compromisso inescapável dessa estratégia é o retardo temporal de fechamento. Para construir uma estimativa fidedigna de variância ou taxa de bytes, o extrator precisa testemunhar o término da transação ou aguardar a certeza estatística de sua inatividade. Em ataques fulminantes de exploração rápida, o vetor hostil pode ter sido concluído antes que o alerta seja emitido;
3. **Estratégias de Mitigação no ALF-MoE:** Para amortecer esse gargalo, o projeto ALF-MoE adotou a redução agressiva do `active_timeout` de 1.800 s para 240 s e estruturou as fundações para classificação precoce (*early flow classification*), na qual fluxos de alta intensidade volumétrica podem ser inferidos prematuramente após os primeiros pacotes de abertura.

5.2.3 Avaliação de Falsos Positivos em Tráfego Operacional e Calibração de Salvaguardas

Um requisito fundamental para a viabilidade operacional de qualquer ferramenta de segurança de redes reside na minimização da taxa de falsos positivos (FPR). Alarmes espúrios recorrentes sobre tráfego legítimo causam a chamada fadiga de alertas, sobrecarregando as equipes de monitoramento ou provocando a desativação indevida dos módulos de bloqueio automatizado.

Para quantificar esse comportamento em ambiente físico de produção, o pipeline em tempo real operou em escuta contínua na máquina vítima durante uma sessão prolongada de tráfego corporativo e navegação rotineira. Foram capturados e classificados mais de 24.000 fluxos estritamente legítimos, contemplando navegação web concorrente (sobre HTTP/1.1, HTTP/2 e HTTP/3), transmissão ininterrupta de vídeo e áudio em alta definição (YouTube e Spotify), operações de sincronização em nuvem e comunicações de serviços em segundo plano do sistema operacional Linux.

5.2.3.1 Diagnóstico de Falsos Positivos Iniciais e Calibração

Nas primeiras execuções do monitoramento de bancada, o classificador emitiu alertas pontuais em dois cenários específicos de tráfego legítimo:

1. **Telemetria de Aplicação em Nuvem (Spotify para o IP 35.186.224.9 na porta 443 HTTPS):** O modelo atribuiu rótulo de infiltração (*Infiltration - Dropbox Download*) a esse fluxo. A investigação forense esclareceu a causa estatística: conforme documentado por Ding, Kulkarni & Yekhanin (2017), serviços modernos de telemetria agregam dados locais e os transmitem em rajadas curtas, periódicas e criptografadas. No plano de atributos de fluxo (sem inspeção de carga útil), essa dinâmica rítmica e compacta aproxima-se dos padrões de canais de exfiltração furtiva e balizamento (*beaconing*) de comando e controle;
2. **Descoberta Local SSDP/UPnP Multicast (239.255.255.250):** O tráfego de descoberta local via protocolo SSDP (porta 1900 UDP) foi classificado como anomalia volumétrica (*DoS*). Por operar em regime multicast unidirecional não orientado a conexão, os datagramas UDP são disparados em rajadas sem confirmações TCP (*ACKs*), apresentando razão de subida/descida (`down_up_ratio`) nula e curta duração. O classificador interpretou essa assimetria pontual como tentativa de inundação.

Para neutralizar tais desvios sem degradar a sensibilidade a intrusões reais, o endereço de grupo *multicast* local (239.255.255.250) e os destinos estáveis de telemetria foram incorporados à lista de exceções de salvaguarda (`custom_whitelist`) do `ActiveDefenseAgent`. Além disso, a calibragem dos pesos com o conjunto de dados higienizado segundo os preceitos de Liu et al. (2022) eliminou a tendência do modelo de correlacionar encerramentos abruptos com intenção hostil. Em baterias subsequentes de monitoramento estendido sobre mais de 24.000 fluxos benignos adicionais, o sistema operou com **0% de falsos positivos** (0,0000), consolidando a estabilidade necessária para operação contínua em redes de produção.

6 CONCLUSÃO

6.1 SÍNTESE DO TRABALHO

Esta dissertação de graduação investigou e endereçou três dos mais prementes desafios contemporâneos na concepção de Sistemas de Detecção e Prevenção de Intrusão em Redes (*Network Intrusion Detection and Prevention Systems* – NIDS/NIPS) baseados em Aprendizado Profundo (*Deep Learning*): (i) a extrema heterogeneidade estatística e multimodalidade dos fluxos de tráfego de rede; (ii) o severo desbalanceamento de classes e a prevalência de erros crônicos de rotulação nos conjuntos de dados públicos de referência; e (iii) o gargalo de engenharia associado à transição de modelos teóricos treinados em lote (*batch*) para pipelines de mitigação ativa em tempo real operando no espaço de *kernel* do sistema operacional.

Para responder a essas problemáticas, foi concebida, treinada e avaliada a arquitetura ****ALF-MoE**** (*Attention-Based Learnable Fusion of Specialized Expert Networks*), um modelo híbrido fundamentado no paradigma de Mistura de Especialistas (*Mixture of Experts* – MoE) combinado a um bloco de fusão aprendível por mecanismos de atenção. A inovação estrutural do modelo consiste na decomposição sistemática do vetor canônico de 73 atributos de fluxo em subespaços de domínio semanticamente coerentes, processados por cinco especialistas neurais dedicados:

- Um Especialista Denso ($\mathcal{E}_{\text{DNN}}$), responsável pelas métricas globais e contadores agregados de sinalizadores TCP/IP;
- Um Especialista Convolutacional 2D ($\mathcal{E}_{\text{CNN}}$), otimizado para padrões espaciais na geometria e distribuição de comprimentos de pacotes;
- Dois Especialistas Recorrentes ($\mathcal{E}_{\text{GRU}}$ e $\mathcal{E}_{\text{LSTM}}$), encarregados de modelar a dinâmica temporal fina dos intervalos entre chegadas (*Inter-Arrival Times* – IAT) e dos ciclos de atividade/inatividade (*Active/Idle*);
- Um Especialista Autoencoder Convolutacional 1D ($\mathcal{E}_{\text{CAE}}$), cuja tarefa de reconstrução espectral no domínio da frequência introduz restrições indutivas de regularização contra o colapso latente de representações.

A integração das predições supervisionadas dos especialistas é governada por uma Rede de Roteamento (*Gating Network*) dotada da camada customizada *AttentionRefinementLayer*, que aplica projeção linear sobre os logits preliminares, compressão simétrica não-linear via $\tanh$ e normalização temperada, emitindo o vetor de pesos de atenção $\mathbf{a} \in \mathbb{R}^5$. A fusão realiza a combinação linear convexa estrita $\mathbf{z} = \sum a_k \hat{\mathbf{y}}^{(k)}$, canalizando todo o gradiente através do produto atencional e alimentando a cabeça profunda de decisão multiclasse. O treinamento conjunto sob a formulação multi-tarefa combinou a função *Focal Loss* com $\gamma = 2,0$ e balanceamento de classes atenuado por raiz quadrada ($w_c = \sqrt{N/(C \cdot N_c)}$) à perda de reconstrução espectral $\mathcal{L}_{\text{CAE},\text{rec}}$.

A validação empírica offline realizada sobre quatro conjuntos de dados de referência (CIC-UNSW-NB15, CIC-BCCC-NRC TabularIoTAttack-2024, CSE-CIC-IDS2018 Canônico e CSE-CIC-IDS2018 Corrigido) em sete configurações experimentais comprovou a superioridade absoluta da arquitetura: o ALF-MoE superou o melhor especialista individual isolado em todos os cenários sem exceção. Destaca-se o salto de desempenho observado no CSE-CIC-IDS2018 Corrigido, alcançando 99,97% de Acurácia Global e 0,8918 de Macro F_1 -Score, comprovando tanto a eficácia da sanitização de rótulos proposta por Liu et al. (2022) quanto a resiliência do mecanismo de atenção diante de distribuições assimétricas.

No âmbito da engenharia de produção, foi desenvolvido e implantado o pipeline de inferência em tempo real, integrando a biblioteca NFStream, o subsistema de auditoria SIEM em formato JSON Lines (*'InferenceAuditor'*) e o agente de defesa ativa (*'ActiveDefenseAgent'*). A arquitetura respeitou o Princípio da Responsabilidade Única (SRP), isolando a extração estatística de baixo nível nos processos de *worker* do NFStream e centralizando o *forward pass* neural no processo principal, superando assim as restrições de concorrência e perdas de contexto de GPU

decorrentes do *fork* em ambiente Linux. Os testes em bancada real com hardware dedicado (GPU NVIDIA GeForce RTX 4050 Laptop) comprovaram uma latência média de inferência neural de apenas 54,23 ms, viabilizando a inserção atômica de regras de descarte no *firewall* de última geração ‘nftables’ e a neutralização comprovada de fluxos hostis em nível de kernel com 0% de falsos positivos em tráfego de produção calibrado.

6.2 LIMITAÇÕES IDENTIFICADAS

A despeito dos expressivos resultados teóricos e operacionais obtidos, a análise rigorosa dos experimentos laboratoriais e da bancada em tempo real evidenciou limitações estruturais inerentes à abordagem adotada:

1. **Latência Estrutural Inerente à Abordagem Baseada em Fluxos:** Embora o tempo de processamento neural puro do ALF-MoE seja extremamente reduzido (54,23 ms por amostra na GPU), o tempo total ponta a ponta (*end-to-end*) decorrido entre o primeiro pacote malicioso e a inserção da regra de bloqueio no *firewall* é dominado pelos temporizadores de expiração do extrator de fluxo (`idle_timeout = 120s` e `active_timeout = 240s`). Em vetores de ataque acelerados que completam suas transmissões em poucos segundos, o NIDS baseado em fluxo só toma conhecimento da anomalia após o encerramento por inatividade, criando uma janela temporal de vulnerabilidade em que as sondagens já foram concluídas antes da emissão do alerta;
2. **Cegueira Semântica a Canais Criptografados e Exfiltração Furtiva:** Como a abordagem investigada fundamenta-se estritamente em propriedades estatísticas agregadas de fluxo e cabeçalhos de transporte, sem inspeção profunda de carga útil (*Deep Packet Inspection* – DPI), o classificador apresenta sensibilidade reduzida a ataques cuja pegada volumétrica mimetiza tráfego corporativo comum. Isso ficou demonstrado na classe *Infiltration - Dropbox Download* ($F_1 = 0,1818$), na qual o tráfego malicioso de exfiltração confunde-se com fluxos HTTPS legítimos de armazenamento em nuvem e telemetria de aplicações de streaming;
3. **Dependência de Calibração Perimetral do Limiar de Decisão:** A configuração do limiar de confiança operacional exerce papel determinante na eficácia do sistema em tempo de execução. O valor padrão comumente adotado na literatura ($\tau = 0,80$) revelou-se excessivamente conservador para a contenção perimetral imediata de certas classes de varredura furtiva, cujas predições situam-se na faixa de 50% a 75%, exigindo calibração empírica para deflagrar bloqueios no kernel sem gerar alarmes falsos em serviços corporativos homologados;
4. **Custo de Processamento Unitário vs. Vazão em Lote:** A transição do regime de inferência em megablocos (onde a GPU atinge vazões superiores a 84.000 fluxos/s com amortização de overhead) para a inferência em fluxo contínuo unitário ($B = 1$) acarreta uma redução na taxa máxima de classificação para cerca de 17,6 fluxos/s por worker de consumo, decorrente dos tempos de transferência host-dispositivo via barramento PCIe e sincronização de tensores.

6.3 TRABALHOS FUTUROS

Com base nas limitações diagnosticadas e nas perspectivas abertas por esta pesquisa, delineiam-se as seguintes direções para investigações e desenvolvimentos futuros:

1. **Classificação Precoce de Fluxos (*Early Flow Classification*):** Adaptar a arquitetura ALF-MoE para operar em regime de classificação prematura, no qual o modelo emite um diagnóstico preliminar a partir da observação dos primeiros k pacotes da conexão ($k \in [3, 10]$), sem aguardar a expiração dos temporizadores de transporte. Essa abordagem eliminaria o atraso de 120 segundos imposto pelo `idle_timeout`, permitindo contenção perimetral no milissegundo inicial da intrusão;

2. **Fusão Multimodal com *Fingerprinting* TLS/Criptográfico:** Incorporar ao vetor de entrada atributos derivados de *fingerprints* criptográficos passivos, tais como os padrões JA4, JA4S e telemetria de negociação TLS (cifras oferecidas, extensões e versões do protocolo), sem necessidade de quebra de sigilo ou descryptografia. Essa adição proveria a separabilidade semântica necessária para distinguir exfiltrações encobertas de fluxos HTTPS benignos de serviços corporativos em nuvem;
3. **Sondas de Telemetria e Filtragem com eBPF/XDP:** Integrar sondas eBPF (*Extended Berkeley Packet Filter*) e ganchos XDP (*eXpress Data Path*) diretamente aos drivers de rede do kernel Linux. Essa infraestrutura permitirá pré-filtragem e extração estatística em nível de linha (*line-rate*) sem cópias desnecessárias de pacotes para o espaço de usuário, reduzindo a latência de transferência de dados e aumentando exponencialmente a taxa de descarte sob ataques volumétricos massivos de negação de serviço;
4. **Quantização, Poda e Otimização para Borda (*Edge Deployment*):** Aplicar técnicas de quantização pós-treinamento para formatos de precisão reduzida (FP16 e INT8) via TensorRT e exportação para formatos interoperáveis (ONNX), visando a implantação do modelo ALF-MoE em roteadores de borda, dispositivos de Internet das Coisas (IoT) e *smart NICs* programáveis baseadas na arquitetura P4;
5. **Mecanismo de Gating Esperso (*Top-k Routing*):** Investigar variações de roteamento esperso na Rede de Roteamento, ativando estritamente os $k = 2$ especialistas mais relevantes por pacote em vez da soma ponderada contínua dos 5 especialistas. Essa estratégia reduziria ainda mais o custo computacional por amostra em enlaces de altíssima vazão (10 Gbps ou superiores).

REFERÊNCIAS

- ABREU, D.; ABELÉM, A. Sistema híbrido e on-line de detecção e classificação de tráfego malicioso. **Anais do XL Simpósio Brasileiro de Redes de Computadores e Sistemas Distribuídos (SBRC 2022)**, Sociedade Brasileira de Computação, p. 322–335, 2022.
- AOUINI, Z.; PEKAR, A. NFStream: A flexible network data analysis framework. **Computer Networks**, v. 204, p. 108719, 2022. ISSN 1389-1286. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1389128621005739>.
- BORGIOLO, N. et al. A convolutional autoencoder architecture for robust network intrusion detection in embedded systems. **Journal of Systems Architecture**, Elsevier BV, v. 156, p. 103283, 2024.
- CAO, B. et al. Network intrusion detection model based on CNN and GRU. **Applied Sciences**, MDPI, v. 12, n. 9, p. 4184, 2022.
- CHANDROTH, J.; STOIAN, G.; DANCULESCU, D. ALF-MoE: An attention-based learnable fusion of specialized expert networks for accurate traffic classification. **Mathematics**, MDPI AG, v. 14, n. 3, p. 525, 2026.
- CHEN, Y. et al. P4-NIDS: High-performance network monitoring and intrusion detection in P4. **Lecture Notes in Networks and Systems**, Springer Nature Switzerland, p. 355–373, 2025.
- DARI, S. S. et al. Neural networks and cyber resilience: Deep insights into AI architectures for robust security framework. **Journal of Electrical Systems**, Science Research Society, v. 19, n. 3, p. 78–95, 2024.
- DING, B.; KULKARNI, J.; YEKHANIN, S. Collecting telemetry data privately. In: **Advances in Neural Information Processing Systems (NeurIPS 2017)**. [s.n.], 2017. v. 30, p. 3571–3580. Disponível em: <https://arxiv.org/abs/1712.01524>.
- DREYER, P. A. et al. **Estimating the Global Cost of Cyber Risk: Methodology and Examples**. [S.l.], 2018.
- FERRAZ, Á. L. R. et al. The procedural semantics gap in structured CTI: A measurement-driven STIX analysis for APT emulation. **arXiv preprint arXiv:2512.12078**, 2025.
- GUADARRAMA, J. C. M. et al. Advanced IDS: a comparative study of datasets and machine learning algorithms for network flow-based intrusion detection systems. **Applied Intelligence**, 2025.
- GUO, C. et al. On calibration of modern neural networks. In: PMLR. **International Conference on Machine Learning (ICML)**. [S.l.], 2017. p. 1321–1330.
- HE, Q.; FU, X.; ZHANG, L. Trafficmoe: Heterogeneity-aware mixture of experts for encrypted traffic classification. **arXiv preprint arXiv:2603.29520**, 2026.
- JACOBS, R. A. et al. Adaptive mixtures of local experts. **Neural Computation**, MIT Press, v. 3, n. 1, p. 79–87, 1991.
- JADA, I.; MAYAYISE, T. O. The impact of artificial intelligence on organisational cyber security: An outcome of a systematic literature review. **Data and Information Management**, Elsevier BV, v. 8, n. 2, p. 100063, 2024.
- KAUR, D.; KAUR, P. Empirical analysis of web attacks. **Procedia Computer Science**, Elsevier BV, v. 78, p. 298–306, 2016.
- LIN, T.-Y. et al. Focal loss for dense object detection. In: **IEEE International Conference on Computer Vision (ICCV)**. [S.l.: s.n.], 2017. p. 2980–2988.
- LIU, L. et al. Error prevalence in NIDS datasets: A case study on CIC-IDS-2017 and CSE-CIC-IDS-2018. In: **IEEE. 2022 IEEE Conference on Communications and Network Security (CNS)**. [S.l.], 2022. p. 254–262.
- LUAY, M. et al. Temporal analysis of netflow datasets for network intrusion detection systems. **arXiv preprint arXiv:2503.04404**, 2025.
- LUAY, M. et al. Time matters: Temporal netflow features for ml-based network intrusion detection. **IEEE Access**, Institute of Electrical and Electronics Engineers (IEEE), v. 14, p. 66899–66913, 2026.

- MACIÁ-FERNÁNDEZ, G. et al. Ugr'16: A new dataset for the evaluation of cyclostationarity-based network idss. **Computers & Security**, Elsevier BV, v. 73, p. 411–424, 2018.
- MOUSTAFA, N.; SLAY, J. UNSW-NB15: a comprehensive data set for network intrusion detection systems (UNSW-NB15 network data set). In: IEEE. **2015 Military Communications and Information Systems Conference (MilCIS)**. [S.l.], 2015. p. 1–6.
- Netfilter Project. **nftables: High performance packet classification framework**. 2024. Acesso em: 25 set. 2026. Disponível em: <https://netfilter.org/projects/nftables/>.
- NETO, E. C. P. et al. CICIOT2023: A real-time dataset and benchmark for large-scale attacks in IoT environment. **Sensors**, MDPI AG, v. 23, n. 13, p. 5941, 2023.
- NOOR, M. H. M.; IGE, A. O. A survey on state-of-the-art deep learning applications and challenges. **Engineering Applications of Artificial Intelligence**, Elsevier BV, v. 159, p. 111225, 2025.
- OLIVEIRA, J. A. de; GONÇALVES, V. P.; FILHO, G. P. R. F-NIDS: Sistema de detecção de intrusão baseado em aprendizado federado. **Anais Estendidos do XLIII Simpósio Brasileiro de Redes de Computadores e Sistemas Distribuídos (SBRC 2025)**, Sociedade Brasileira de Computação - SBC, p. 212–221, 2025.
- ORBINATO, V. et al. Laccolith: Hypervisor-based adversary emulation with anti-detection. **IEEE Transactions on Dependable and Secure Computing**, Institute of Electrical and Electronics Engineers (IEEE), v. 21, n. 6, p. 5374–5387, 2024.
- PHAN, T. V.; NGUYEN, T. G.; BAUSCHERT, T. DeepStage: Learning autonomous defense policies against multi-stage APT campaigns. **arXiv preprint arXiv:2603.16969**, 2026.
- SAINIS, N.; SRIVASTAVA, D.; SINGH, R. Feature classification and outlier detection to increased accuracy in intrusion detection system. **International Journal of Applied Engineering Research**, v. 13, n. 10, p. 7249–7255, 2018.
- SARHAN, M. et al. Netflow datasets for machine learning-based network intrusion detection systems. **Lecture Notes of the Institute for Computer Sciences, Social Informatics and Telecommunications Engineering**, Springer International Publishing, p. 117–135, 2021.
- SARHAN, M.; LAYEGHY, S.; PORTMANN, M. Towards a standard feature set for network intrusion detection system datasets. **Mobile Networks and Applications**, Springer Science and Business Media LLC, v. 27, n. 1, p. 357–370, 2022.
- SASI, T. et al. An efficient self attention-based 1D-CNN-LSTM network for IoT attack detection and identification using network traffic. **Journal of Information and Intelligence**, Elsevier, v. 3, n. 4, p. 375–400, 2025.
- SHARAFALDIN, I.; LASHKARI, A. H.; GHORBANI, A. A. Toward generating a new intrusion detection dataset and intrusion traffic characterization. In: **International Conference on Information Systems Security and Privacy**. [s.n.], 2018. Disponível em: <https://api.semanticscholar.org/CorpusID:4707749>.
- SHARIF, M. H. U. Web attacks analysis and mitigation techniques. **International Journal of Engineering Research & Technology (IJERT)**, v. 11, n. 02, 2022.
- SHAZEER, N. et al. Outrageously large neural networks: The sparsely-gated mixture-of-experts layer. In: **International Conference on Learning Representations (ICLR)**. [S.l.: s.n.], 2017. p. 1–19.
- SILVA, F. C. d. **HSAE: Um Autoencoder Híbrido Não Supervisionado para Detecção de Ataques Zero-Day e sua Extensão Ensemble**. 2025. Dissertação (Dissertação de Mestrado) — Universidade Federal de Pernambuco, 2025.
- SOUZA, C. A. d. **Detecção e prevenção de intrusão em computação de nevoeiro e Internet das Coisas**. 2023. Tese (Tese de Doutorado) — Universidade Federal de Santa Catarina, 2023.
- WANG, Y.-C.; HOUNG, Y.-C.; LIN, H.-X. Network anomaly intrusion detection based on deep learning approach. **Sensors**, MDPI, v. 23, n. 4, p. 2171, 2023.
- YANG, X. et al. One-for-all does not work! enhancing vulnerability detection by mixture-of-experts (moe). In: **Proceedings of the ACM on Software Engineering**. [S.l.]: Association for Computing Machinery (ACM), 2025. v. 2, n. FSE, p. 446–464.

ČENYS, A.; HORA, S. K.; GORANIN, N. Emulation-based dataset EmuIoT-VT for NIDS in IoT systems. **Sensors**, MDPI AG, v. 25, n. 16, p. 5077, 2025.